

ESCUELA TÉCNICA SUPERIOR DE INGENIEROS INFORMÁTICOS

Modelado de Comportamiento de Conductores con Técnicas de Inteligencia Computacional

DEFENSA PARA LA OBTENCIÓN DEL TÍTULO DE

DOCTORADO EN INTELIGENCIA ARTIFICIAL

AUTOR

ALBERTO DÍAZ ÁLVAREZ

DIRECTORES

FRANCISCO SERRADILLA GARCÍA

FELIPE JIMÉNEZ ALONSO

Tabla de contenidos



Introducción

Motivación y estado
de la cuestión



Objetivos

Planteamiento
tras el análisis



Metodología

Cuerpo del
desarrollo de la tesis



Conclusiones

Consecuencias y
líneas futuras



Publicaciones

Resultados
publicados

Introducción

Modelos de comportamiento de conductor

Niveles de abstracción de [Michon, 1985] sobre los procesos cognitivos durante la conducción.

Estratégico

- Planificaciones a alto nivel.
- Decisiones de nivel cognitivo medio.
- Comportamientos prácticamente automáticos.

Táctico

Control

Los modelos de comportamiento que consideraremos trabajan en el nivel táctico.

Simulación de tráfico

El tráfico es un sistema que emerge de la interacción de actores en algún tipo de camino o vía.

Se puede considerar un Sistema Complejo.

Es muy difícil analizar a partir de cada elemento que lo compone.

Su estudio directo:

Afecta a las propias mediciones.
En ocasiones es peligroso o ilegal.

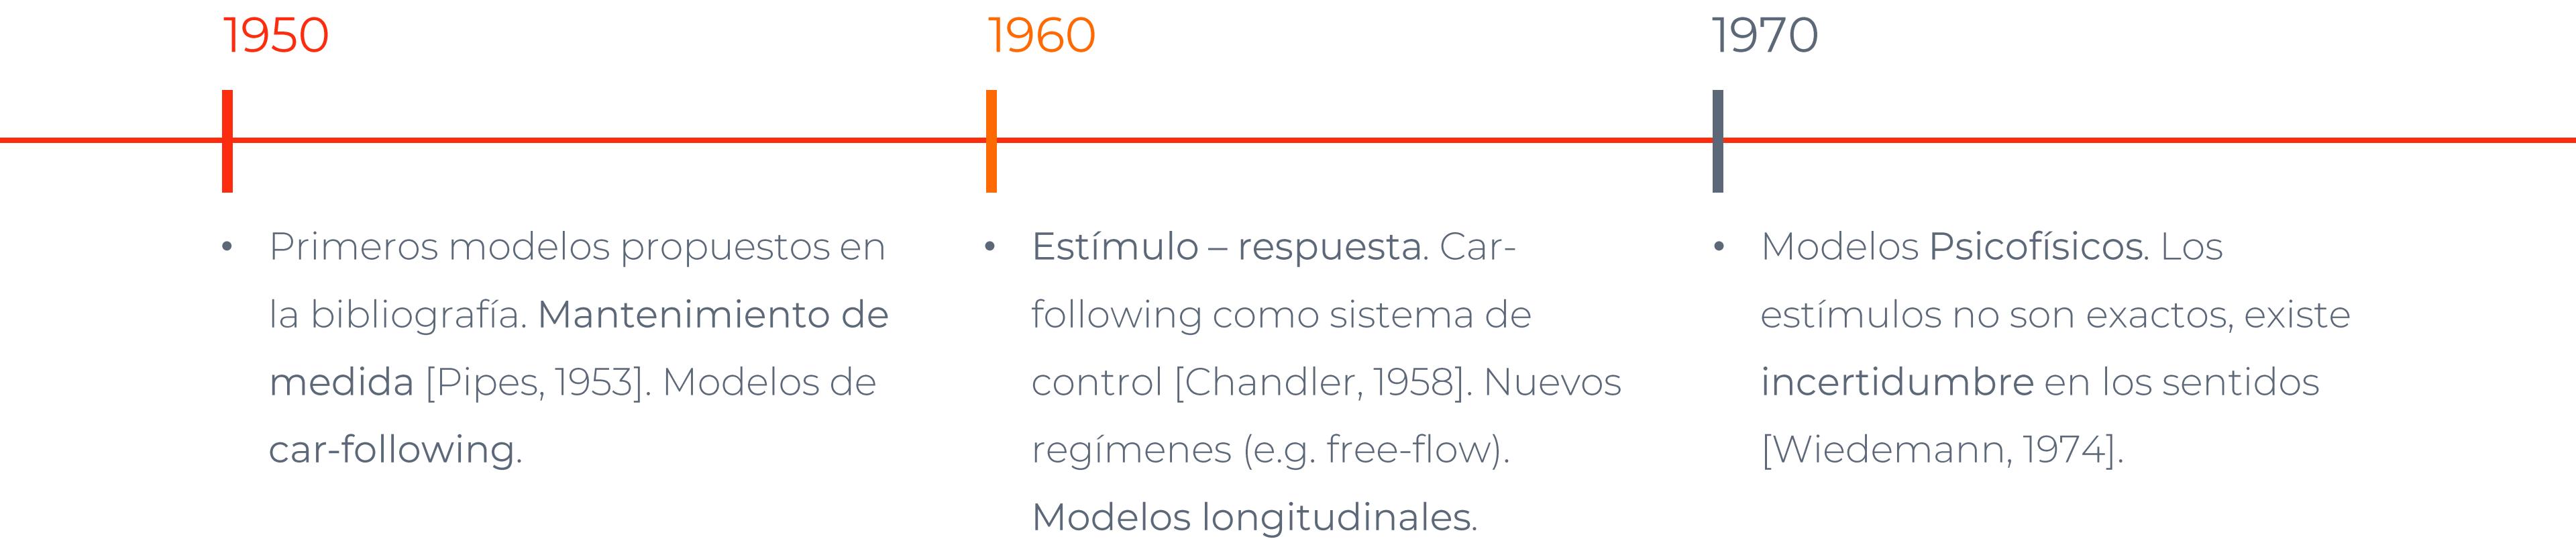
La simulación es una de las soluciones para el estudio del tráfico.

Micro-simulación

Macro-simulación

La micro-simulación permite el estudio del tráfico a nivel de modelos de conductor.

Modelos de comportamiento (I)



Modelos deterministas, con carencias para replicar comportamiento real.

Modelos de comportamiento (II)

1980

1990

2000

- Primer trabajo real que integra comportamientos longitudinal [Gipps, 1981] y lateral [Gipps, 1986]. Problemas que se heredan: interbloqueos y acciones en secuencia.

Modelo lateral

Selection y merging

Gap acceptance

Tipologías:
MLC, DLC, ...

- Primeros trabajos con datos reales en simuladores top-view de redes neuronales [Fix & Armstrong] y lógica borrosa [Kikuchi & Chakroborty, 1992]. Problemas de falta de datos.

- Árboles de secuencia para solucionar problemas de modelos basados en Gipps [Hidas, 2002]. Mitiga el efecto pero no lo elimina.
- Comportamiento lateral con lógica borrosa (sin datos reales) [McDonald et al., 1997].
- Datos reales para control longitudinal y lateral con redes neuronales [Jia et al., 2003].

No replican suficientemente bien comportamientos humanos en simulación

Conclusiones del estado actual

2010

- Vehículos instrumentados para modelos en situaciones complejas [Naranjo et al., 2006].
- Árboles probabilísticos para evitar los problemas de secuencia [Toledo at al., 2007]. Problemas: Asignación de probabilidades y explosión combinatoria de acciones.
- Simuladores en primera persona para captura de datos y entrenamiento de redes neuronales [Van Hoorn et al., 2009].

Modelos clásicos

- Tienden a ser simples y muy eficientes.
- Limitados para replicar comportamiento humano.
- Comportamientos complejos implican mucha modelización.

Modelos IC

- Abstraen comportamiento complejo.
- No utilizan valores del entorno que les rodea como un todo.
- A día de hoy, no es posible explicar el porqué de las conclusiones de una red neuronal de una o más capas ocultas.

Necesitamos modelos que repliquen mejor comportamientos humanos en simuladores.

Objetivos

Objetivo general

Desarrollo de una metodología que permita la generación de modelos de conductores humanos a partir de los datos extraídos de los sensores de un vehículo, de tal manera que puedan ser implantables dentro de un agente inteligente.



Justificación

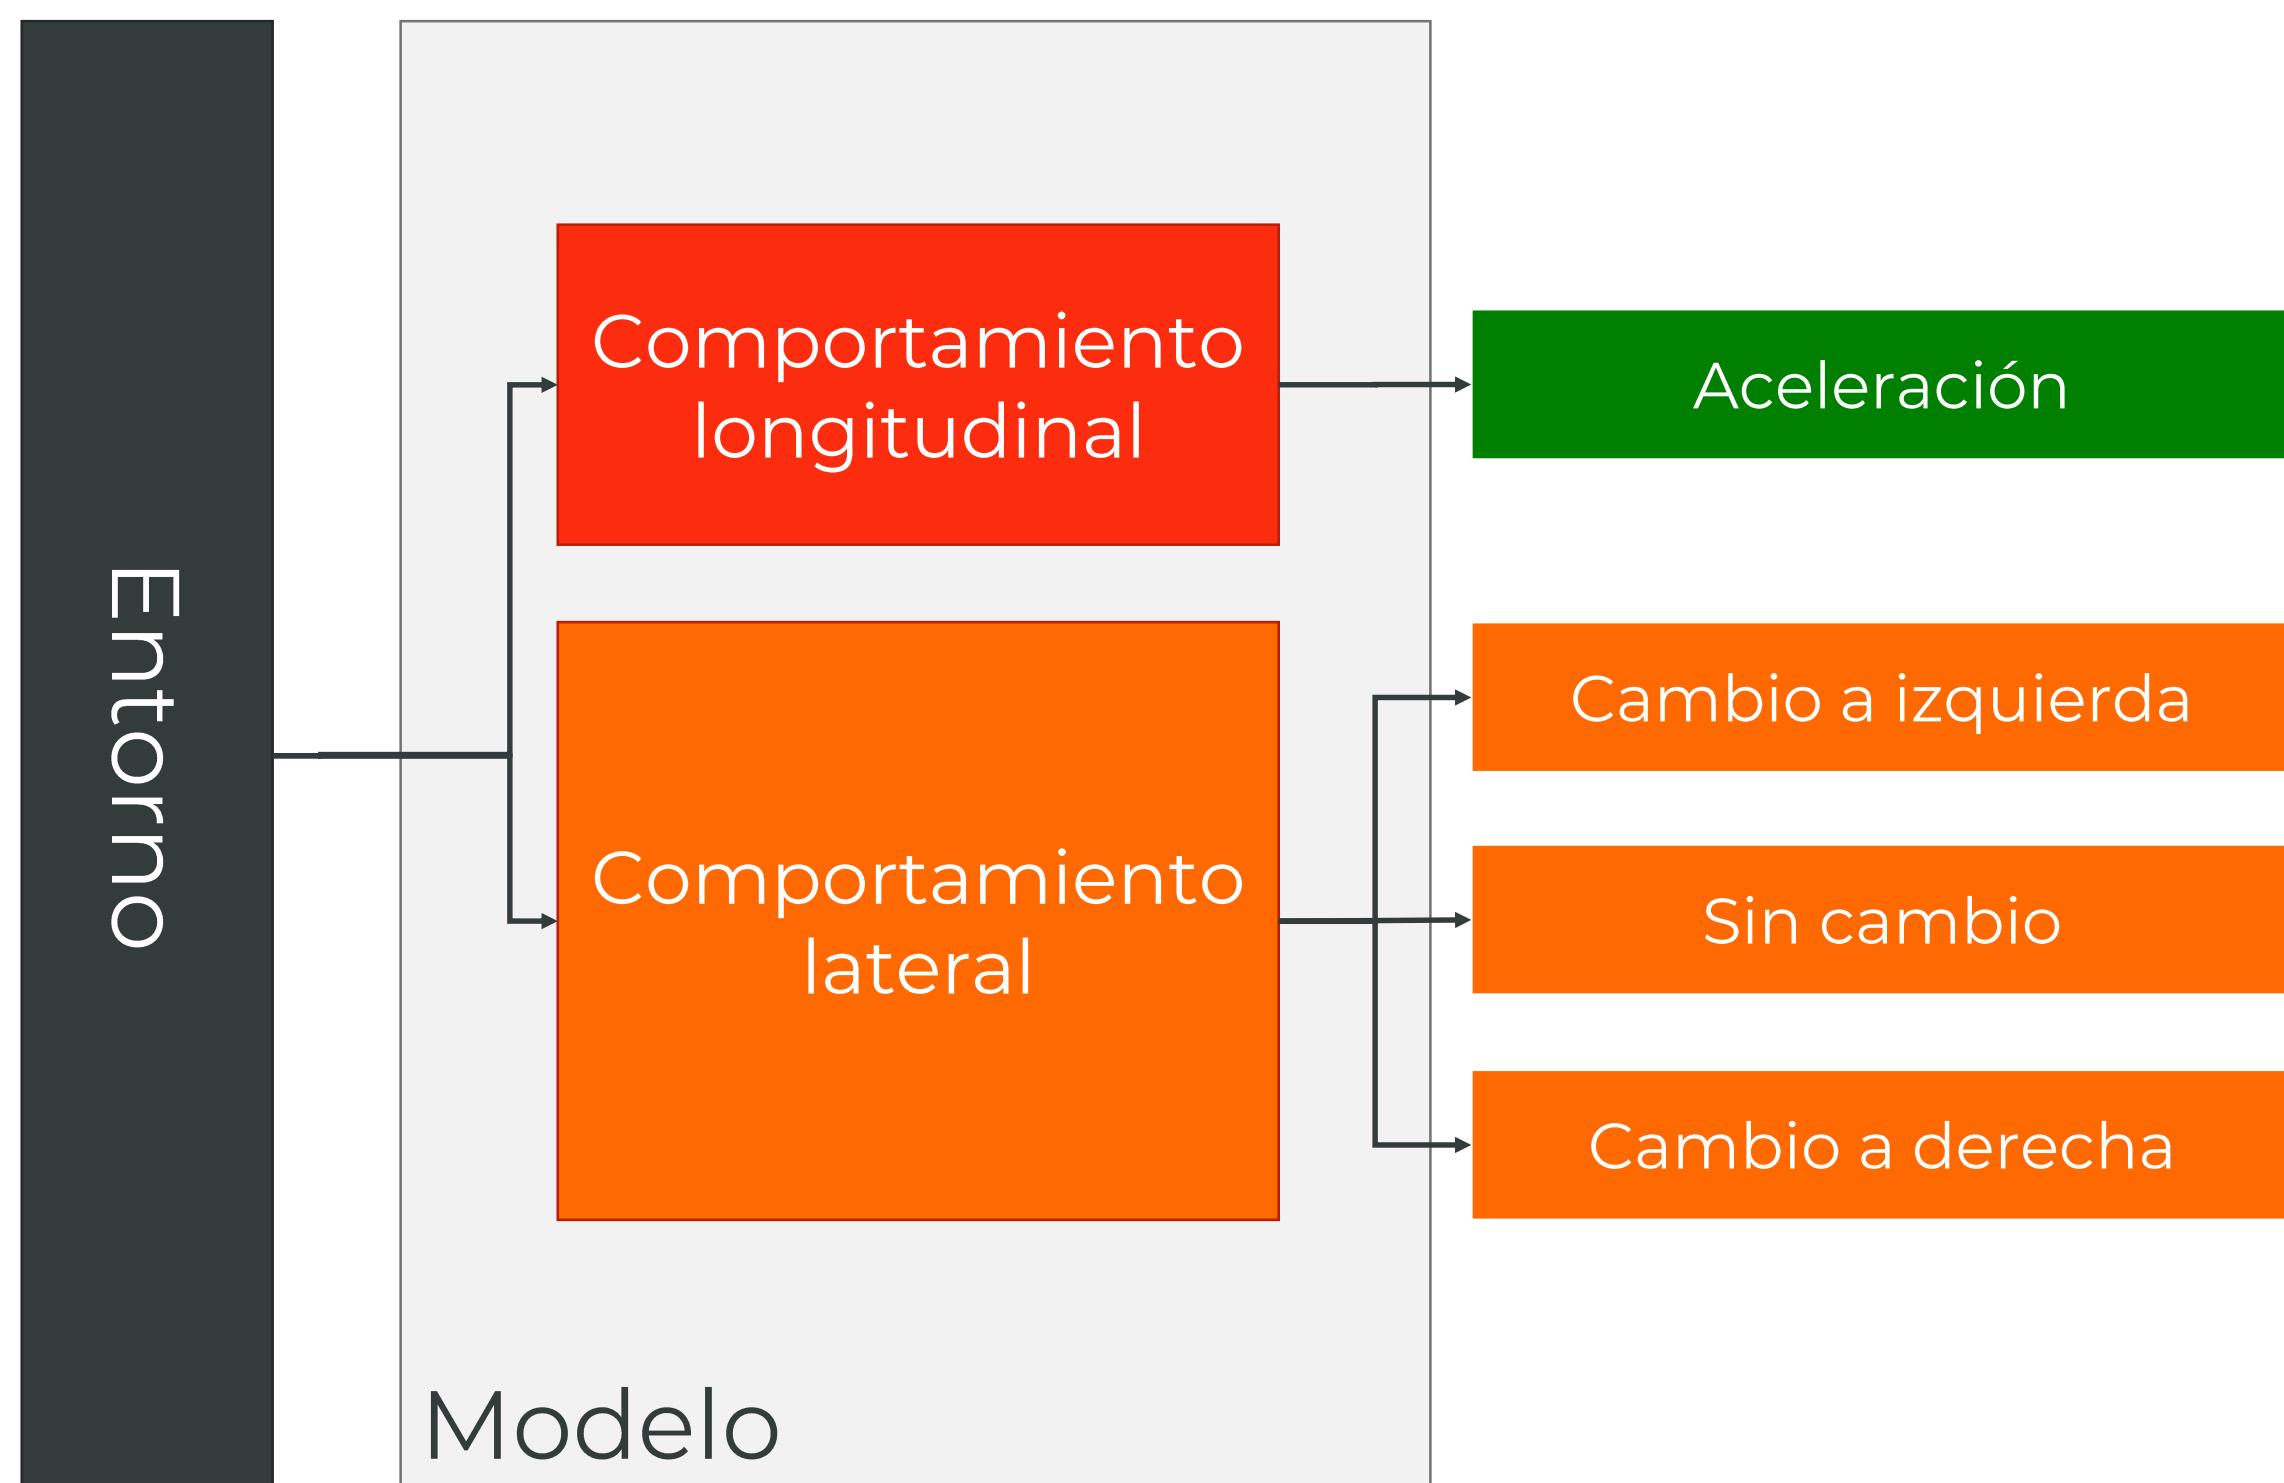
El transporte por carretera es el principal medio de transporte.

- Simulaciones más realistas permitirían estudiar mejor el tráfico.
- Modelos más realistas permitirían estudiar el comportamiento de conductores reales en simulación.
- Comportamientos más humanos en vehículos autónomos facilitarían el periodo de coexistencia.

Metodología

Modelo a desarrollar

Modelo que replique los comportamientos longitudinal y lateral de conductores a partir de sus datos reales durante la conducción para encapsularlos dentro de un agente inteligente que responda como ellos.



Tecnologías a utilizar

Tanto para el modelo longitudinal como para el lateral se compararán dos tecnologías para medir su desempeño. La mejor de cada una será elegida como candidata para ese componente del modelo global de conductor.

Perceptrones multicapa

Solución clásica para problemas de regresión.

Controladores borrosos auto-adaptativos

Permiten modelar el comportamiento procedimental del razonamiento humano.

Modelo longitudinal

Perceptrones multicapa


Solución clásica para problemas de clasificación.

Redes de Convolución

Son capaces de reconocer patrones relacionados espacialmente en los datos.


Selección de simulador

- Seleccionado entorno de simulación de tráfico SUMO, desarrollado por el Instituto de Sistemas de Transporte en el Centro Aeroespacial Alemán.
- Muchas ventajas de cara a la simulación y la extensibilidad mediante APIs.
- Restricciones en materia espacial, manejo del vehículo y representación del entorno vehicular.



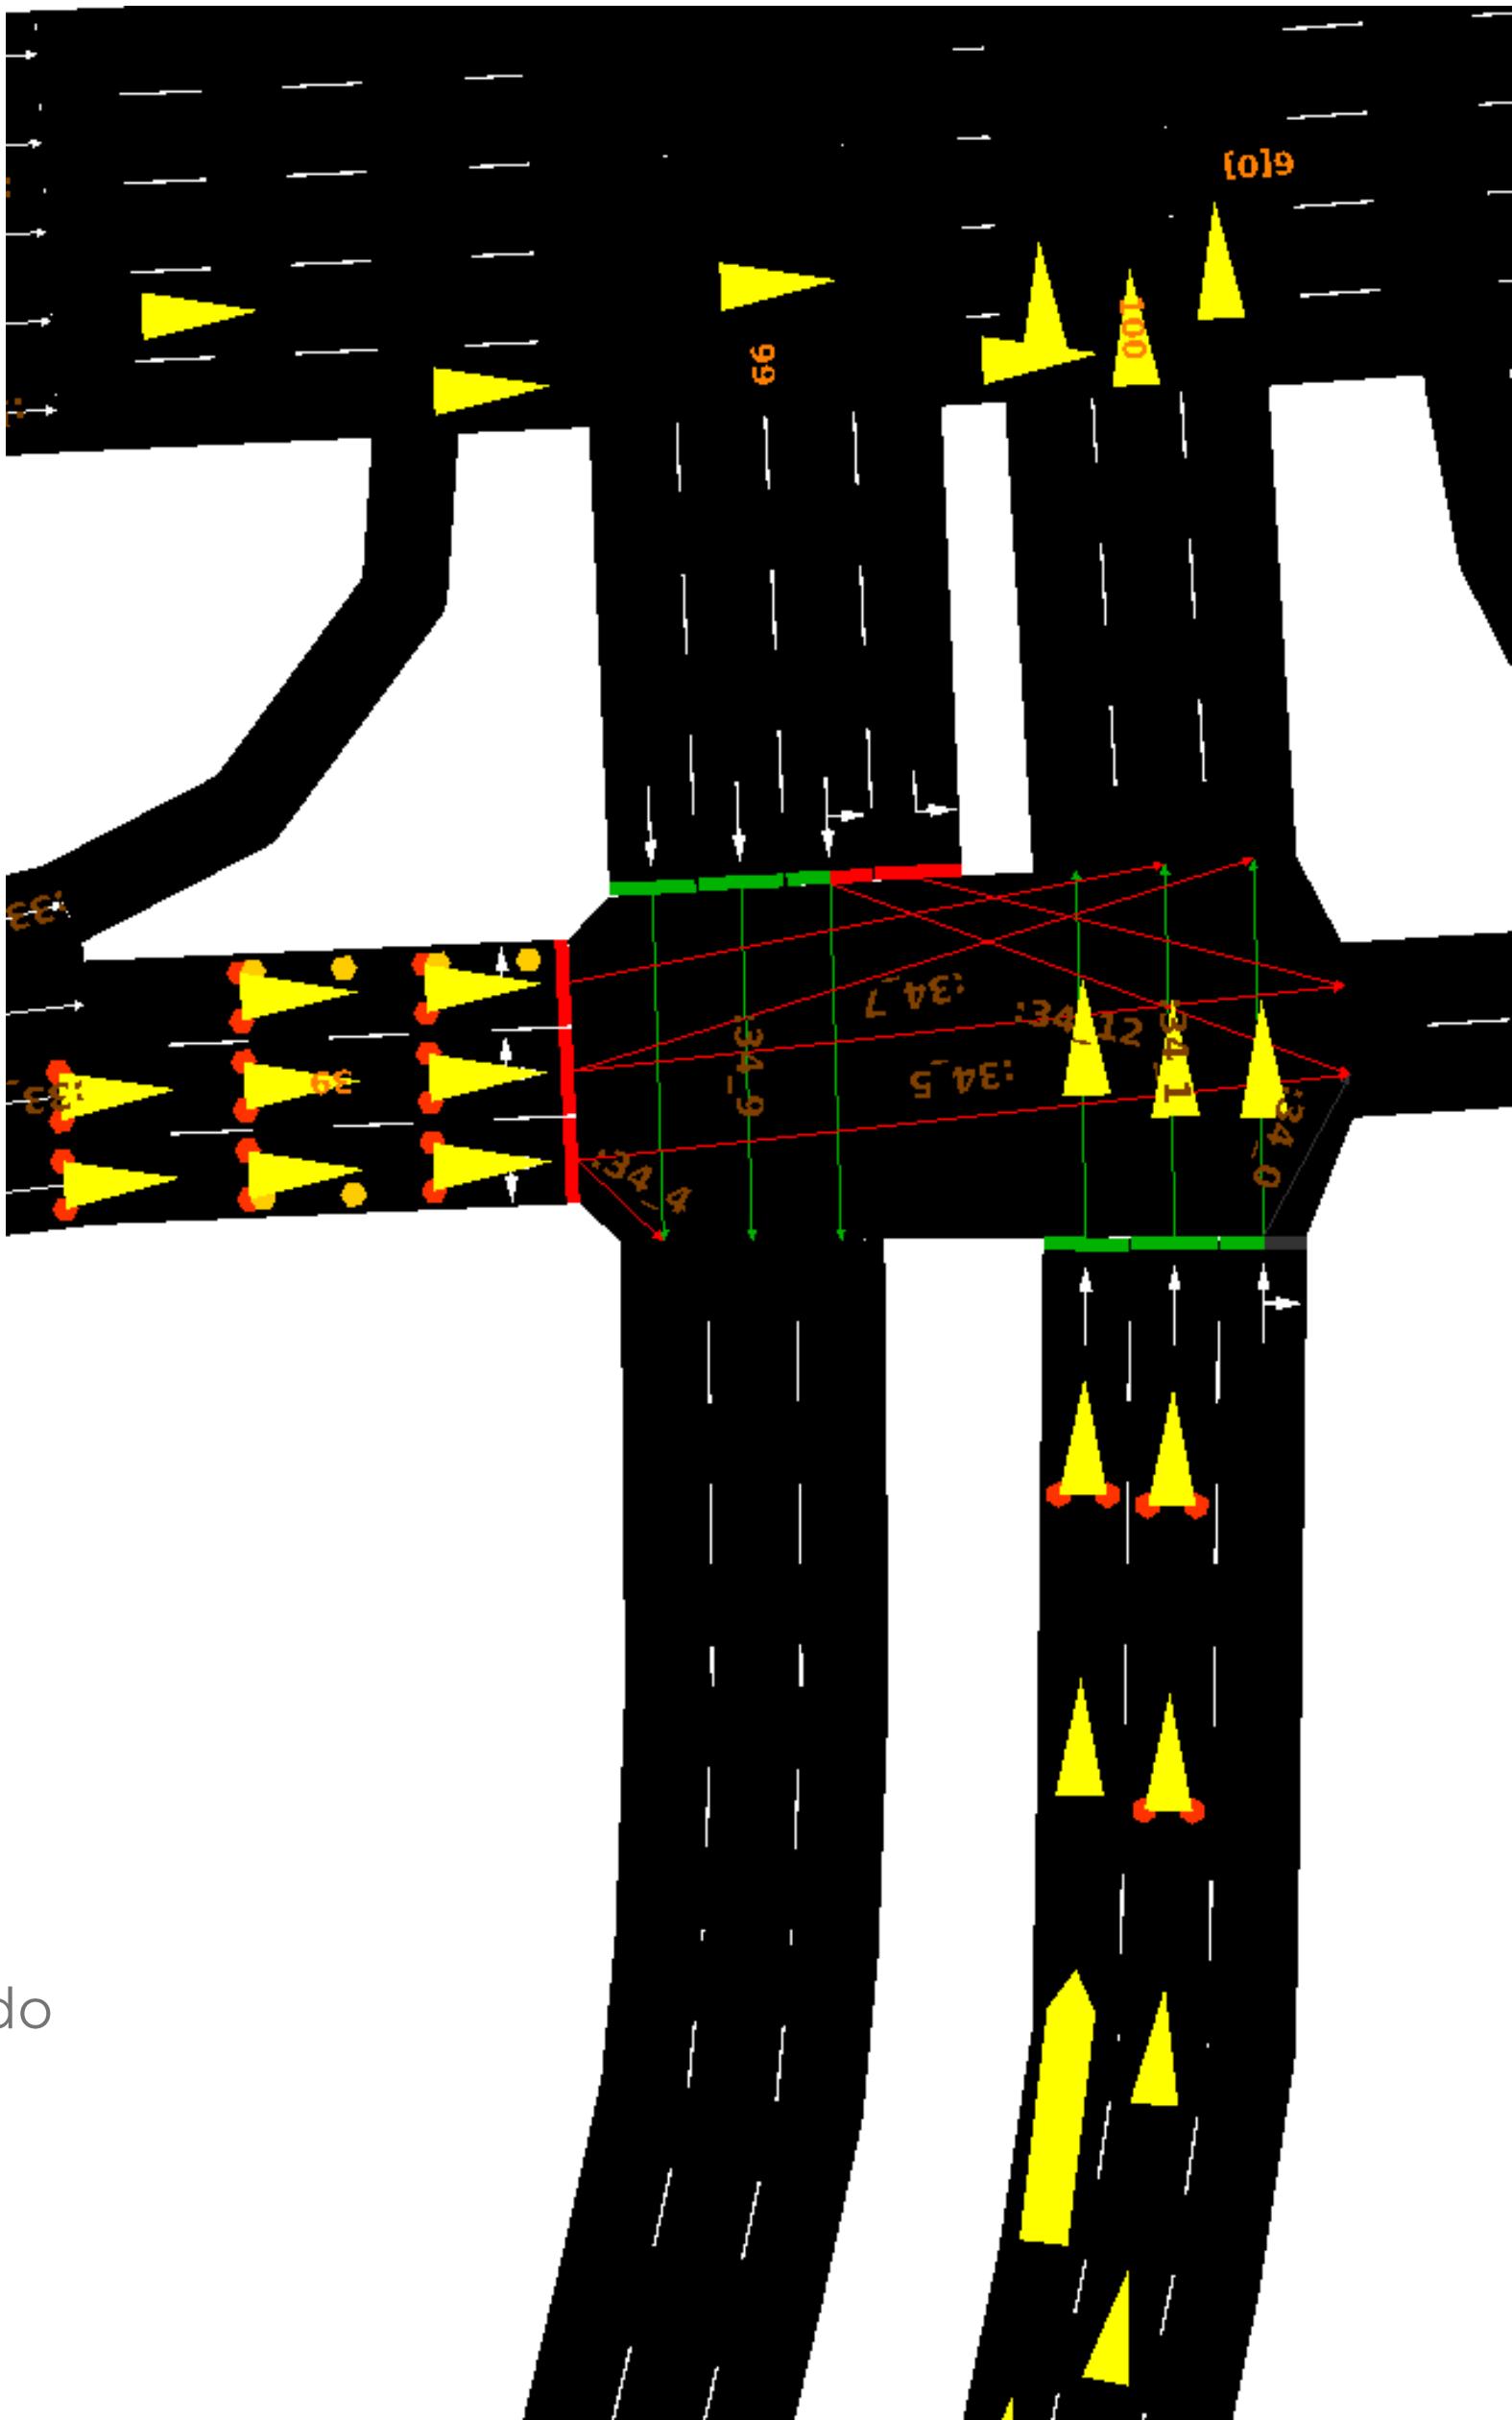
Ventajas

- Open Source Software
- Arquitectura Cliente/Servidor
- API pública
- Edición de mapas y escenarios



Inconvenientes

- Entorno del vehículo muy limitado
- Cambios de carril instantáneos
- Teleportaciones eventuales



Proceso a seguir

A lo largo de la sección se describirán los pasos seguidos durante el desarrollo de la tesis para la generación y posterior validación de los modelos de comportamiento



01 Obtención de datos

Se realizan recorridos reales con sujetos de prueba en un vehículo instrumentado para la captura de sus datos de conducción de entrenamiento y test.

02 Modelo longitudinal

Se compararán controladores borrosos (FCS) y perceptrones multicapa (MLP) para el modelo longitudinal, seleccionando el mejor para el modelo.


03 Modelo lateral

Se compararán perceptrones multicapa (MLP) y redes de convolución (CNN) para el modelo lateral, seleccionando el mejor para el modelo.

04 Validación en simulador

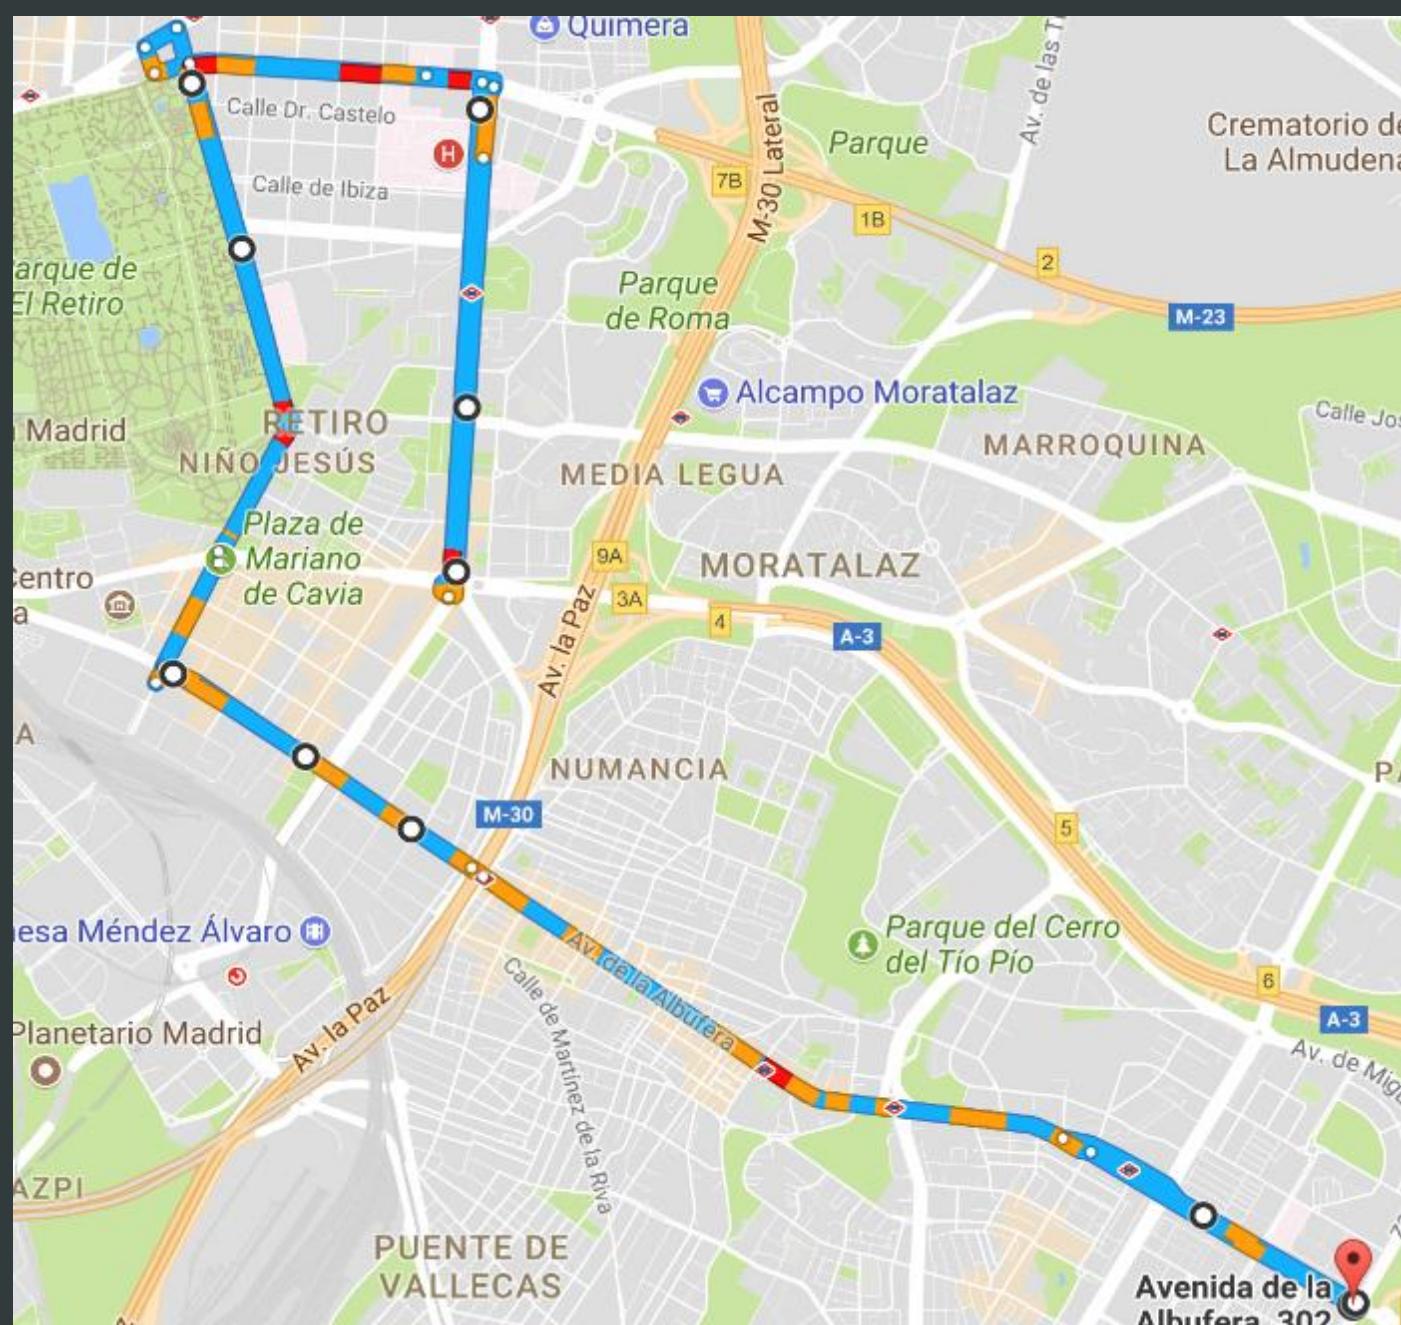
Los modelos desarrollados serán probados en un entorno de simulación para evaluar marcadores que indiquen si replican comportamientos humanos.

Proceso a seguir




Recorridos realizados

Son recorridos urbanos, con velocidades máximas que oscilan entre 30 km/h y 50 km/h, con zonas de 1, 2 y 3 carriles, rotundas y cruces.



Entrenamiento



Test

Instrumentación del vehículo

Los recorridos son realizados con un vehículo instrumentando capturando datos a la máxima frecuencia que permite el sensor en cuestión.

LiDAR (VLP-16)

Captura del entorno circundante.

GPS (INSIA)

Geoposicionamiento del vehículo.

Cámara (Kinect)

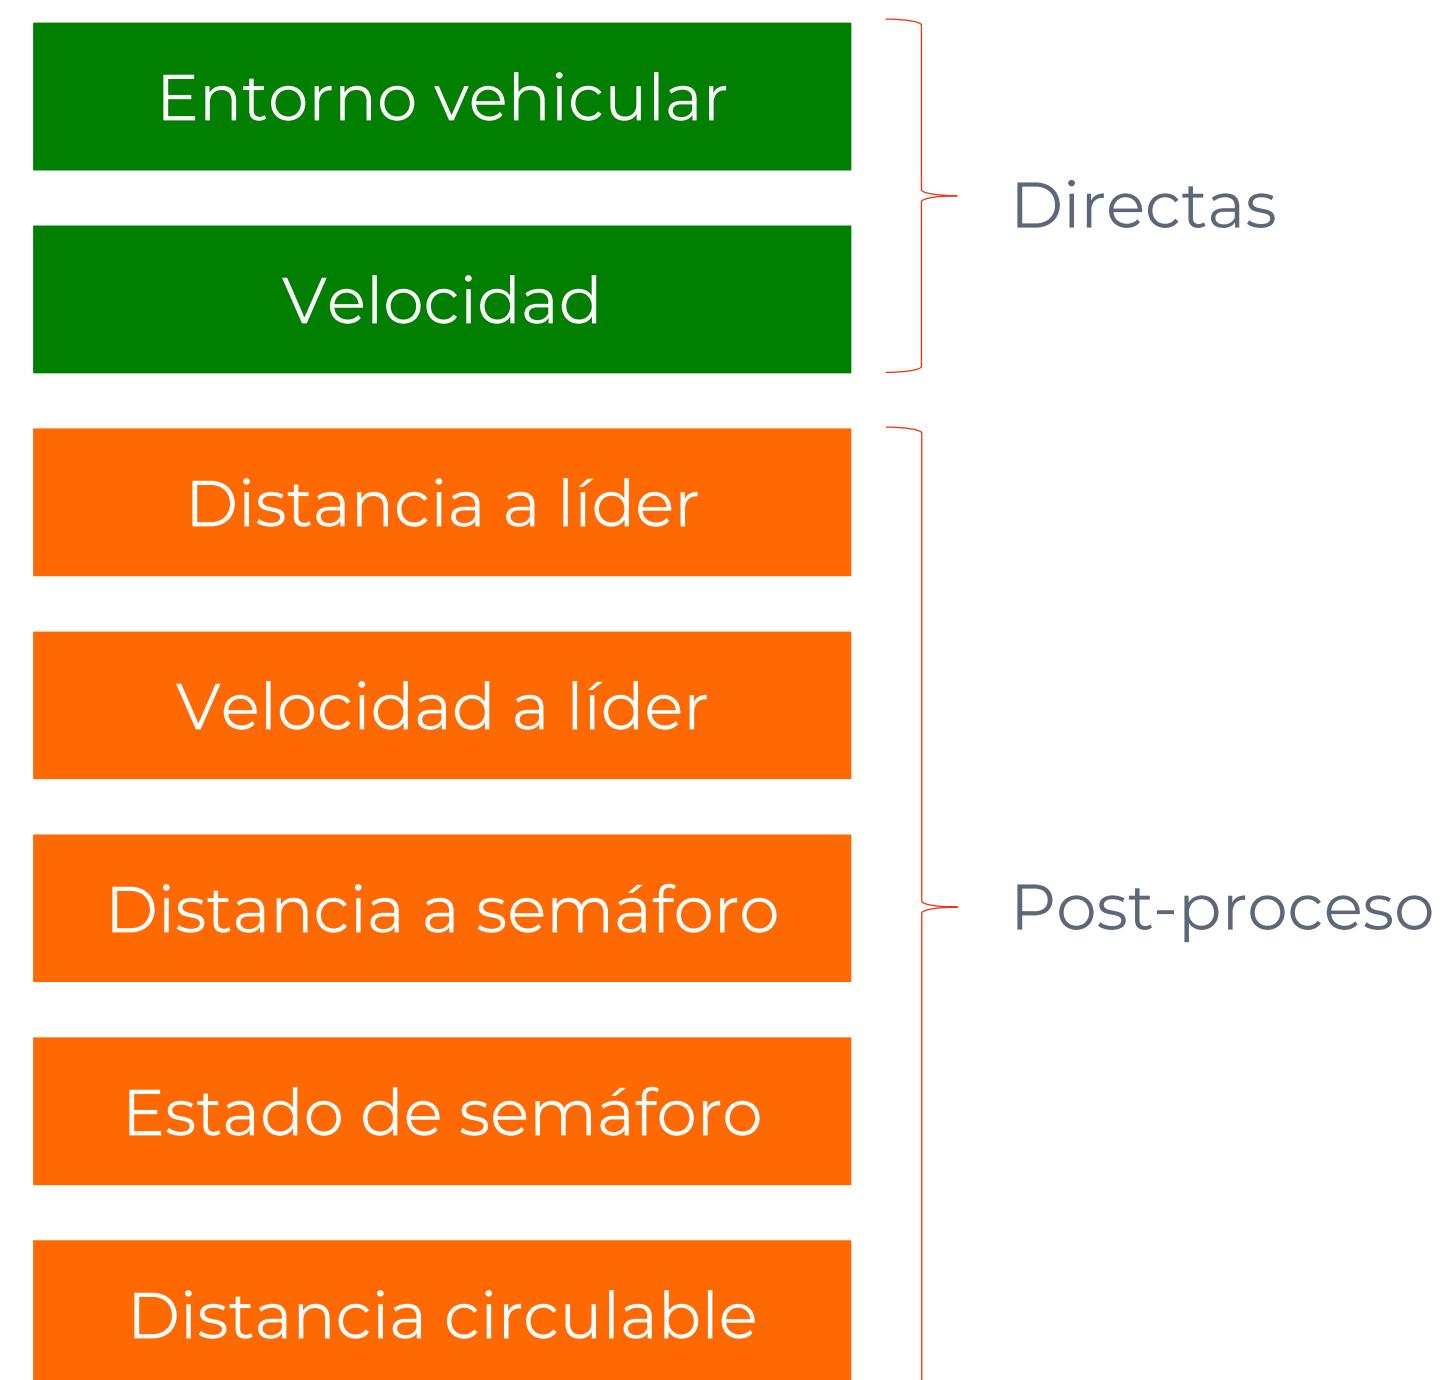
Visualización frontal para post-proceso.



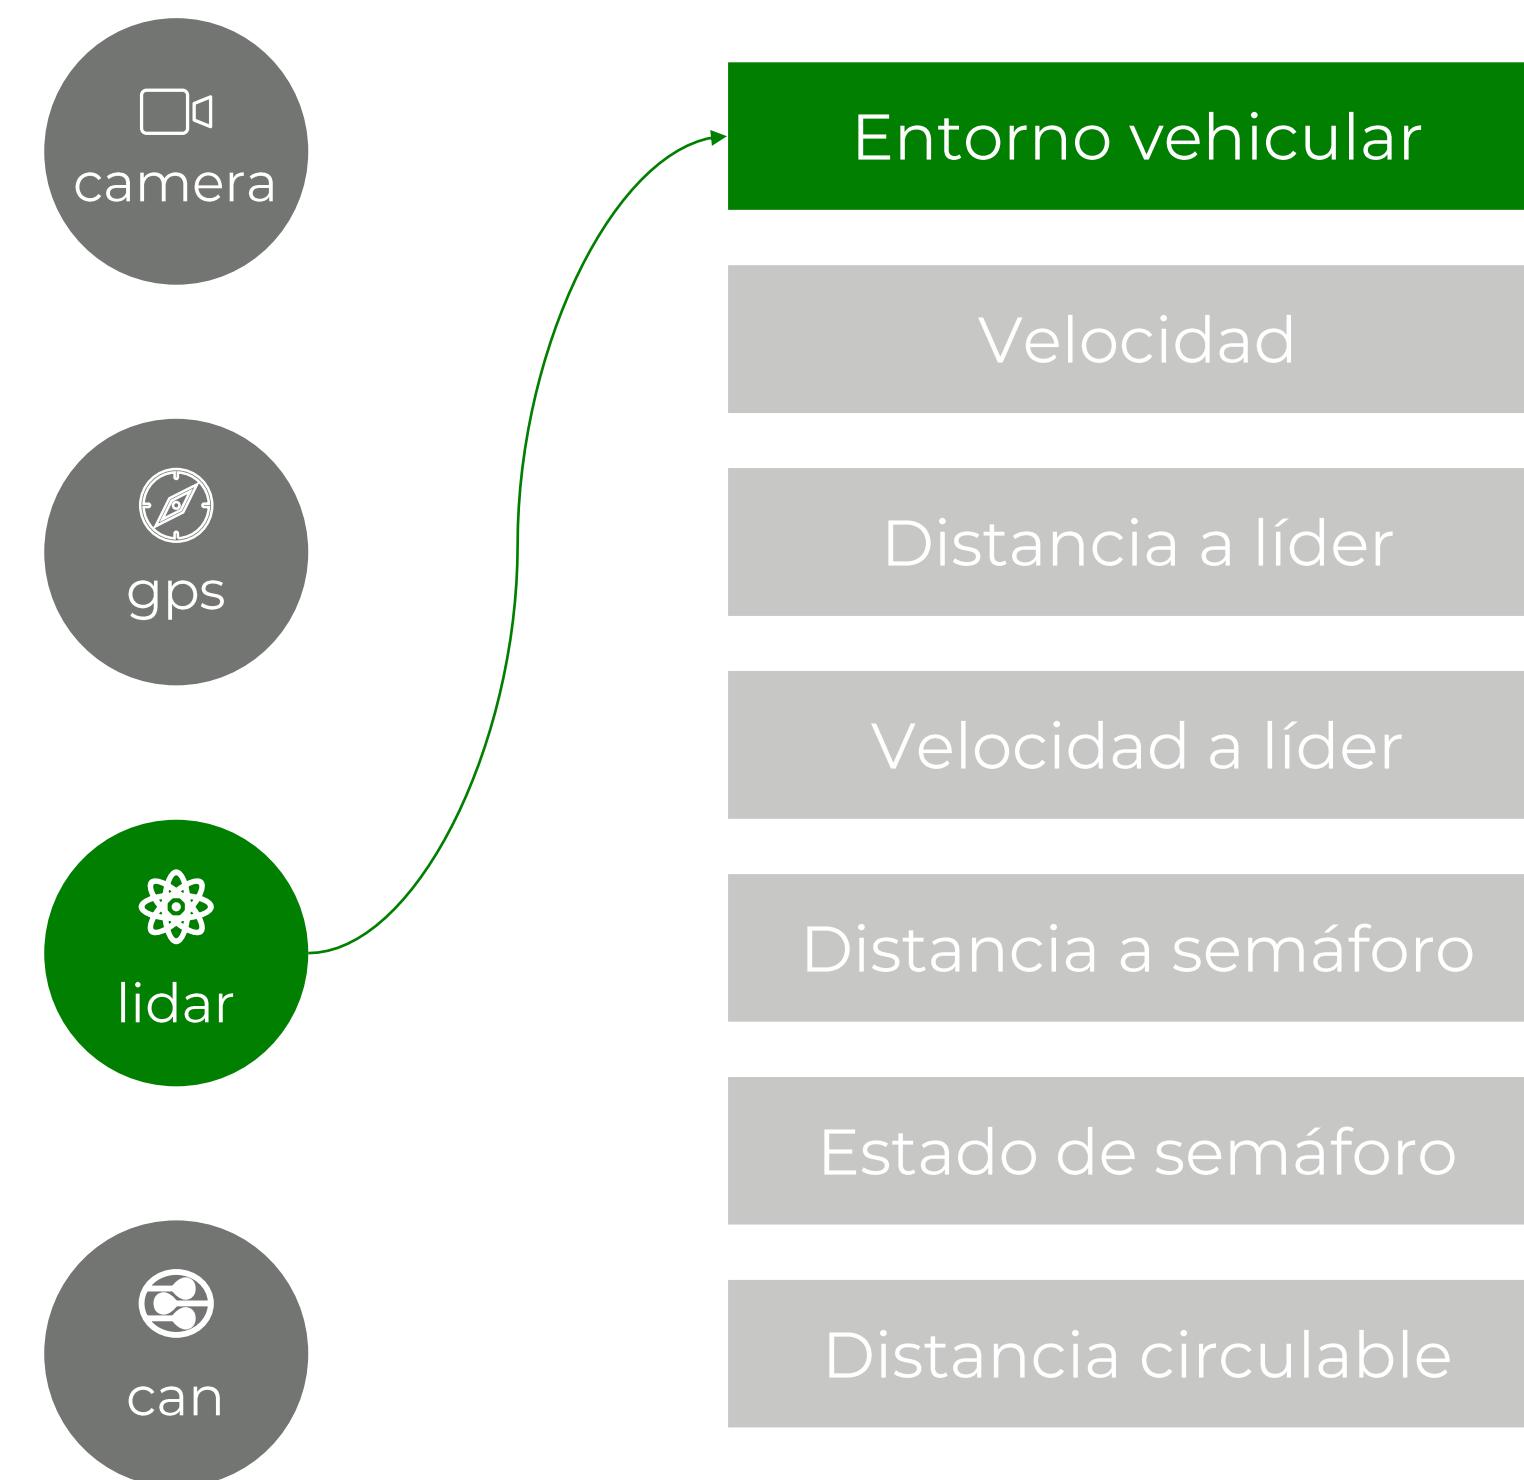
Bus CAN

Obtención del estado interno.


Variables capturadas



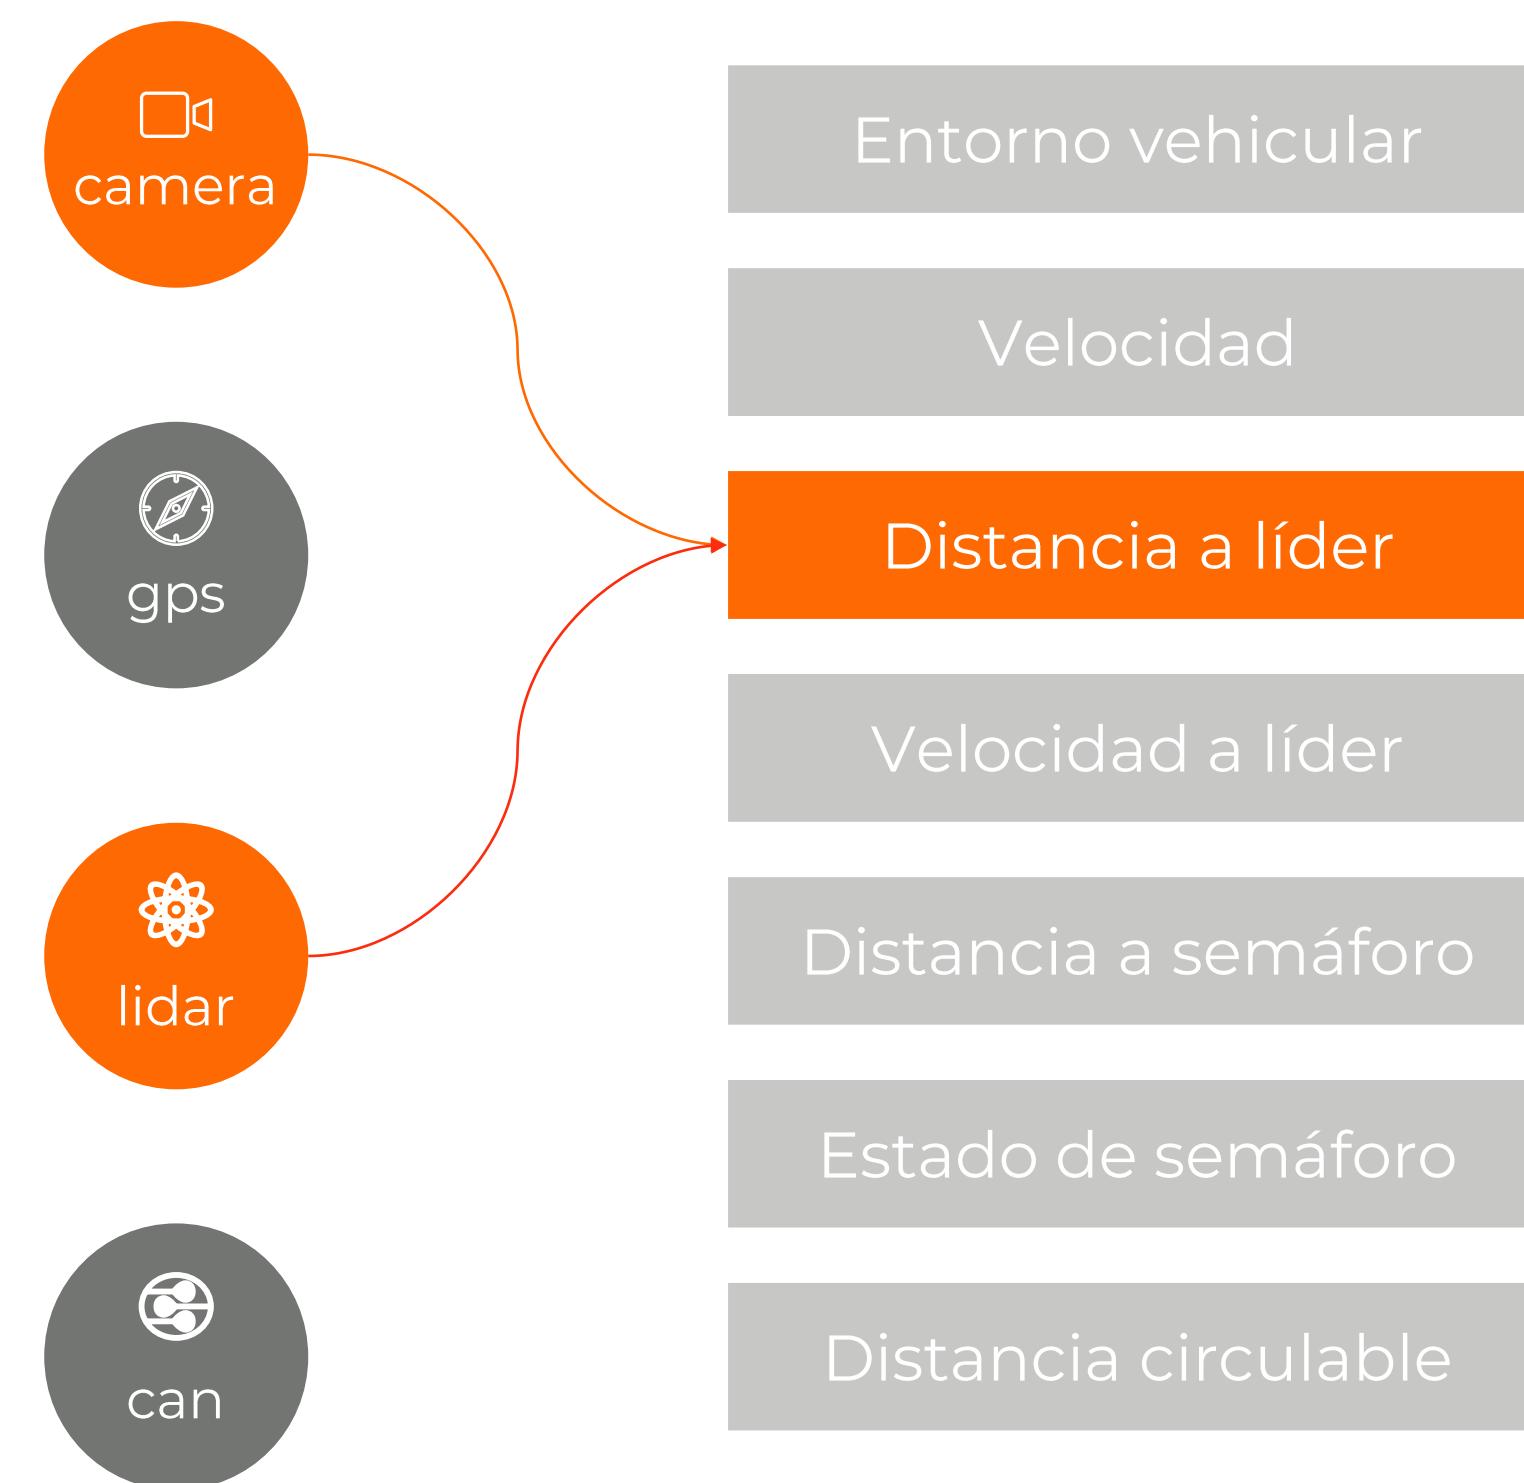
Variables capturadas



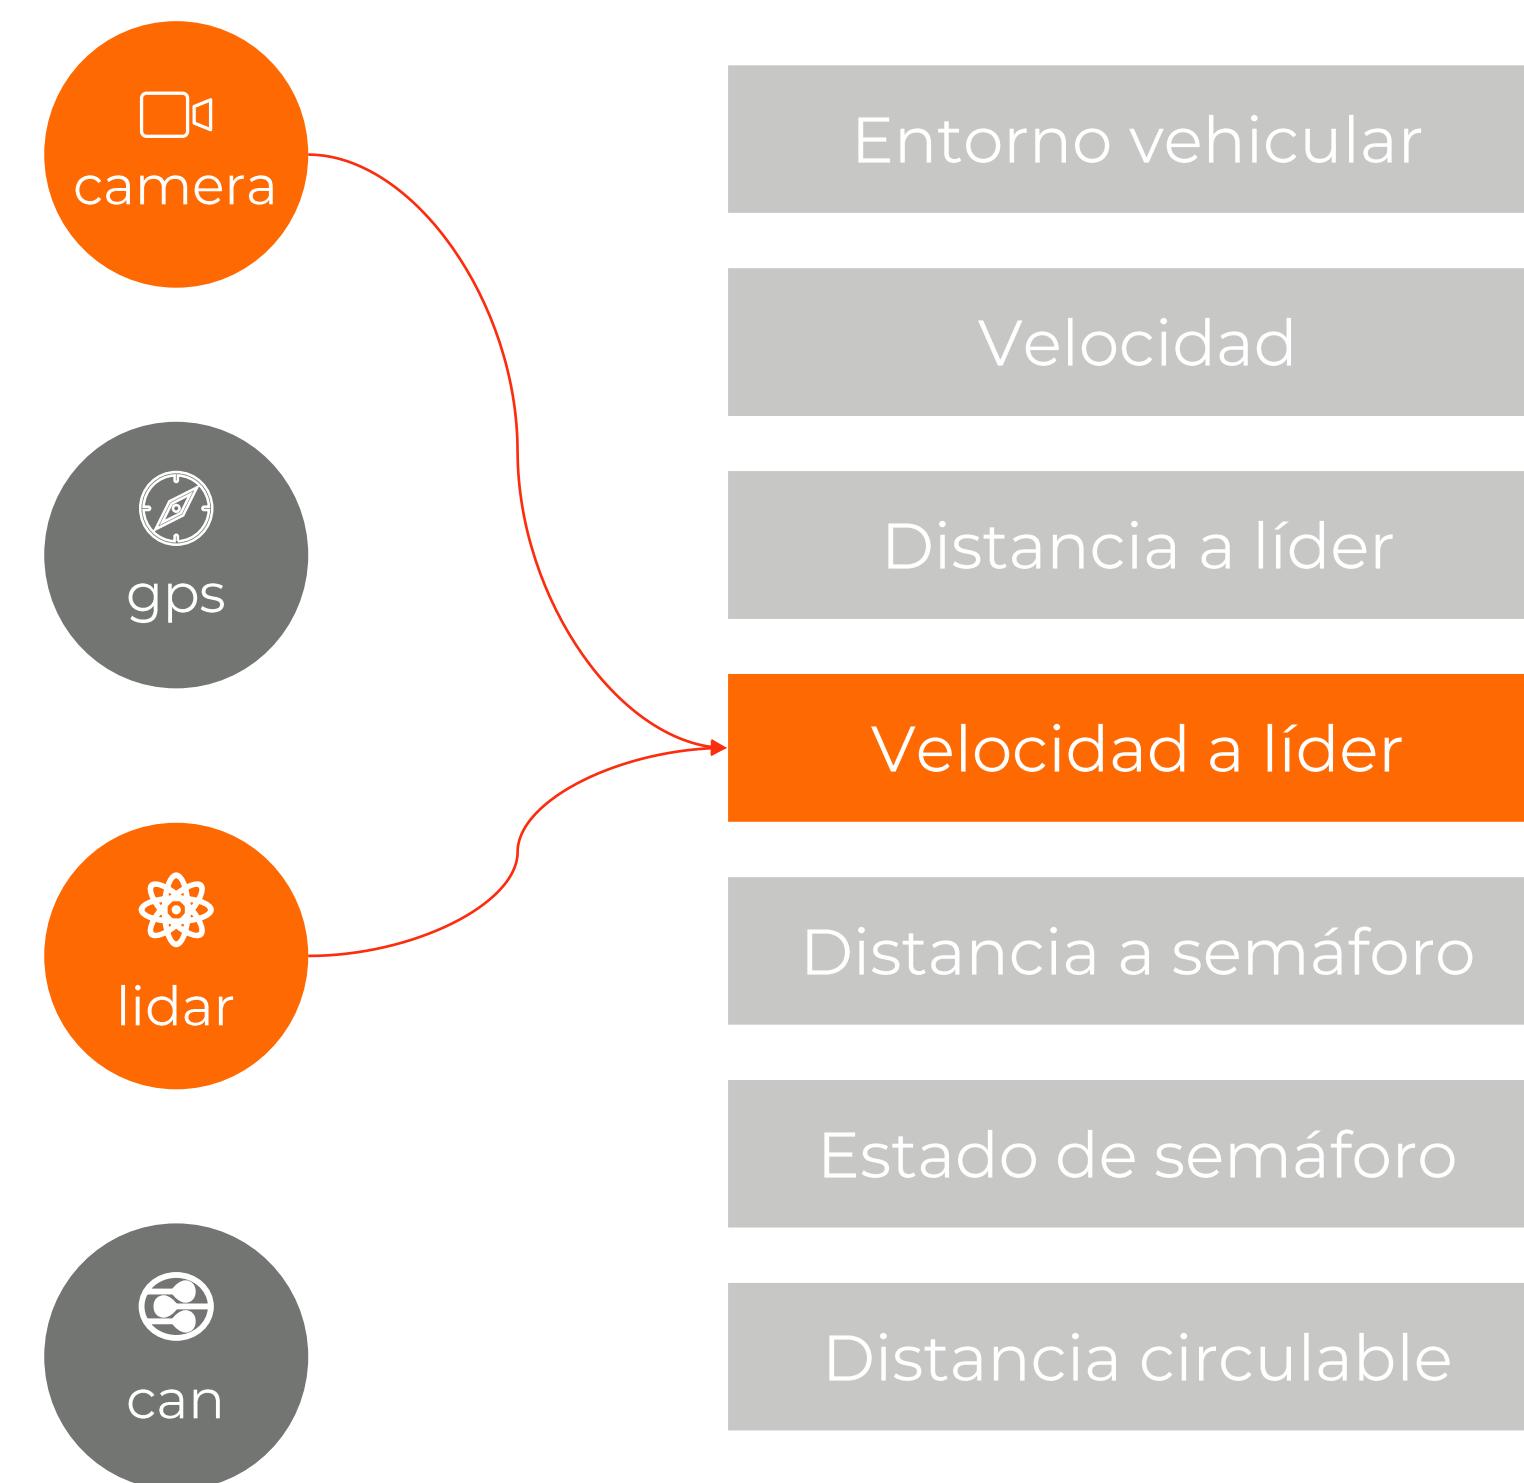
Variables capturadas



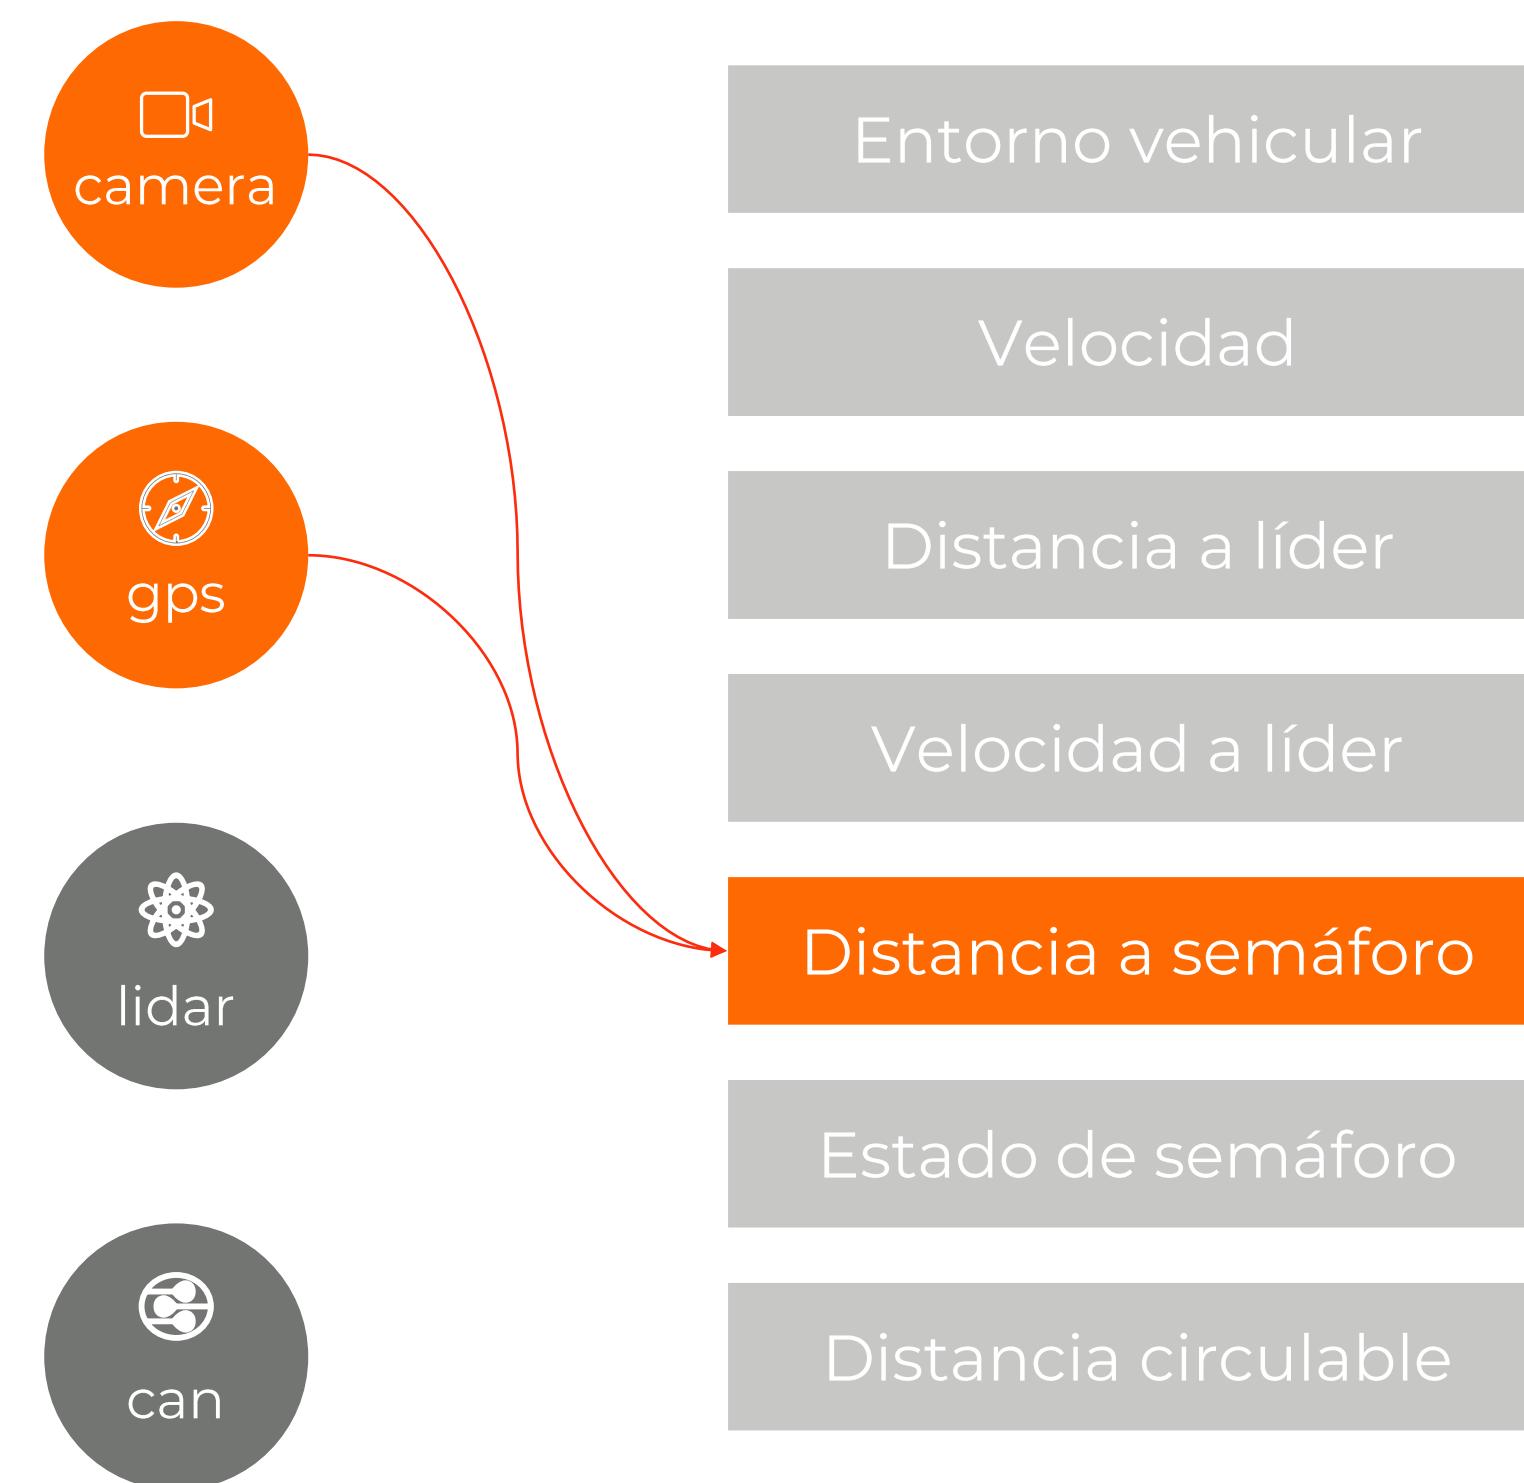
Variables capturadas



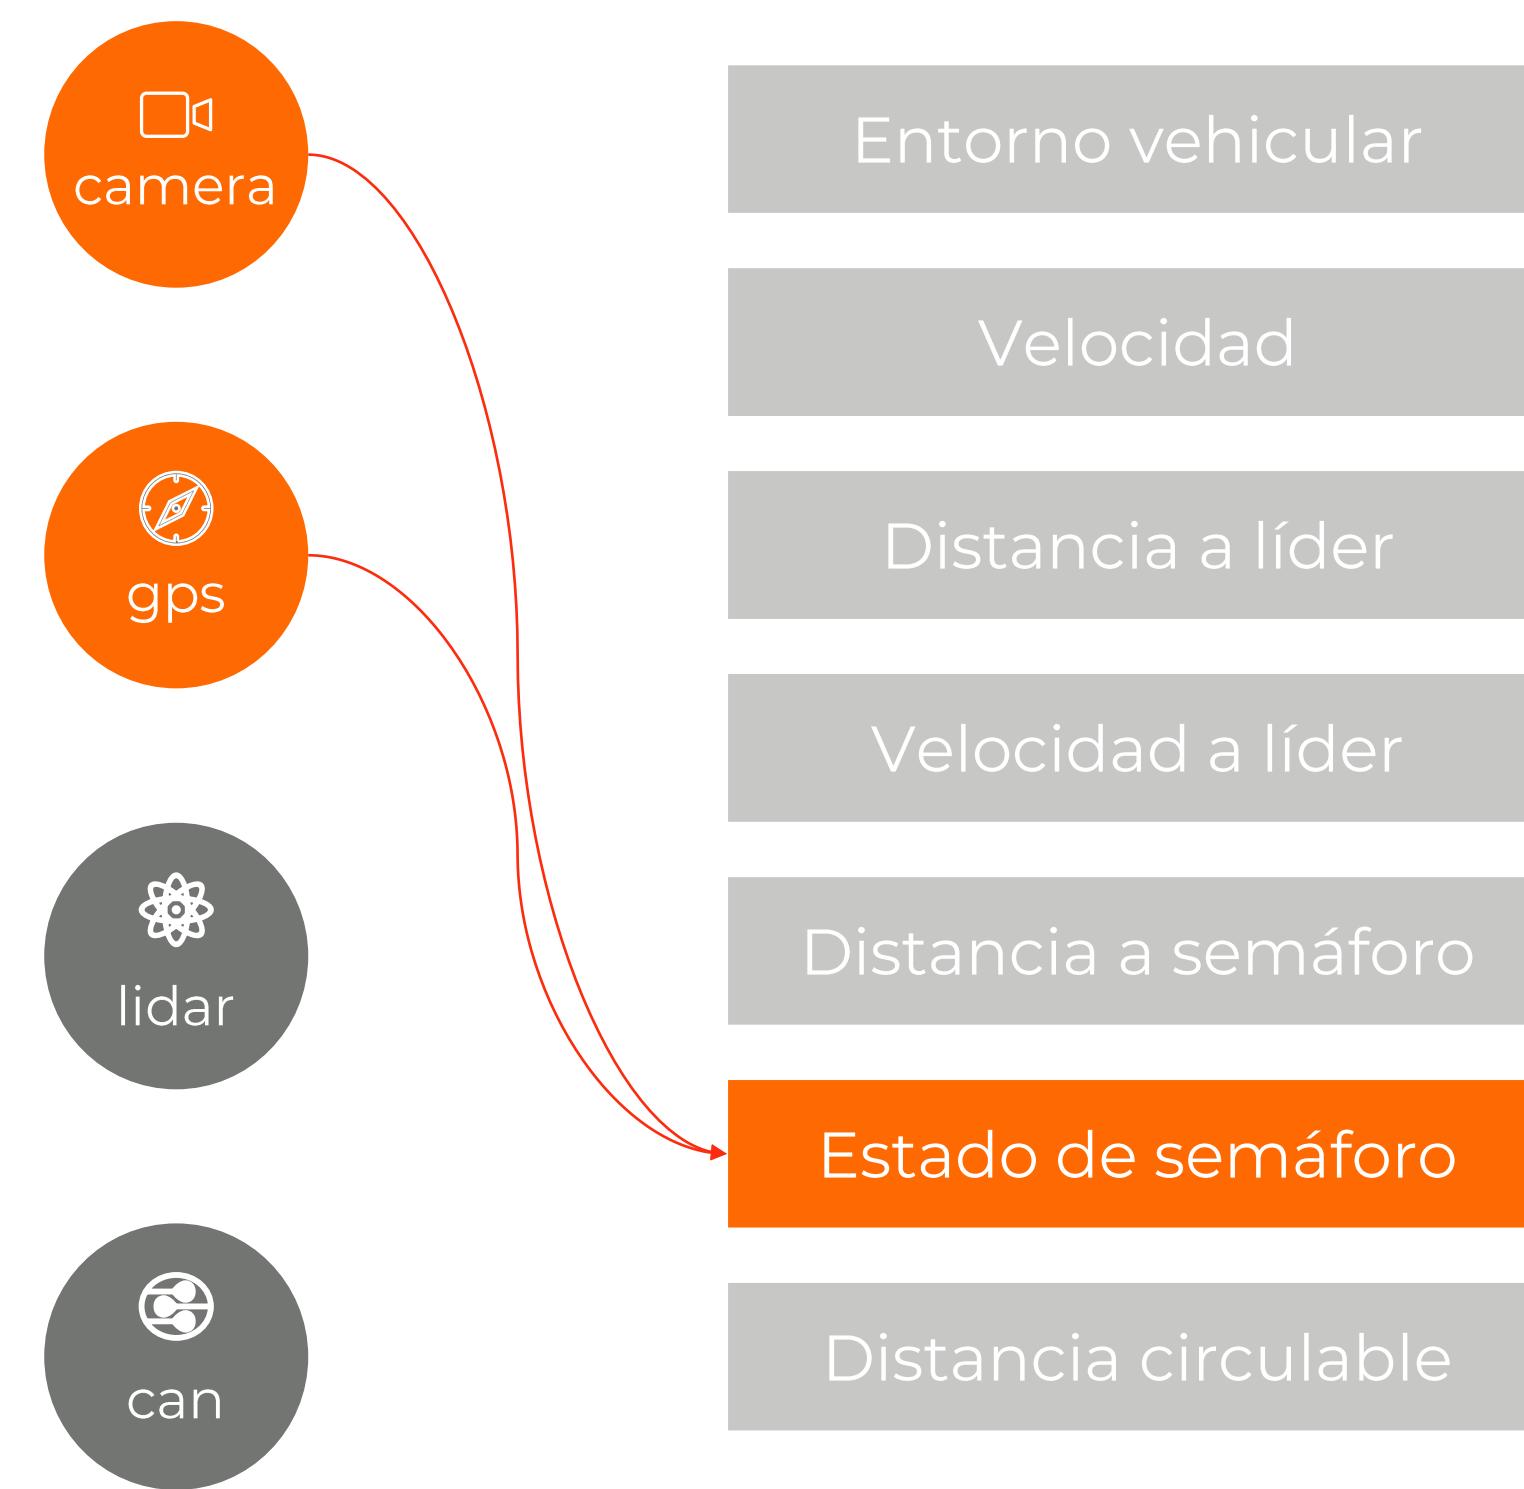
Variables capturadas



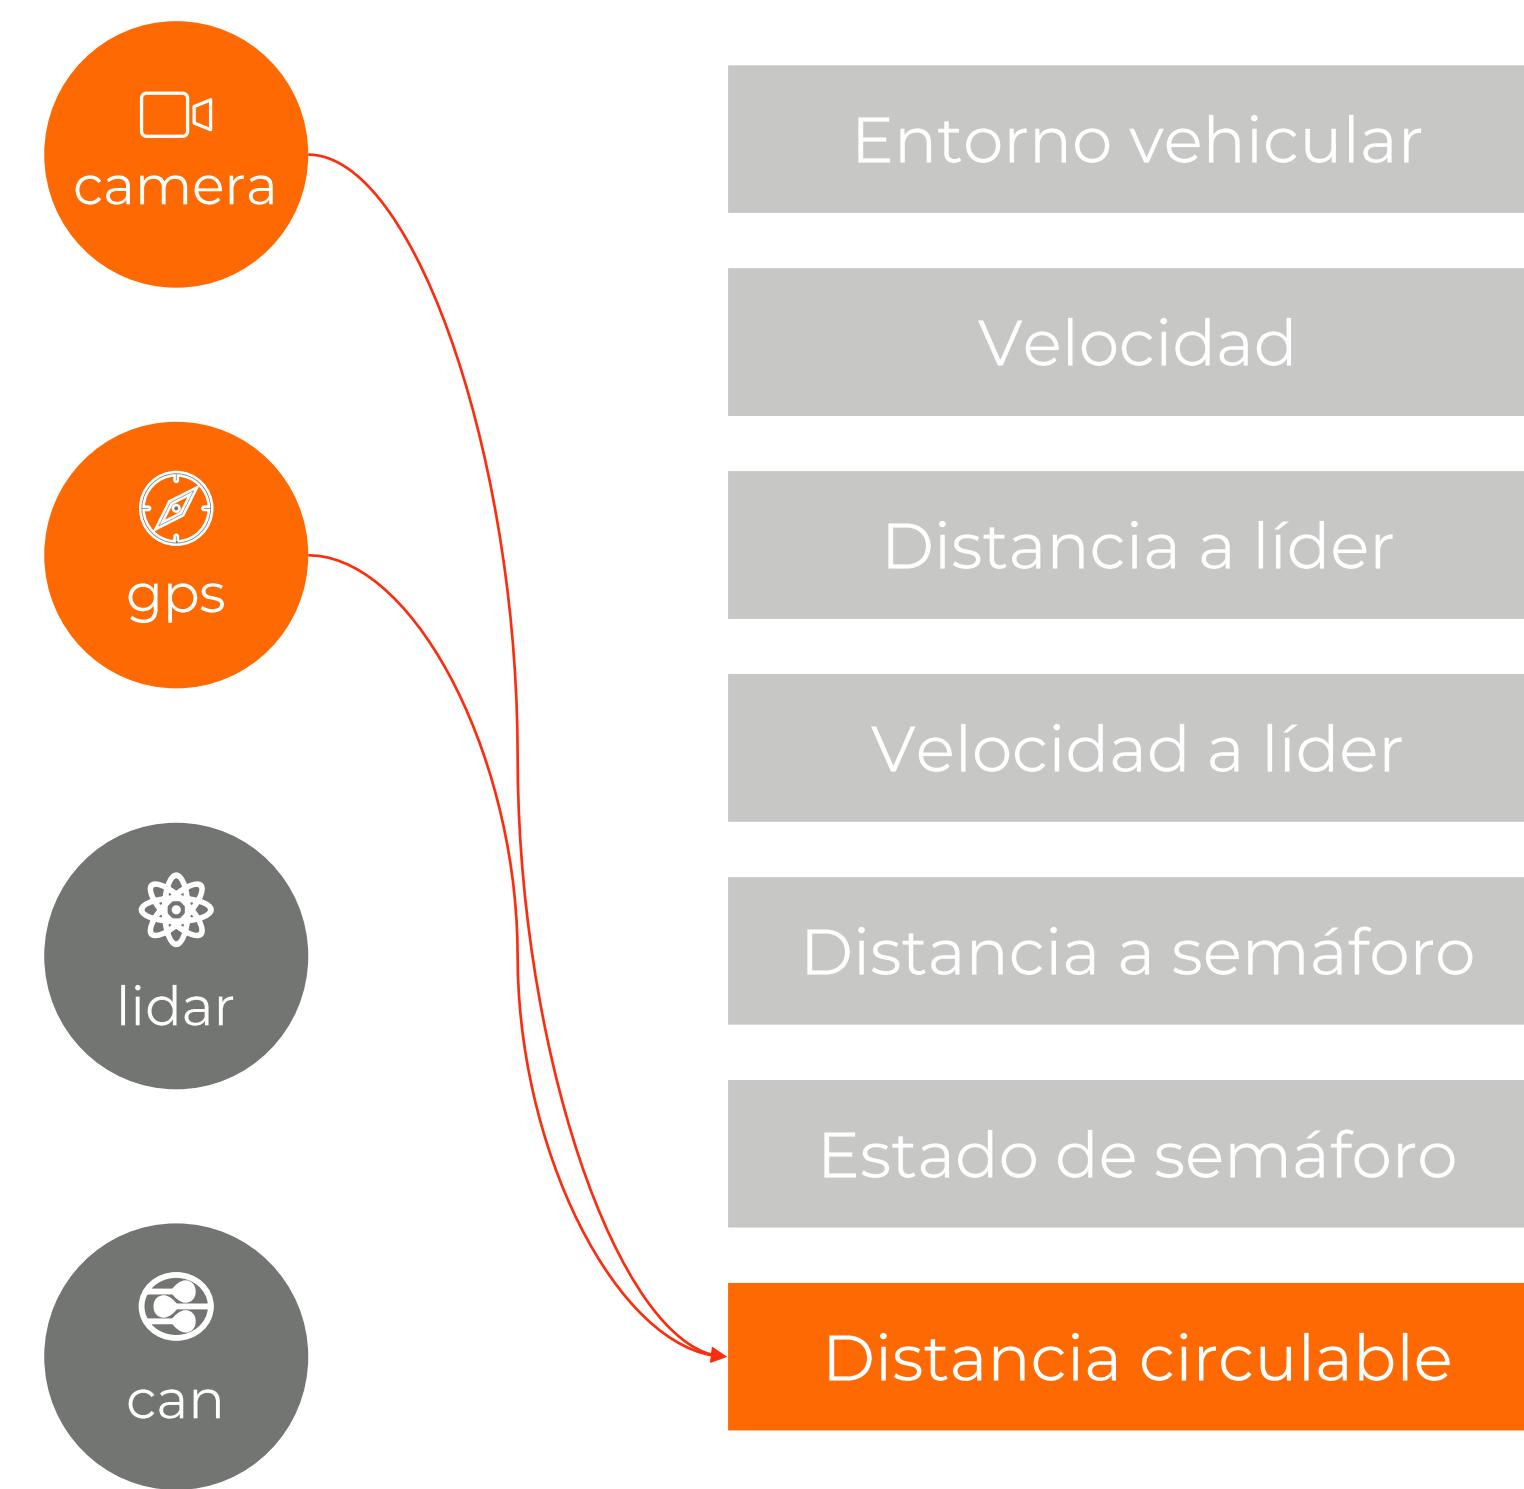
Variables capturadas




Variables capturadas



Variables capturadas



Arquitectura del sistema de captura



Sujetos de prueba


La captura de datos se han realizado con tres sujetos S_1 , S_2 y S_3 diferentes sobre los recorridos de entrenamiento y de test. Estas capturas se han tratado de realizar en las mismas condiciones en la medida de lo posible.

Tres sujetos de prueba

Los sujetos son varones de entre 30 y 34 años con más de 5 años de experiencia en conducción.

Recorrido conocido

Al conocer el recorrido previamente, se prescinde en lo posible del nivel estratégico.



Un dataset global

Los datos de los tres sujetos S_A darán lugar a un dataset de entrenamiento y otro de test.

Un dataset por sujeto

Cada sujeto S_1 , S_2 y S_3 tendrá asociado un conjunto de entrenamiento y otro de test.

Proceso a seguir



Controlador borroso

Aportación de la tesis: **Representación del controlador borroso como grafo computacional.**

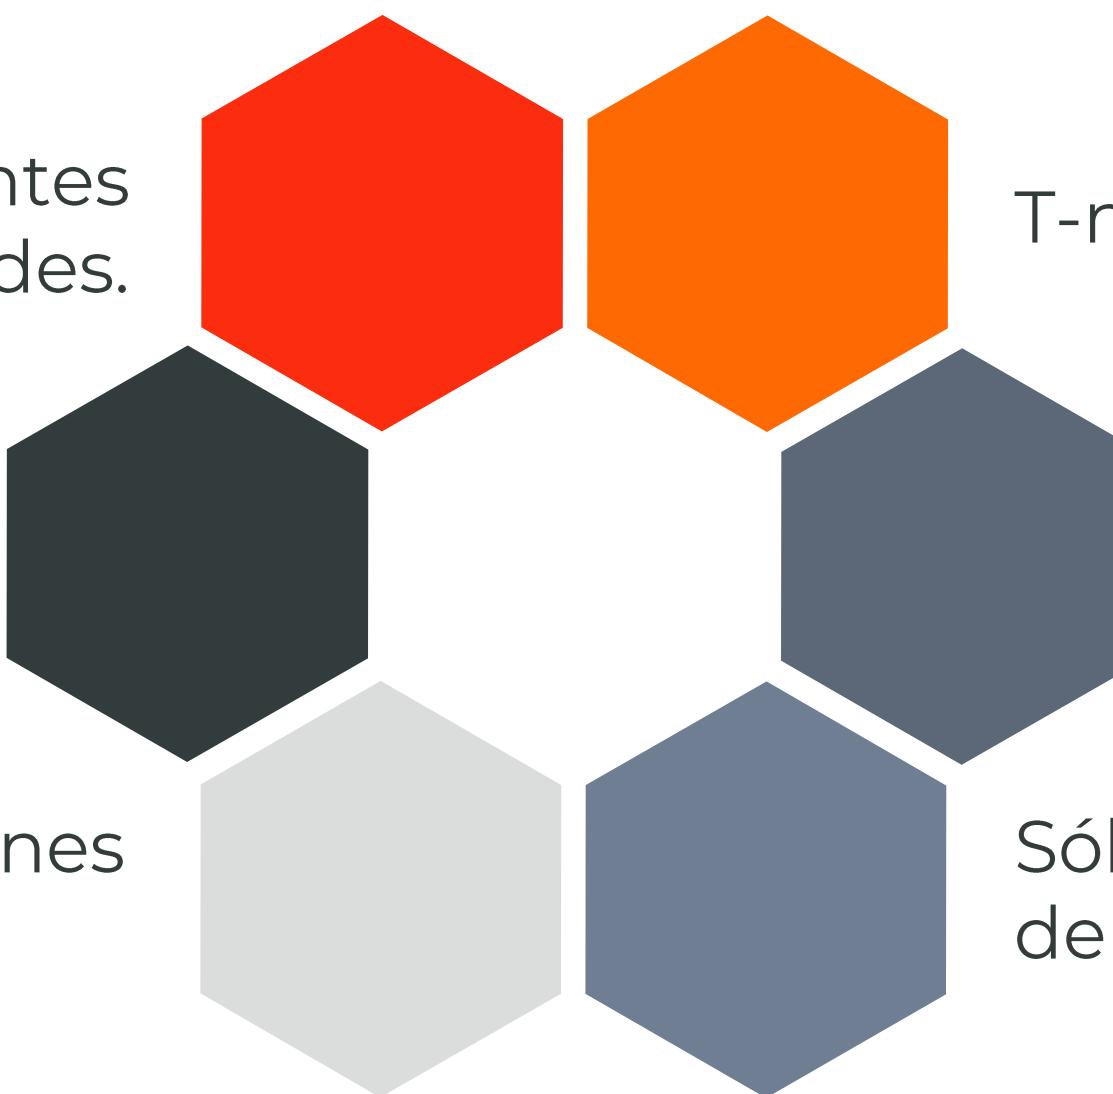
Cómo ajustar las variables del controlador: **Descenso del gradiente.**

Limitaciones del estudio

Ascendentes, descendentes
y trapezoides.

Controlador tipo Takagi-
Sugeno de orden 0.

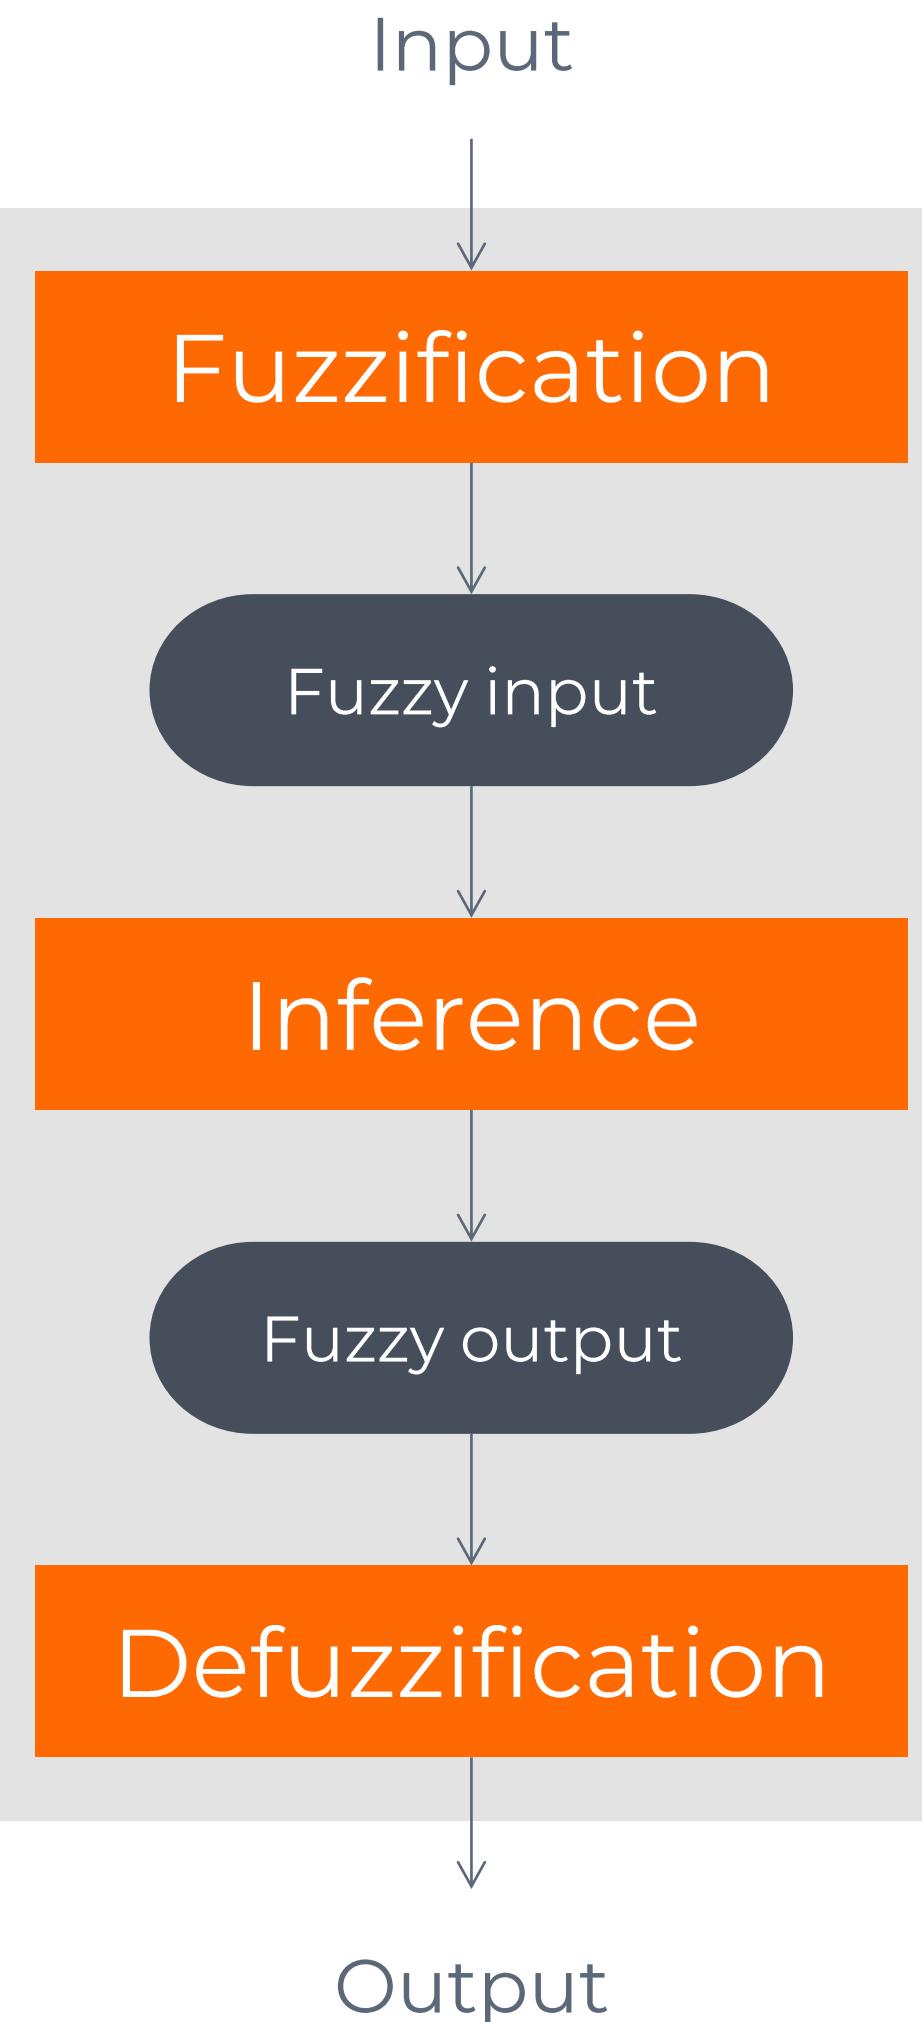
Número de particiones
por variable fijo.



T-norm: mínimo.

S-norm: máximo.

Sólo una variable
de salida.



Representación como grafo computacional

Fuzzificación

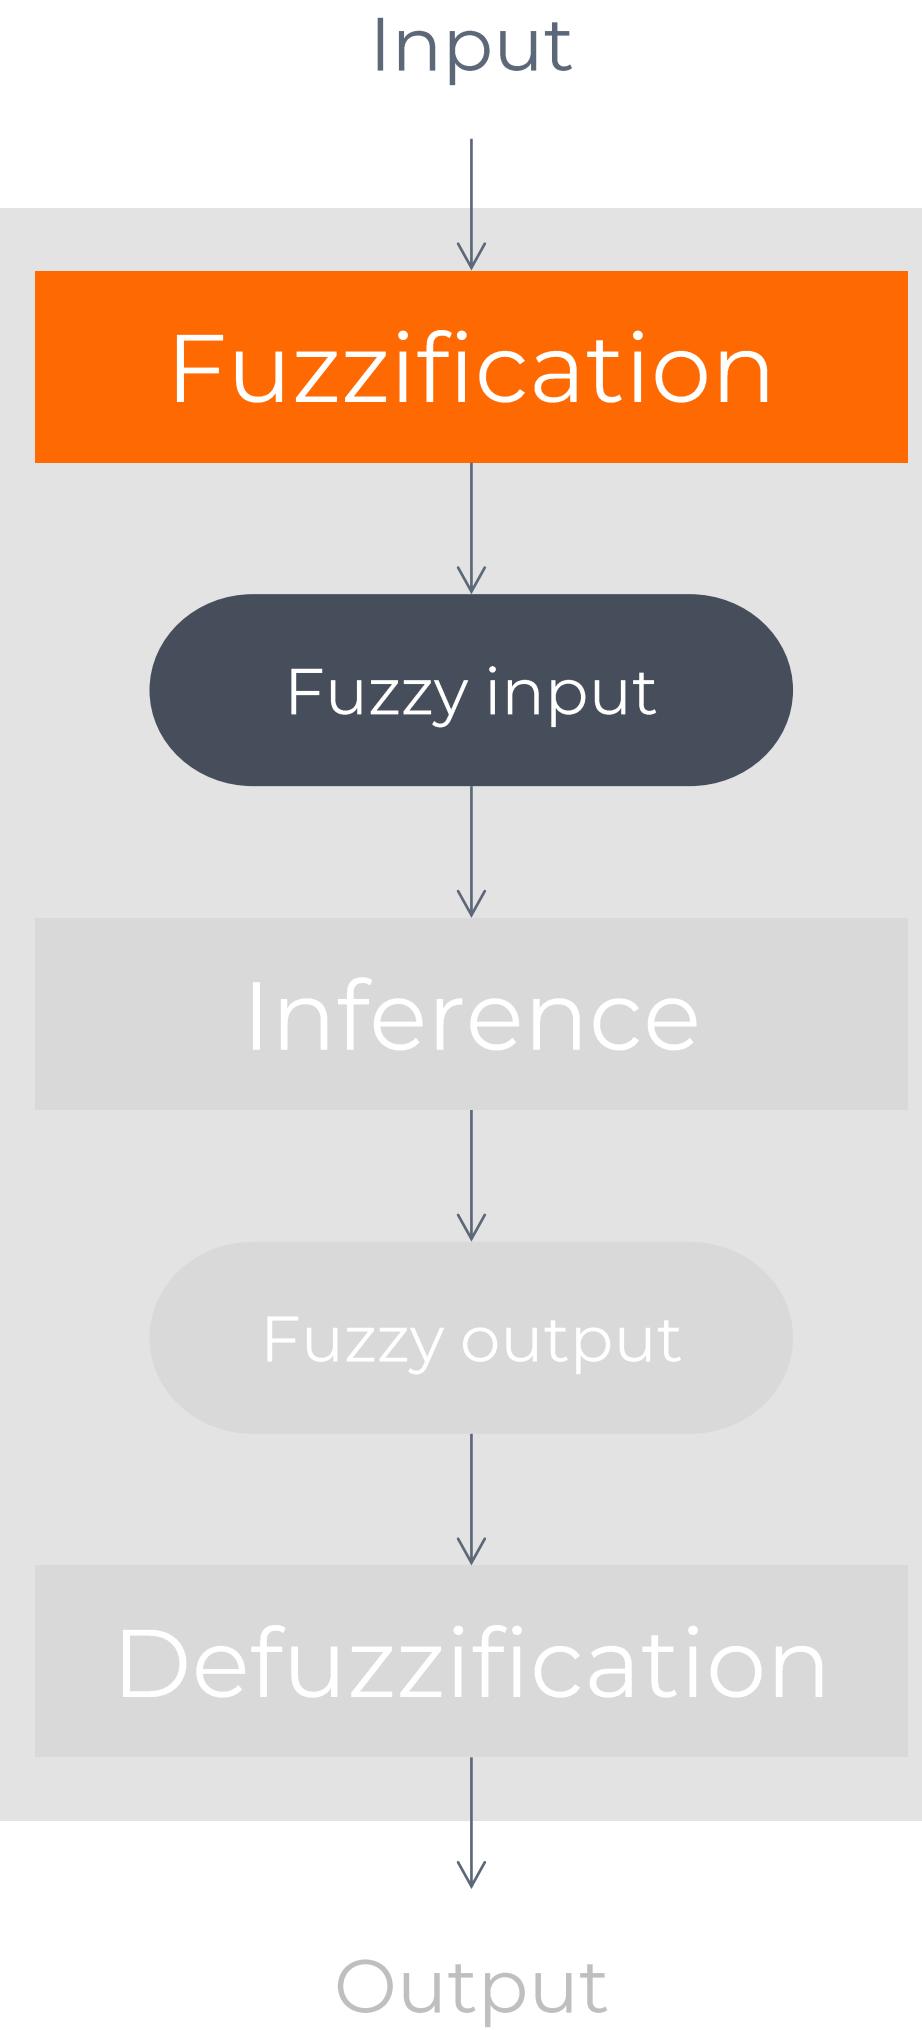
Es necesario ajustar las variables asociadas a las funciones de pertenencia de cada conjunto borroso.

Inferencia


Es necesario ajustar las variables asociadas a las reglas que se activan en el proceso de inferencia.

Defuzzificación

Es una operación que no necesita de ajuste.




Grafo de fuzzificación

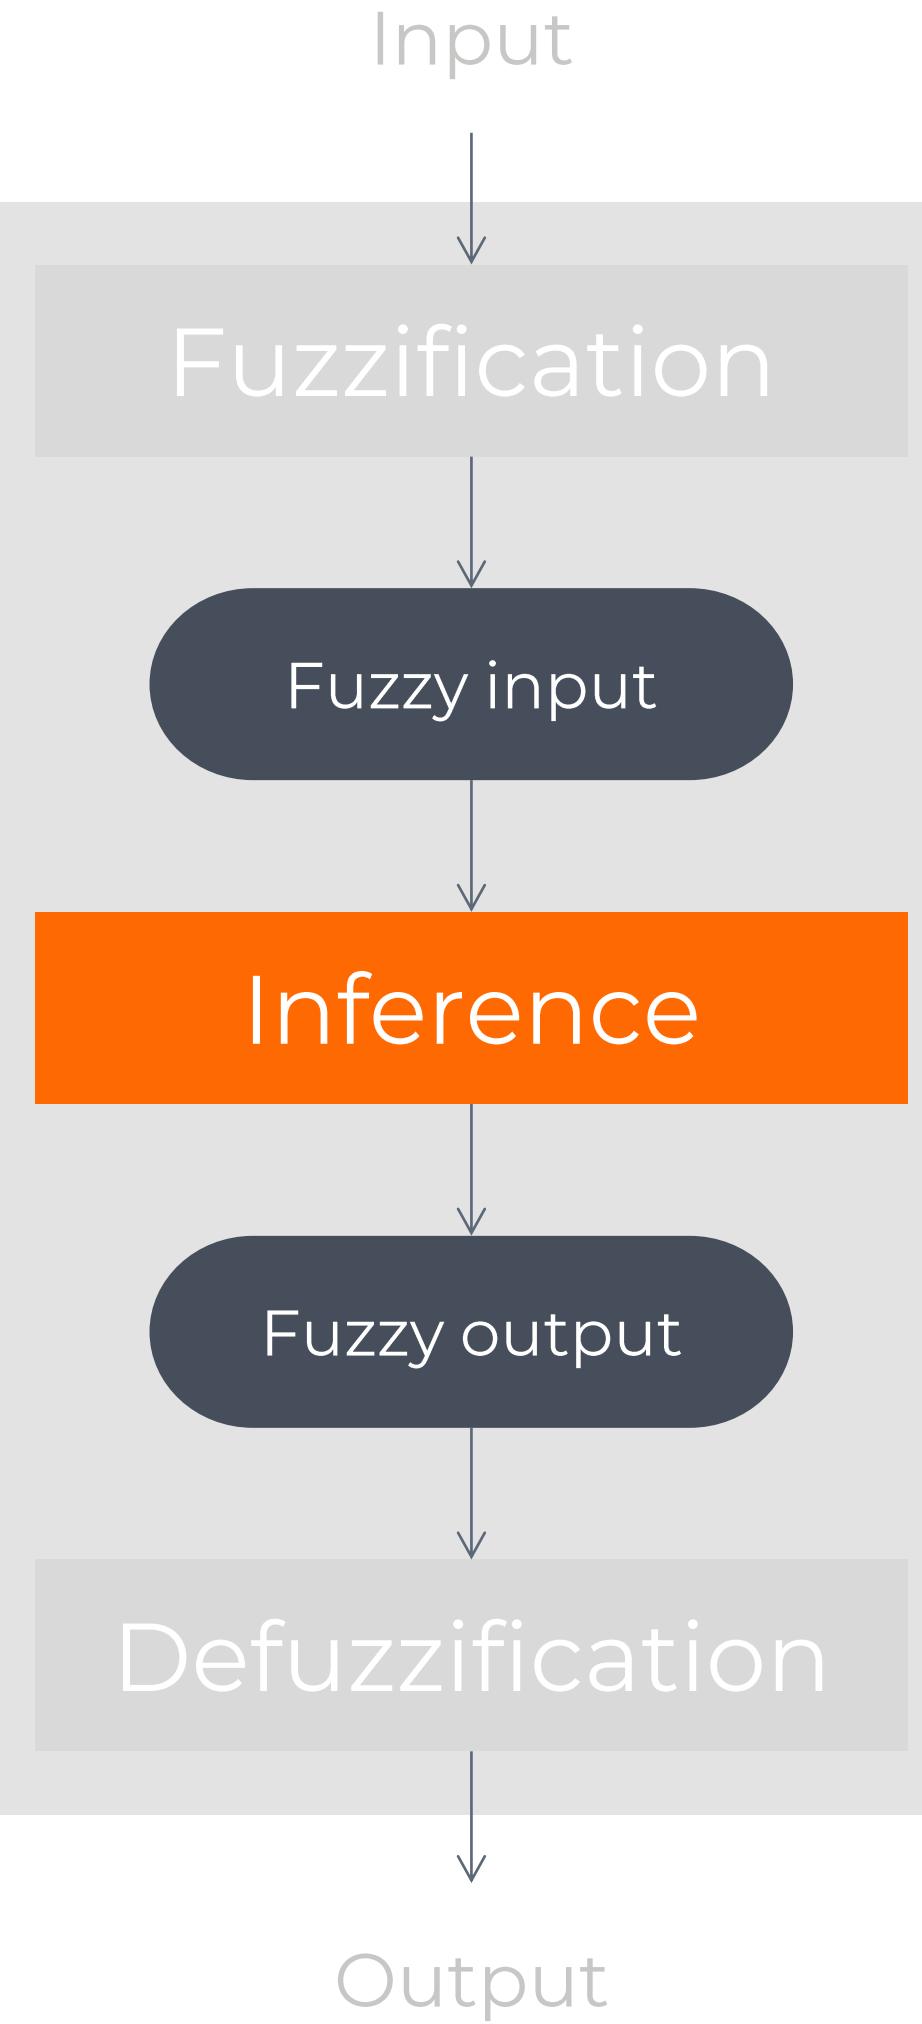


Cada función está relacionada, y posee su propio grafo computacional.

$$\text{Ejemplo: } \mu(x) = \min\left(\max\left(\frac{x-S_i}{\Delta_i}, 0\right), 1\right)$$



B, y cada Δ_i son las variables del grafo a ajustar.



Grafo de inferencia (I)

Entradas: $\mathbf{F} = \cup_{i=1}^n S_i$, donde:

S_i

Entrada borrosa de la variable i -ésima

n

El número de variables

- **Representación matricial de reglas** para cada salida borrosa.
- **Matriz de pesos asociada** a cada matriz de reglas.

Salida borrosa para cada variable k : $\mu_{ok} = \bigvee T_{ok} \circ W_{ok}$ siendo \vee la S -norma.

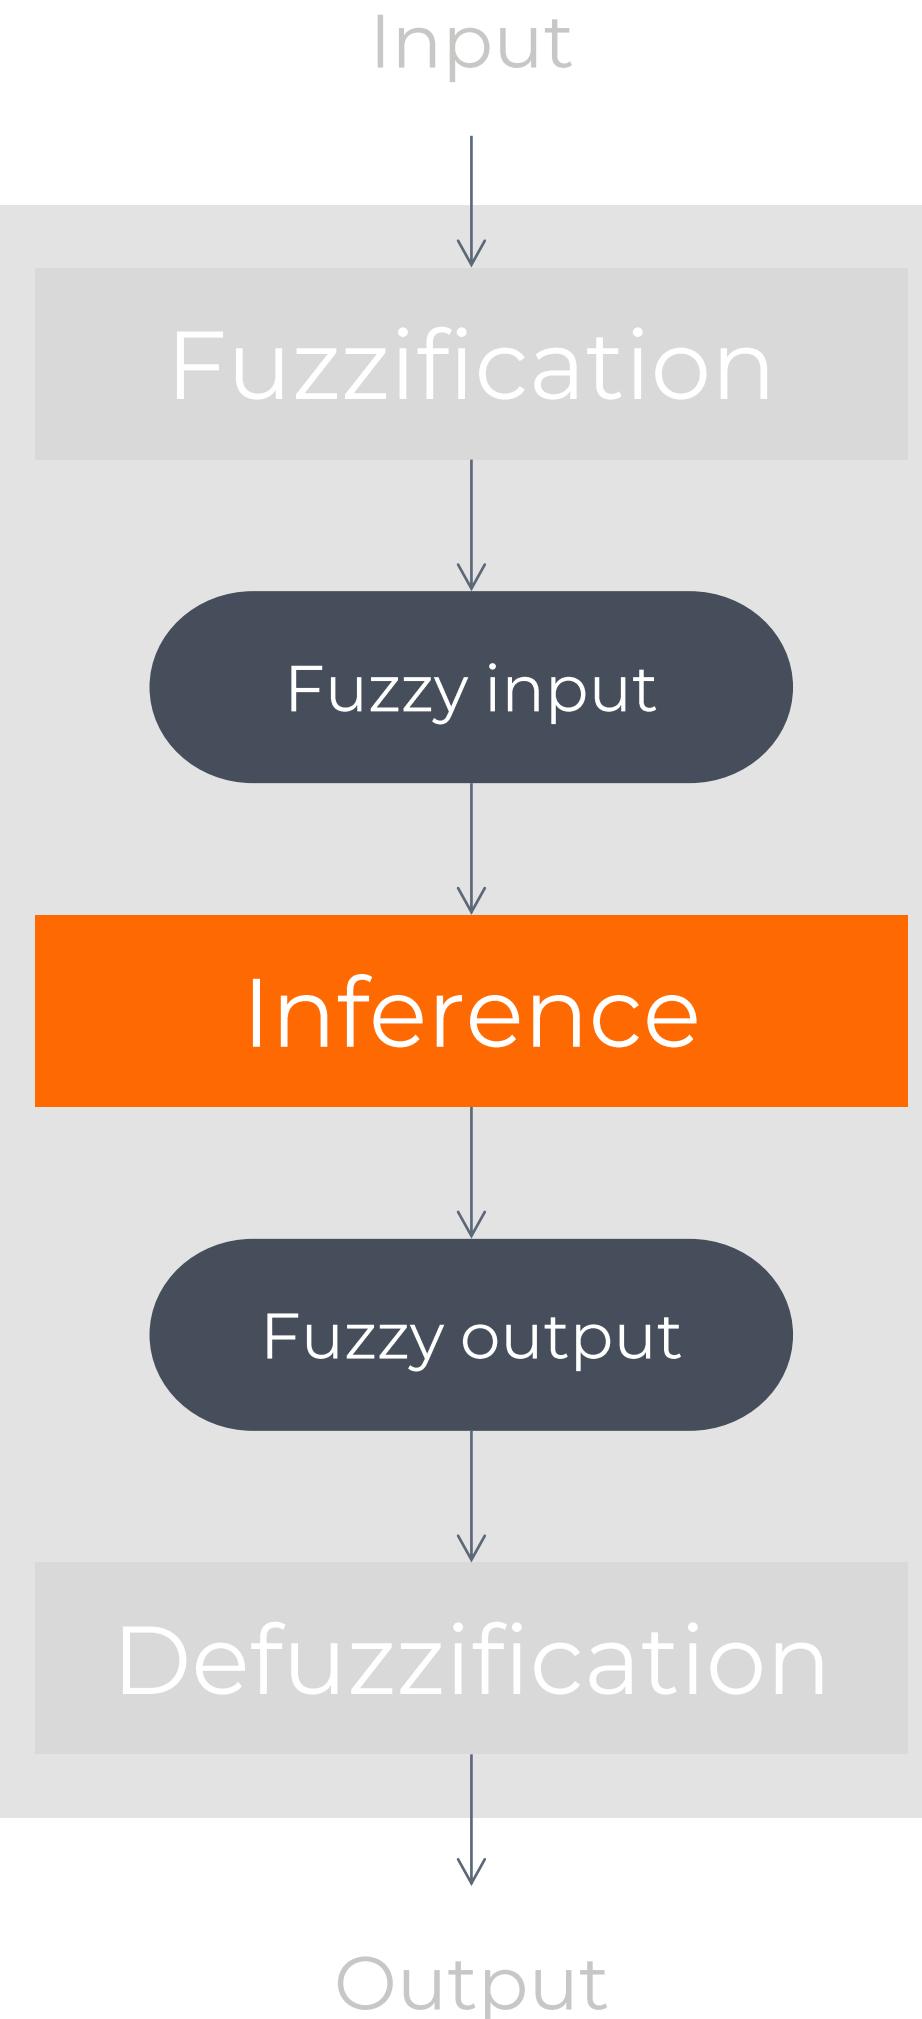
Ejemplo para dos variables de entrada con dos conjuntos borrosos cada una.

	μ_{11}	μ_{12}	μ_{13}
μ_{21}	T_1	T_2	T_3
μ_{22}	T_4	T_5	T_6

Reglas difusas (AND)

	w_{11}	w_{12}	w_{13}
w_{21}	1	1	0
w_{22}	0	1	0

Activación de reglas



Grafo de inferencia (II)

$$\mu_{ok} = \bigvee T_{ok} \circ W_{ok}$$

Esta representación sigue sin permitir el ajuste por descenso del gradiente.


Solución

Pesos reales en lugar de binarios

Aplicación de sigmoidal σ

$$\mu_{ok} = \bigvee T_{ok} \circ \sigma(W_{ok})$$

Cada $w \in W_{ok}$ es una variable del grafo a ajustar.



Grafo de defuzzificación

El grafo es una simple operación que no requiere de ajuste de variables.

Hemos optado por la función de la media ponderada:

$$\text{output} = \frac{\sum_{i=1}^K \mu_i x_i}{\sum_{i=1}^K \mu_i}$$

Donde:

K	x_i	μ_i
• El número de conjuntos borrosos de salida.	• El valor del conjunto borroso i -ésimo.	• La salida borrosa para el conjunto borroso i -ésimo de salida.

Comparación de modelos longitudinales

Se entrenan diferentes modelos de perceptrones multicapa y controladores borrosos para obtener el representante de cada una de estas dos clases. Los entrenamiento se realizan con los datos del conductor genérico S_A .


Controlador borroso (FCS)

- Dos conjuntos borrosos por variable de entrada.

Perceptrón multicapa (MLP)

- Dos capas ocultas de 8 y 2 neuronas.

	RMSE ($m s^{-2}$)	Training	Validation	Test
FCS	0,059	0,064	0,062	
MLP	0,061	0,061	0,056	



El comportamiento longitudinal se modeliza mejor con perceptrones multicapa.

Capacidad de especificidad del modelo

Se compara el desempeño de los modelos específicos S_1 , S_2 y S_3 contra los datos reales de éstos en los conjuntos de test, esto es, datos con los que nunca han sido entrenados ninguno de los modelos.

RMSE (ms^{-2})	S_1	S_2	S_3
S_1	0,059	0,074	0,070
S_2	0,064	0,058	0,067
S_3	0,065	0,065	0,057

El menor error en cada prueba lo produce el modelo del sujeto que la realizó.

Proceso a seguir



Retos

La naturaleza de las variables capturadas implica una serie de retos a superar antes de entrenar los modelos de comportamiento longitudinal.



Información de entorno de tamaño variable

Los perceptrones multicapa y las redes de convolución requieren un número fijo de entradas. El tamaño del entorno ofrecido por el LiDAR, sin embargo, fluctúa.



Tamaño de los conjuntos de datos

El número de variables de entrada es extremadamente grande, por lo que son necesarios conjuntos de datos también suficientemente grandes.



Datos de tipo no imagen

Las redes de convolución están diseñadas para funcionar con matrices n -dimensionales. Nuestros conjuntos incluyen además otros tipos de variables.



Percepción temporal

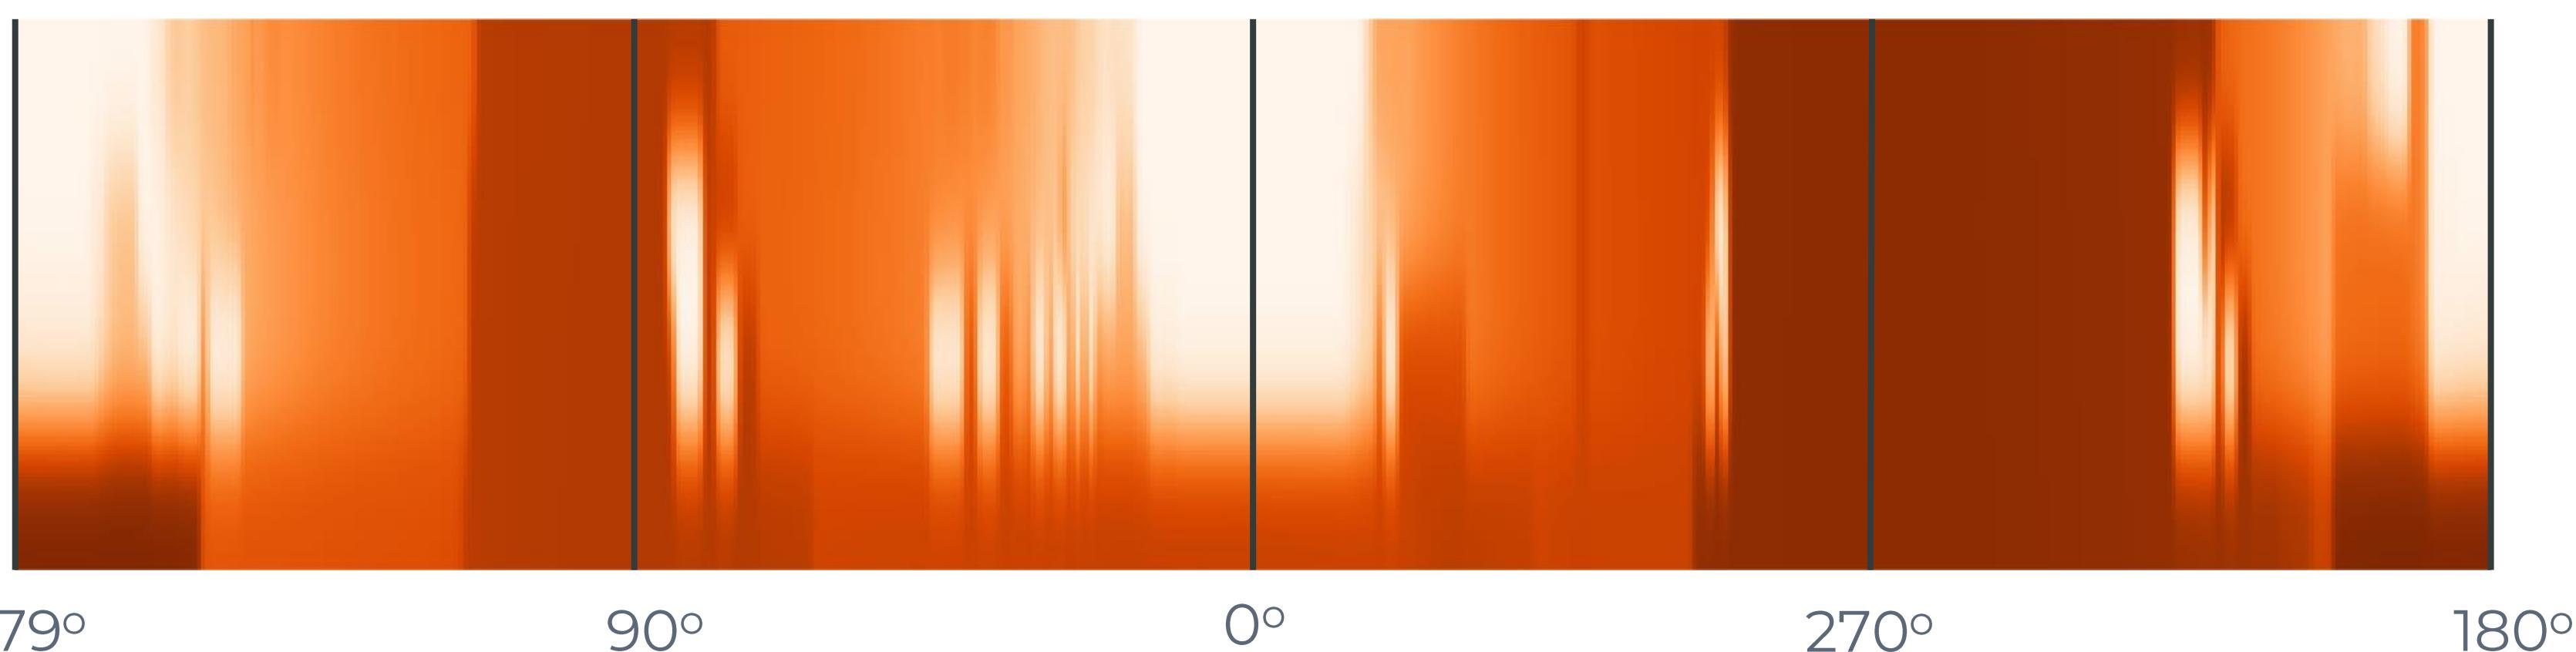
Los cambios de carril no se deciden de manera inmediata, sino que requieren un tiempo de decisión que es necesario modelar.

Información del entorno de tamaño variable (I)



Mapa de profundidad

Dimensión $d = 360 \times 6 = 2160$ entradas

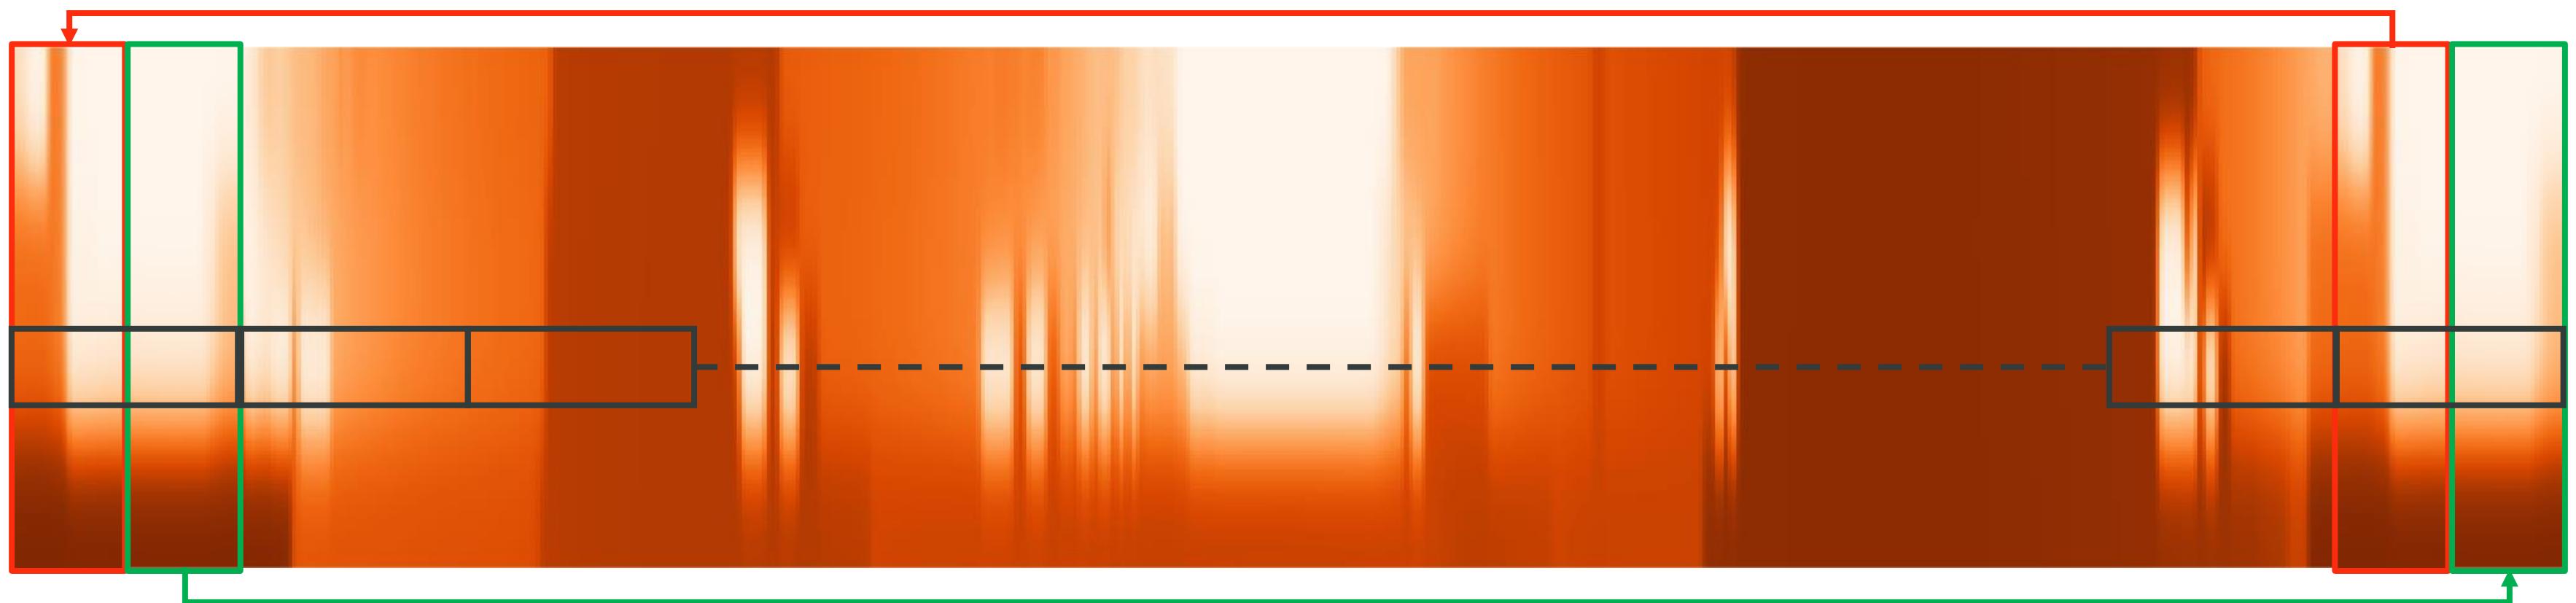


Información del entorno de tamaño variable (II)

La propia naturaleza de las convoluciones hace que en los extremos se pierda información.


Los extremos derecho e izquierdo de nuestra imagen son la parte trasera del vehículo.

Solución: añadir un *padding* con los extremos opuestos de la imagen.




De esta manera las convoluciones actúan sobre todos los posibles patrones horizontales.

Datos de tipo no imagen




El componente de detección de patrones sólo se aplica a la imagen de entrada.



El componente de inferencia se aplica a los patrones detectados de la imagen y a las entradas tipo no imagen.



Nube de puntos original



Mirroring

Shaking ($\Delta = 3\text{cm}$)Shaking ($\Delta = 20\text{cm}$)

Tamaño de los conjuntos de datos

En [Díaz Álvarez et al., 2018] se probó empíricamente que el uso de las técnicas *mirroring* y *shaking* mejoraban la precisión y generalización de los modelos entrenados.

Mirroring

Asumimos que en entorno urbano, las situaciones se pueden considerar simétricas.


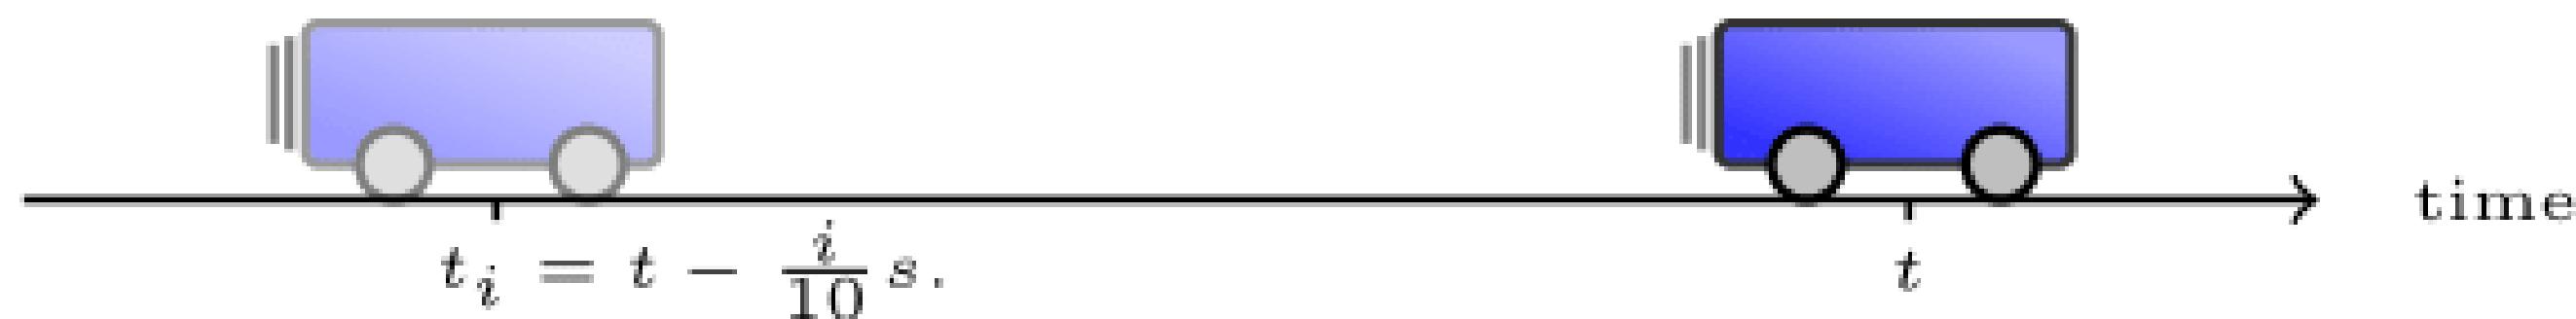
Shaking

A cada uno de los puntos de la nube original se le aplica un desplazamiento aleatorio en un pequeño rango.

La imagen resultante es ligeramente diferente, pero representa un escenario muy similar.

Percepción temporal

En este trabajo asumimos que la maniobra de cambio de carril involucra tanto al córtex visual como al córtex prefrontal, los cuales se estima que tienen un tiempo de proceso de entre 0.2 s y 1.2 s [Buzsáki et al., 2012].



Ventana temporal

Las entradas se duplican tantas veces como momentos anteriores queremos percibir.



t_0, t_{10} y t_{20}

En [Díaz Álvarez et al., 2018] t_0, t_{10} y t_{20} son los momentos que mejores resultado arrojan.



Representación

En las redes de convolución, se presentan como imágenes apiladas a lo largo de una dimensión.

Comparación de modelos laterales

Se entrenan diferentes modelos de perceptrones multicapa redes de convolución para obtener el representante de cada una de estas dos clases. Los entrenamiento se realizan con los datos del conductor genérico S_A .


Perceptrón multicapa (MLP)

- Ninguna arquitectura superó el 33% de acierto.

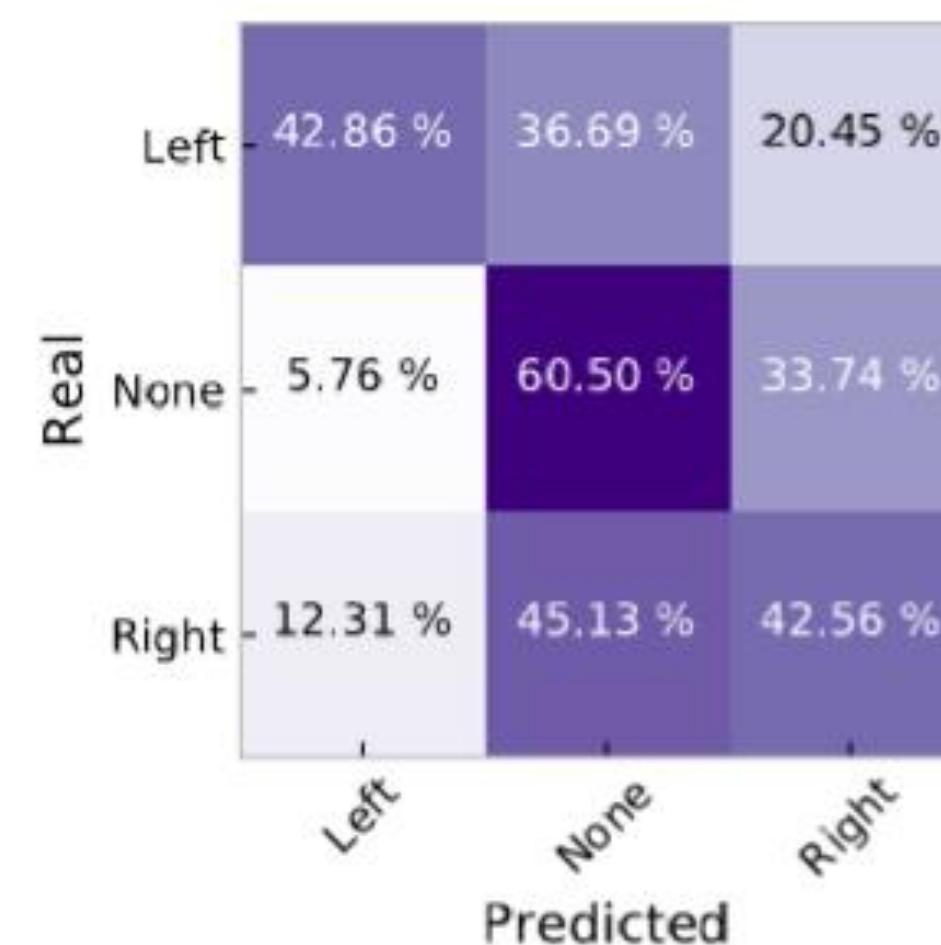
Red de convolución

- Convolución (5 × 36), convolución (3 × 5) y dos capas de 128 y 16 neuronas.

Accuracy	Training	Validation	Test
MLP	0,333	0,333	0,333
CNN	0,506	0,531	0,518



Instantáneo



Después de 2,5 s.

El comportamiento lateral se modeliza mejor con redes de convolución.

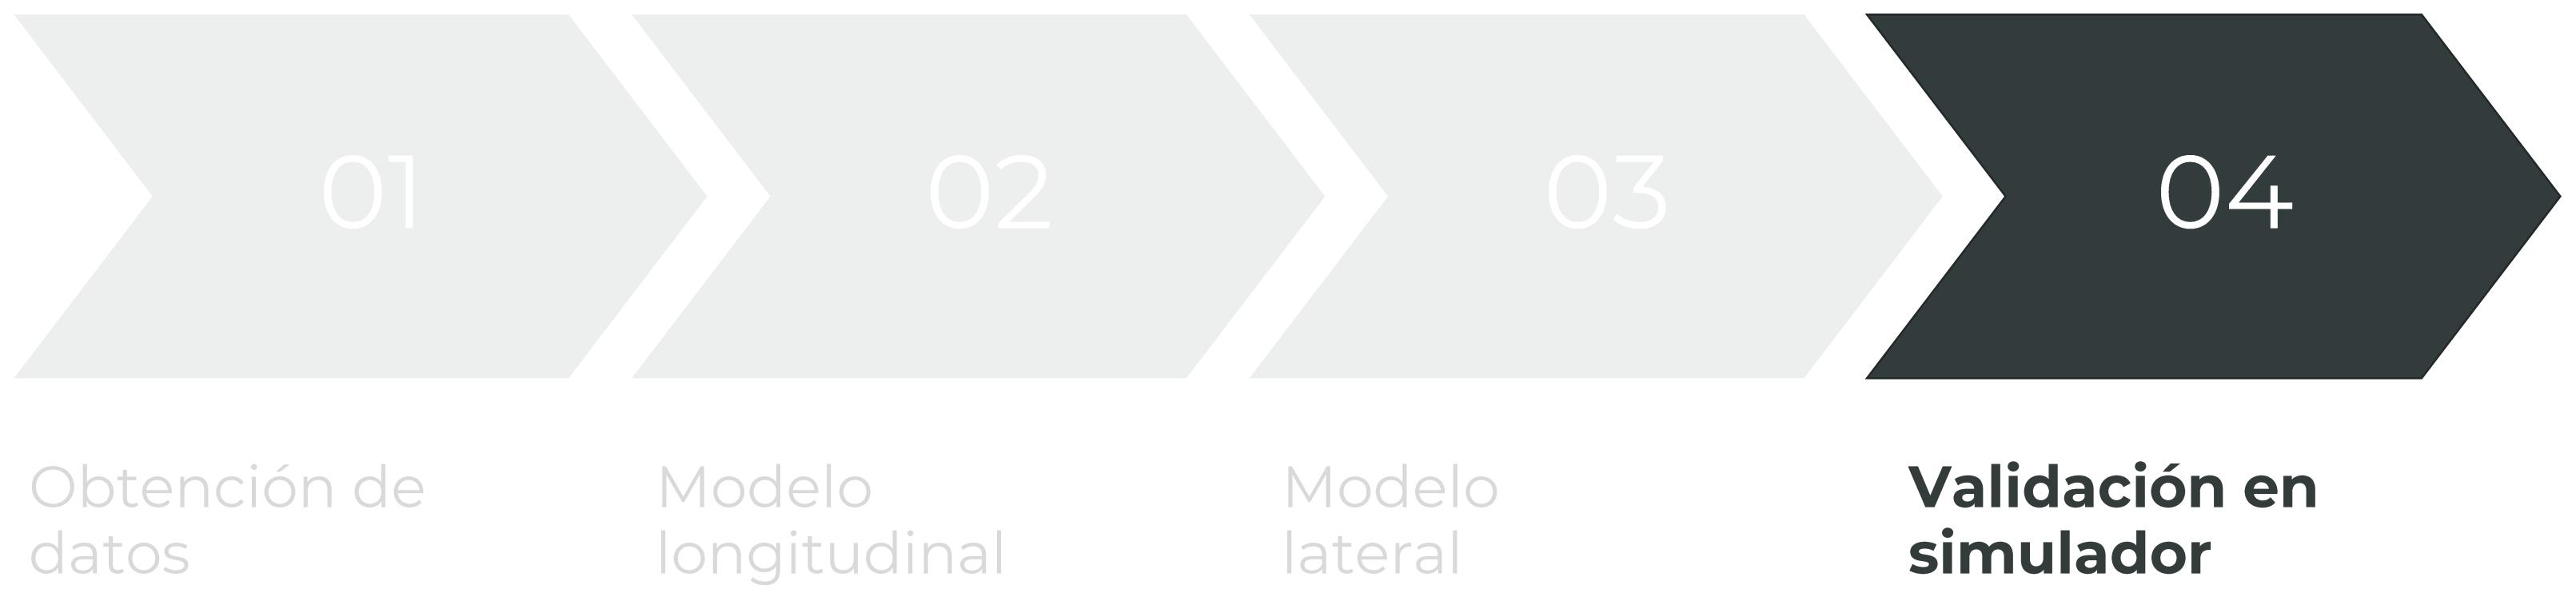
Capacidad de especificidad del modelo

Se compara la precisión de los modelos específicos S_1 , S_2 y S_3 contra los datos reales de éstos en los conjuntos de test, esto es, datos con los que nunca han sido entrenados ninguno de los modelos.

Precisión	S_1	S_2	S_3
S_1	0,768	0,314	0,601
S_2	0,601	0,706	0,511
S_3	0,648	0,666	0,710

La mayor precisión en cada prueba la produce el modelo del sujeto que la realizó.

Proceso a seguir



Comparativa

Se han comparado los valores de los cuatro conjuntos de conductores S_A , S_1 , S_2 y S_3 con los valores de sus respectivos conductores simulados, y con el modelo por defecto de SUMO. Los resultados mostrados se limitan a los del modelo general S_A por ser resultados similares a los de los conjuntos.



El recorrido simulado es similar al recorrido real de test

El recorrido se ha extraído de OpenStreet Maps (OSM) y ha sido modificado para corregir los problemas, eliminar las características sobrantes y añadir aquellas que faltan.




Tres recorridos por modelo

Se han utilizado los datos de tres recorridos para cada modelo de conductor simulador en escenarios con diferentes semillas aleatorias.


Validación del modelo longitudinal (I)

Los comportamientos longitudinales se comparan a partir de indicadores de velocidad, aceleración y sobre-aceleración. Las gráficas muestran los valores para los datos extraídos de los sujetos reales, de los modelos de conductor asociados a dichos sujetos y de los modelos de conductor proporcionados por SUMO.



Las velocidades entre modelo real y simulado difieren del modelo de SUMO.



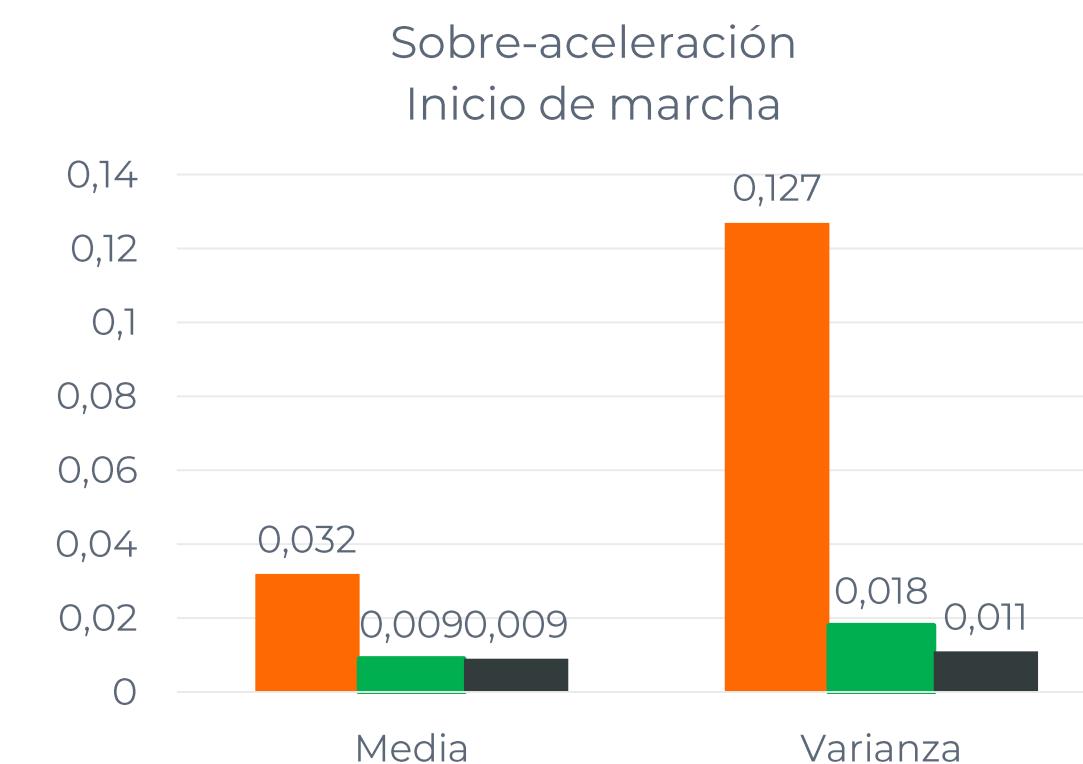
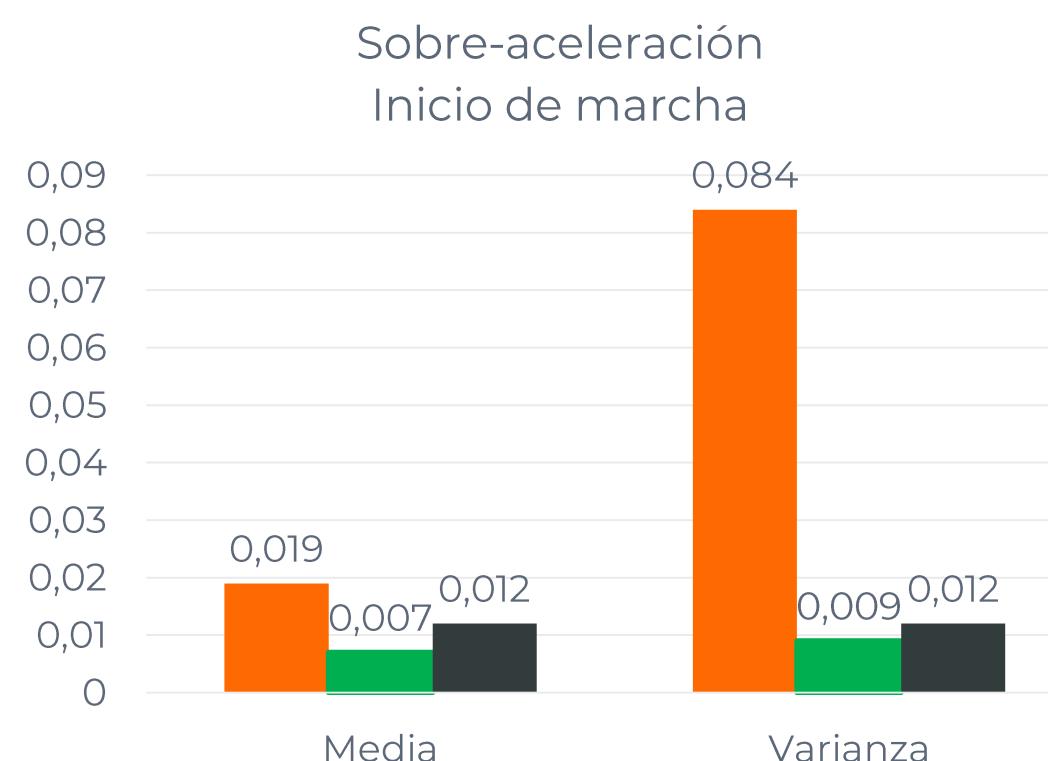
Validación del modelo longitudinal (II)



Las aceleraciones son mucho mayores en SUMO.

La varianza de la aceleración positiva es significativamente mayor en el modelo real.

Validación del modelo longitudinal (III)



■ Conductor real

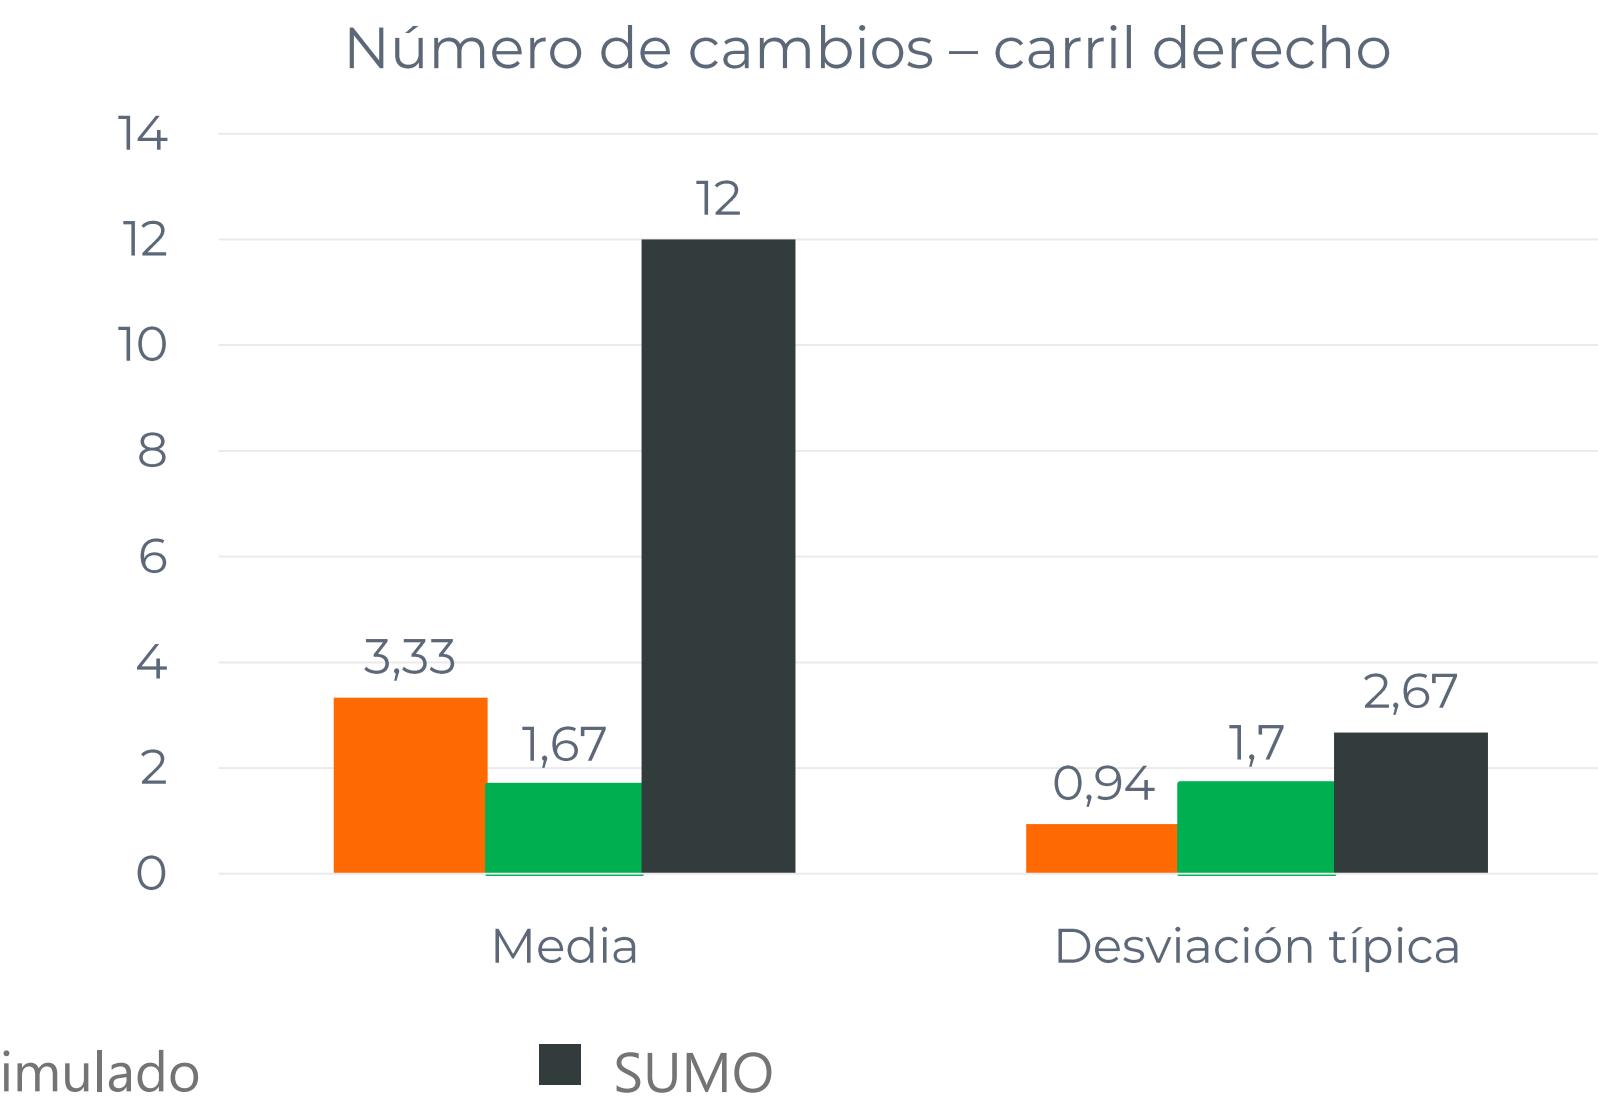
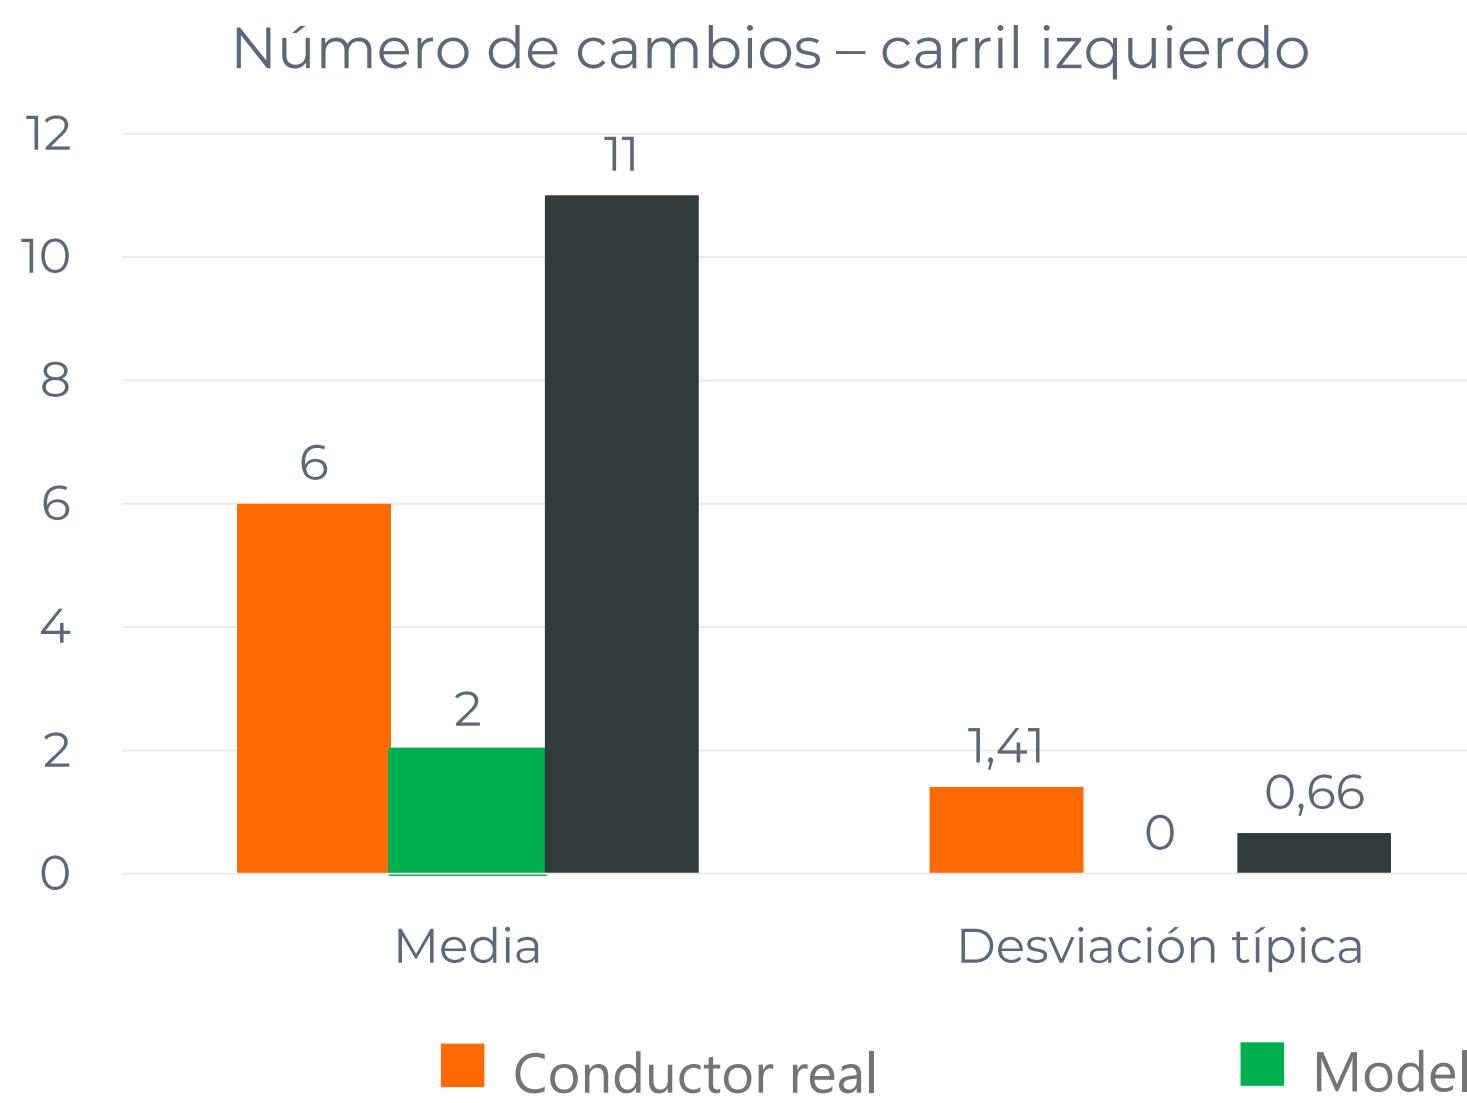
■ Modelo simulado

■ SUMO

Las sobre-aceleraciones son mayores en el caso de los datos de conducción reales.

Validación del modelo lateral

El comportamiento lateral se compara atendiendo a los valores medios de número de cambios de carril entre todos los modelos.



Significativamente más cambios de carril en el modelo de SUMO.

Ligeramente menos cambios de carril en modelo entrenado.

Conclusions

Objectives

-  Driving models have been developed from actual driver data, mimicking their behaviours.
-  Those behaviours have been embedded into agents in operation within simulators.
-  The behaviour models have been adapted to specific drivers, differentiating themselves from the models of other drivers.
-  Simulation models replicate human behavior better than deterministic models already implemented.

Main contributions to the literature

Methodology for generating driver's behaviour models from actual real data

Behavioural models capable of being customized at the subject level

Representation of fuzzy control systems as computational graphs

Adjustment of fuzzy controllers through gradient descent methods

Future lines of research

More realistic traffic simulators

Adaptation of driving simulators to the traffic problem in order to incorporate the models described and thus avoid the limitations of the environment.

Other vehicle characteristics

Modelling characteristics profiles such as fuel consumption, gas emission or noise emission from the exact data of the vehicle under study.

Different scenarios and actors

Work on different vehicle typologies, such as large vehicles, specific scenarios such as roundabouts, or directly on autonomous vehicles.

Recurrent Neural Networks

The use of recurring networks can further assist in the customization of each subject's time window.

Publicaciones

Revistas

2018 (Q2)

Talavera, E., Díaz-Álvarez, A., Jiménez, F., & Naranjo, J. E. *Impact on Congestion and Fuel Consumption of a Cooperative Adaptive Cruise Control System with Lane-Level Position Estimation*. Energies, 11(1), 194, 2018.

2018 (Q2)

Díaz-Álvarez, A., Clavijo, M., Jiménez, F. Talavera, E., & Serradilla, F. *Modelling the human lane-change execution behaviour through Multilayer Perceptrons and Convolutional Neural Networks*. Transportation Research Part F: Psychology and Behaviour, 2018.

2018 (Q2)

Olaverri-Monreal, C., Errea-Moreno, J., & Díaz-Álvarez, A. *Implementation and Evaluation of a Traffic Light Assistance System Based on V2I Communication in a Simulation Framework*. Journal of Advanced Transportation, 2018

2016 (Q1)

Jiménez, F., Naranjo, J. E., Serradilla, F., Pérez, E., Hernández, M. J., Ruiz, T., ... & Díaz-Álvarez, A.

Intravehicular, short-and long-range communication information fusion for providing safe speed warnings. Sensors, 16(1), 131, 2016.

2015 (Q4)

Díaz-Álvarez, A., Serradilla-García, F., Anaya-Catalán, J. J., Jiménez-Alonso, F., & Naranjo-Hernández, J. E.
Estimación de la autonomía de un vehículo eléctrico según el estilo de conducción. DYNA-Ingeniería e Industria, 90(3), 2015.

2014 (Q3)

Díaz-Álvarez, A., Garcia, F. S., Naranjo, J. E., Anaya, J. J., & Jimenez, F. (2014). *Modeling the driving behavior of electric vehicles using smartphones and neural networks.* IEEE Intelligent Transportation Systems Magazine, 6(3), 44-53, 2014

Congresos

2017

Clavijo, M., Serradilla, F., Naranjo, J.E., Jiménez F., & Díaz-Álvarez, A. *Application of Deep Learning to Route Odometry Estimation from LiDAR Data*. Advances in Vehicular Systems, Technologies and Applications, 2017 The Sixth International Conference on (pp. 60-65).

2018

Clavijo, M., Díaz-Álvarez, A., Serradilla, F., Jiménez F., Naranjo, J.E. *Deep learning application for 3D LiDAR odometry estimation in autonomous vehicles*. Connected and Automated Transport, 2018 Transport Research Arena (TRA).

2015

Jiménez, F., Amarillo, J. C., Naranjo, J. E., Serradilla, F., & Díaz-Álvarez, A. *Energy consumption estimation in electric vehicles considering driving style*. In Intelligent Transportation Systems (ITSC), 2015 IEEE 18th International Conference on (pp. 101-106). IEEE.

ESCUELA TÉCNICA SUPERIOR DE INGENIEROS INFORMÁTICOS

Modelado de Comportamiento de Conductores con Técnicas de Inteligencia Computacional

DEFENSA PARA LA OBTENCIÓN DEL TÍTULO DE

DOCTORADO EN INTELIGENCIA ARTIFICIAL

AUTOR

ALBERTO DÍAZ ÁLVAREZ

DIRECTORES

FRANCISCO SERRADILLA GARCÍA

FELIPE JIMÉNEZ ALONSO