

Escuela Técnica Superior de Ingenieros Informáticos

# **Modelado de Comportamiento de Conductores con Técnicas de Inteligencia Computacional**

*Para la obtención del título de*

Doctorado en Inteligencia Artificial

*Autor*

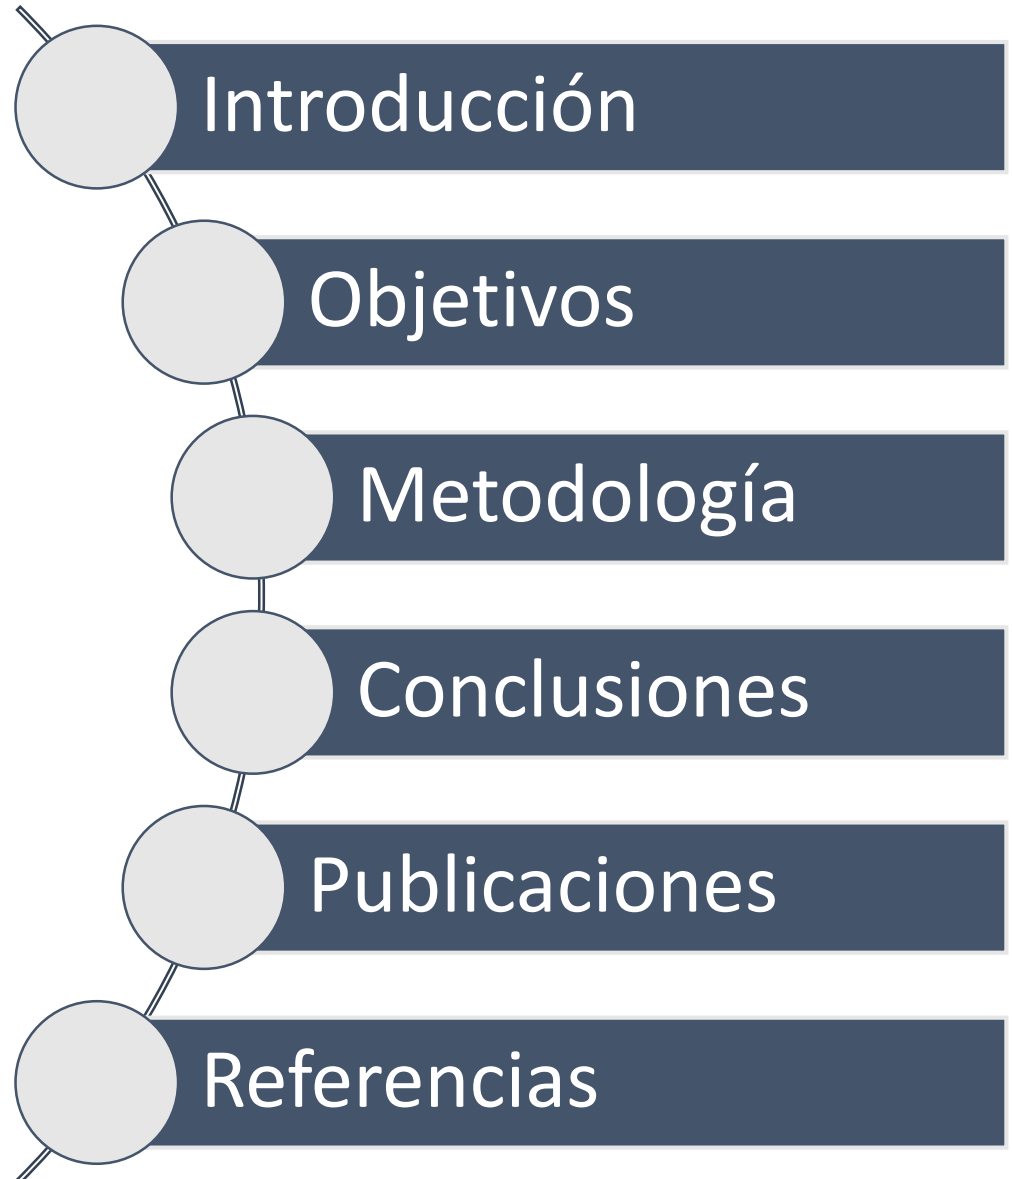
Alberto Díaz Álvarez

*Directores*

Francisco Serradilla García

Felipe Jiménez Alonso

# Índice



# INTRODUCCIÓN

# Modelos de comportamiento de conductor

¿Cómo se comporta el vehículo en un entorno de tráfico?

Se puede considerar a **tres niveles** de abstracción [Michon, 1985]




*La diferenciación entre niveles no es exacta, depende del conductor y del entorno*

Los **modelos de comportamiento** trabajan, sobre todo, en el nivel **táctico**

# Modelos de conductor y simulación (I)

**Tráfico:** Sistema que **emerge** de la **interacción** de **actores** en algún tipo de camino o vía



Se puede considerar  
como un Sistema  
Complejo.




No se puede  
estudiar únicamente  
a partir de sus  
componentes




Su estudio desde  
dentro es, en rasgos  
generales, inviable

# Modelos de conductor y simulación (II)

**Simulación:** Representación de un **sistema real** a partir de la **abstracción** de las **reglas** que definen su funcionamiento




Micro-simulación



Macro-simulación

La **micro-simulación** requiere **modelos de comportamiento de conductor**

# Modelos longitudinales



Son los primeros modelos propuestos en la bibliografía




Se estudian múltiples regímenes distintos



Modelos lineales, con **poca o nula representación de comportamiento real**

# Modelos laterales (I)

**¿Cómo y cuándo  
cambia de carril el  
vehículo?**



Diferenciación entre selection y merging

Gap-acceptance para determinar si se cambia o no de carril

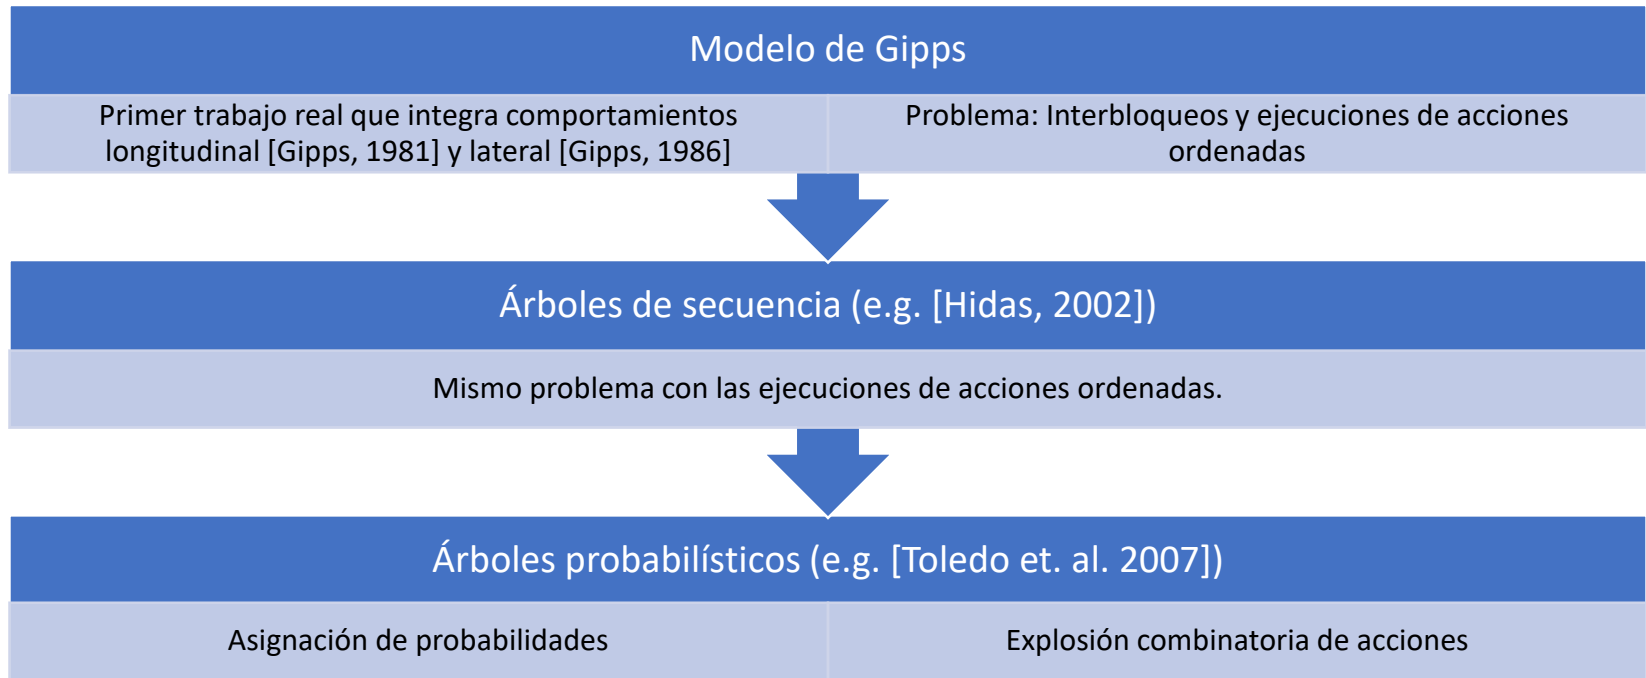
Tipología del cambio: obligatorio (MLC), opcional (DLC), ...

***¿Cuándo cambiar de carril?***

Se empiezan a vislumbrar los problemas de la falta de datos



# Modelos laterales (II)



**Los modelos clásicos no replican comportamientos humanos**

# Modelos basados en IC

## Redes neuronales

Simuladores top-view

Simuladores primera persona

Vehículos instrumentados

- Primeros trabajos con datos reales desde simulador [Fix & Armstrong, 1990]

- Aumentar el realismo para obtener comportamientos más fieles a la realidad [Muñoz et al., 2010, Van Hoorn et al., 2009]

- Toma de datos reales para el control longitudinal y lateral [Jia et al., 2003, Simonelli et al. 2009]

## Lógica borrosa

Comportamiento longitudinal

Comportamiento lateral

Comportamientos complejos

- Simulación de controladores difusos no basados en datos reales [Kikuchi & Chakroborty, 1992]

- Complemento a controladores longitudinales. No se basan en datos reales [McDonald et al., 1997, Wu et al., 2003]

- Vehículos instrumentados para situaciones complejas (e.g. adelantamientos) [Naranjo et al., 2006]

*También se usan computación evolutiva, cadenas de Markov, árboles de decisión, redes bayesianas, ...*

**Los modelos no generalizan correctamente comportamientos humanos**

# Conclusiones del estado actual

## Modelos clásicos

- Muy eficientes
- Poca o nula capacidad de emular comportamiento humano
- Comportamientos complejos implican mucha modelización

## Modelos basados en IC

- Abstraen comportamientos complejos
- No utilizan valores del entorno que les rodea
- Es complicado explicar el por qué de su funcionamiento (redes neuronales)

En definitiva

**No disponemos de modelos que emulen comportamientos humanos basados en el entorno eficientes en simuladores**

# OBJETIVOS

# Objetivos

## Hipótesis

H1

- La aplicación de IC para la generación de modelos de conductor permite la incorporación de características humanas no reproducibles por los modelos existentes en la actualidad.

H2

- La aplicación de IC para la generación de modelos de conductor permite la reproducción de comportamiento de conductores concretos.

## Objetivos específicos

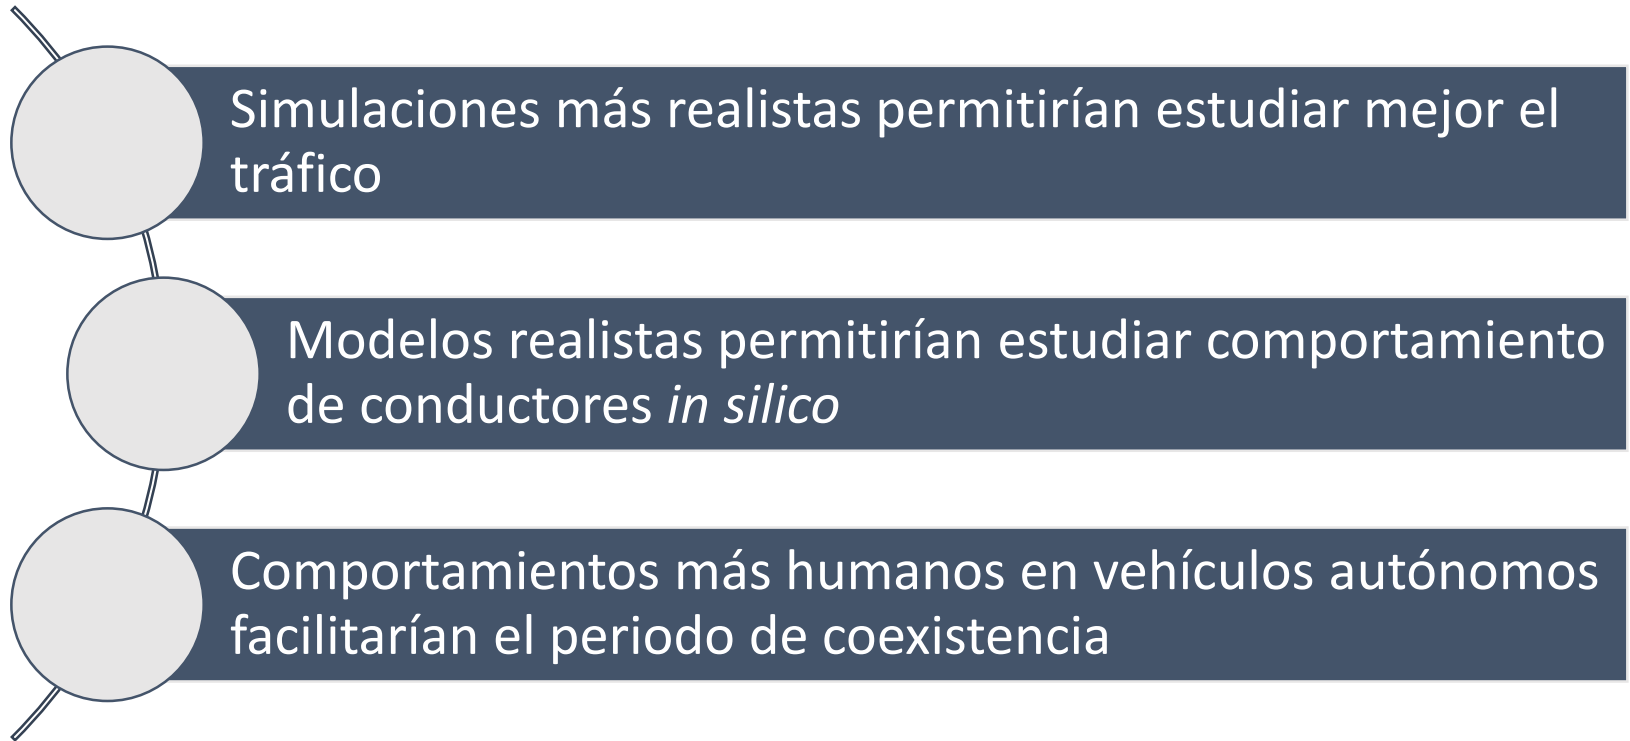
Estudio naturalista

Modelo longitudinal  
MLP vs. FCS

Modelo lateral  
MLP vs. CNN

# Justificación

**El transporte por carretera es el principal medio de transporte**



# METODOLOGÍA

# Selección de simulador

**SUMO como entorno de simulación para los modelos**




Open Source Software

Arquitectura cliente/servidor

API pública

Edición de mapas y escenarios



Entorno del vehículo muy limitado

Cambios de carril “ninja”

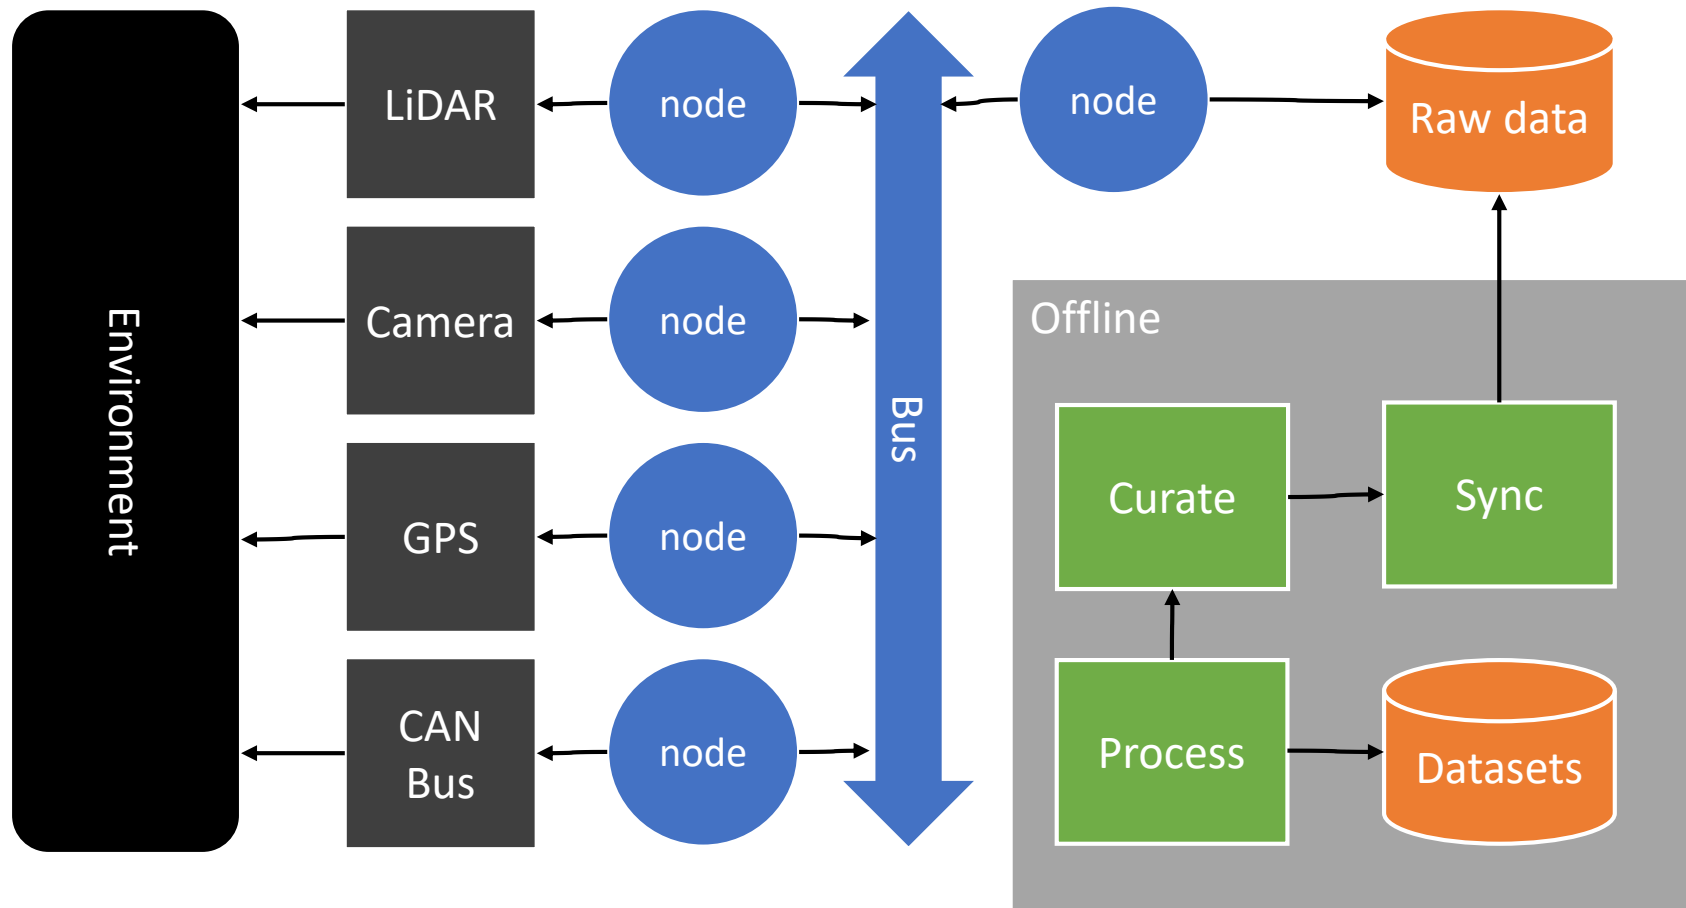
Teleportaciones eventuales



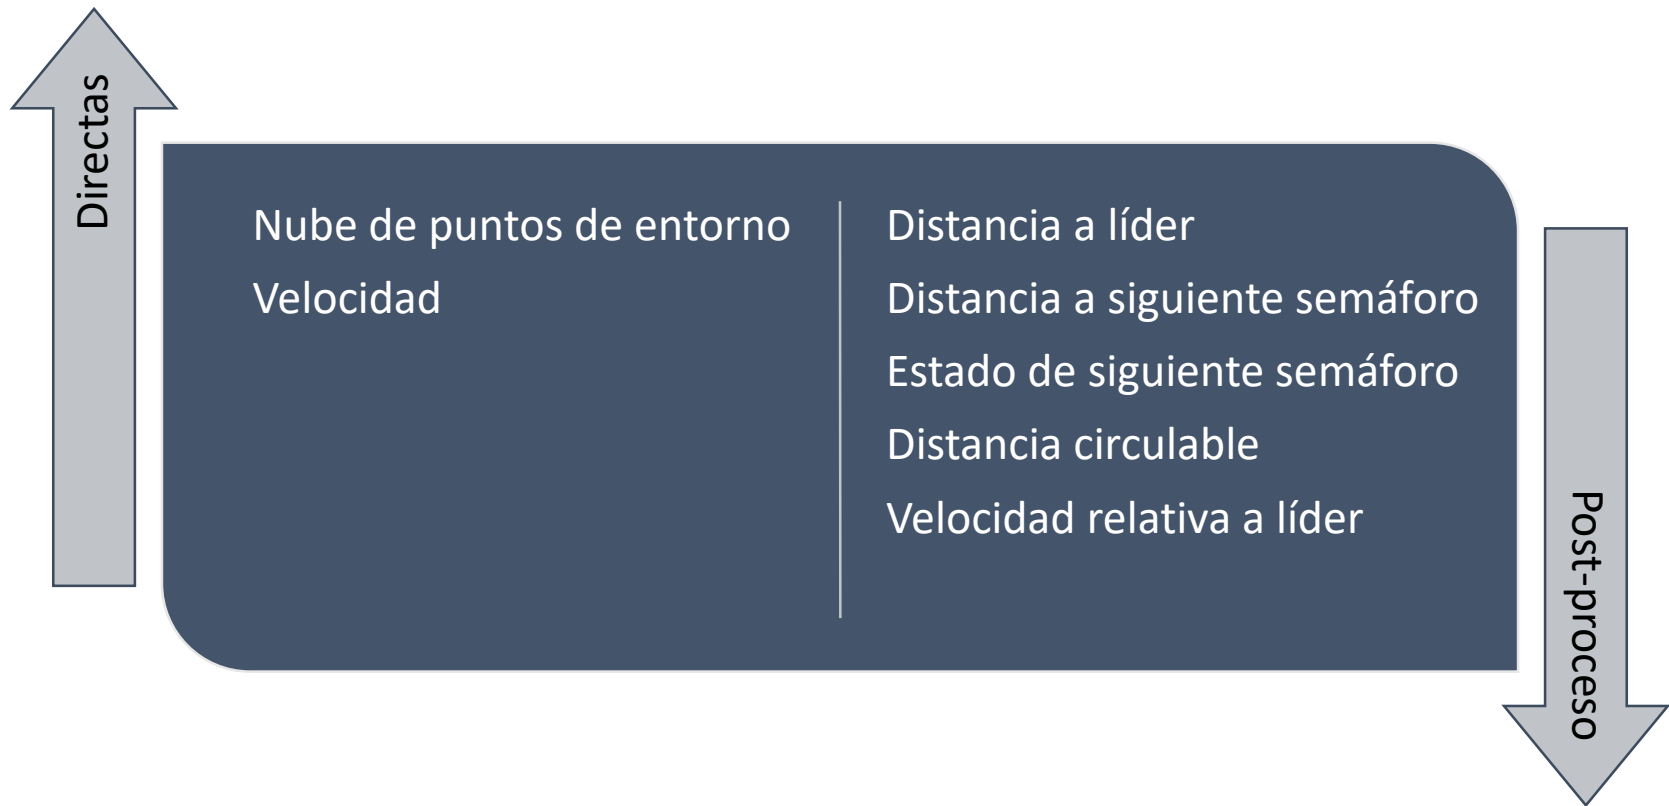
# Instrumentación del vehículo



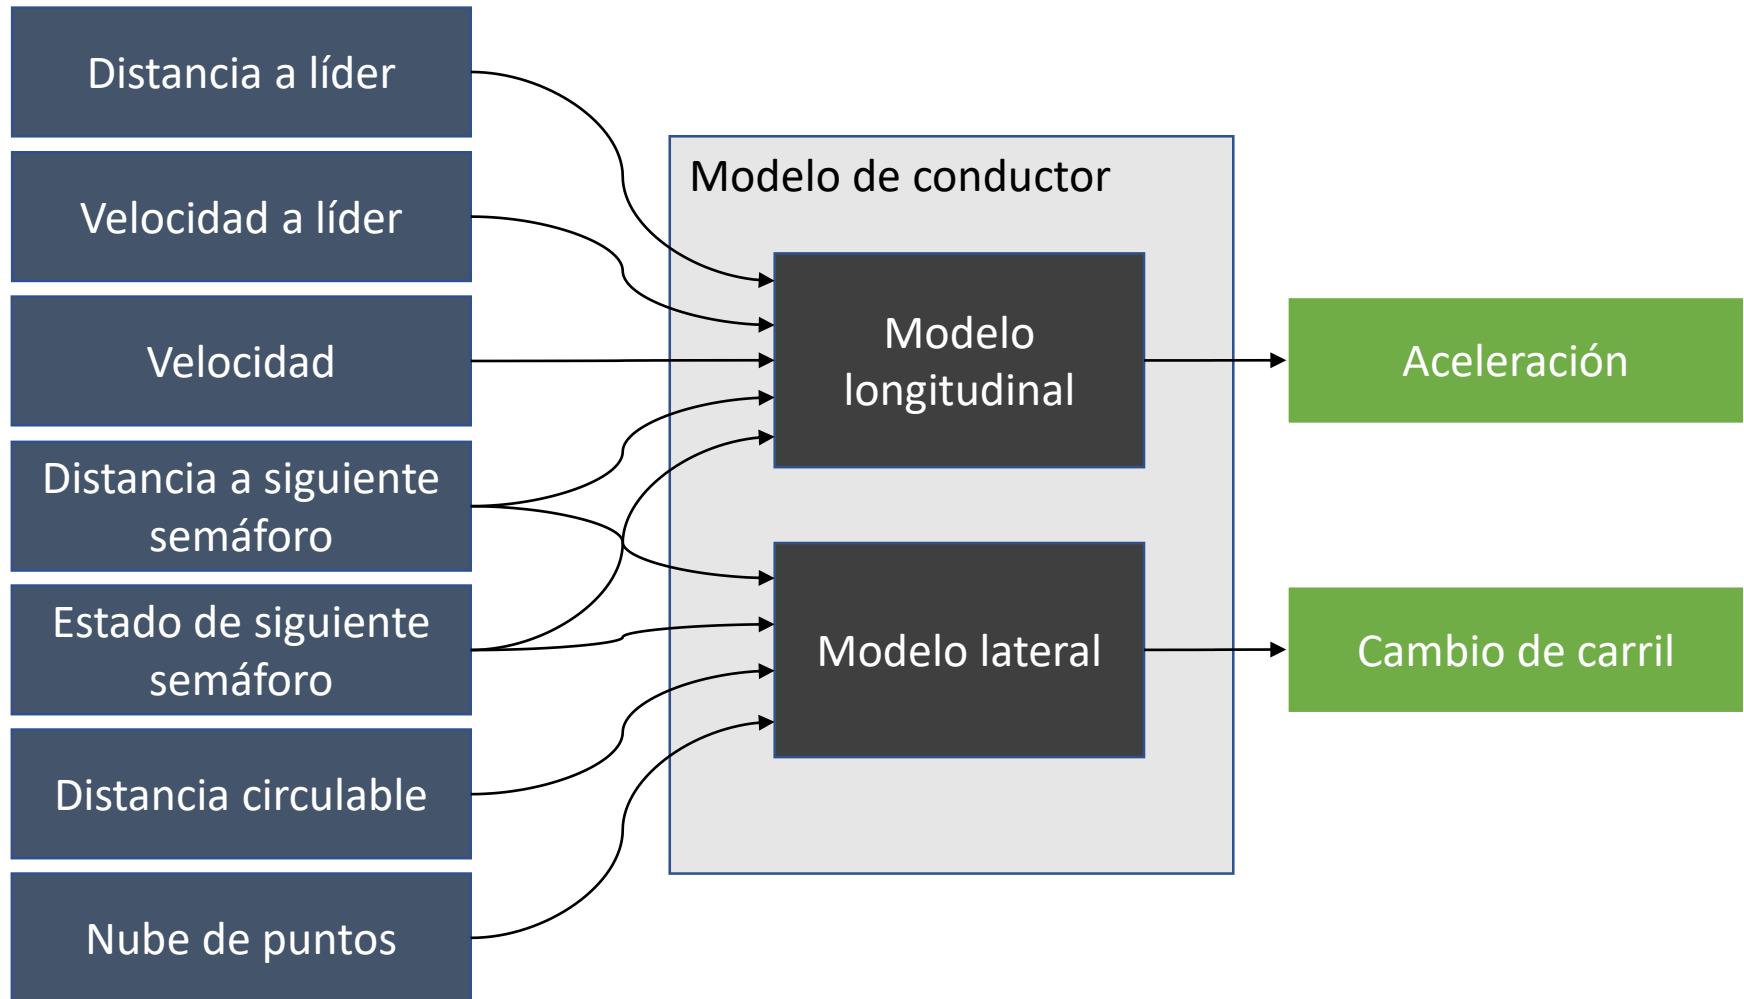
# Arquitectura del sistema de captura



# Variables capturadas



# Modelo de conductor propuesto



A thin vertical black line is positioned to the left of the text.

# Modelo longitudinal

# Modelo longitudinal

**Controlador borroso (FCS) y perceptron multicapa (MLP) como propuesta**

*Pero... ¿cómo ajustar FCS a los valores de un conductor en concreto?*

**Propuesta: Ajuste de FCS por descenso del gradiente**

## Método

Representación de FCS como grafo computacional

Aplicación de descenso de gradiente a las variables del grafo

## Limitaciones

Líneas  
ascendentes,  
descendentes y  
trapezoides

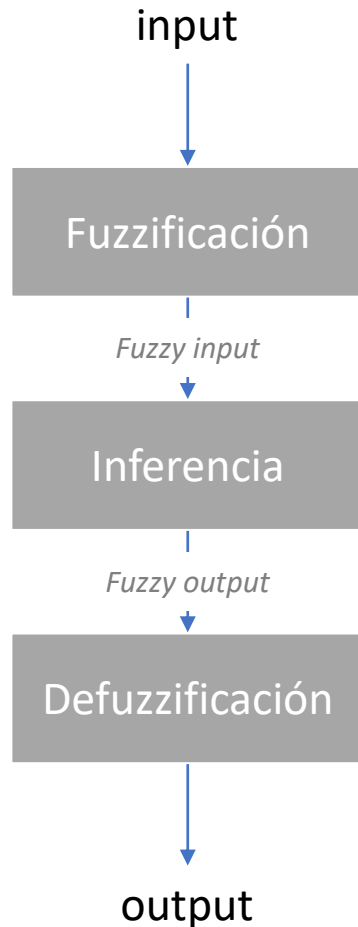
T-norm mínimo y  
s-norm máximo

Takagi-Sugeno  
de orden 0

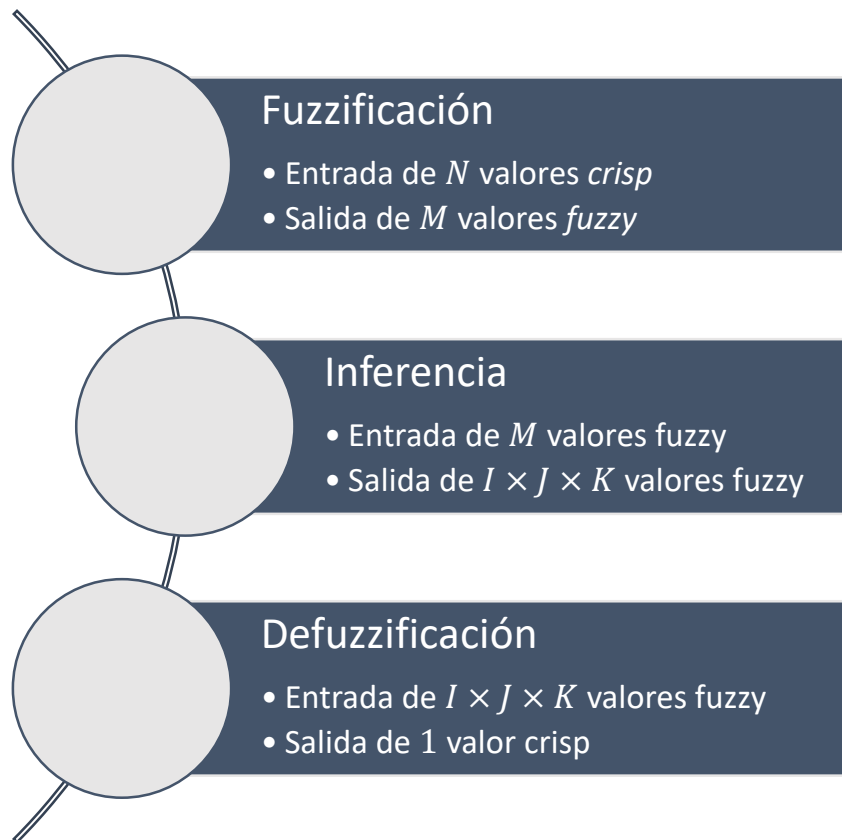
Número de  
particiones fijo

Variables de  
salida: 1

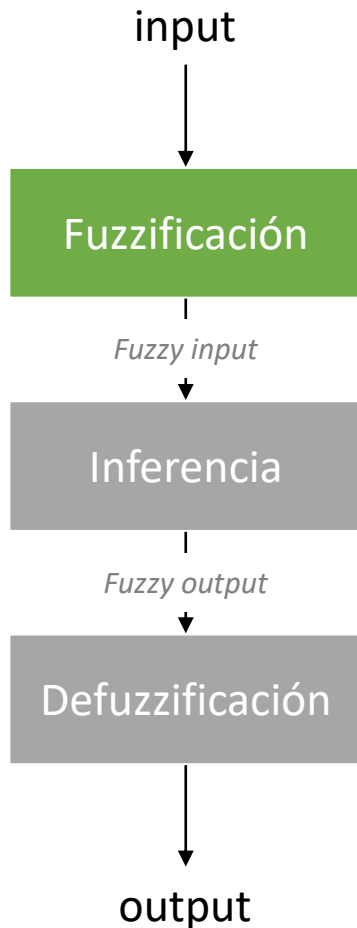
# FCS como grafo computacional



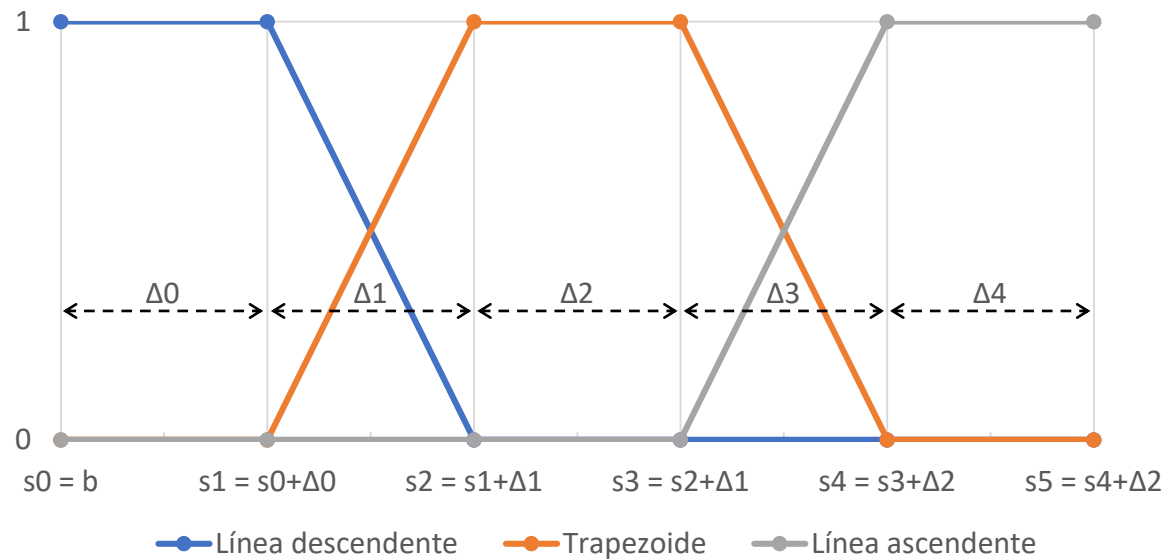
## Representación como tres subgrafos



# Grafo de fuzzificación (I)



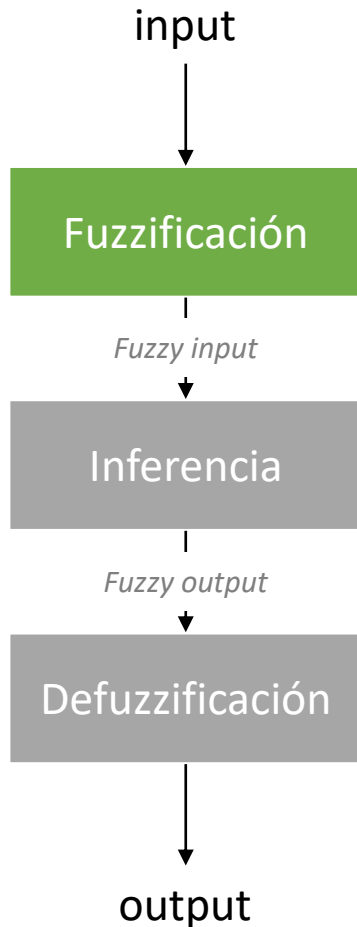
Ejemplo de partición



**Cada  $\Delta_i$  es una de las variables del grafo a ajustar**




# Grafo de fuzzificación (II)



Ejemplo de función de pertenencia

Línea ascendente:

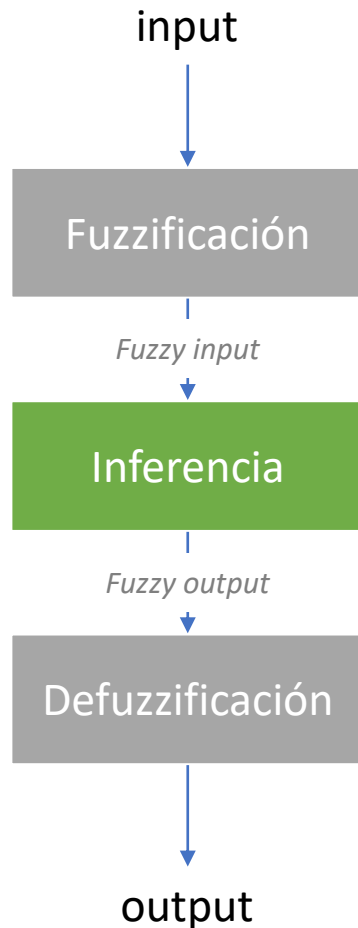
$$\mu(x) = \min\left(\max\left(\frac{x-a}{db}, 0\right), 1\right)$$



*Los desplazamientos  $\Delta i$  de la partición son las variables en las funciones de pertenencia*

**Todas las funciones de una partición dependen entre sí**

# Grafo de inferencia (I)



Entradas:  $F = \bigcup_{i=1}^n S_i$   
Donde:

$S_i$

- La entrada borrosa correspondiente a la variable  $i$ -ésima

$n$

- El número de variables

Representaremos las reglas como matriz  $n$ -dimensional

$\mu_{ok}$	$\mu_{11}$	$\mu_{12}$	$\mu_{13}$
$\mu_{21}$	?	?	?
$\mu_{22}$	?	?	?

$\mu_{ok}$


- Pertenencia al conjunto borroso  $k$ -ésimo de la variable de salida

$\mu_{ij}$

- Pertenencia  $j$ -ésima de la variable  $i$ -ésima de entrada

**Una matriz por conjunto borroso de salida**

# Grafo de inferencia (II)



$\mu_{ok}$	$\mu_{11}$	$\mu_{12}$	$\mu_{13}$
$\mu_{21}$	$T(\mu_{11}, \mu_{21})$	$T(\mu_{11}, \mu_{21})$	$T(\mu_{11}, \mu_{21})$
$\mu_{22}$	$T(\mu_{11}, \mu_{21})$	$T(\mu_{11}, \mu_{21})$	$T(\mu_{11}, \mu_{21})$

$\times$

$\sigma$

$W_{ok}$	$\mu_{11}$	$\mu_{12}$	$\mu_{13}$
$\mu_{21}$	$x_{1121}$	$x_{1221}$	$x_{1321}$
$\mu_{22}$	$x_{1122}$	$x_{1222}$	$x_{1322}$

**$W_{ok}$**

• Matriz de pesos para el conjunto borroso  $k$ -ésimo de salida

**$x_{ijkm}$**

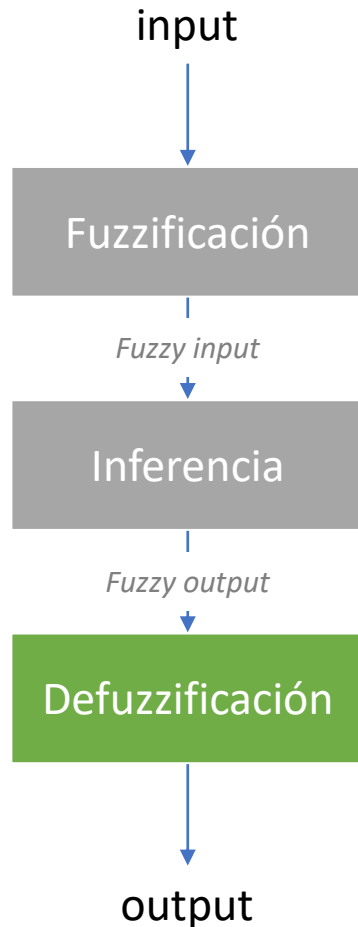
• Variable asociada a la  $t$ -norma entre los conjuntos  $F_{ij}$  y  $F_{km}$

**$\sigma$**

• Restringe el valor de los pesos al intervalo  $(0, 1)$

**Cada  $x_{ijkm}$  es una variable a ajustar**

# Grafo de defuzzificación



Entrada: pertenencias a cada conjunto de salida

Salida: Variable crisp

Las pertenencias de una misma variable se agregan según la *t*-conorm

Controlador Takagi-Sugeno de orden 0

$$output = \frac{\sum_{i=1}^K \mu_i x_i}{\sum_{i=1}^K \mu_i}$$

**K**

•El número de conjuntos borrosos de salida

**w<sub>i</sub>**

•El valor del conjunto borroso i-ésimo

**w<sub>i</sub>**

•La salida borrosa agregada para el conjunto borroso i-ésimo de salida


**No se requiere del ajuste de ninguna variable**

# Mejor modelo longitudinal



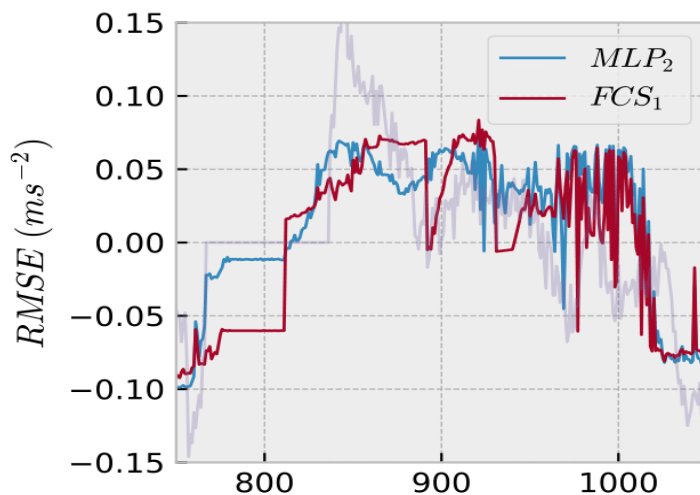
## Controlador borroso (FCS)

- Dos conjuntos borrosos por variable de entrada



## Perceptr3n multicapa (MLP)

- Dos capas ocultas de 8 y 4 neuronas respectivamente

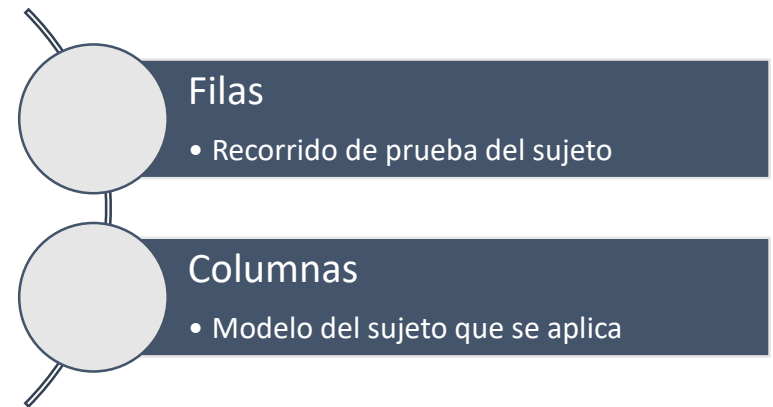


RMSE (MLP)			
	Train	Validation	Test
$S_A$	0,056	0,062	0,057
$S_1$	0,045	0,039	0,060
$S_2$	0,048	0,047	0,058
$S_3$	0,055	0,054	0,058

El comportamiento longitudinal se modeliza mejor con MLP

# Modelo longitudinal específico

RMSE (MLP)			
	$S_1$	$S_2$	$S_3$
$S_1$	<b>0,059</b>	0,074	0,070
$S_2$	0,064	<b>0,058</b>	0,067
$S_3$	0,065	0,065	<b>0,057</b>



El error de los modelos es menor en su recorrido de prueba



Modelo lateral

# Modelo lateral

Perceptron multicapa (MLP) y red de convolución (CNN) como propuesta

## Retos

¿Nube de puntos a imagen?

- Mapas de profundidad

¿Data augmentation?



- Mirroring
- Shaking



¿Datos tipo no imagen? (sólo CNN)

- Inyección en capas de inferencia






# Mapa de profundidad



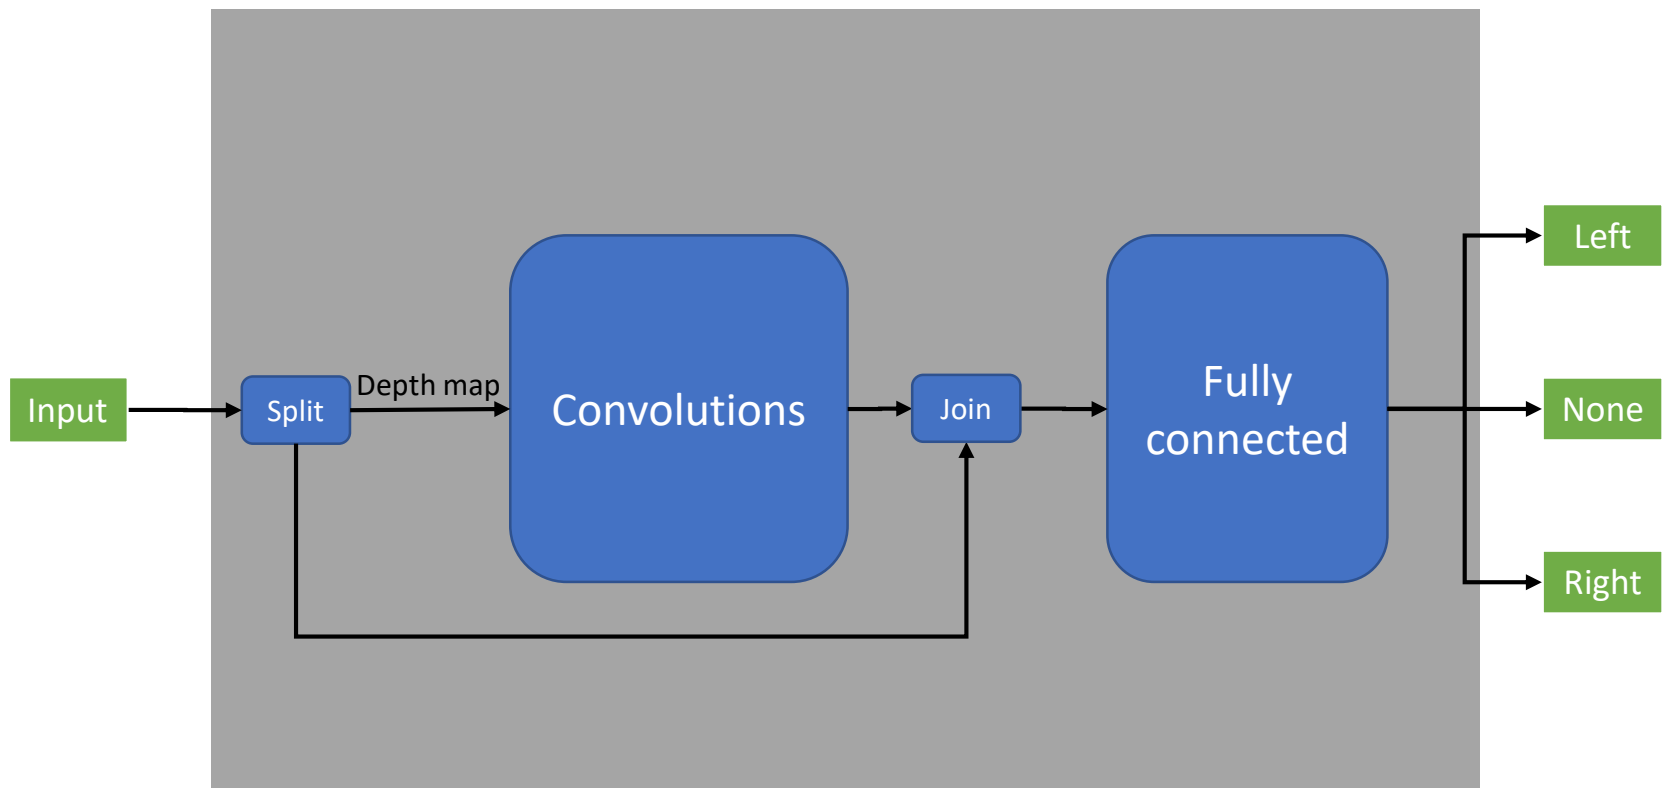


Mirroring



Shaking


# Inyección en capas de inferencia




# Percepción temporal

Se asumen procesos cognitivos de entre  $0.2s$  y  $1.2s$   
(córtex visual y córtex prefrontal)

Seleccionados  $t_0$ ,  $t_{10}$  y  $t_{20}$




# Padding lateral



**Los extremos izquierdo y derecho son aumentados a la mitad del tamaño de los filtros**


Así no se pierde información de patrones en las parte trasera del vehículo

# Mejor modelo lateral



## Perceptrón multicapa (MLP)

- Ninguna arquitectura superó el 33% de acierto



## Red de convolución (CNN)

- Convolución ( $5 \times 36$ ), convolución ( $3 \times 5$ ) y dos capas de 128 y 16 neuronas

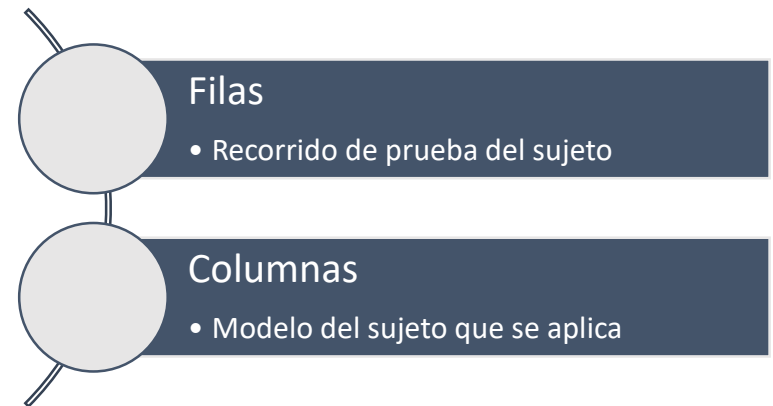
Real	Left	7.37 %	0.50 %	6.88 %
	None	5.66 %	45.80 %	24.12 %
	Right	3.00 %	0.24 %	6.44 %
		Left	None	Right

RMSE (CNN)			
	Train	Validation	Test
$S_A$	0,588	0,576	0,573
$S_1$	0,805	0,763	0,768
$S_2$	0,683	0,708	0,706
$S_3$	0,727	0,706	0,710

El comportamiento lateral se modeliza mejor con redes de convolución


# Modelo lateral específico

RMSE (MLP)			
	$S_1$	$S_2$	$S_3$
$S_1$	<b>0,768</b>	0,314	0,601
$S_2$	0,601	<b>0,706</b>	0,511
$S_3$	0,648	0,666	<b>0,710</b>





El error de los modelos es menor en su recorrido de prueba



A thin vertical black line is positioned to the left of the title text.

# Pruebas de simulación



# Comportamiento longitudinal

# Comportamiento lateral

		$S_A$		$S_1$		$S_2$		$S_3$		$S_S$	
		$\mu$	$\sigma$	$\mu$	$\sigma$	$\mu$	$\sigma$	$\mu$	$\sigma$	$\mu$	$\sigma$
LC	Real	6	1,41	7		4		7			
	Sim.	2	0	2	0	1	0,47	2	0,81	11	0,66
RC	Real	3,33	0,94	2		4		4			
	Sim	1,67	1,70	0,67	0,47	2,33	1,89	0,67	0,94	12	2,67

Mayor número de cambios de carril en modelo de SUMO

Bajo número de cambios en modelos de comportamiento

Los modelos entrenados se aproximan más a la realidad

Es probable que se necesiten más datos de cambio de carril

# CONCLUSIONES

## H1

- Se han incorporado comportamientos humanos a un simulador a través de un modelo propio
- El comportamiento longitudinal se diferencia de los modelos incorporados
- El comportamiento lateral también
- **Se puede considerar demostrada la hipótesis**

## H2

- Los modelos entrenados para los diferentes sujetos se comportan mejor con sus respectivos datos
- **Se puede considerar demostrada la hipótesis**

## Sería interesante no obstante

- Determinar nuevas variables a analizar
- Aumentar la cantidad de datos recogidos

# Objetivos planteados

## Sistemas de control borroso (FCS)

- La técnica de aprendizaje basada en descenso del gradiente es rápida
- En el problema del comportamiento longitudinal, no mejora el desempeño de un MLP
- Con problemas sí modelables con FCS, permite la explicación de su funcionamiento

## Perceptrones multicapa (MLP)

- Se comporta según lo esperado en problemas de regresión
- En el problema concreto del cambio de carril, no ha sido capaz de extraer características del conjunto de entrada

## Redes de convolución (CNN)

- Son idóneas para capturar características relacionadas espacialmente
- Su lento entrenamiento y su cantidad de metavARIABLES hace del proceso de búsqueda de arquitectura muy tedioso.

# Técnicas utilizadas

## Información interna del vehículo (iMiEV)

- Muy precisa, pero únicamente in-car
- Puede ser usada como guía de referencia para otras medidas
- Precisión muy dependiente del vehículo

## GPS (INSIA)

- Suficiente precisión para pruebas
- Es muy arriesgado su uso sin otros sensores de apoyo

## LiDAR (VLP-16)

- Flujo de información varios órdenes de magnitud mayor que otros sensores
- 16 capas son insuficientes para capturar un entorno de calidad

## Entorno de simulación (SUMO)

- Muy completo y mucha versatilidad
- Extremadamente limitado a percepción del entorno y a comportamiento

# Datos, sensores y simulación

# Líneas futuras

## Entornos de simulación más realistas

Los simuladores estudiados no aportan suficiente información

Adaptación de simuladores de conducción al problema del tráfico

Incorporación de los modelos descritos sin las limitaciones que imponen los simuladores de tráfico tradicionales

## Diferentes escenarios y actores

Trabajo sobre escenarios específicos complicados para el vehículo autónomo (e.g. cruces sin señalizar, rotondas, ...)

Comportamiento de otros actores como vehículos de grandes dimensiones o incluso peatones

## Estudio de otras características vehiculares

Creación de perfiles de características como consumo, emisión de gases o de ruido basándose en los datos exactos del vehículo en lugar de modelos genéricos

## Redes neuronales recurrentes

La ventana temporal entre dos sujetos puede ser diferente

El uso de redes recurrentes puede ayudar a la personalización de la ventana temporal de cada sujeto



# PUBLICACIONES

---

Clavijo, M., Díaz, A., Serradilla, F., Jiménez F., Naranjo, J.E. (2017, July). **Deep learning application for 3D LiDAR odometry estimation in autonomous vehicles**. Connected and Automated Transport, 2018 Transport Research Arena (TRA).Internacional.

---

Clavijo, M., Serradilla, F., Naranjo, J.E., Jiménez F., & Díaz, A. (2017, July). **Application of Deep Learning to Route Odometry Estimation from LiDAR Data**. Advances in Vehicular Systems, Technologies and Applications, 2017 The Sixth International Conference on (pp. 60-65). Internacional.


---

Felipe, J., Amarillo, J. C., Naranjo, J. E., Serradilla, F., & Díaz, A. (2015, September). **Energy consumption estimation in electric vehicles considering driving style**. In Intelligent Transportation Systems (ITSC), 2015 IEEE 18th International Conference on (pp. 101-106). IEEE.

---

Congresos

# Artículos



- Díaz-Álvarez, A., Clavijo, M., Jiménez, F. Talavera, E., & Serradilla, F. (2018). **Modelling the human lane-change execution behaviour through Multilayer Perceptrons and Convolutional Neural Networks**. Transportation Research Part F: Psychology and Behaviour, 2018. (Q2).
- Olaverri-Monreal, C., Errea-Moreno, J., & Díaz-Álvarez, A. (2018). **Implementation and Evaluation of a Traffic Light Assistance System Based on V2I Communication in a Simulation Framework**. Journal of Advanced Transportation, 2018. (Q2).
- Talavera, E., Díaz-Álvarez, A., Jiménez, F., & Naranjo, J. E. (2018). **Impact on Congestion and Fuel Consumption of a Cooperative Adaptive Cruise Control System with Lane-Level Position Estimation**. Energies, 11(1), 194. (Q2).
- Jiménez, F., Naranjo, J. E., Serradilla, F., Pérez, E., Hernández, M. J., Ruiz, T., ... & Díaz, A. (2016). **Intravehicular, short-and long-range communication information fusion for providing safe speed warnings**. Sensors, 16(1), 131. (Q1).
- Díaz-Álvarez, A., Serradilla-García, F., Anaya-Catalán, J. J., Jiménez-Alonso, F., & Naranjo-Hernández, J. E. (2015). **Estimación de la autonomía de un vehículo eléctrico según el estilo de conducción**. DYNA-Ingeniería e Industria, 90(3). (Q4).
- Alvarez, A. D., Garcia, F. S., Naranjo, J. E., Anaya, J. J., & Jimenez, F. (2014). **Modeling the driving behavior of electric vehicles using smartphones and neural networks**. IEEE Intelligent Transportation Systems Magazine, 6(3), 44-53. (Q3).

# REFERENCIAS

# Referencias

- [Chandler et al., 1958] Chandler, R. E., Herman, R., and Montroll, E. W. (1958). **Traffic Dynamics: Studies in Car Following**. Operations Research, 6(2):165–184.
- [Fix and Armstrong, 1990] Fix, E. and Armstrong, H. (1990). **Modeling human performance with neural networks**. 1990 IJCNN International Joint Conference on Neural Networks, pages 247–252 vol.1.
- [Gipps, 1981] Gipps, P. G. (1981). **A behavioural car-following model for computer simulation**.
- [Gipps, 1986] Gipps, P. G. (1986). **A model for the structure of lane-changing decisions**. Transportation Research Part B, 20(5):403–414.
- [Hidas, 2002] Hidas, P. (2002). **Modelling lane changing and merging in microscopic traffic simulation**. Transportation Research Part C: Emerging Technologies, 10(5-6):351–371.
- [Jia et al., 2003] Jia, H., Juan, Z., and Ni, A. (2003). **Develop a car-following model using data collected by 'five-wheel system'**. IEEE Conference on Intelligent Transportation Systems, Proceedings, ITSC, 1:346–351.

# Referencias

- [Muñoz et al., 2010] Muñoz, J., Gutierrez, G., and Sanchis, A. (2010). **A human-like torcs controller for the simulated car racing championship**. In Proceedings of the 2010 IEEE Conference on Computational Intelligence and Games, pages 473–480. IEEE.
- [Naranjo et al., 2007] Naranjo, J. E., Sotelo, M. A., Gonzalez, C., Garcia, R., and De Pedro, T. (2007). **Using fuzzy logic in automated vehicle control**. IEEE intelligent systems, 22(1):36–45.
- [Pipes, 1953] Pipes, L. (1953). **An operational analysis of traffic dynamics**. Journal of applied physics.
- [Kikuchi and Chakroborty, 1992] Kikuchi, S. and Chakroborty, P. (1992). **Car-following model based on fuzzy inference system**. Transportation Research Record, pages 82–82.
- [McDonald et al., 1997] McDonald, M., Wu, J., and Brackstone, M. (1997). **Development of a fuzzy logic based microscopic motorway simulation model**. IEEE Conference on.
- [Michon, 1985] Michon, J. A. (1985). **A critical view of driver behavior models: what do we know, what should we do?** In Human behavior and traffic safety, pages 485–524. Springer.

# Referencias

- [Simonelli et al., 2009] Simonelli, F., Bifulco, G.N., and Martinis, V.D. (2009). **Human-Like Adaptive Cruise Control Systems through a Learning Machine Approach**. Applications of Soft Computing, pages 240–249.
- [Toledo et al., 2007] Toledo, T., Koutsopoulos, H. N., and Ben-Akiva, M. (2007). **Integrated driving behavior modeling**. Transportation Research Part C: Emerging Technologies, 15(2):96–112
- [Van Hoorn et al., 2009] Van Hoorn, N., Togelius, J., Wierstra, D., and Schmidhuber, J. (2009). **Robust player imitation using multiobjective evolution**. In 2009 IEEE Congress on Evolutionary Computation, pages 652–659. IEEE.
- [Wiedemann, 1974] Wiedemann, R. (1974). **Simulation des strassenverkehrsflusses**. Institute for Traffic Engineering, University of Karlsruhe.
- [Wu et al., 2003] Wu, J., Brackstone, M., and McDonald, M. (2003). **The validation of a microscopic simulation model: A methodological case study**. Transportation Research Part C: Emerging Technologies, 11(6):463–479.

Escuela Técnica Superior de Ingenieros Informáticos

# **Modelado de Comportamiento de Conductores con Técnicas de Inteligencia Computacional**

*Para la obtención del título de*

Doctorado en Inteligencia Artificial

*Autor*

Alberto Díaz Álvarez

*Directores*

Francisco Serradilla García

Felipe Jiménez Alonso