

ESCUELA TÉCNICA SUPERIOR DE INGENIEROS INFORMÁTICOS

Modelado de Comportamiento de Conductores con Técnicas de Inteligencia Computacional

DEFENSA PARA LA OBTENCIÓN DEL TÍTULO DE
DOCTORADO EN INTELIGENCIA ARTIFICIAL

AUTOR

ALBERTO DÍAZ ÁLVAREZ

DIRECTORES

FRANCISCO SERRADILLA GARCÍA

FELIPE JIMÉNEZ ALONSO

Tabla de contenidos



Introducción

Motivación y estado de la cuestión



Objetivos

Planteamiento tras el análisis



Metodología

Cuerpo del desarrollo de la tesis



Conclusiones

Consecuencias y líneas futuras



Publicaciones

Resultados en la comunidad científica

Introducción

Modelos de comportamiento de conductor

Niveles de abstracción de [Michon, 1985] sobre los procesos cognitivos durante la conducción

La diferenciación no tiene una separación exacta, y depende de multitud de factores como la experiencia del conductor o el entorno en el que se encuentra



- Planificaciones a alto nivel
- Decisiones de nivel cognitivo medio
- Comportamientos prácticamente automáticos

Los modelos de comportamiento que consideraremos trabajan en el nivel táctico

Simulación de tráfico

El tráfico es un sistema que emerge de la interacción de actores en algún tipo de camino o vía

Se puede considerar un Sistema Complejo.

Es muy difícil analizar a partir de cada elemento que lo compone.

Su estudio directo:

Afecta a las propias mediciones

En ocasiones es peligroso o ilegal

La simulación es una de las soluciones para el estudio del tráfico

Micro-simulación

Macro-simulación

La **micro-simulación** permite el **estudio** del tráfico a nivel de **modelos de conductor**

Modelos de comportamiento (I)

1950

Primeros modelos propuestos en la bibliografía. **Mantenimiento de medida** [Pipes, 1953]. Modelos de **car-following**.

1960

Estímulo – respuesta. Car-following como sistema de control [Chandler, 1958]. Nuevos regímenes (e.g. free-flow). **Modelos longitudinales.**

1970

Modelos **Psicofísicos**. Los estímulos no son exactos, existe **incertidumbre** en los sentidos [Wiedemann, 1974]

Modelos deterministas, con **carencias para replicar comportamiento real**

Modelos de comportamiento (II)

1980

- Primer trabajo real que integra comportamientos **longitudinal** [Gipps, 1981] y **lateral** [Gipps, 1986]. Problemas que se heredan: interbloqueos y acciones en secuencia

1990

- Primeros trabajos con datos reales en simuladores top-view de **redes neuronales** [Fix & Armstrong] y **lógica borrosa** [Kikuchi & Chakroborty, 1992]. **Problemas de falta de datos.**

2000

- **Árboles de secuencia** para solucionar problemas de modelos basados en Gipps [Hidas, 2002]. Mitiga el efecto pero no lo elimina.
- Comportamiento lateral con **lógica borrosa** (sin datos reales) [McDonald et al., 1997].
- **Datos reales** para control longitudinal y lateral con redes neuronales [Jia et al., 2003].

Modelo lateral

Selection y merging

Gap acceptance

Tipologías:
MLC, DLC, ...

No replican suficientemente **bien comportamientos humanos** en simulación

Conclusiones del estado actual

2010

- **Vehículos instrumentados** para modelos en **situaciones complejas** [Naranjo et al., 2006].
- **Árboles probabilísticos** para evitar los problemas de secuencia [Toledo et al., 2007]. Problemas: Asignación de probabilidades y explosión combinatoria de acciones.
- **Simuladores en primera persona** para captura de datos y entrenamiento de redes neuronales [Van Hoorn et al., 2009].

Modelos clásicos

- Muy eficientes
- Limitados a la hora de replicar el comportamiento humanos
- Comportamientos complejos implican mucha modelización

Modelos IC

- Abstraen comportamientos complejos
- No utilizan valores del entorno que les rodea
- A día de hoy, no es posible explicar el porqué de las conclusiones de una red neuronal de una o más capas ocultas

Necesitamos modelos que repliquen mejor comportamientos humanos en simuladores

Objetivos

Objetivo general

Desarrollo de una metodología que permita la **generación de modelos** de conductores humanos **a partir de** los datos extraídos de los **sensores de un vehículo**, de tal manera que puedan ser **implantables dentro de un agente inteligente**



Justificación

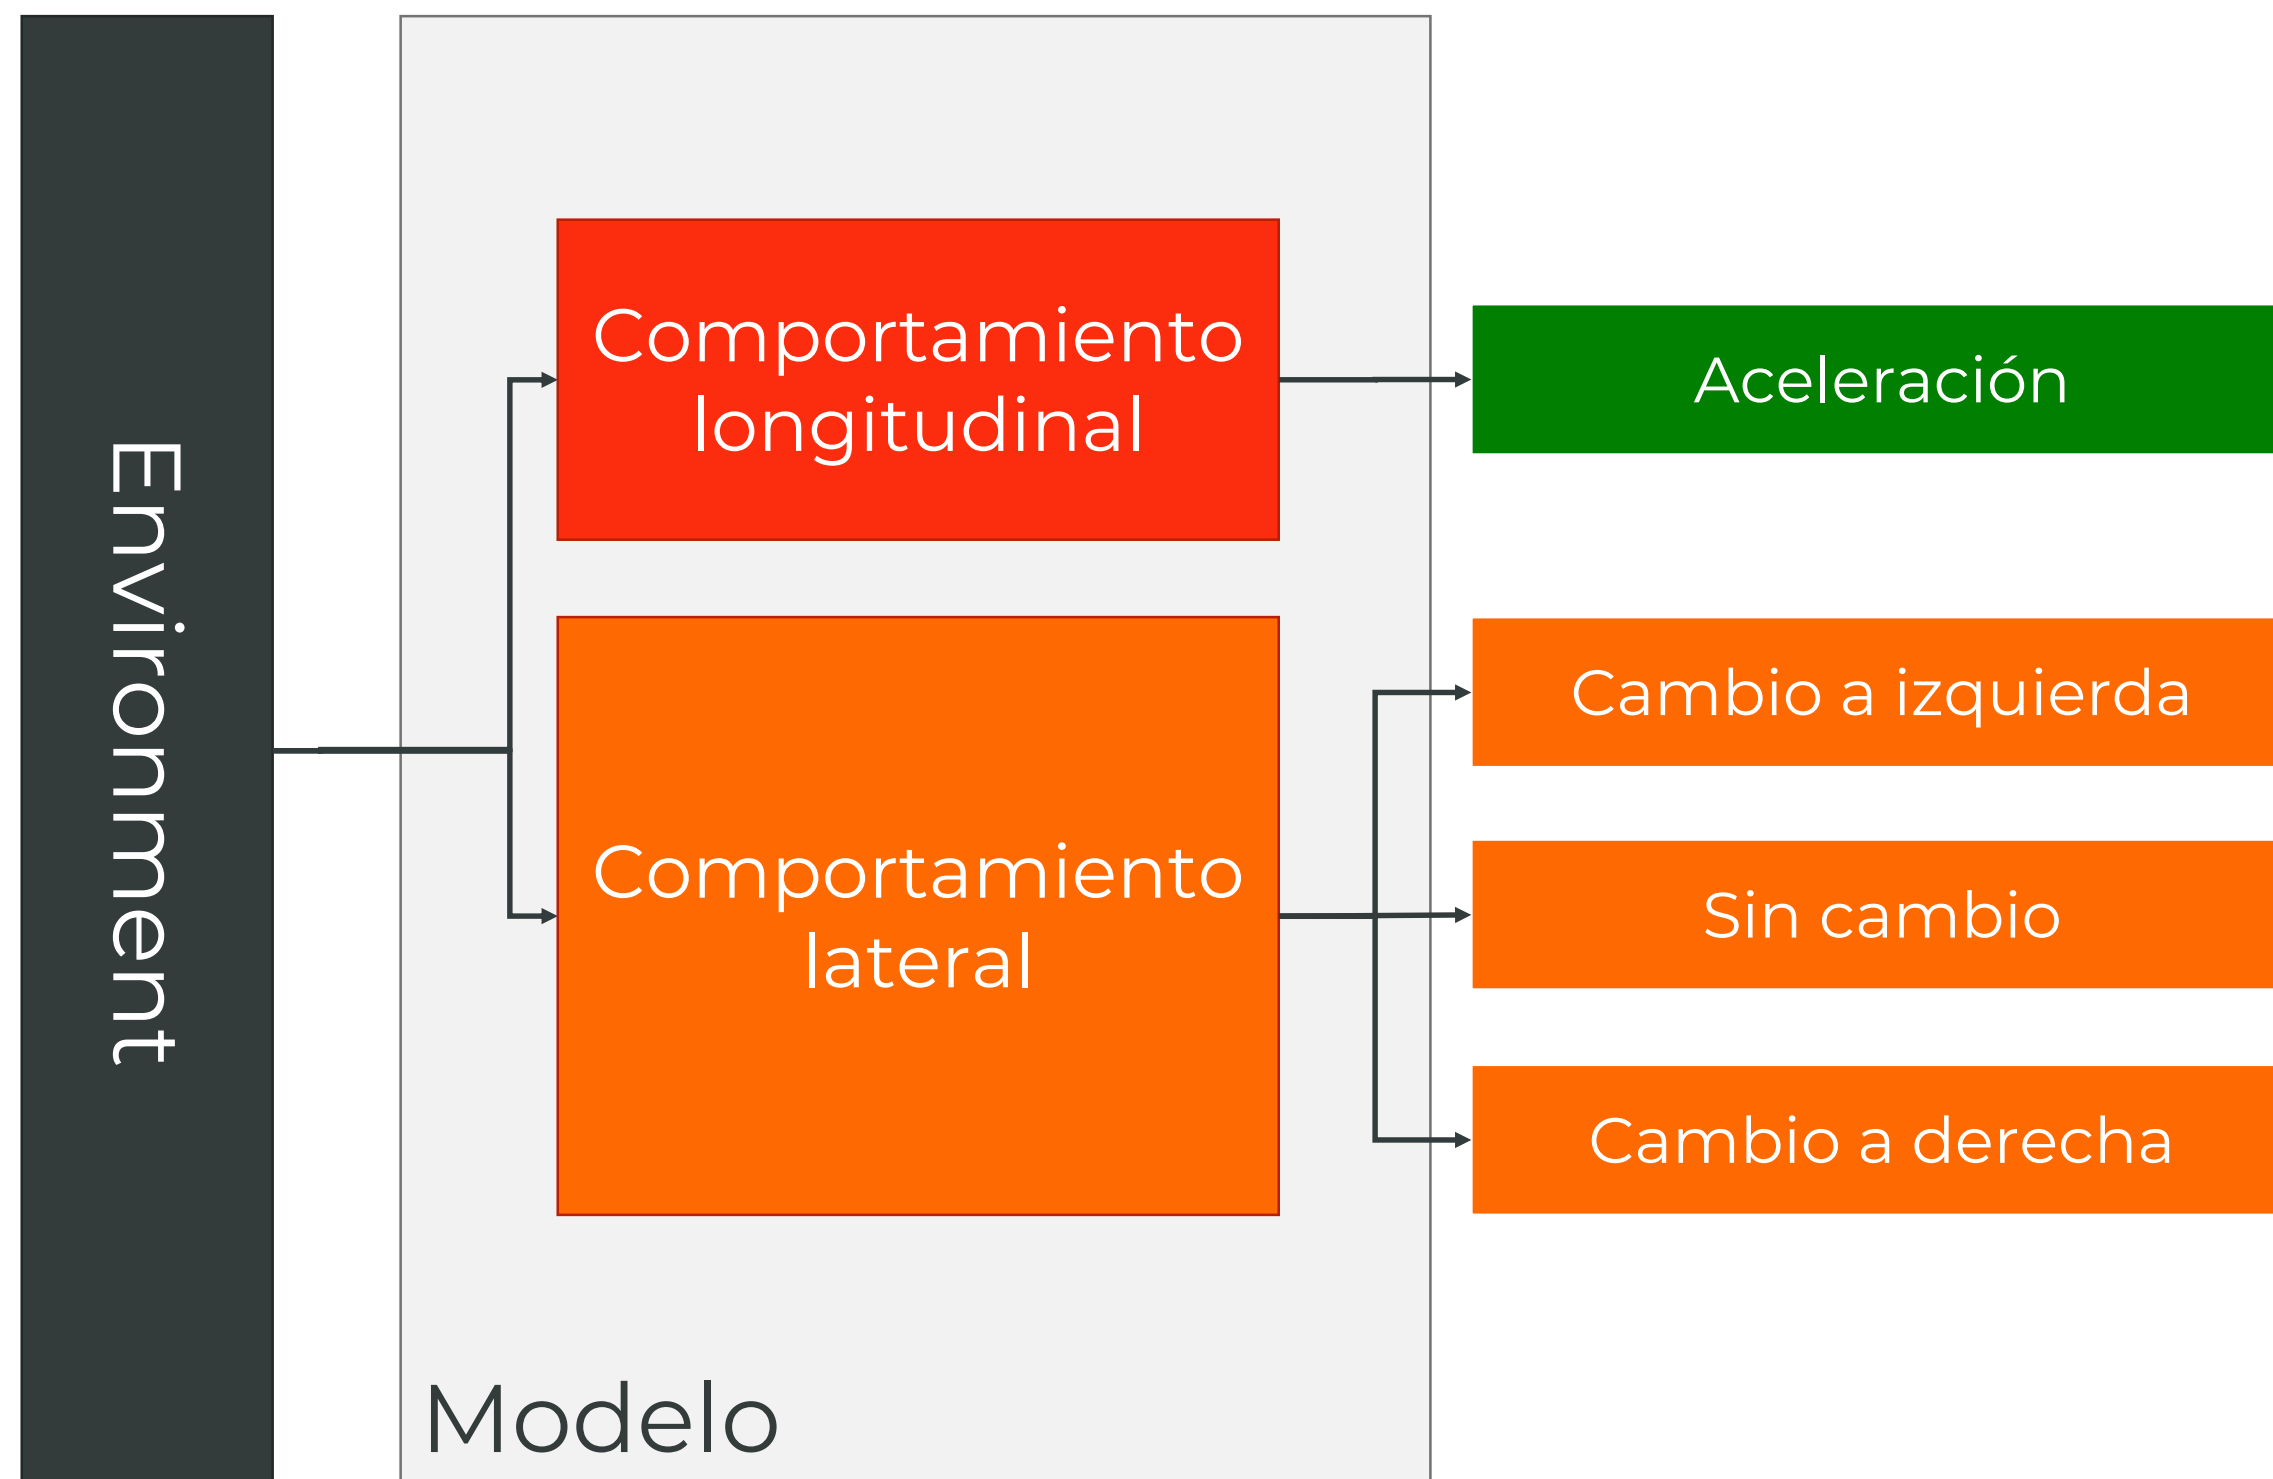
El transporte por carretera es el principal medio de transporte

- Simulaciones más realistas permitirían **estudiar mejor el tráfico.**
- Modelos más realistas permitirían **estudiar** el comportamiento de **conductores reales en simulación.**
- **Comportamientos** más humanos en **vehículos autónomos** facilitarían el periodo de **coexistencia.**

Metodología

Modelo a desarrollar

Modelo que replique los comportamientos **longitudinal** y **lateral** de conductores **a partir** de sus **datos reales** durante la conducción para encapsularlos dentro de un agente inteligente que responda como ellos.



Tecnologías a utilizar

Tanto para el modelo longitudinal como para el lateral se compararán dos tecnologías para medir su desempeño. La mejor de cada una será elegida como candidata para ese componente del modelo global de conductor.

Perceptrones multicapa

Solución clásica para problemas de regresión.

Controladores borrosos

Permiten modelar el comportamiento procedimental del comportamiento humano.

Modelo longitudinal

Modelo lateral

Perceptrones multicapa

Solución clásica para problemas de clasificación.

Redes de Convolución


Son capaces de reconocer patrones relacionados espacialmente en los datos

Proceso a seguir

A lo largo de la sección se describirán los pasos seguidos durante el desarrollo de la tesis para la generación y posterior validación de los modelos de comportamiento



Proceso a seguir



Selección de simulador


- Seleccionado entorno de simulación de tráfico SUMO, desarrollado por el Instituto de Sistemas de Transporte en el Centro Aeroespacial Alemán.
- Muchas ventajas de cara a la simulación y la extensibilidad mediante APIs.
- Restricciones en materia espacial, manejo del vehículo y representación del entorno vehicular.

Ventajas

- Open Source Software
- Arquitectura Cliente/Servidor
- API pública
- Edición de mapas y escenarios

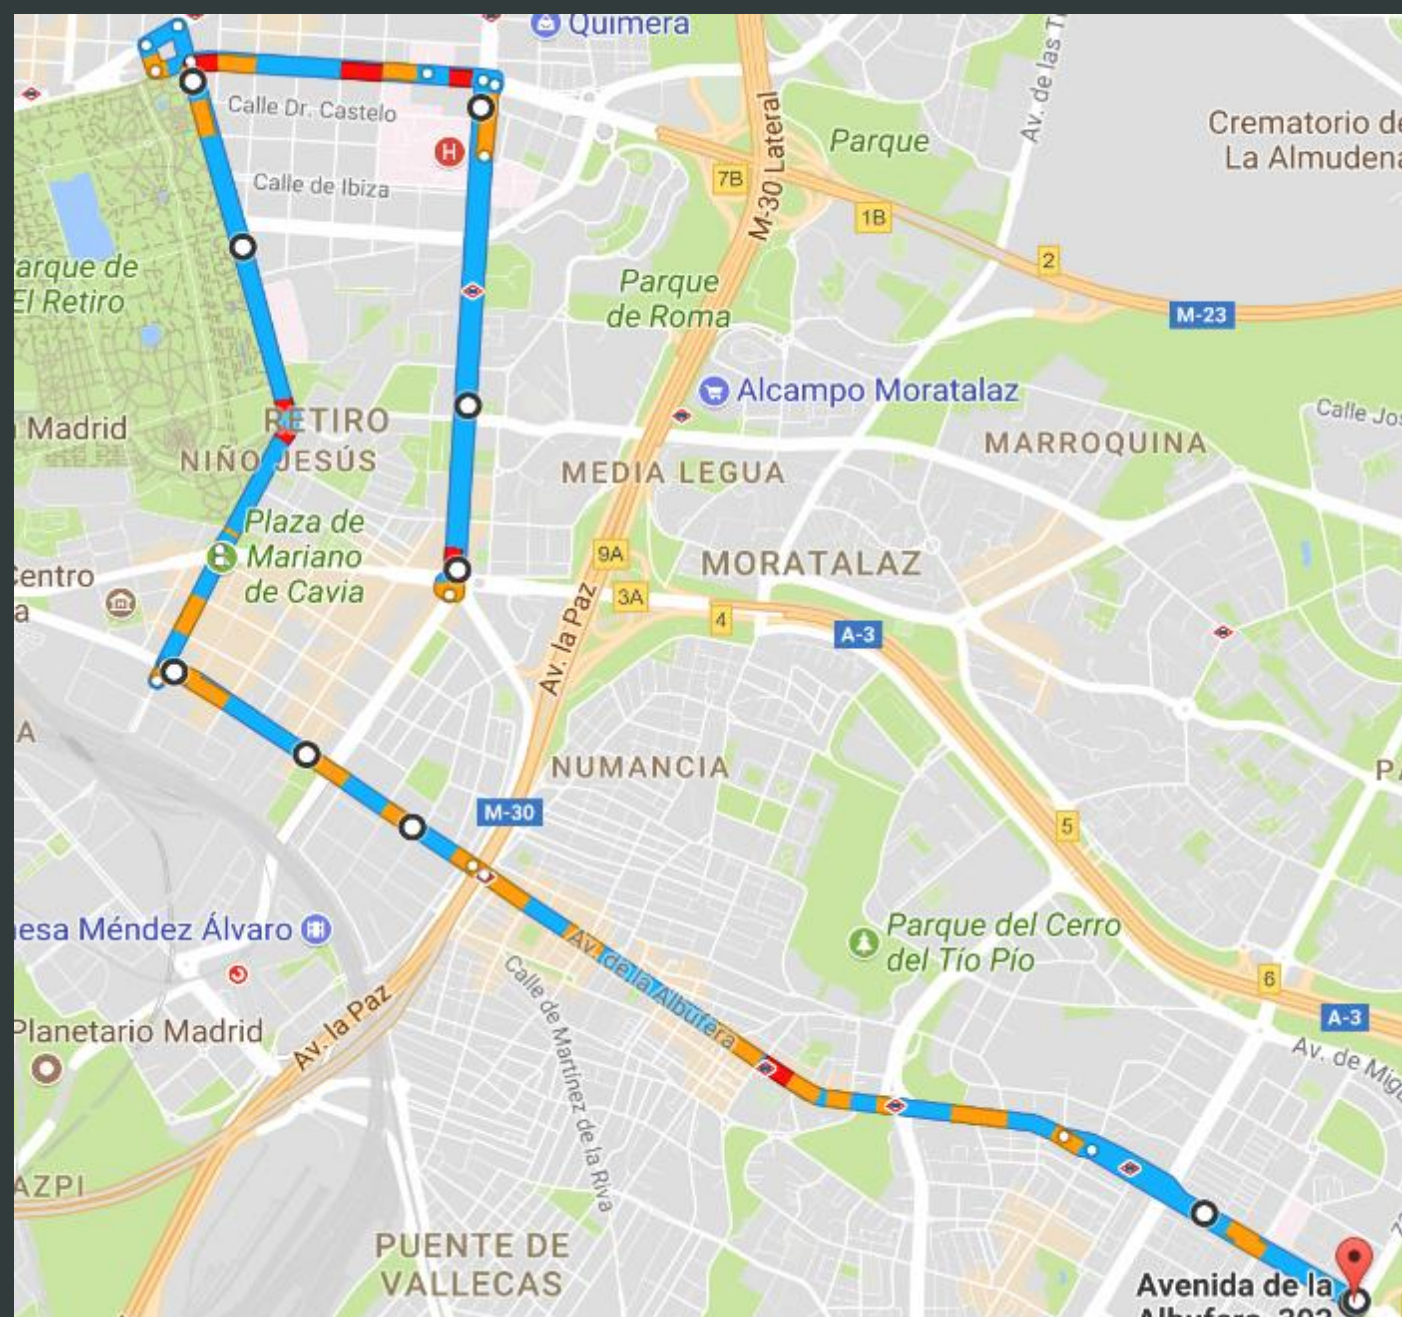
Inconvenientes

- Entorno del vehículo muy limitado
- Cambios de carril instantáneos
- Teleportaciones eventuales

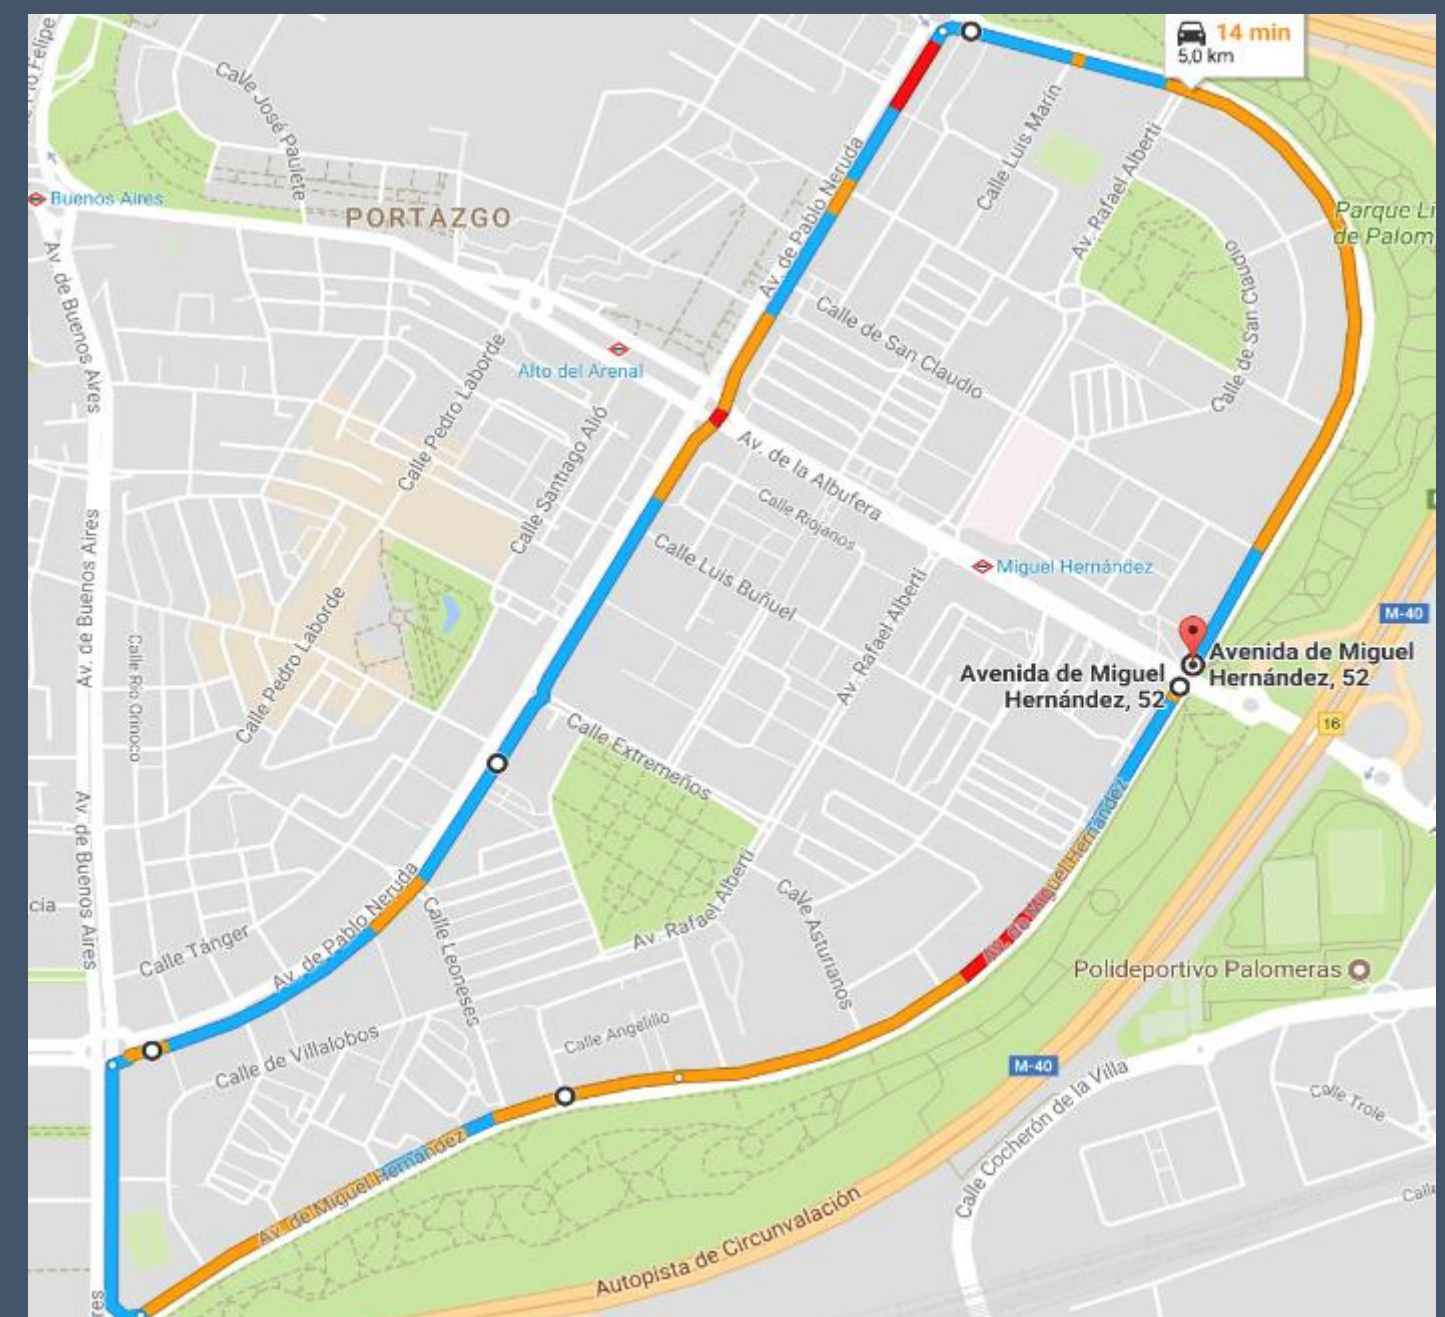


Recorridos realizados

Se tratan de recorridos urbanos, con velocidades máximas de entre 30 km/h a 50km/h, con zonas de 2 y 3 carriles, rotondas y cruces con y sin señales luminosas.



Entrenamiento



Test

Instrumentación del vehículo

Los recorridos son realizados con un vehículo instrumentando capturando datos a la máxima frecuencia que permite el sensor en cuestión.

LiDAR (VLP-16)

Captura del entorno circundante.

Cámara (Kinect)

Visualización frontal para post-proceso

GPS (INSIA)

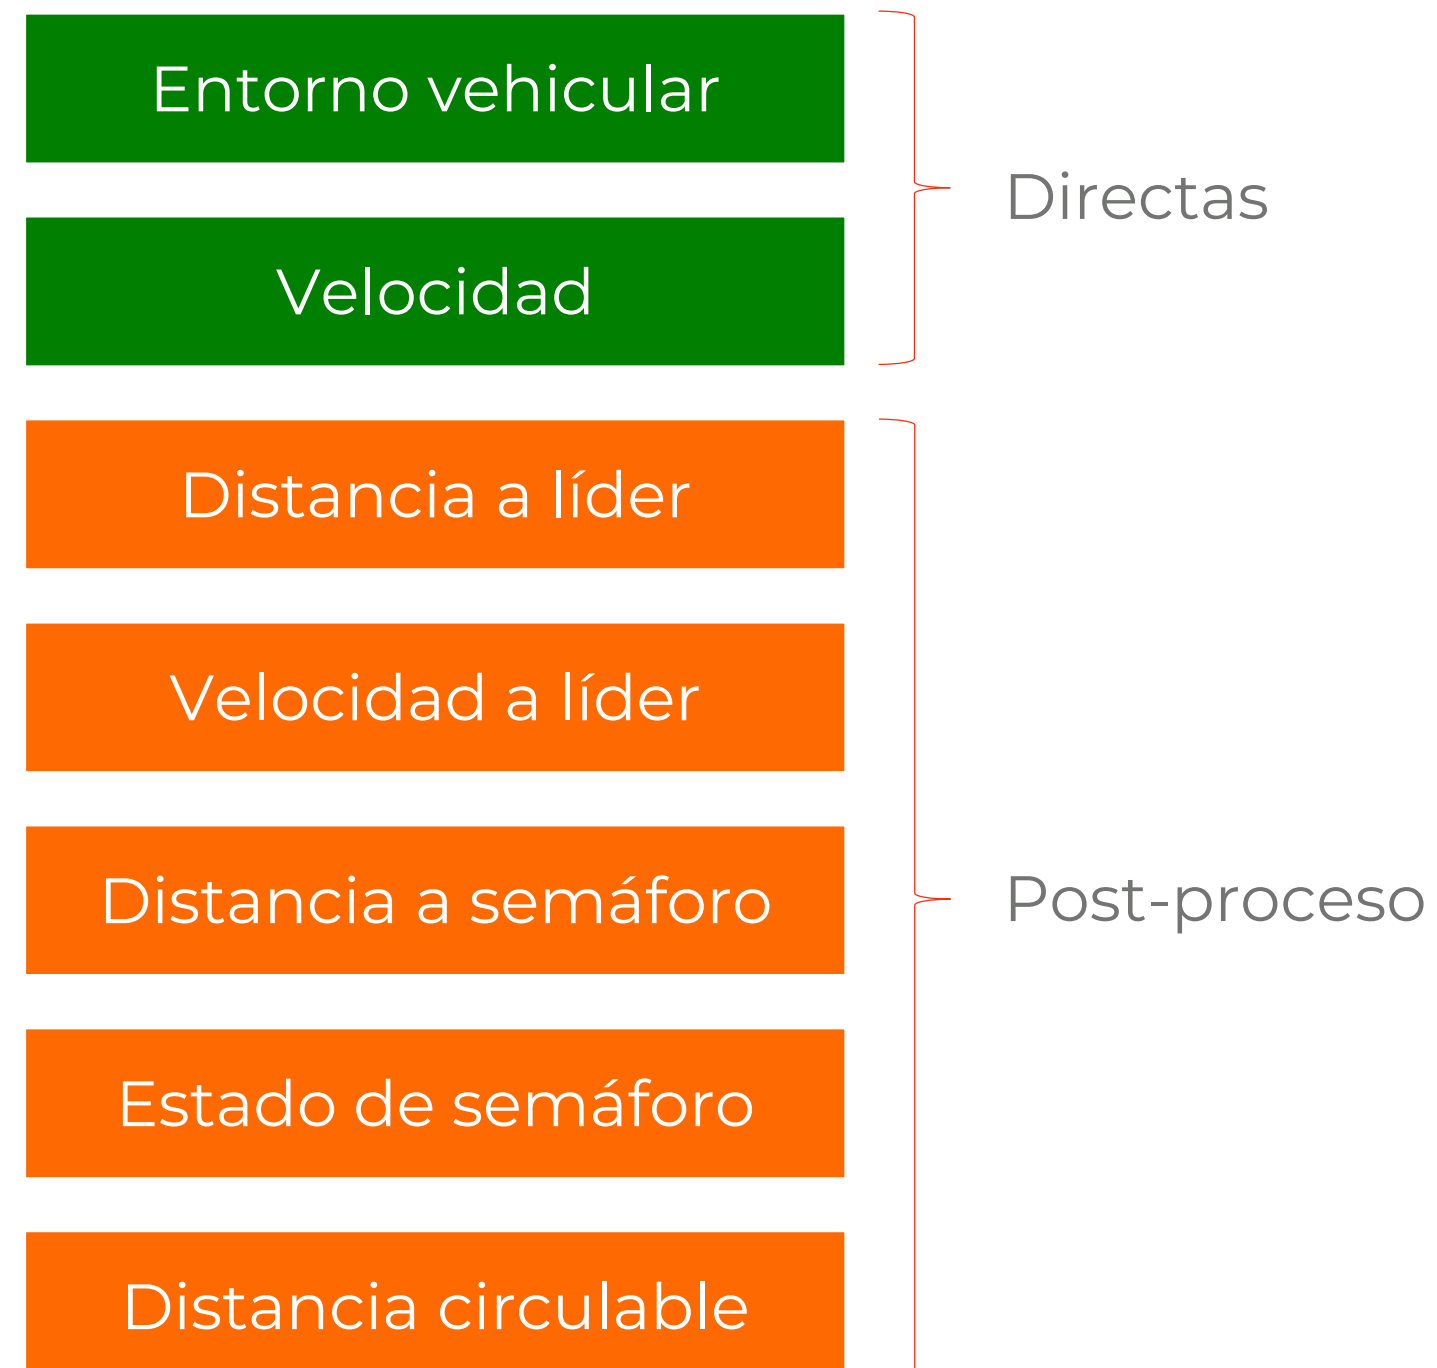
Posicionamiento 3D sobre el globo

CAN Bus

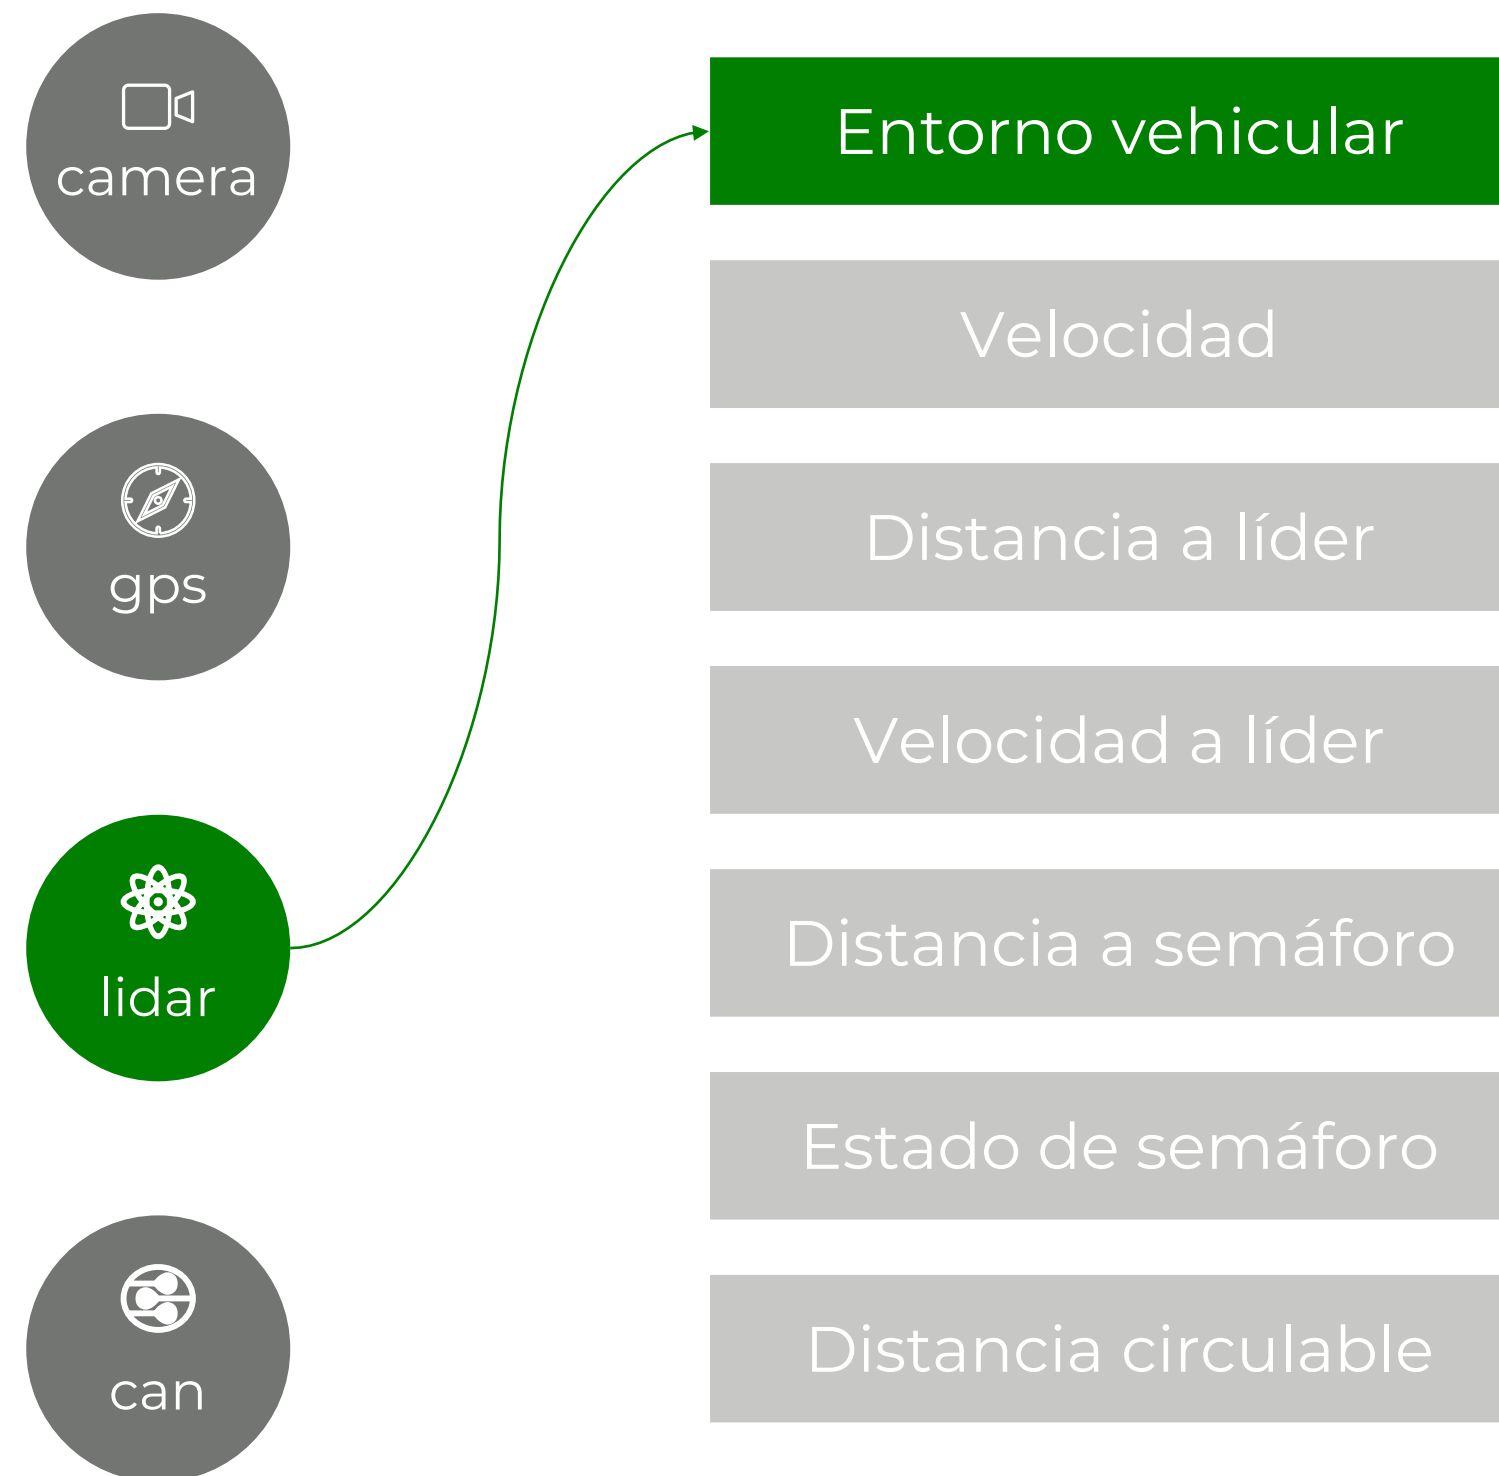
Obtención del estado interno



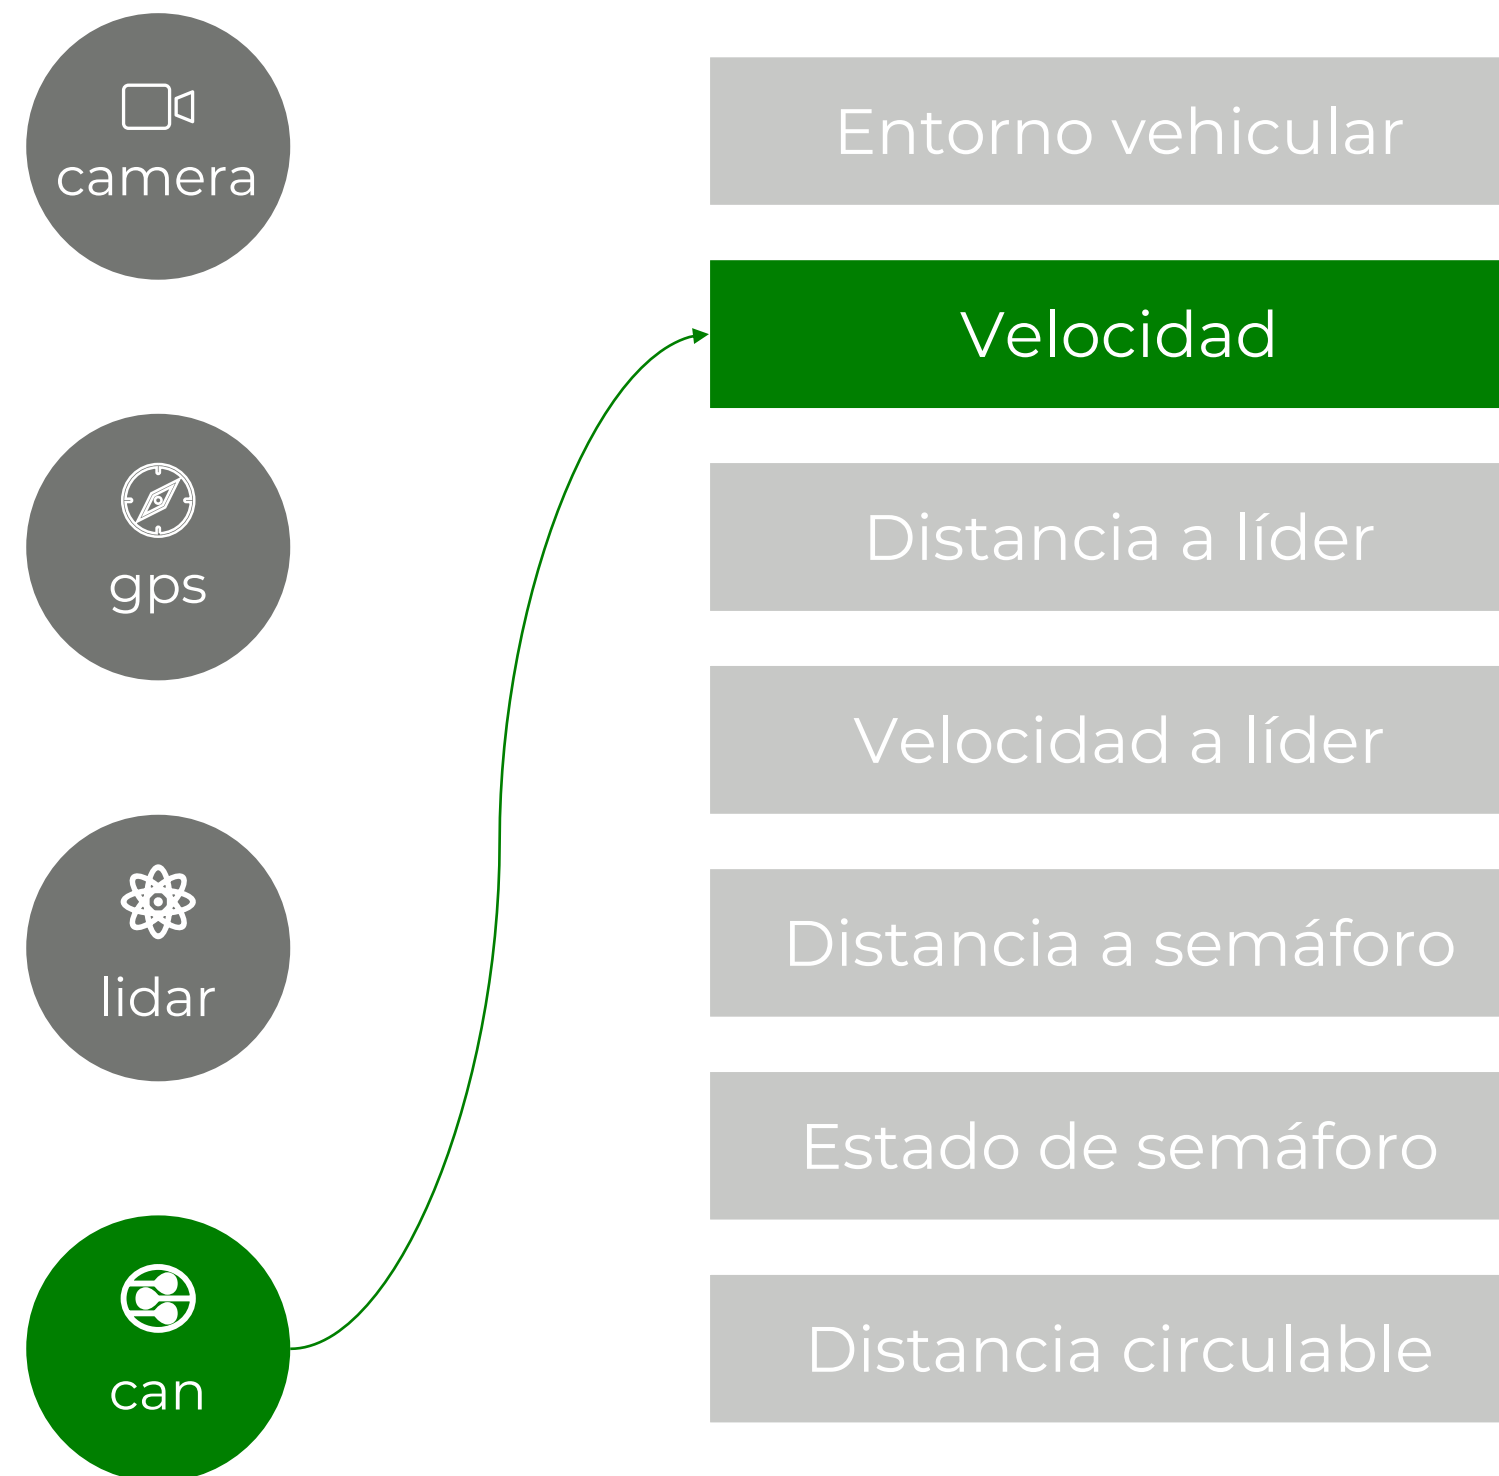
Variables capturadas



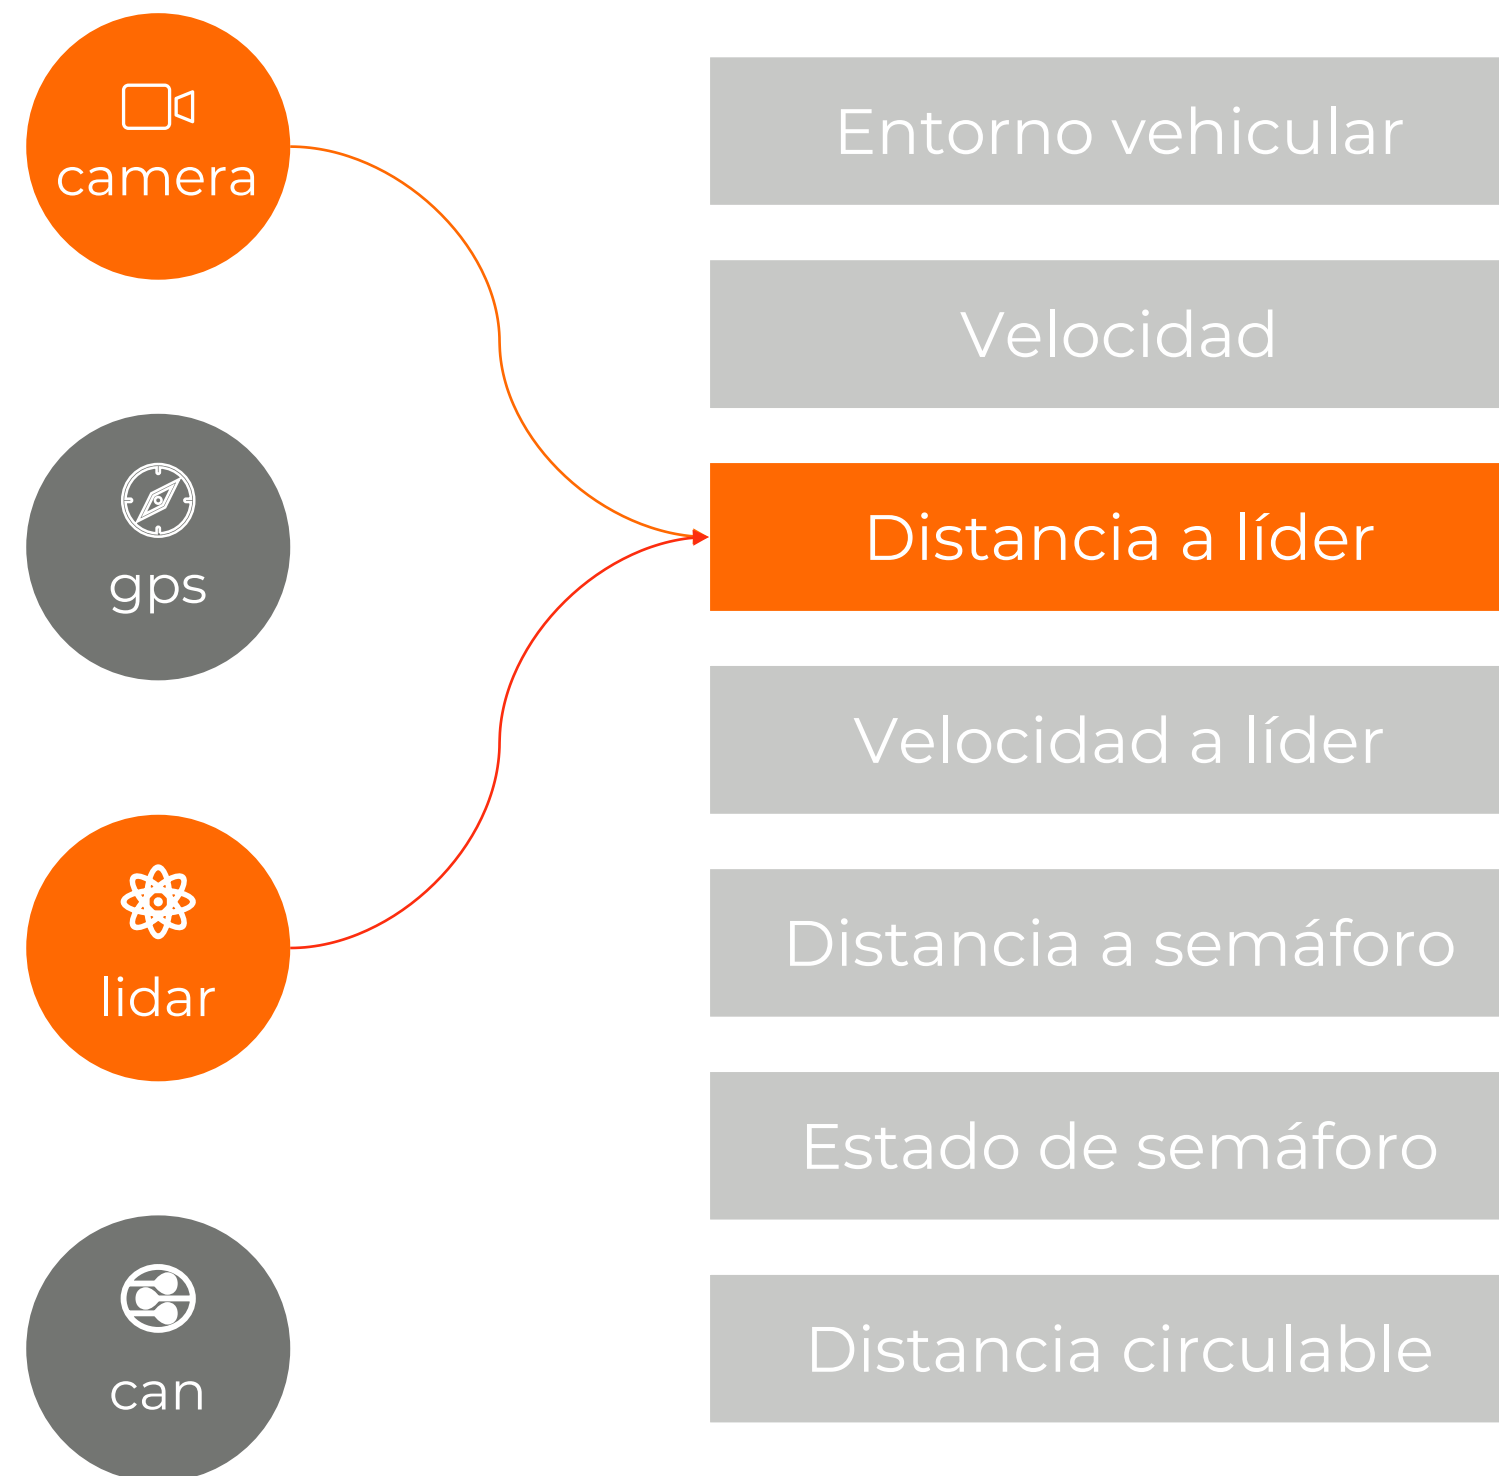
Variables capturadas



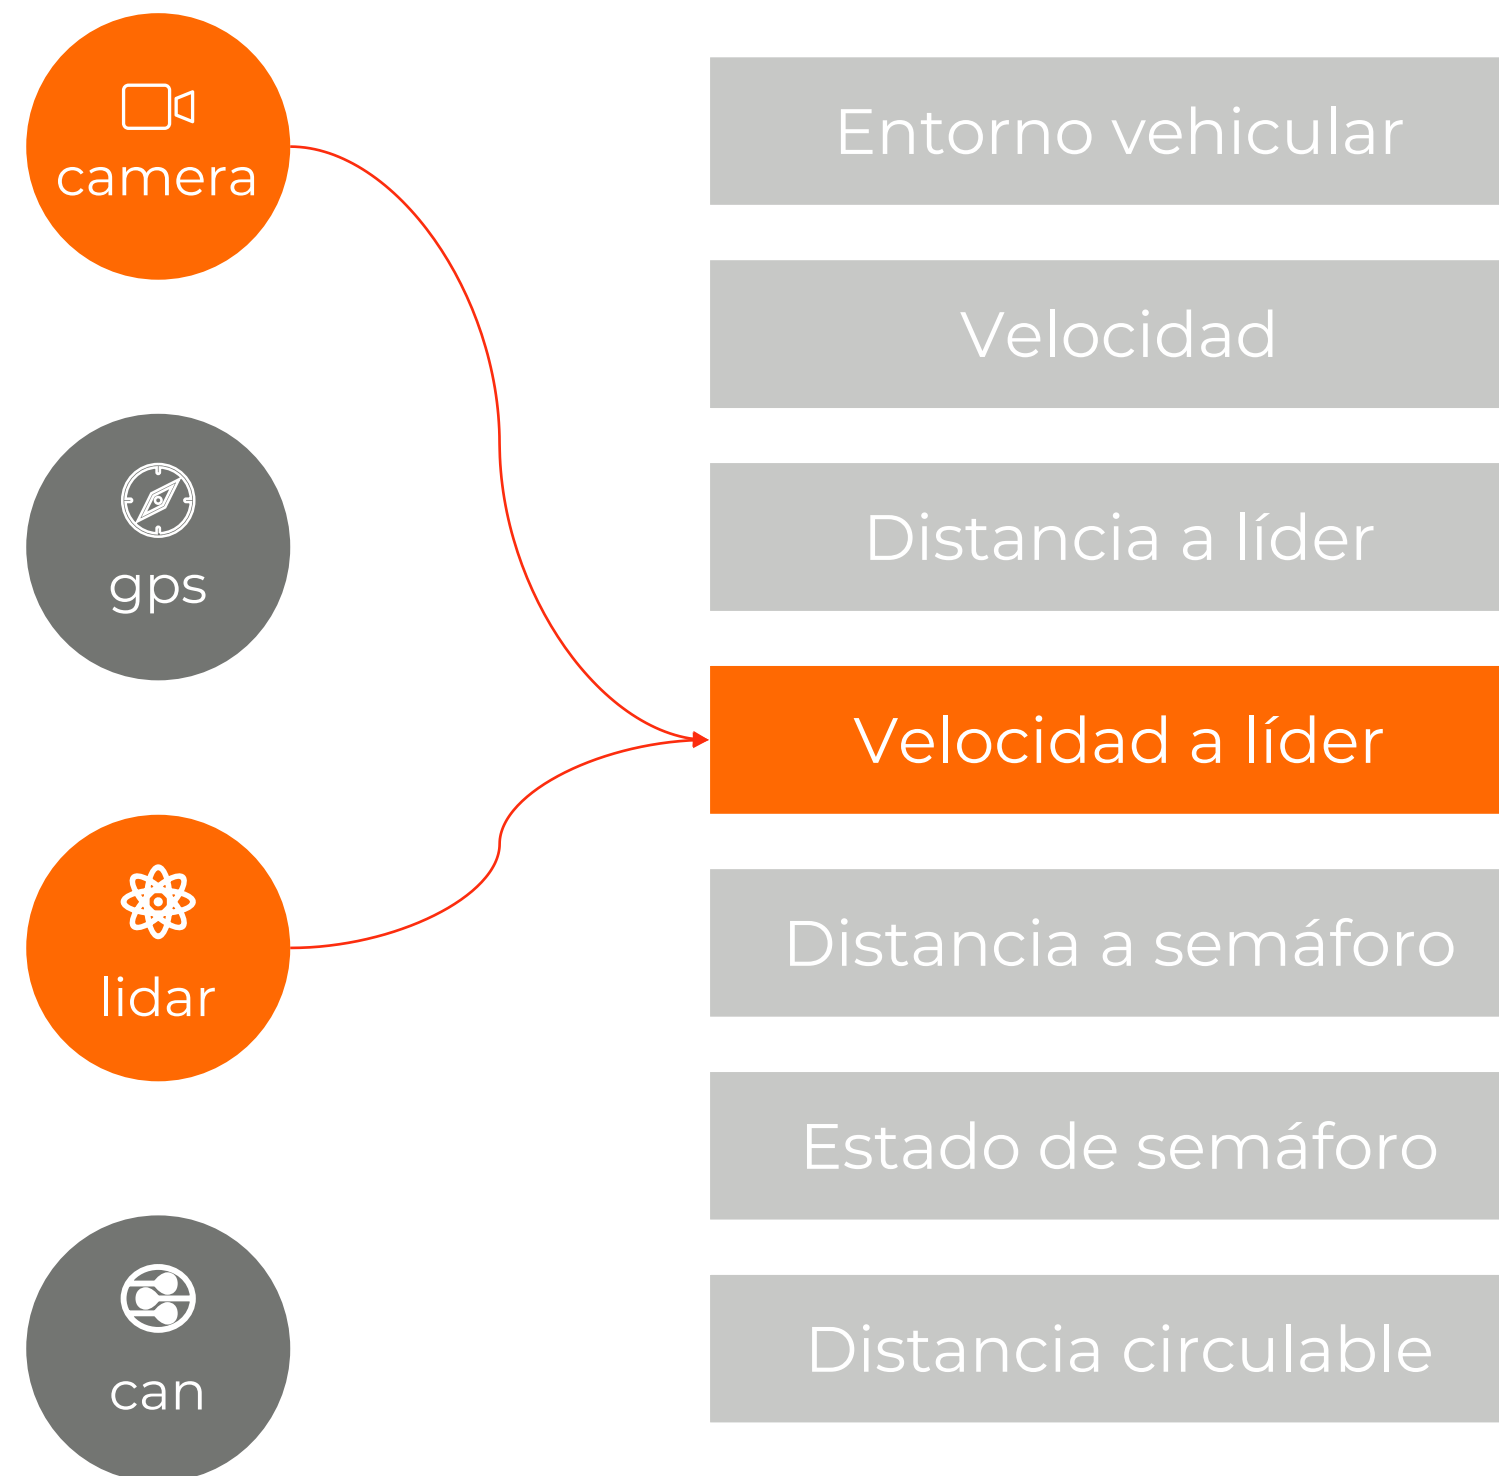
Variables capturadas



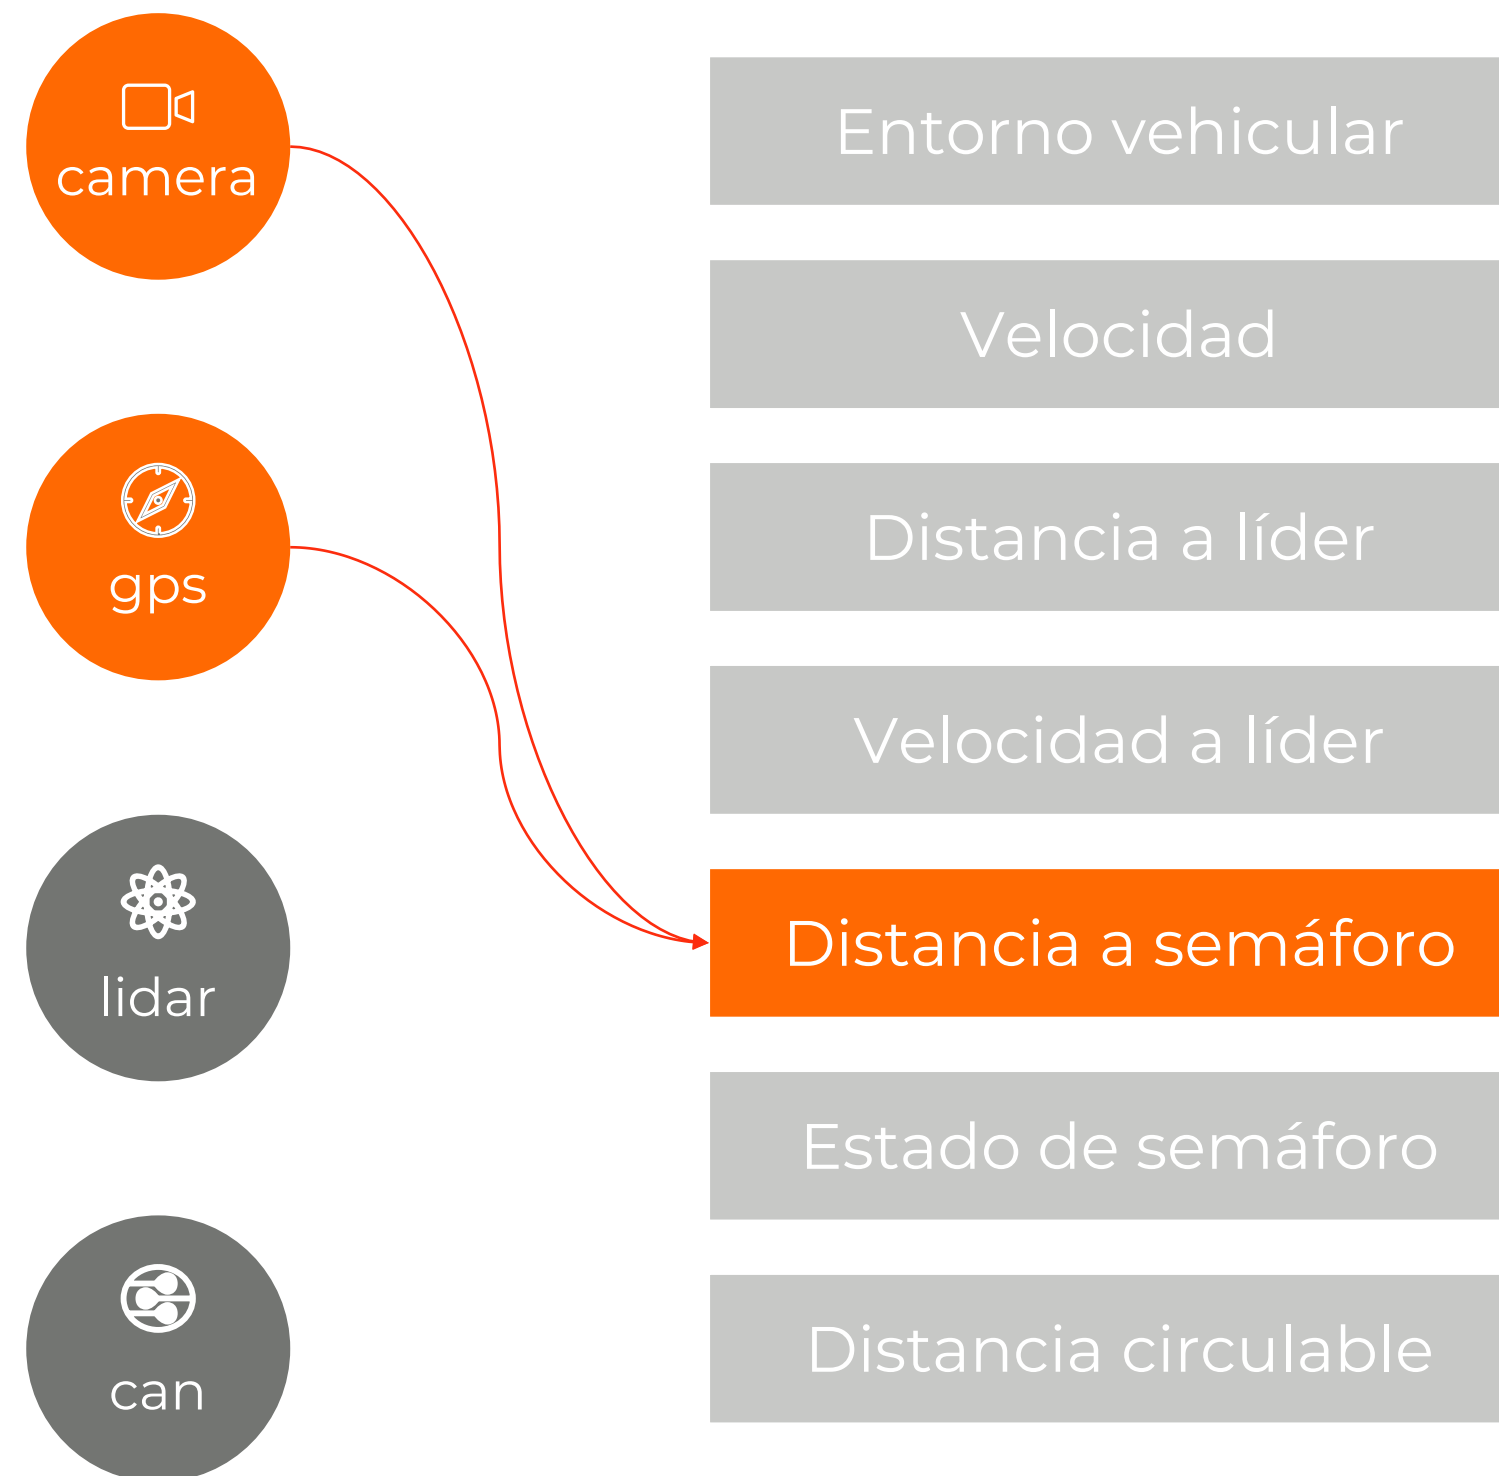
Variables capturadas



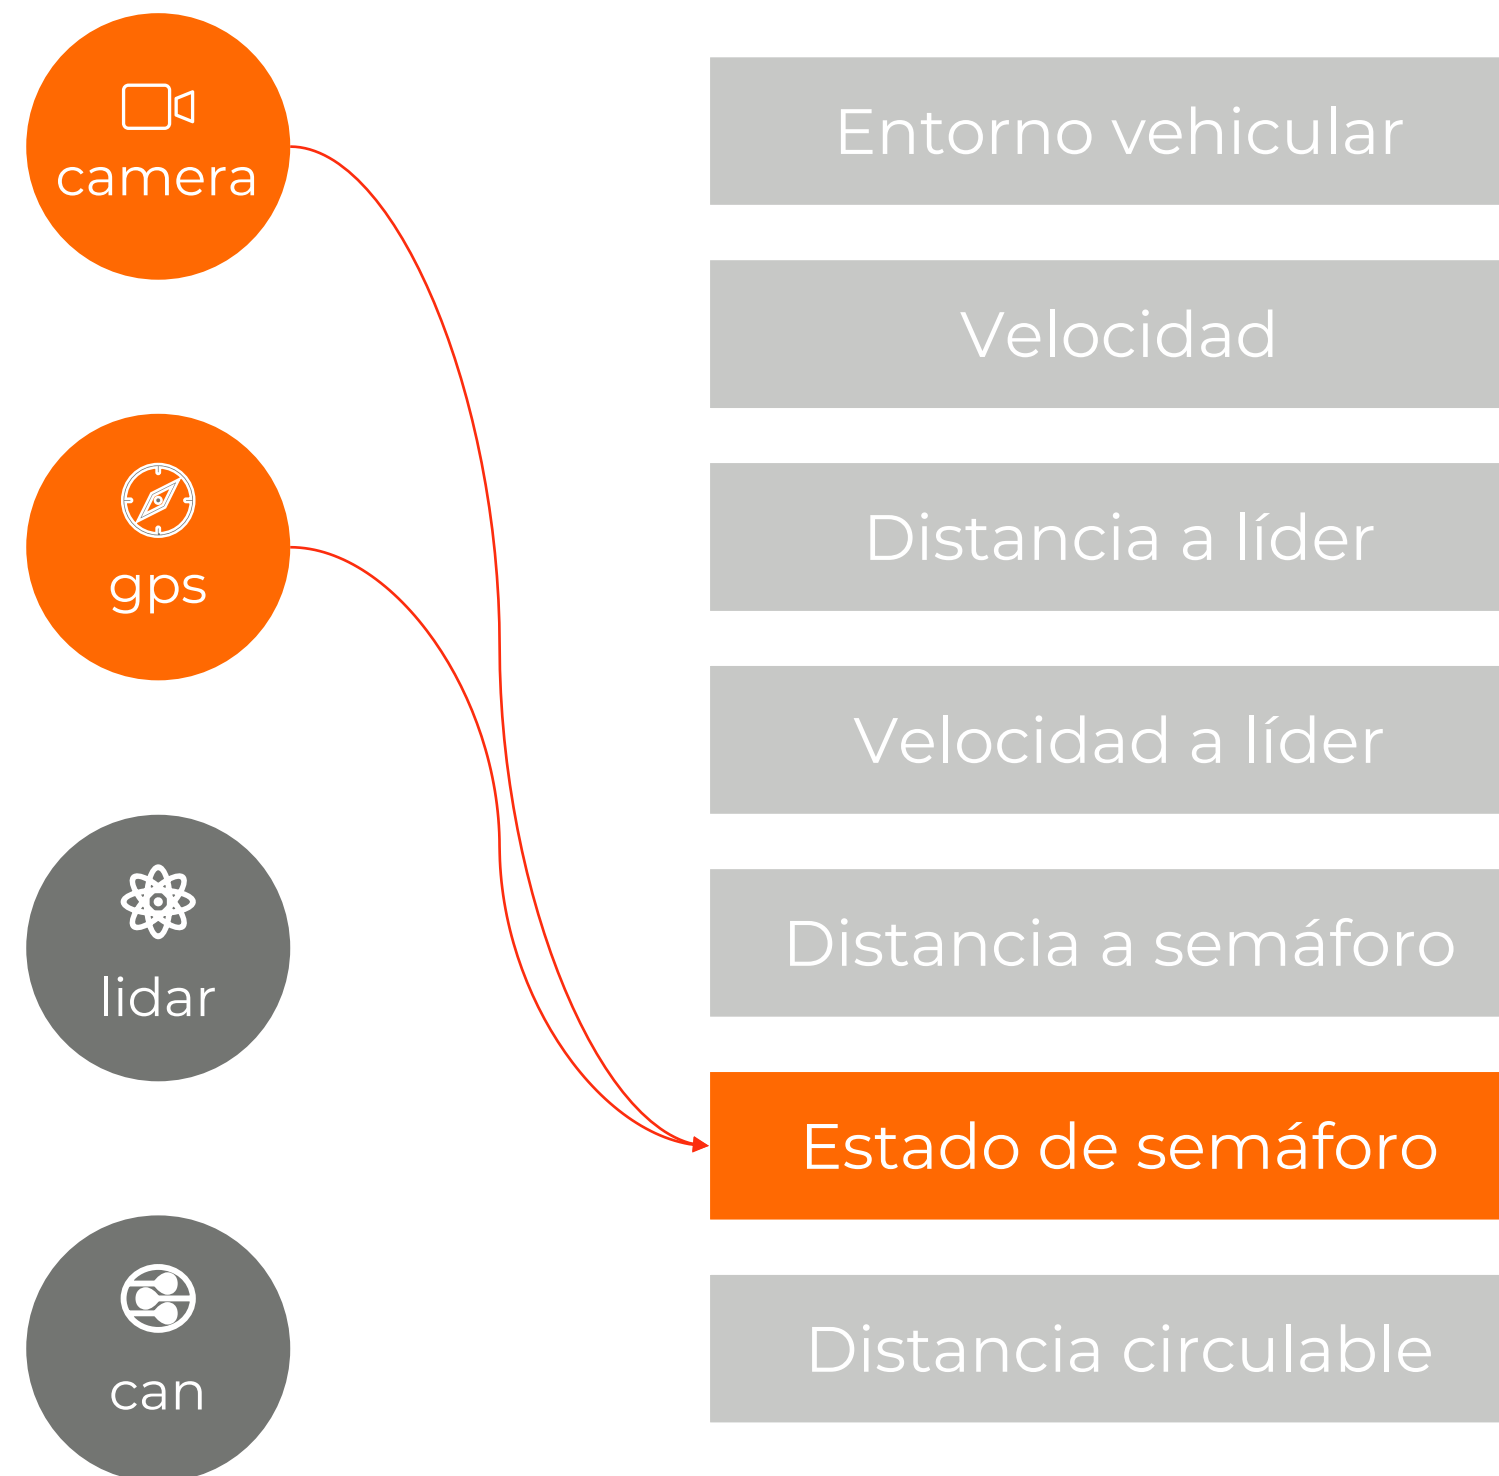
Variables capturadas



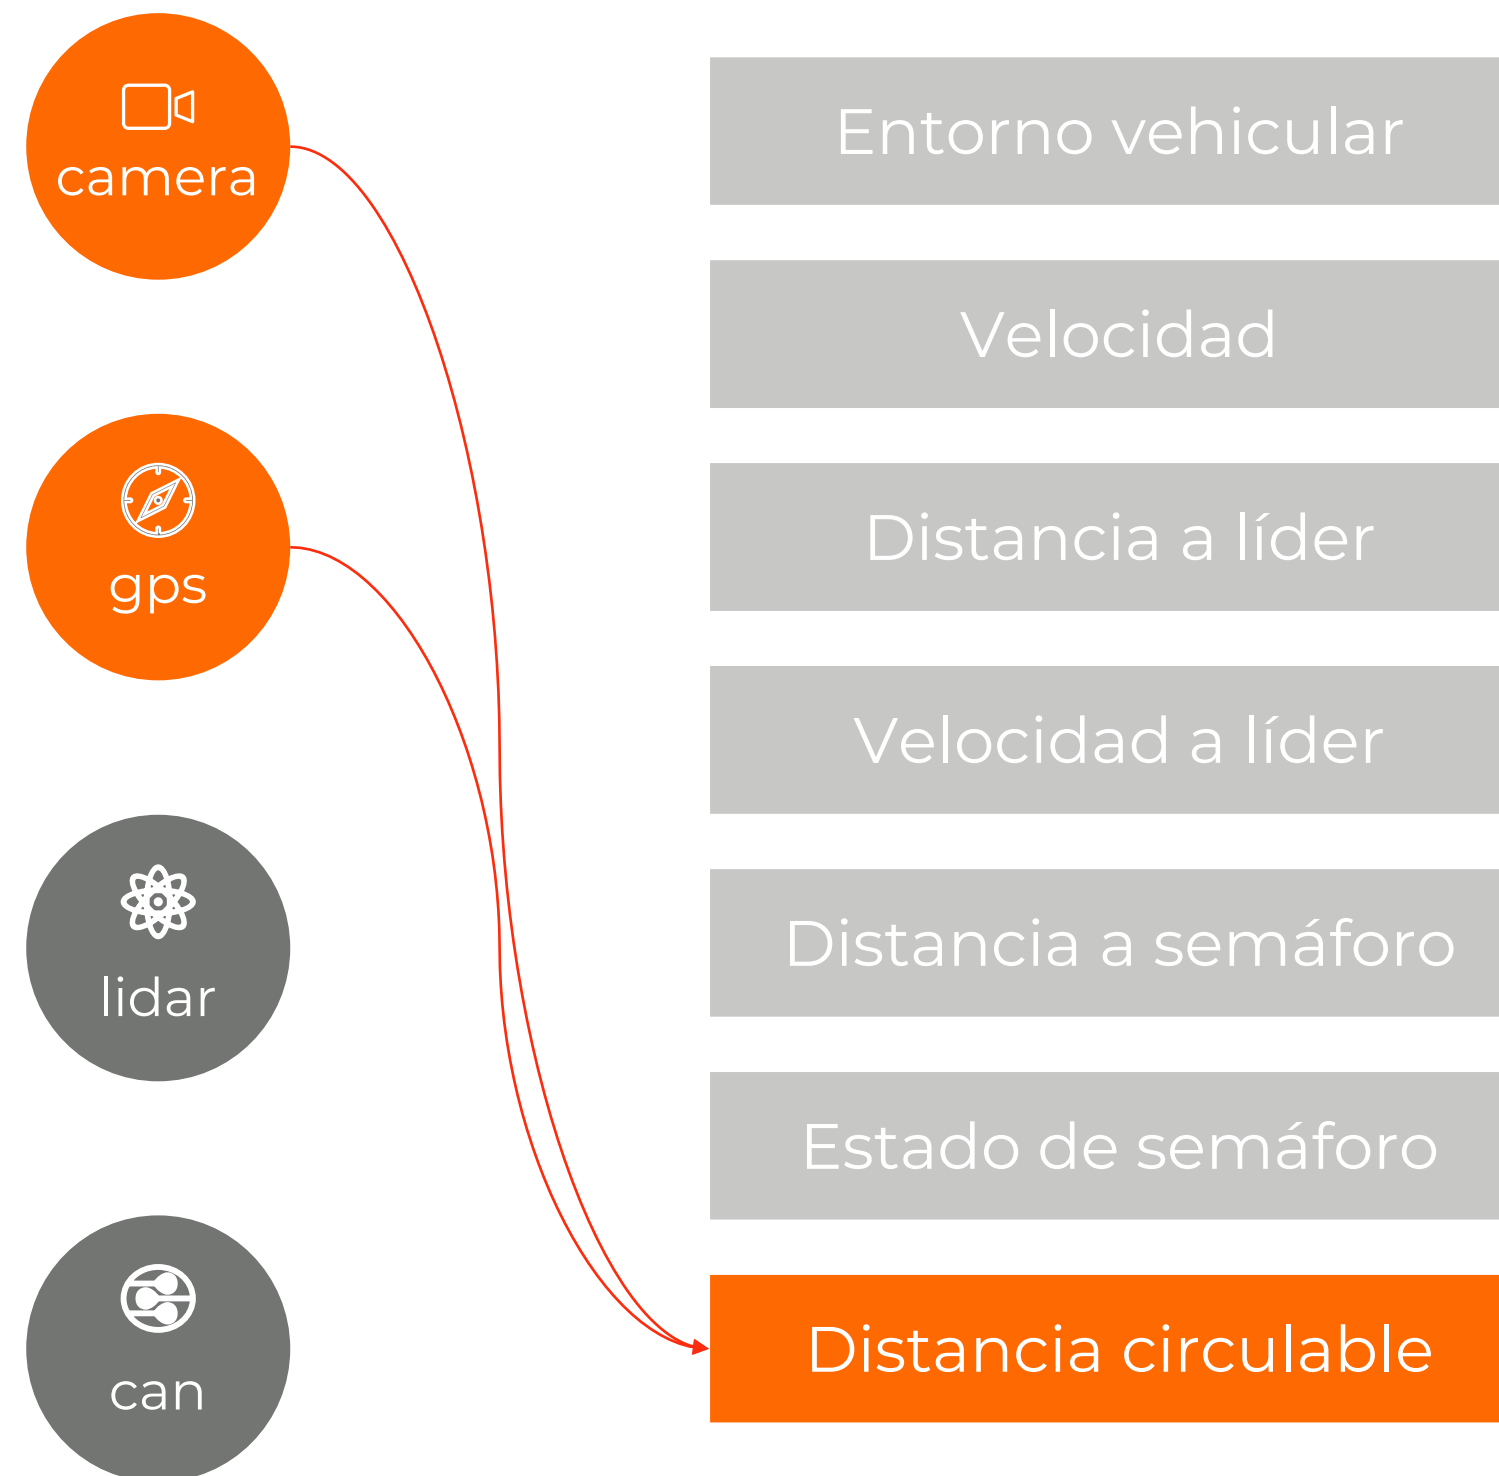
Variables capturadas



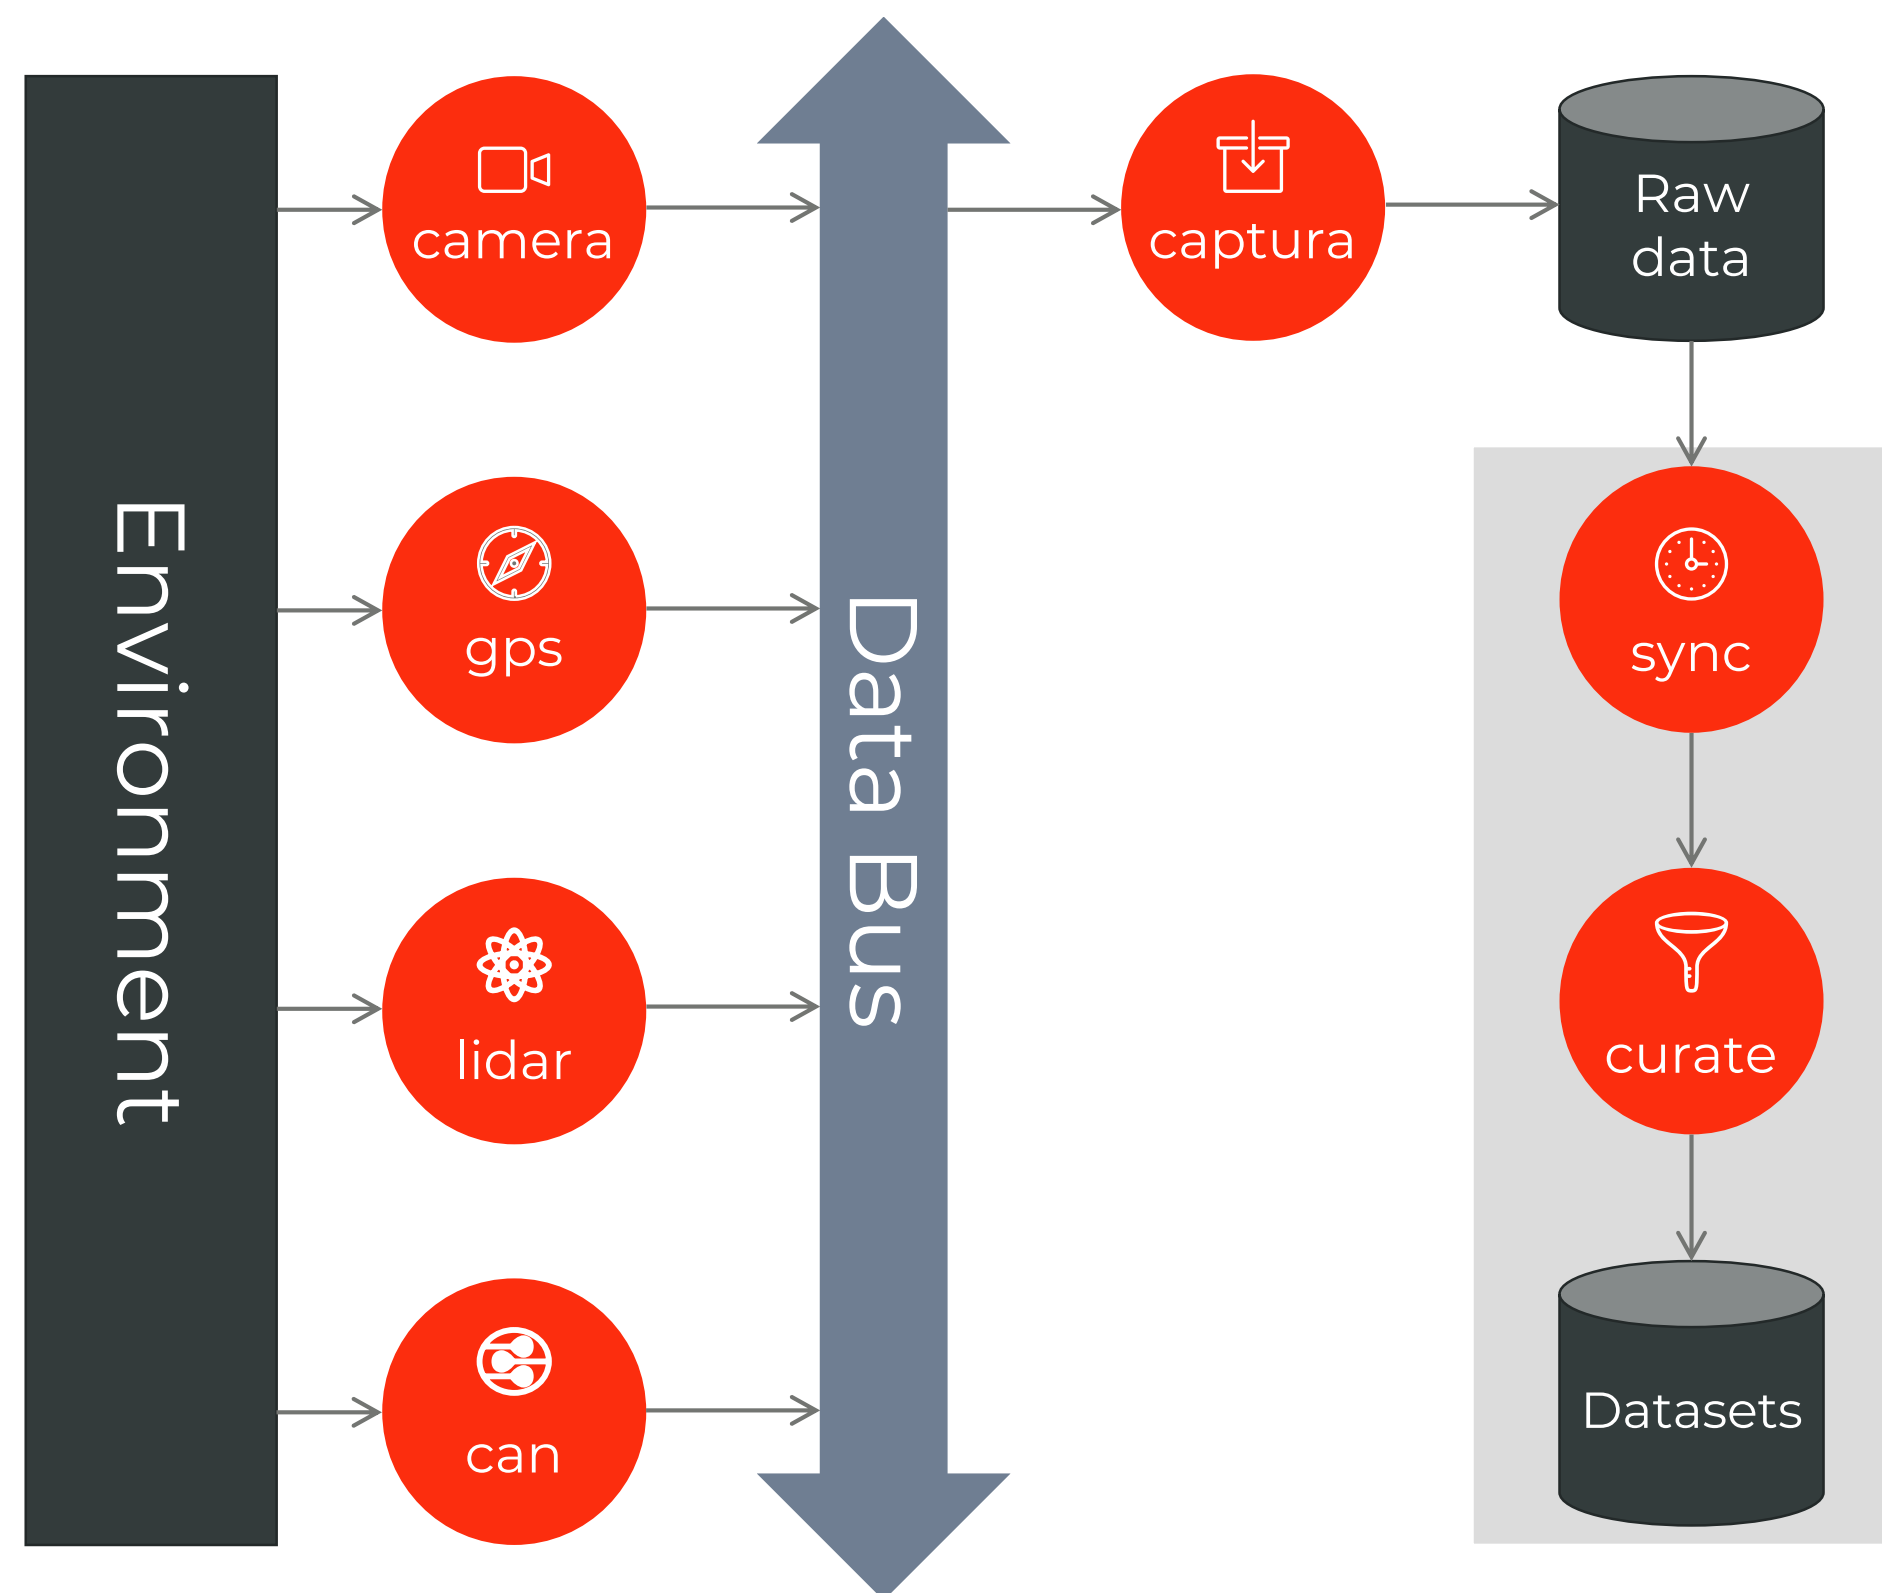
Variables capturadas



Variables capturadas



Arquitectura del sistema de captura



Sujetos de prueba

La captura de datos se han realizado con tres sujetos S_1 , S_2 y S_3 diferentes sobre los recorridos de entrenamiento y de test. Estas capturas se han tratado de realizar en las mismas condiciones en la medida de lo posible.

Tres sujetos de prueba

Los sujetos son varones de entre 30 y 34 años con más de 5 años de experiencia en conducción

Recorrido conocido

Al conocer el recorrido previamente, se prescinde en lo posible del nivel estratégico



Un dataset global

Los datos de los tres sujetos S_A darán lugar a un dataset de entrenamiento y otro de test.

Un dataset por sujeto

Cada sujeto S_1 , S_2 y S_3 tendrá asociado un conjunto de entrenamiento y otro de test.

Proceso a seguir



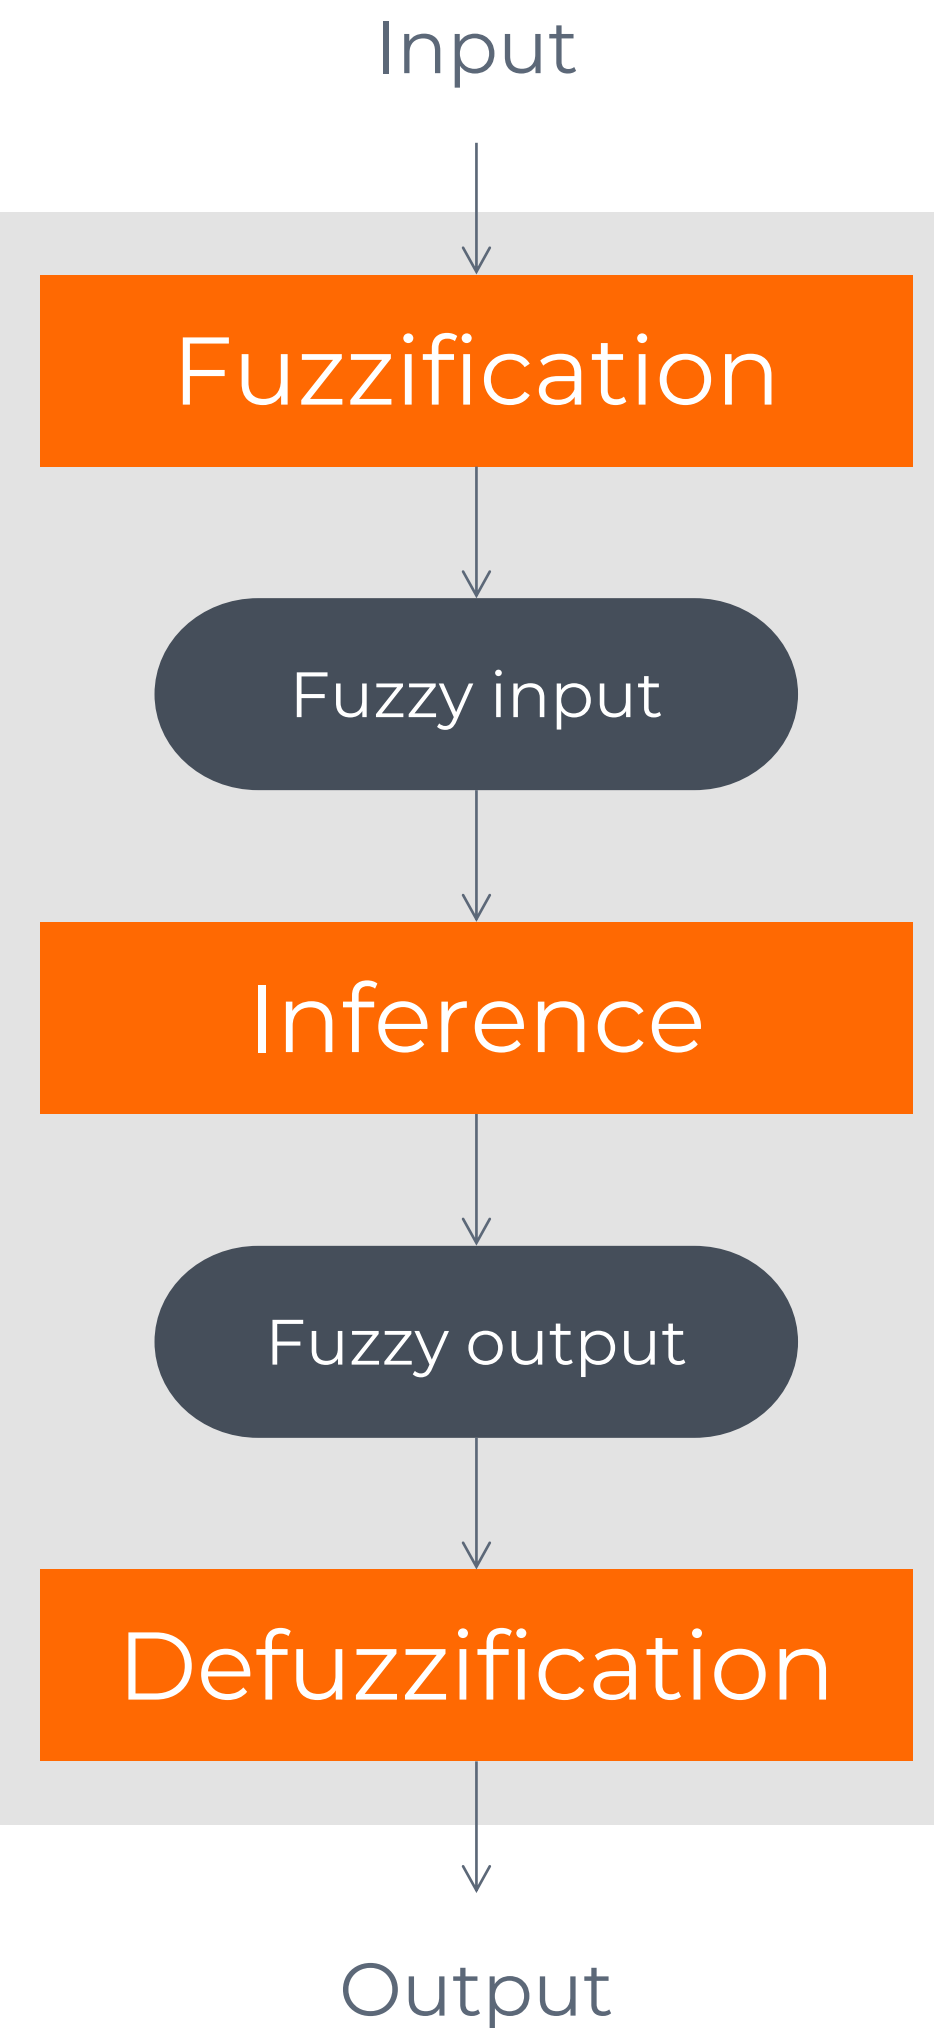
Controlador borroso

Cómo ajustar las variables del controlador: **Descenso del gradiente**

Aportación de la tesis: **Representación del controlador borroso como grafo computacional**

Limitaciones del estudio





Representación como grafo computacional



Fuzzificación

Es necesario **ajustar las variables** asociadas a las funciones de pertenencia de cada conjunto borroso.



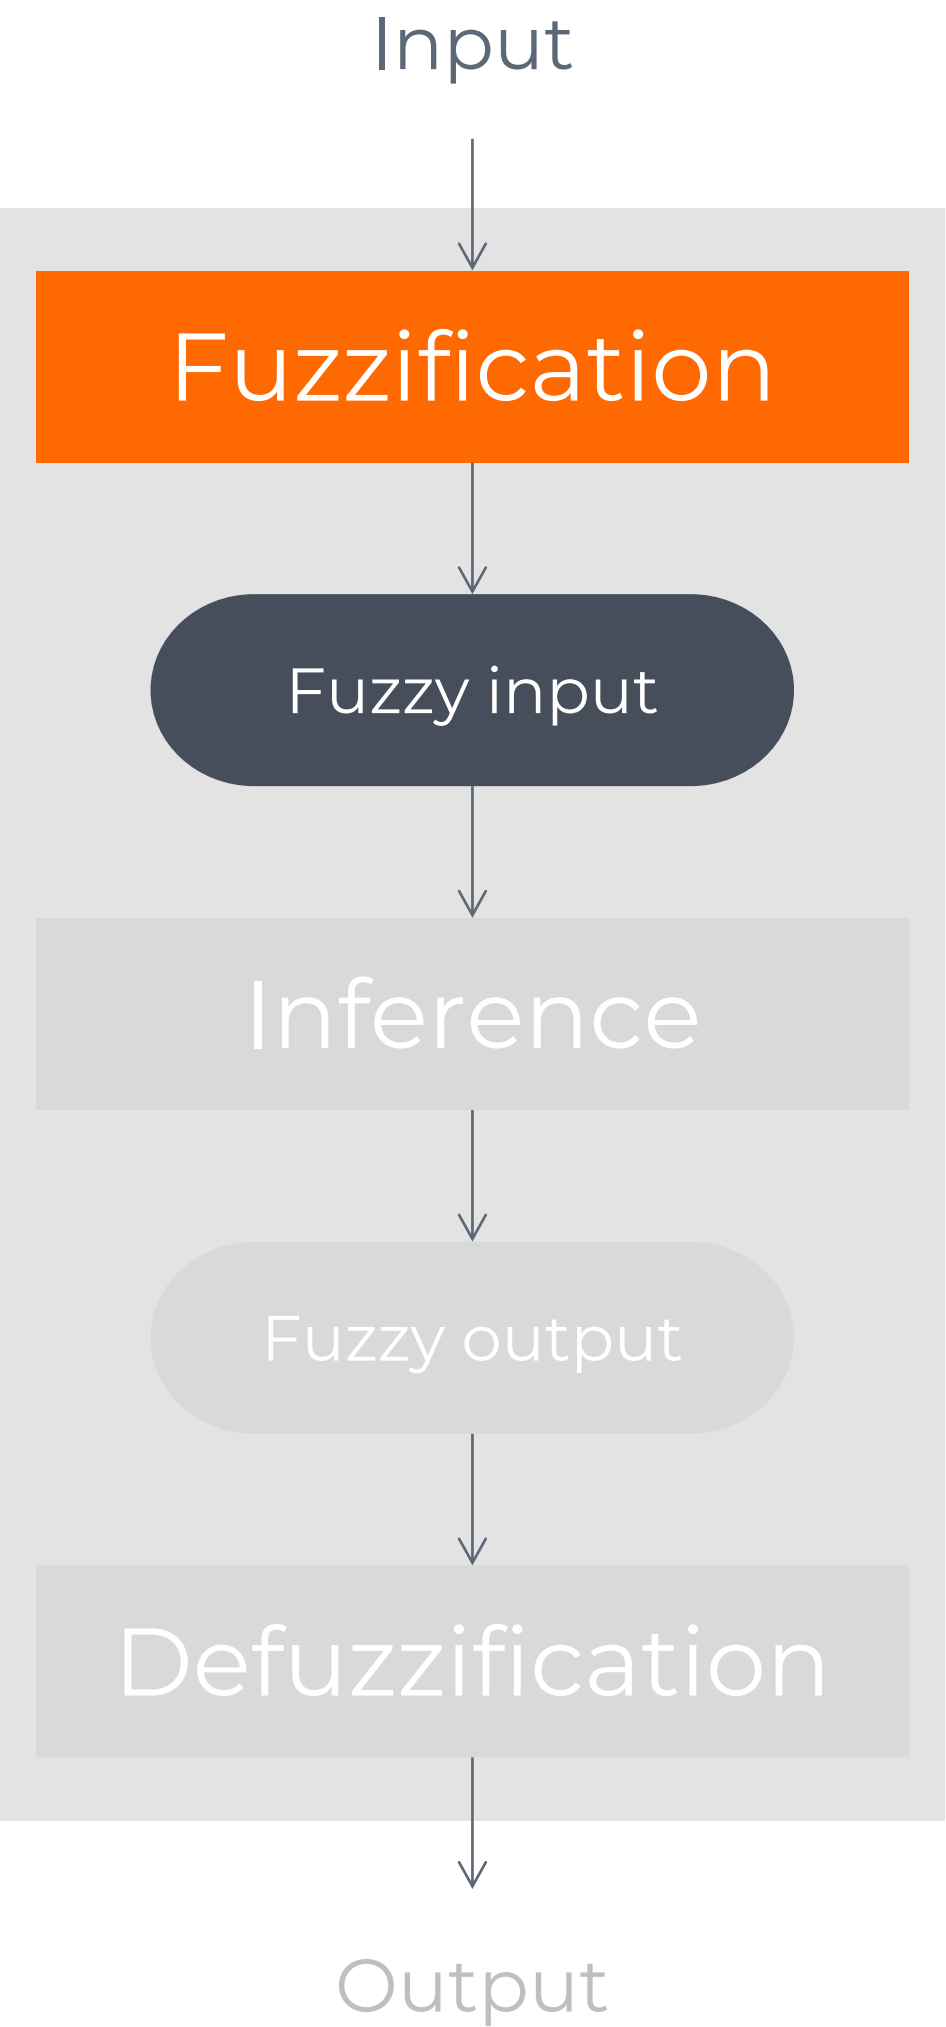
Inferencia

Es necesario **ajustar las variables** asociadas a las reglas que se activan en el proceso de inferencia.




Defuzzificación

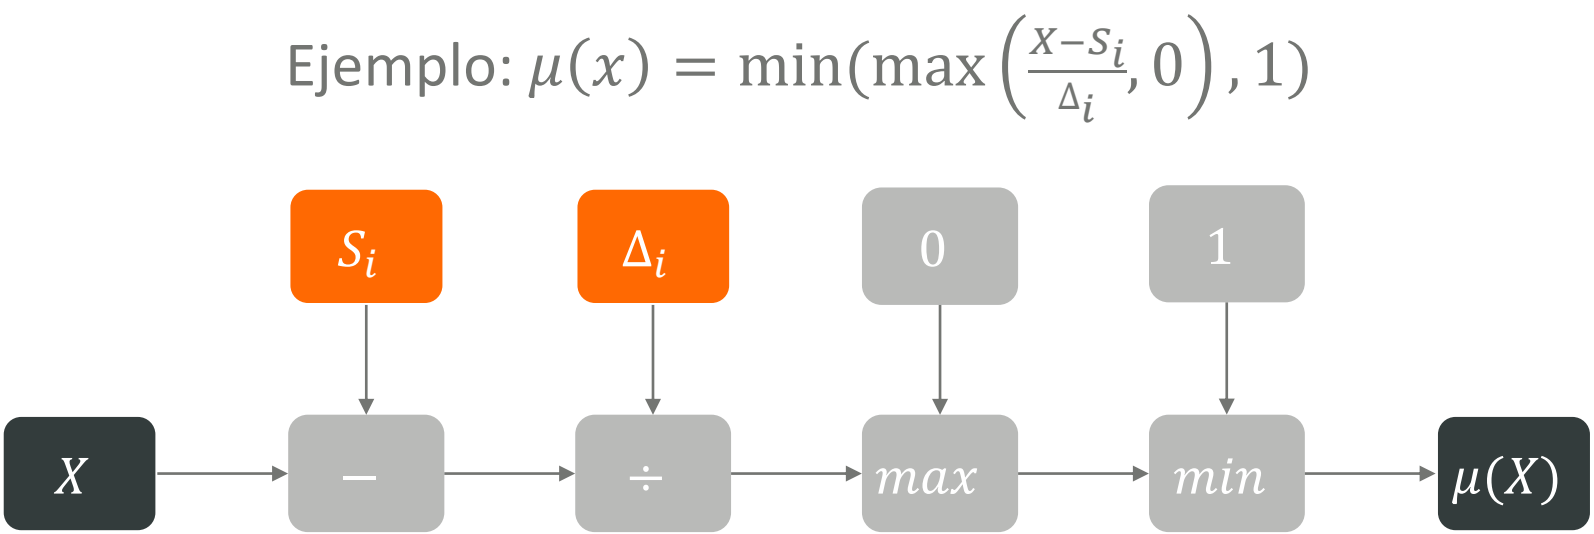
Es una operación que no necesita de ajuste.



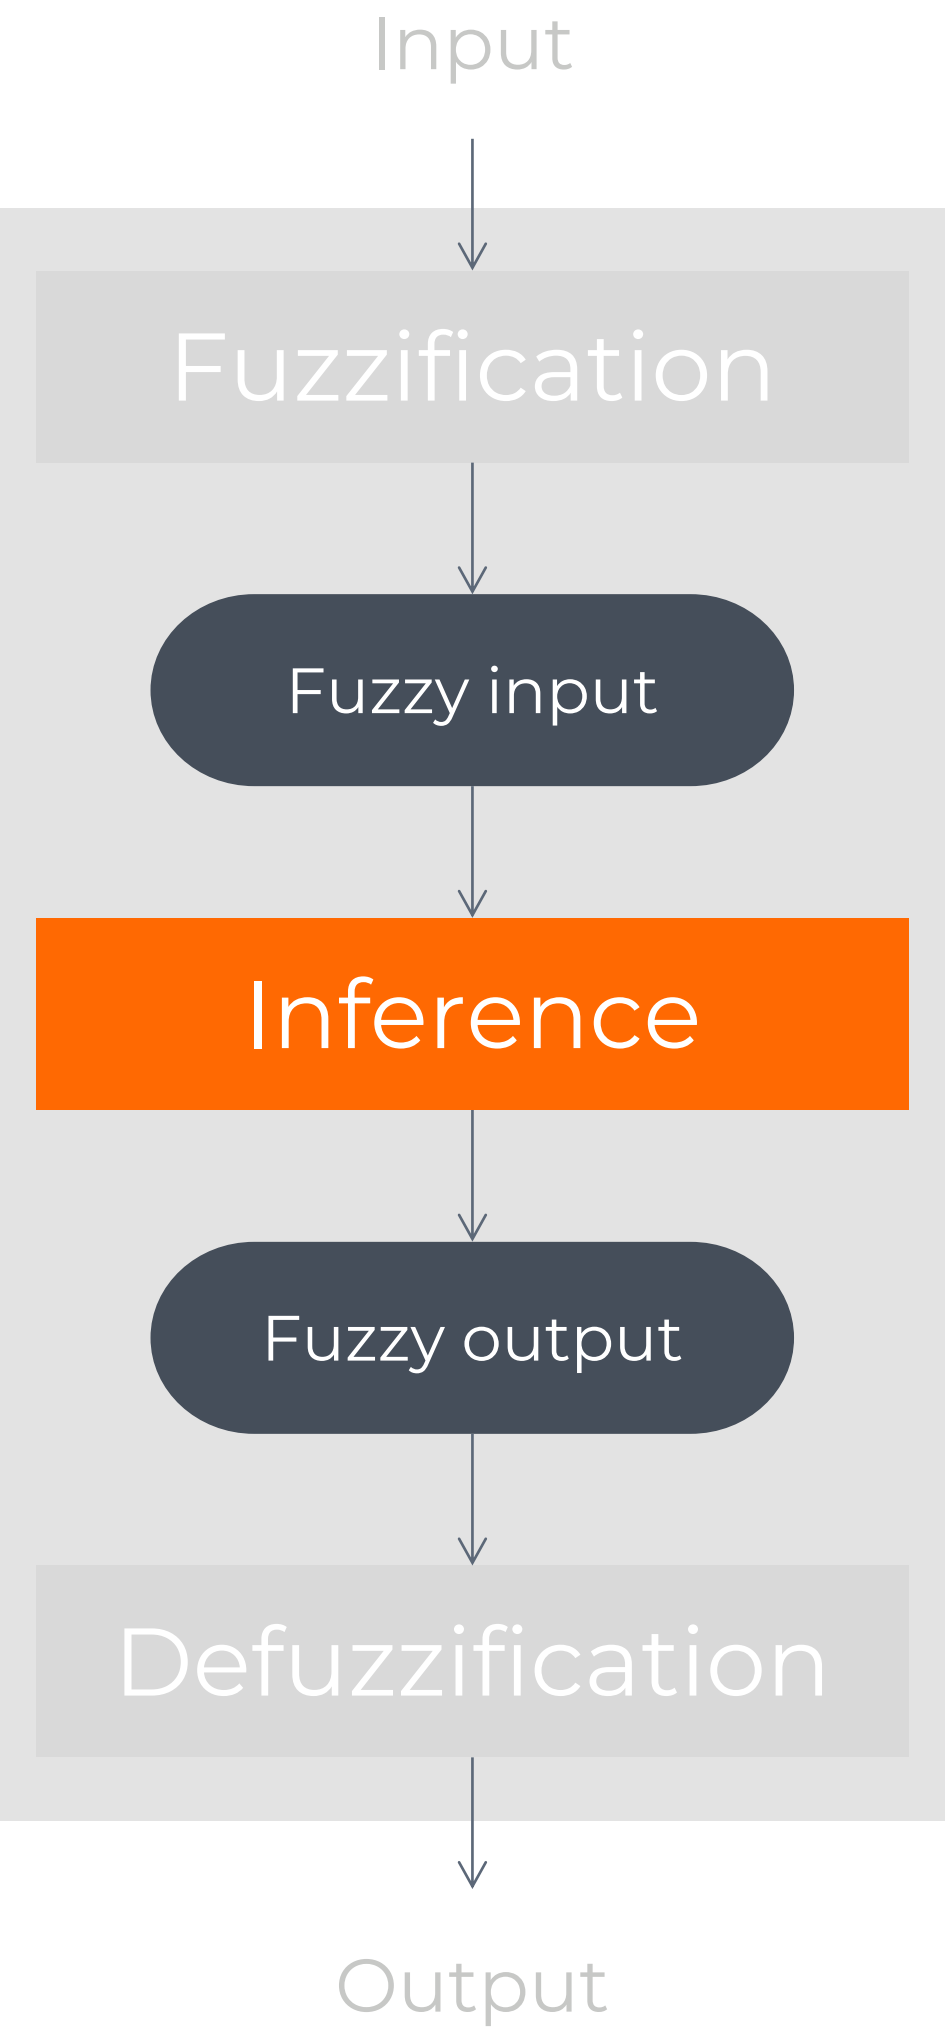
Grafo de fuzzificación



Cada función está **relacionada**, y posee **su propio grafo computacional**



Cada Δ_i es una de las variables del grafo a ajustar



Grafo de inferencia (I)

Entradas: $F = \cup_{i=1}^n S_i$, donde:



- **Representación matricial de reglas** para cada salida borrosa.
- **Matriz de pesos asociada** a cada matriz de reglas.

Salida borrosa para cada variable k : $\mu_{ok} = \bigvee T_{ok} \circ W_{ok}$ siendo \wedge la S -norm

Ejemplo para dos variables de entrada con dos conjuntos borrosos cada una

$T_{ok} =$

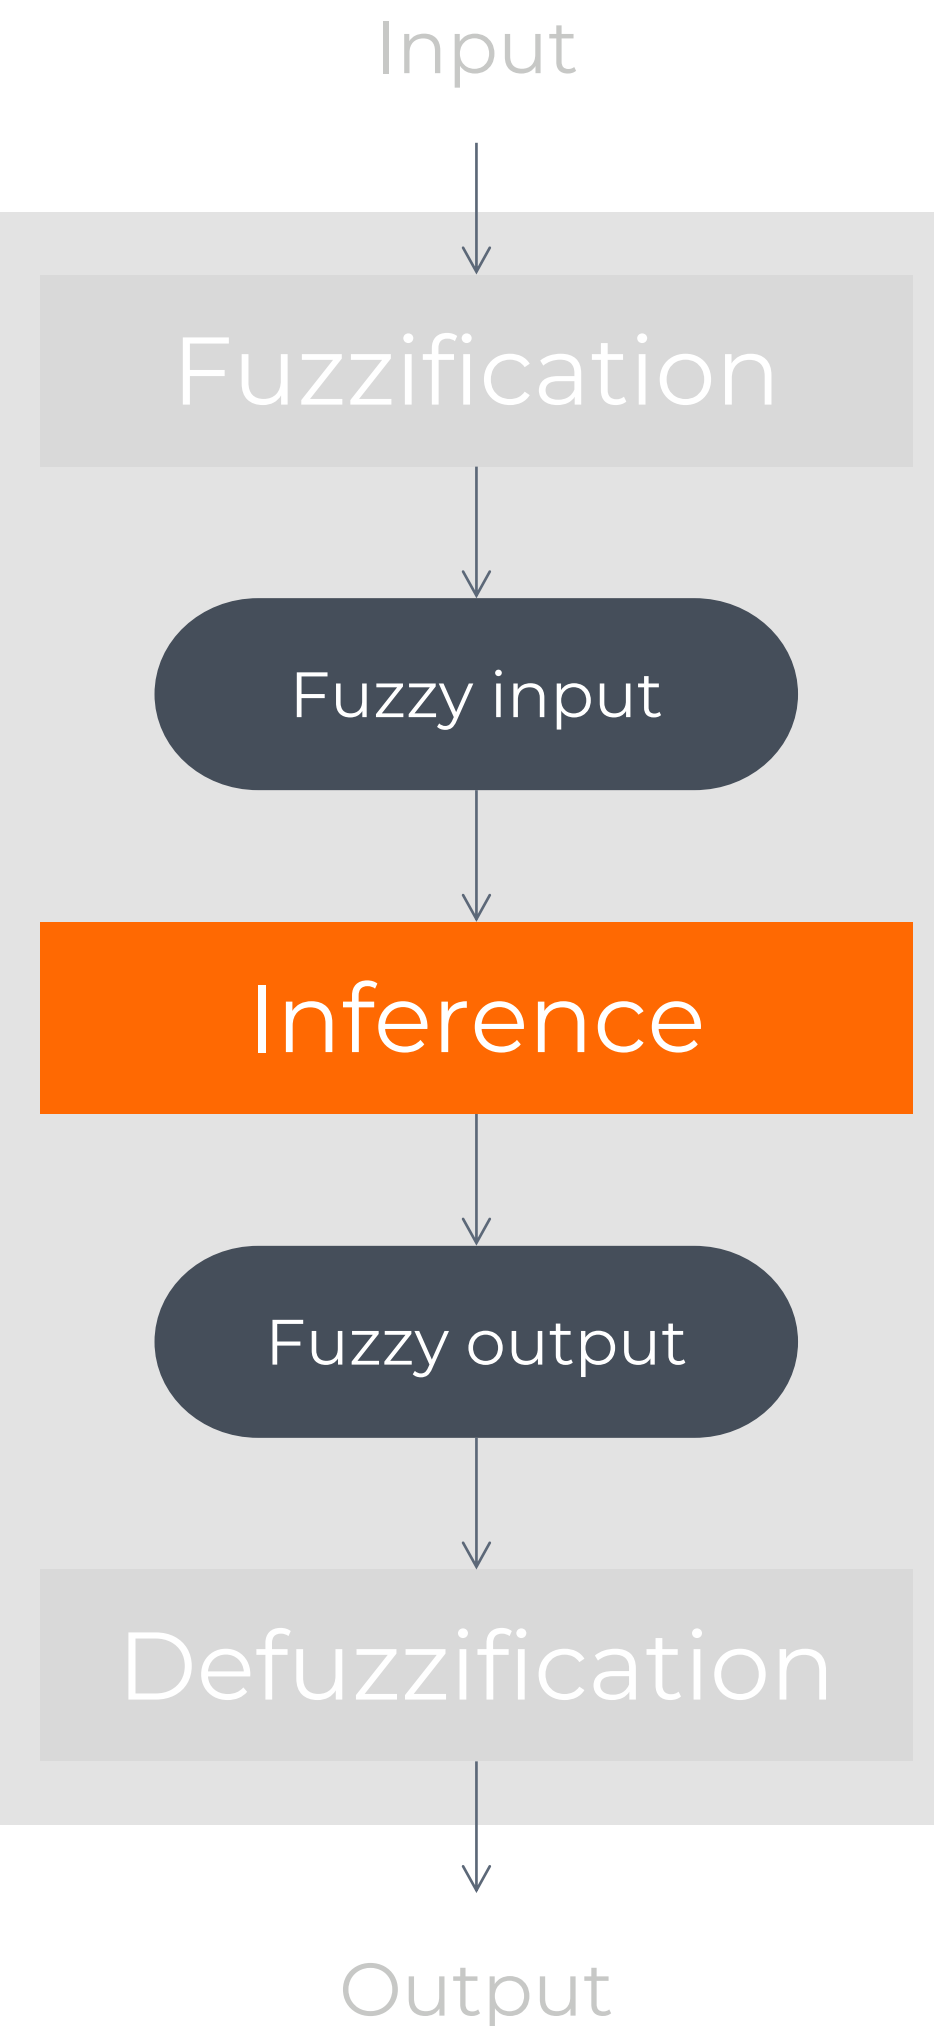
	μ_{11}	μ_{12}	μ_{13}
μ_{21}	T_1	T_2	T_3
μ_{22}	T_4	T_5	T_6

Reglas difusas (AND)

$W_{ok} =$

	w_{11}	w_{12}	w_{13}
w_{21}	1	1	0
w_{22}	0	1	0

Activación de reglas



Grafo de inferencia (II)

$$\mu_{ok} = \bigvee T_{ok} \circ W_{ok}$$

Esta representación sigue sin permitir el ajuste por descenso del gradiente

Solución

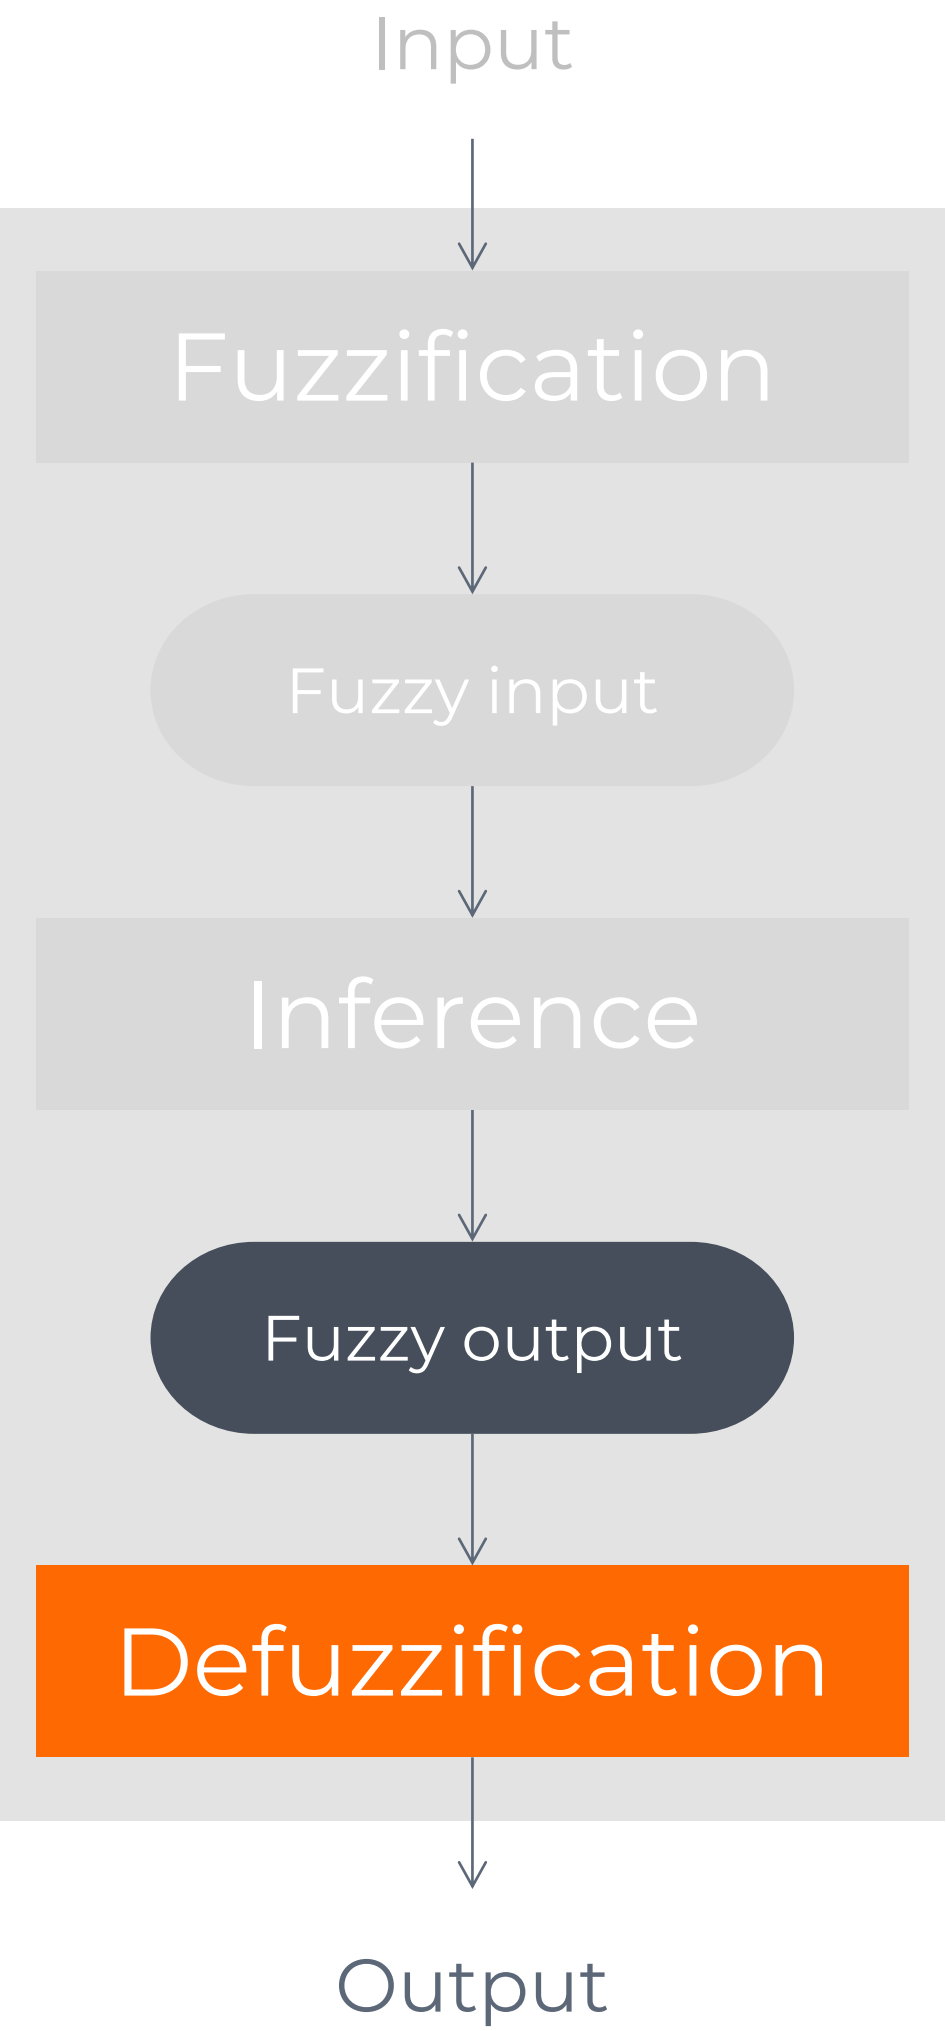
Pesos reales en lugar de binarios

Aplicación de sigmoideal σ

(Otras funciones, como tangente hiperbólica ofrecen, por ejemplo, reglas negadas)

$$\mu_{ok} = \bigvee T_{ok} \circ \sigma(W_{ok})$$

Cada $w \in W_{ok}$ es una variable del grafo a ajustar



Grafo de defuzzificación

El grafo es una simple operación que no requiere de ajuste de variables

Hemos optado por la función de defuzzificación media ponderada:

$$output = \frac{\sum_{i=1}^K \mu_i x_i}{\sum_{i=1}^K \mu_i}$$

Donde:

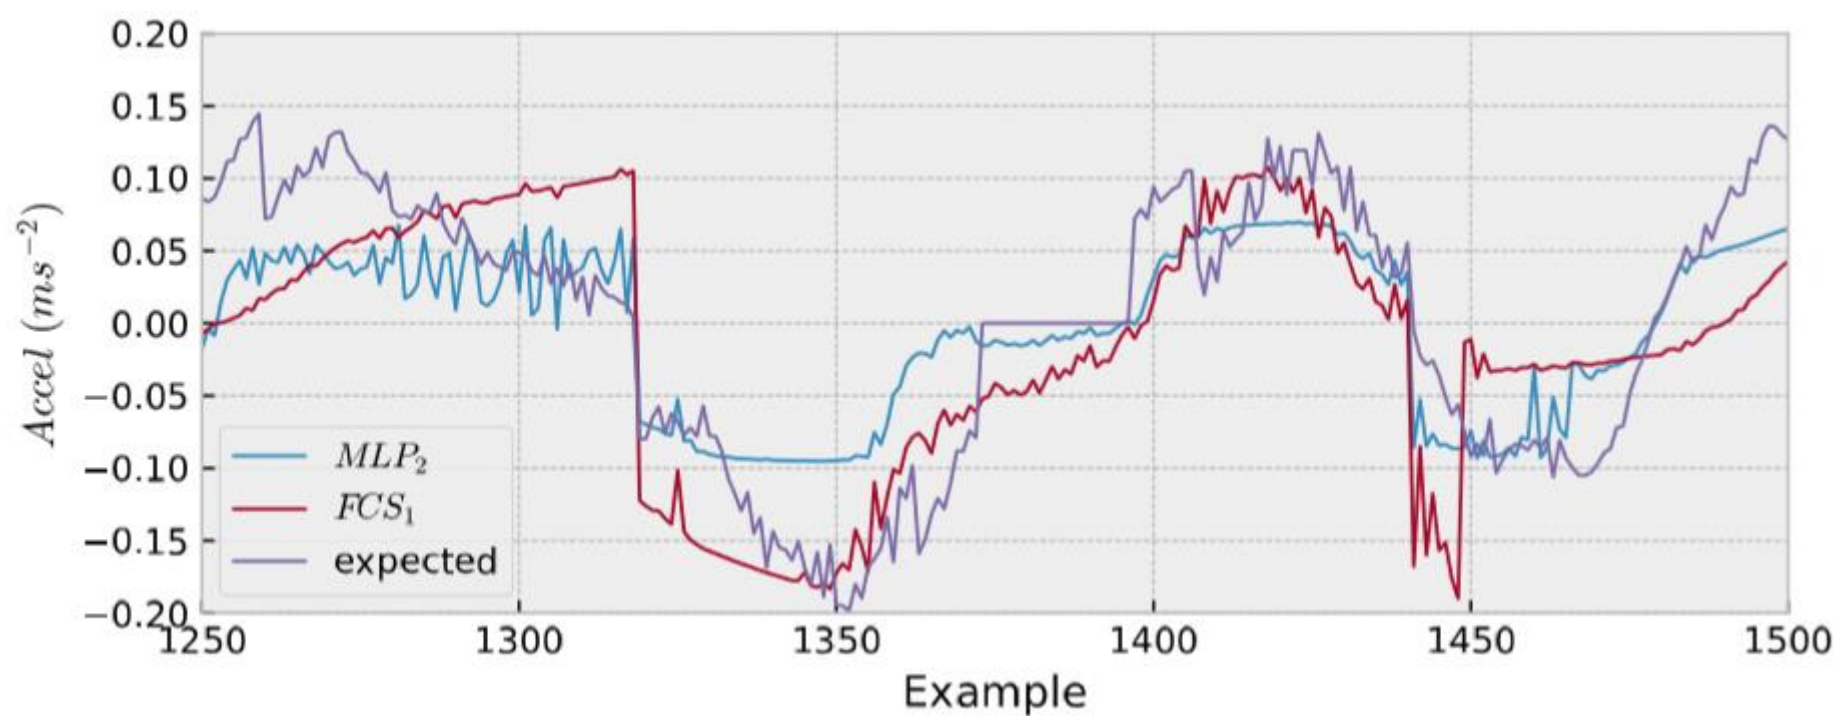
K	x_i	μ_i
<ul style="list-style-type: none">El número de conjuntos borrosos de salida	<ul style="list-style-type: none">El valor del conjunto borroso i-ésimo	<ul style="list-style-type: none">La salida borrosa para el conjunto borroso i-ésimo de salida

Comparación de modelos longitudinales

Se entrenan diferentes modelos de perceptrones multicapa y controladores borrosos para obtener el representante de cada una de estas dos clases. Los entrenamiento se realizan con los datos del conductor genérico S_A .

- Controlador borroso (FCS)
 - Dos conjuntos borrosos por variable de entrada
- Perceptrón multicapa (MLP)
 - Dos capas ocultas de 8 y 2 neuronas

RMSE (ms^{-1})	Training	Validation	Test
FCS	0,059	0,064	0,062
MLP	0,061	0,061	0,056



El comportamiento longitudinal se modeliza mejor con perceptrones multicapa

Capacidad de especificidad del modelo

Se compara el desempeño de los modelos específicos S_1 , S_2 y S_3 contra los datos reales de éstos en los conjuntos de test, esto es, datos con los que nunca han sido entrenados ninguno de los modelos.

RMSE	S_1	S_2	S_3
S_1	0,059	0,074	0,070
S_2	0,064	0,058	0,067
S_3	0,065	0,065	0,057

El menor error en cada prueba lo produce el modelo del sujeto que la realizó

Proceso a seguir



Retos

La naturaleza de las variables capturadas implica una serie de retos a superar antes de entrenar los modelos de comportamiento longitudinal



Información de entorno de tamaño variable

Los perceptrones multicapa y las redes de convolución requieren un número fijo de entradas. El tamaño del entorno ofrecido por el LiDAR, sin embargo, fluctúa.



Tamaño de los conjuntos de datos

El número de variables de entrada es extremadamente grande, por lo que son necesarios conjuntos de datos también suficientemente grandes.



Datos de tipo no imagen


Las redes de convolución están diseñadas para funcionar con matrices n -dimensionales. Nuestros conjuntos incluyen además otros tipos de variables.



Percepción temporal


Los cambios de carril no se deciden de manera inmediata, sino que requieren un tiempo de decisión que es necesario modelar.

Información del entorno de tamaño variable (I)



Mapa de profundidad

Dimensión $d = 360 \times 6 = 2160$ entradas




Información del entorno de tamaño variable (II)

La propia naturaleza de las convoluciones hace que en los extremos se pierda información

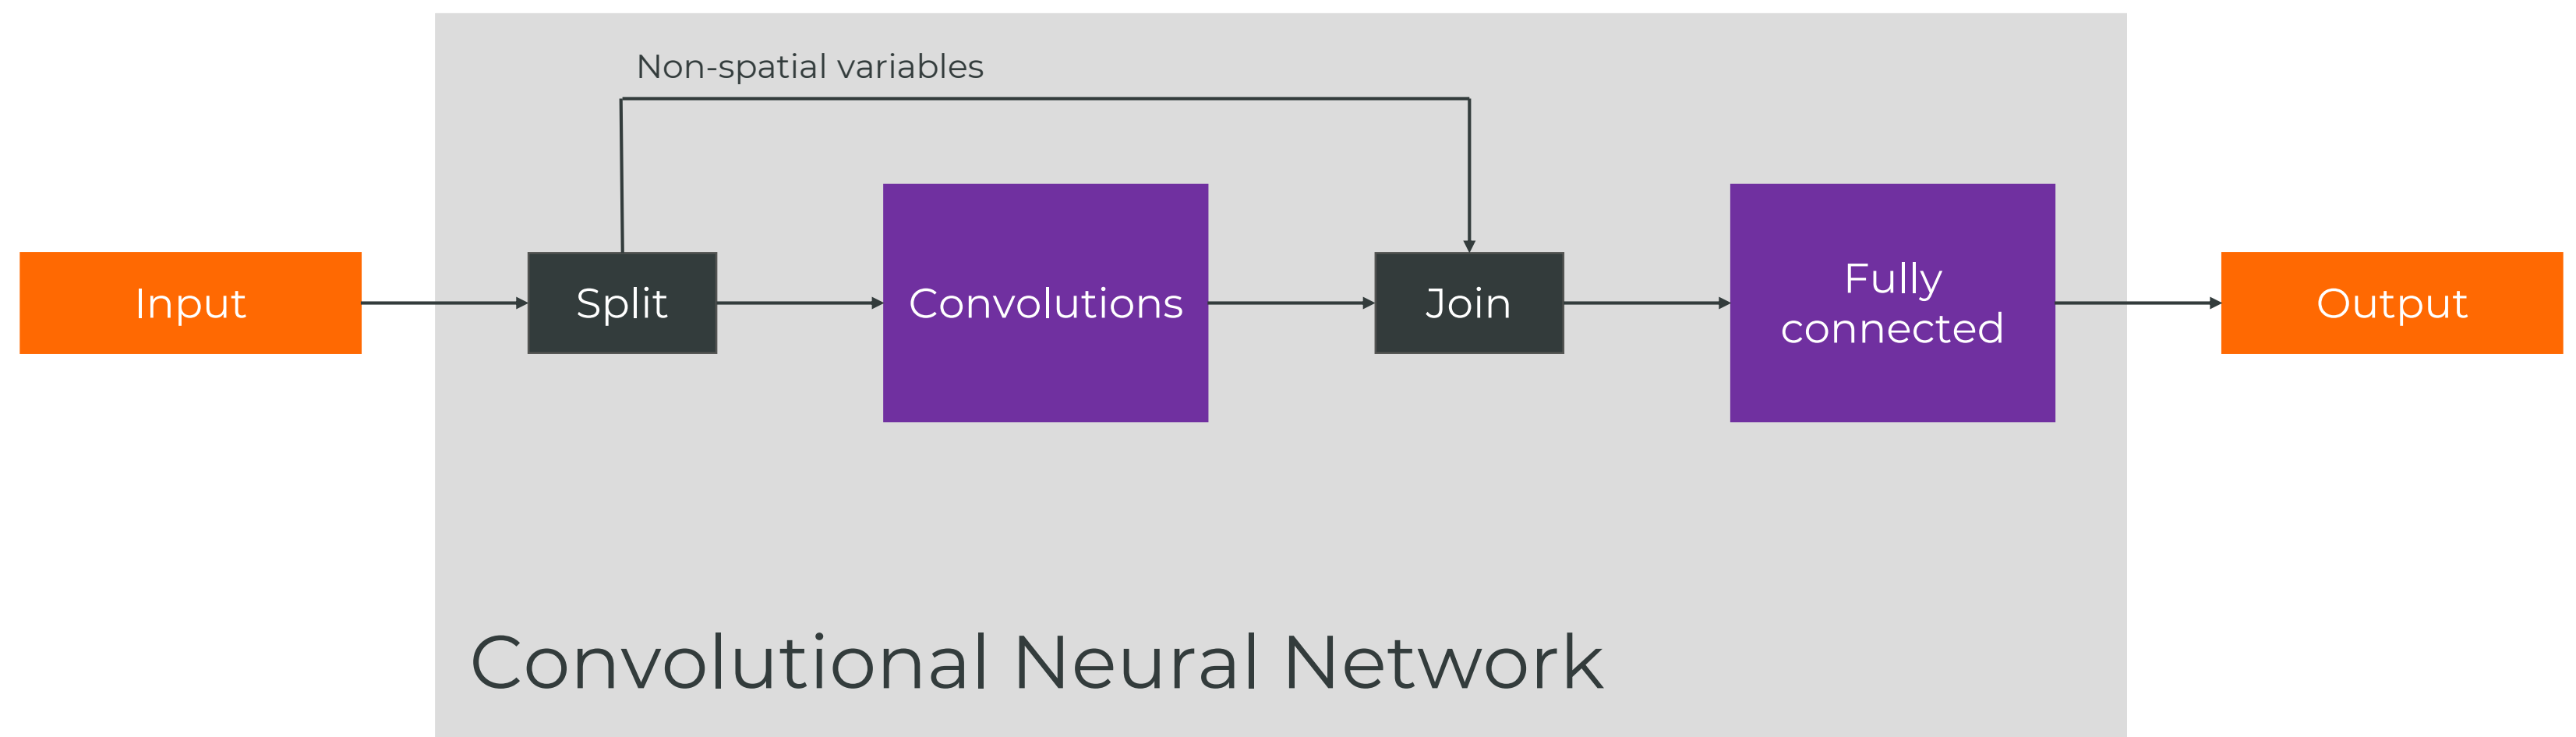
Los extremos derecho e izquierdo de nuestra imagen son la parte trasera del vehículo

Solución: añadir un padding con los extremos opuestos de la imagen



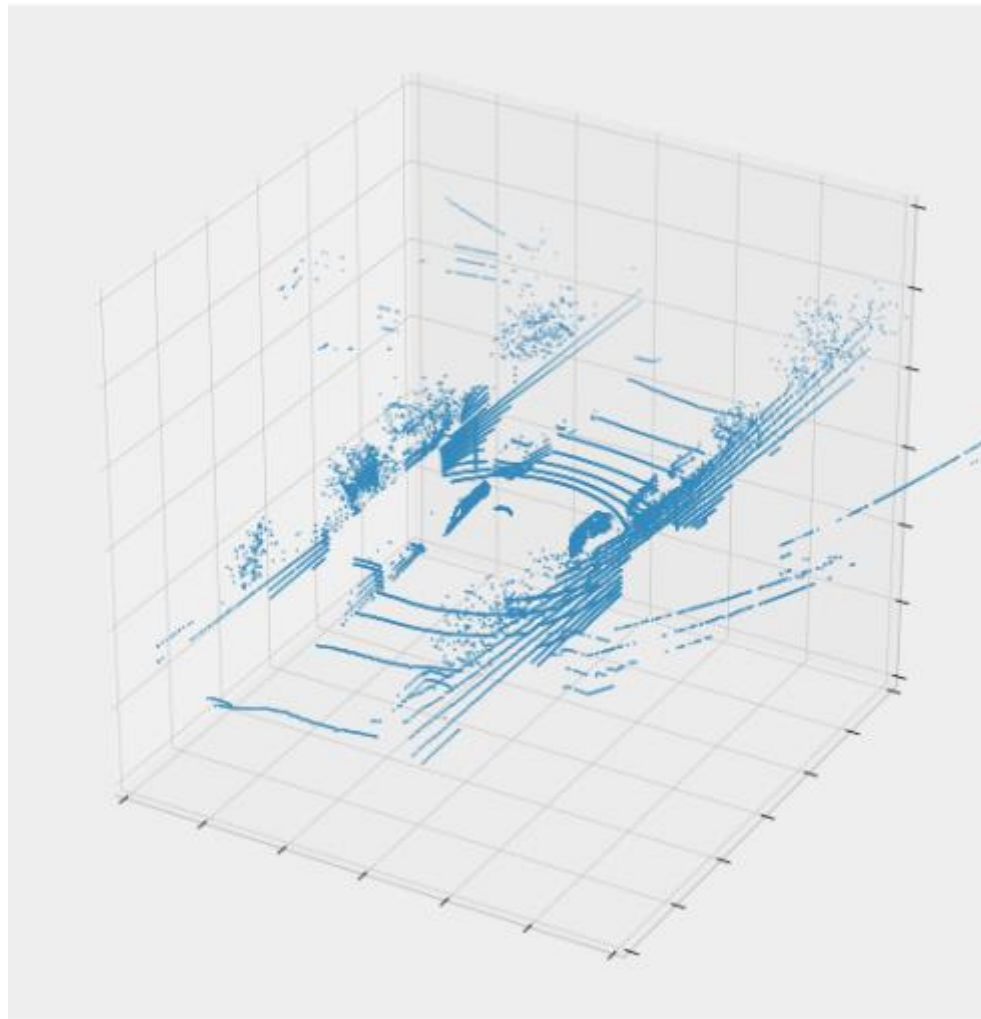
De esta manera las convoluciones actúan sobre todos los posibles patrones horizontales

Datos de tipo no imagen




El componente de **detección de patrones sólo** se **aplica** a la **imagen** de entrada



El componente de **inferencia** se **aplica** a los patrones detectados de la **imagen** y a las entradas tipo **no imagen**



Nube de puntos original



Mirroring

Shaking ($\Delta = 3cm$)Shaking ($\Delta = 20cm$)

Tamaño de los conjuntos de datos

En [Díaz Álvarez et al., 2018] se probó empíricamente que el uso de las técnicas *mirroring* y *shaking* mejoraban la precisión y generalización de los modelos entrenados

Mirroring

Asumimos que en entorno urbano, las situaciones se pueden considerar simétricas.

Shaking

A cada uno de los puntos de la nube original se le aplica un desplazamiento aleatorio en un pequeño rango.

La imagen resultante es ligeramente diferente, pero representa un escenario muy similar.

Percepción temporal

En este trabajo asumimos que la maniobra de cambio de carril involucra tanto al córtex visual como al córtex prefrontal, los cuales se estima que tienen un tiempo de proceso de entre 0.2 s y 1.2 s [Buzsáki et al., 2012].



Ventana temporal

Las entradas se duplican tantas veces como momentos anteriores queremos percibir.



t_0, t_{10} y t_{20}

En [Díaz Álvarez et al., 2018] t_0 , t_{10} y t_{20} son los momentos que mejores resultado arrojan



Project Three

En las redes de convolución, se presentan como imágenes apiladas a lo largo de una dimensión.

Comparación de modelos laterales

Se entrenan diferentes modelos de perceptrones multicapa redes de convolución para obtener el representante de cada una de estas dos clases. Los entrenamiento se realizan con los datos del conductor genérico S_A .


Perceptrón multicapa (MLP)

- Ninguna arquitectura superó el 33% de acierto


Red de convolución

- Convolución (5 × 36), convolución (3 × 5) y dos capas de 128 y 16 neuronas

Precisión	Training	Validation	Test
MLP	0,333	0,333	0,333
CNN	0,506	0,531	0,518



Instantáneo



Después de 3 s.

El comportamiento lateral se modeliza mejor con redes de convolución


Capacidad de especificidad del modelo

Se compara la precisión de los modelos específicos S_1 , S_2 y S_3 contra los datos reales de éstos en los conjuntos de test, esto es, datos con los que nunca han sido entrenados ninguno de los modelos.

Precisión	S_1	S_2	S_3
S_1	0,768	0,314	0,601
S_2	0,601	0,706	0,511
S_3	0,648	0,666	0,710

La mayor precisión en cada prueba la produce el modelo del sujeto que la realizó

Proceso a seguir



Comparativa

Para validar el desempeño de los conductores modelados en el simulador se han comparado los valores de los cuatro conjuntos de conductores S_A , S_1 , S_2 y S_3 con los valores de sus respectivos conductores simulados, y con el modelo por defecto de SUMO.



El recorrido simulado es similar al recorrido real de test

El recorrido se ha extraído de OpenStreet Maps (OSM) y ha sido modificado para corregir los problemas, eliminar las características sobrantes y añadir aquellas que faltan.




Tres recorridos por modelo

Se han utilizado los datos de tres recorridos para cada modelo de conductor simulador en escenarios con diferentes semillas aleatorias.


Validación del modelo longitudinal (I)

Los comportamientos longitudinales se comparan a partir de indicadores de **velocidad, aceleración y sobre-aceleración**. Las gráficas muestran los valores para los datos extraídos de los sujetos reales, de los modelos de conductor asociados a dichos sujetos y de los modelos de conductor proporcionados por SUMO.



Las velocidades entre modelo real y simulado difieren del modelo de SUMO


Validación del modelo longitudinal (II)



Las aceleraciones son mucho mayores en SUMO

La varianza de la aceleración positiva es significativamente mayor en el modelo real


Validación del modelo longitudinal (III)



Las sobre-aceleraciones son mayores en el caso de los datos de conducción reales.

Validación del modelo lateral (I)

El comportamiento lateral se compara atendiendo a los valores medios de número de cambios de carril entre todos los modelos.



Significativamente más cambios de carril en el modelo de SUMO

Ligeramente menos cambios de carril en modelo entrenado

Conclusiones

Objetivos

Tras la metodología, se resume el grado de consecución de los objetivos planteados.



Se han desarrollado modelos de conducción a partir de datos de conductores reales.



Los comportamientos de los modelos se han logrado incorporar en agentes en funcionamiento dentro de simuladores.



Los modelos de comportamiento se han logrado adaptar a conductores en concreto.



Los modelos en simulación replican mejor el comportamiento humano que los modelos deterministas ya implementados.

Aportaciones de la tesis

A continuación se resumen las principales aportaciones a la literatura científica que se han conseguido con el desarrollo de la tesis.

Metodología para generación de modelos de comportamiento humano a partir de datos reales

Modelos de comportamiento capaces de ser personalizados a nivel de sujeto

Representación de controladores borrosos como grafos computacionales

Ajuste de controladores borrosos a través de métodos de descenso del gradiente

Líneas futuras de investigación

Se plantean una serie de líneas sobre las que trabajar tomando como base el punto al que se ha llegado tras la consecución de esta tesis.

Entornos de simulación más realistas

Adaptación de simuladores de conducción al problema del tráfico para incorporar los modelos descritos y así evitar las limitaciones del entorno.

Otras características vehiculares

Creación de perfiles de características como consumo, emisión de gases o de ruido a partir de los datos exactos del vehículo estudiado.

Diferentes escenarios y actores

Trabajo sobre vehículos de grandes dimensiones, escenarios específicos como rotondas, o directamente sobre vehículo autónomo.

Redes neuronales recurrentes

El uso de redes recurrentes puede ayudar más a la personalización de la ventana temporal de cada sujeto.

Publicaciones

Revistas

2018 (Q2)

Talavera, E., Díaz-Álvarez, A., Jiménez, F., & Naranjo, J. E. *Impact on Congestion and Fuel Consumption of a Cooperative Adaptive Cruise Control System with Lane-Level Position Estimation*. Energies, 11(1), 194, 2018.

2018 (Q2)

Díaz-Álvarez, A., Clavijo, M., Jiménez, F. Talavera, E., & Serradilla, F. *Modelling the human lane-change execution behaviour through Multilayer Perceptrons and Convolutional Neural Networks*. Transportation Research Part F: Psychology and Behaviour, 2018.

2018 (Q2)

Olaverri-Monreal, C., Errea-Moreno, J., & Díaz-Álvarez, A. *Implementation and Evaluation of a Traffic Light Assistance System Based on V2I Communication in a Simulation Framework*. Journal of Advanced Transportation, 2018

2016 (Q1)

Jiménez, F., Naranjo, J. E., Serradilla, F., Pérez, E., Hernández, M. J., Ruiz, T., ... & Díaz-Álvarez, A. *Intravehicular, short-and long-range communication information fusion for providing safe speed warnings*. Sensors, 16(1), 131, 2016.

2014 (Q3)

Díaz-Álvarez, A., Garcia, F. S., Naranjo, J. E., Anaya, J. J., & Jimenez, F. (2014). *Modeling the driving behavior of electric vehicles using smartphones and neural networks*. IEEE Intelligent Transportation Systems Magazine, 6(3), 44-53, 2014

2015 (Q4)

Díaz-Álvarez, A., Serradilla-García, F., Anaya-Catalán, J. J., Jiménez-Alonso, F., & Naranjo-Hernández, J. E. *Estimación de la autonomía de un vehículo eléctrico según el estilo de conducción*. DYNA-Ingeniería e Industria, 90(3), 2015.

Congresos

2017

Clavijo, M., Serradilla, F., Naranjo, J.E., Jiménez F., & Díaz-Álvarez, A. *Application of Deep Learning to Route Odometry Estimation from LiDAR Data*. Advances in Vehicular Systems, Technologies and Applications, 2017 The Sixth International Conference on (pp. 60-65). Internacional.

2018

Clavijo, M., Díaz-Álvarez, A., Serradilla, F., Jiménez F., Naranjo, J.E. *Deep learning application for 3D LiDAR odometry estimation in autonomous vehicles*. Connected and Automated Transport, 2018 Transport Research Arena (TRA).Internacional.

2015

Jiménez, F., Amarillo, J. C., Naranjo, J. E., Serradilla, F., & Díaz-Álvarez, A. *Energy consumption estimation in electric vehicles considering driving style*. In Intelligent Transportation Systems (ITSC), 2015 IEEE 18th International Conference on (pp. 101-106). IEEE.

ESCUELA TÉCNICA SUPERIOR DE INGENIEROS INFORMÁTICOS

Modelado de Comportamiento de Conductores con Técnicas de Inteligencia Computacional

DEFENSA PARA LA OBTENCIÓN DEL TÍTULO DE
DOCTORADO EN INTELIGENCIA ARTIFICIAL

AUTOR

ALBERTO DÍAZ ÁLVAREZ

DIRECTORES

FRANCISCO SERRADILLA GARCÍA

FELIPE JIMÉNEZ ALONSO