

DEPARTAMENTO DE INTELIGENCIA ARTIFICIAL
ESCUELA TÉCNICA SUPERIOR DE INGENIEROS
INFORMÁTICOS

MODELADO DE COMPORTAMIENTO DE CONDUCTORES CON TÉCNICAS DE INTELIGENCIA COMPUTACIONAL

TESIS DOCTORAL

Alberto Díaz Álvarez

Máster en Ciencias y Tecnologías de la Computación

DIRECCIÓN

Dr. Francisco Serradilla García

Doctor en Inteligencia Artificial

Dr. Felipe Jiménez Alonso

Doctor en Ingeniería Mecánica

Madrid 26 de octubre de 2016

hoja según tribunal

Alberto Díaz Álvarez

Modelado de comportamiento de conductores con técnicas de Inteligencia Computacional

Tesis doctoral, 26 de octubre de 2016

Revisores: Rev1, Rev2 y Rev3

Dirección: Dr. Francisco Serradilla García, Dr. Felipe Jiménez Alonso

Instituto Universitario de Investigación del Automóvil

Universidad Politécnica de Madrid

Campus Sur UPM, Carretera de Valencia (A-3), km7

28031 Madrid

Este documento esta realizado bajo
licencia **Creative Commons**
"Reconocimiento-NoCommercial-
CompartirIgual 3.0 España".



Dedicatoria

Resumen

Aquí el abstract en español

Abstract

Aquí el abstract en inglés

Índice general

Introducción 25

Inteligencia Computacional 33

Simulación de tráfico 67

Modelos de comportamiento 85

Sistemas desarrollados 101

Estudio de modelos de comportamiento 103

Resultados 107

Conclusiones 109

Índice de figuras

1. Desde el comienzo de la revolución industrial, el uso masivo de combustibles fósiles y el crecimiento de la población propició un aumento desproporcionado de CO_2 a la atmósfera, tendencia que sigue en aumento aún con la (lenta) adopción del vehículo eléctrico. La gráfica muestra cómo ambos valores parecen estar correlacionados. Fuente: Environmental Defense Fund (edf.org). 28
2. Último censo de conductores según género segmentado por edades. Fuente: Dirección General de Tráfico (dgt.es). 30
3. Ilustración del Test de Turing. Modelo propuesto para probar si una máquina es capaz de exhibir comportamiento inteligente similar al del ser humano. Hay tres participantes, dos humanos (A y C) y una máquina (B), separados entre sí pero pudiendo intercambiarse mensajes de texto. C envía preguntas a A y B sin saber quién es humano y quién es máquina y éstos le responden. Si C no es capaz de identificar qué participante es la máquina, se puede concluir que la máquina es inteligente. Fuente: Hugo Férée, via Wikimedia Commons. 33

4. “La habitación china” es un experimento mental propuesto por John Searle que parte de un Test de Turing donde la máquina ha aprendido a hablar chino. Ésta es reemplazada por una persona que no sabe nada del idioma pero que va equipada con manual de correspondencias (ideograma de entrada \rightarrow ideograma de salida). Cuando una persona le manda mensajes en chino, esta otra responde. ¿Podemos decir que dicha persona sabe chino? Evidentemente no. Pero entonces, ¿cómo podemos asegurar que la máquina reemplazada ha “aprendido” chino?. Autor: Jolyon Troscianko (<http://www.jolyon.co.uk/>) 34

5. Diferentes objetivos perseguidos por la Inteligencia Artificial. Las filas diferencian entre pensamiento o comportamiento mientras que las columnas separan entre inteligencia humana o el ideal de la inteligencia (racionalidad). Fuente: *Artificial Intelligence: A Modern Approach* (3rd Ed.), [Russell et al., 2003]. 36

6. Una sección del neocórtex humano, región asociada a las capacidades cognitivas y que supone alrededor de un 76 % del volumen total del cerebro humano. Está distribuido en 6 capas y miles de columnas que las atraviesan, cada una con alrededor de 10,000 neuronas y un diámetro de 0,5mm. Fuente: *Blue Brain Project EPFL*, <http://bluebrain.epfl.ch/>. 39

7. Variación de la representación del modelo de neurona artificial propuesto por McCullochs y Pitts. En éste, cada una de las entradas x_i es incrementada o inhibida aplicando el producto con su peso asociado w_i . La activación vendrá determinada por la aplicación de una función (denominada “de activación”) a la suma de los valores. Esta variación en concreto incluye una entrada x_0 y un peso w_0 como bias de la neurona para la variación dinámica del umbral de activación. 40

8. Formas de razonamiento en lógica tradicional: *modus ponendo ponens* y *modus tollendo tollens*. 43

9. Proceso de razonamiento según el *modus ponens* tradicional frente al *modus ponens* generalizado. En el primero, si la premisa A es cierta, entonces la conclusión B será cierta. En el segundo, dado que la premisa A no es del todo cierta (es A'), entonces la conclusión B será cierta sólo en parte (B'). 43
10. Diagrama del esquema general de un Fuzzy Inference System. 44
11. Esquema general del funcionamiento de un Genetic Algorithm. Se parte de una población de individuos y en iteraciones de selección-recombinación-mutación-reemplazo se va mejorando la población hasta llegar a una solución que, si bien no tiene por qué ser necesariamente la mejor, es lo suficientemente buena como para ser válida. 48
12. No sé cómo explicarlo. uando esté más despierto mejor. 50
13. Representación del fitness como función inversamente proporcional al error de una solución. Esta forma mantiene el fitness siempre en el intervalo $(0, 1]$. Cuanto menor es el error, esto es, cuanto más tiende a 0, más se acerca el fitness a 1. 51
14. Tres ilustraciones de las técnicas de selección más comunes en Genetic Algorithm. De izquierda a derecha (a) selección proporcional al fitness, (b) selección proporcional a la posición y (c) selección por torneo. 52
15. Situaciones posibles cuando la cardinalidad del conjunto de las codificaciones de nuestro problema es (a) mayor, (b) menor o (c) igual que la cardinalidad del conjunto del espacio de soluciones posibles. 53
16. Diferencias entre una representación binaria y una representación real de un problema. 55
17. Diferencias entre un árbol que codifica un programa en GP y uno que codifica una palabra de una gramática libre de contexto en Grammar Guide Genetic Programming. 55

18. Esquema de un agente y sus propiedades. Aunque no existe una definición comúnmente aceptada de agente, sí que existe una serie de propiedades que los que los identifican. Es autónomo, opera realiza acciones sobre un entorno dependiendo de las percepciones que le llegan de éste y tiene la capacidad de comunicarse con el resto de elementos, incluidos otros agentes. 58
19. Arquitectura básica de un agente. Aunque existen múltiples arquitecturas diferentes, todas se basan en la misma estructura. El agente percibe el entorno, lo interpreta y toma la decisión de cómo actuar sobre él. 61
20. Ilustración de la diferencia entre un agente sin modelo de entorno y uno con modelo de entorno. Cada acción realizada por el agente con modelo de entorno tiene en cuenta el estado del entorno en momentos pasados. El agente sin modelo de entorno actúa tal y como interpreta el entorno en cada momento, como si sufriese de amnesia. 62
21. Distintas arquitecturas de agentes en función del comportamiento. Dependiendo de las acciones a realizar, se identifican tres tipos, los reactivos que aplican una acción sin proceso deductivo y los basados en modelo y utilidad (en algunos contextos denominados deliberativos) que basan su comportamiento en alguna forma de deducción. 63
22. Ilustración de la diferencia entre un agente sin modelo de entorno y uno con modelo de entorno. Cada acción realizada por el agente con modelo de entorno tiene en cuenta el estado del entorno en momentos pasados. El agente sin modelo de entorno actúa tal y como interpreta el entorno en cada momento, como si sufriese de amnesia. 65
23. A lo largo del capítulo, se utilizarán indistintamente los términos DVU, conductor y vehículo para referirse al mismo concepto. En caso de no ser así, se indicará de manera explícita. 67

24. Taxonomía clásica de simuladores en función de la granularidad (complejidad) de la simulación. En la imagen de la izquierda se muestra un ejemplo clásico de macrosimulador donde el tráfico se modela como un flujo a través de las vías. En la de la derecha, se ilustra un modelo clásico de microsimulación donde cada elemento (en este caso vehículos) circula por un carril de la vía. 70

25. Otras aproximaciones alternativas de modelos en función de la complejidad. Ejemplo de mesosimulación como ventana de microsimulación dentro de un flujo de tráfico en un macrosimulador (e.g. [Munoz et al., 2001]) y ejemplo de submicrosimulación donde se modelan componentes internos de un vehículo. 70

26. Simulador de tráfico basado en CAs. En éste, el espacio se divide en celdas que pueden, o bien estar vacías, o bien ocupadas por un vehículo a una velocidad (más oscuro implica más lento). Concretamente muestra la evolución a lo largo del tiempo del movimiento de un modelo de car-following de 5 vehículos donde en eje x representa la posición en la vía y el eje y el momento temporal (iteración) de la vía. Ilustración generada con el simulador nagel-scherckenberg-demo desarrollado en esta tesis. 71

27. Ejemplo de un modelo lineal en un espacio continuo. La posición del vehículo es un valor $x \in \mathbb{R}$. Este ejemplo muestra un modelo de car-following donde el comportamiento de la aceleración del vehículo es determinado por la distancia al coche siguiente. **TODO!** Si hago yo la ilustración, me quito de esta cita y de este dibujo tan feo. Fuente: [Tordoux et al., 2011]. 72

28. Aparición de retenciones en una autopista de 250 celdas de usando el modelo Nagel-Scherckenberg. La densidad de ocupación es de 50 coches en la vía, la velocidad máxima es de $5c/\Delta t$ y la probabilidad de frenada es de $p = 0,5$. Se puede observar en la figura cómo se desplazan las olas del atasco a lo largo de las 100 iteraciones. Ilustración generada con el simulador nagel-scherckenberg-demo desarrollado para esta tesis. 73

29. Simulación de comportamiento en intersección basada en un MAS. En ésta, cada uno de los vehículos representa a un vehículo real que posee un controlador para hacerlo autónomo. Modelar este caso de estudio con una arquitectura basada en MASs permite centrarse en el diseño del agente en concreto (i.e. el controlador de conducción del vehículo) y estudiar el comportamiento emergente surgido de la interacción de todos los agentes. Fuente: Proyecto AIM (<http://www.cs.utexas.edu/~aim/>). 75
30. Captura de pantalla del simulador MovSim. Este simulador implementa un modelo multiagente donde los vehículos incorporan sistemas de comunicación vehicular. El estudio se centra en el uso de la comunicación entre vehículos para el acoplamiento dinámico de vehículos en sus respectivos carriles. Fuente: [Gu et al., 2015]. 76
31. Captura de pantalla del simulador SUMO. Además de software de simulación propiamente dicho, SUMO provee de una interfaz gráfica que permite una visualización general, de zonas y de elementos en concreto a la vez que permite la variación de configuración de la simulación durante el desarrollo de la misma. **TODO!** Meter una imagen de nuestras simulaciones cuando estén, a poder ser sin color. Hacer el alto más pequeño 81
32. SUMO ofrece la posibilidad de interactuar con la simulación desde cualquier aplicación a través del uso del protocolo TraCI. En la figura podemos ver, de izquierda a derecha, ejemplos de comunicación a través de la interfaz como el *handshake* o inicialización, mensajes de obtención de información y modificación de la misma más una solicitud de avance de paso en la simulación y una señal de finalización de simulación y desconexión. 82

33. Concepto arquitectural de la plataforma TraaS. La plataforma se conecta como cliente a SUMO y ofrece un API basado en SOAP de mensajes que traduce en mensajes del protocolo TraCI, lo que independiza completamente la elección de lenguaje de programación a la vez que abstrae los detalles del protocolo de comunicación. 83
34. Los tres niveles jerárquicos que describen la tarea de conducción según [Michon, 1985]: *estrategia* (i.e. las decisiones generales), la *maniobra* (i.e. decisiones durante la conducción de más corto plazo) y *control* (i.e. automatismos). 85
35. El cambio de carril se divide tradicionalmente en una operación que involucra dos pasos. La selección de carril (*lane-selection*) al que cambiarse y la ejecución del cambio (*merging*). En la operación de *merging* se suele involucrar otra operación denominada *gap-acceptance*, aunque algunos autores la tratan como operación independiente. Otros autores pueden llegar a añadir operaciones más especializadas. 88
36. Representación de los vehículos en una vía junto con la nomenclatura a usar durante el resto de la tesis. 89
37. Evolución de los tres tipos generales de modelo de *car-following*: mantenimiento de medidas, estímulo→respuesta y psico-físicos. Con la llegada de los psico-físicos se vio que *car-following* no era más que uno de tantos regímenes distintos dentro de los modelos de aceleración. 90
38. Tras la aparición de los modelos psico-físicos se comprobó que los umbrales en las percepciones y por tanto el comportamiento podía variar dependiendo de las situaciones. Por ello, el *car-following* no era más que una entre diferentes clases o regímenes de aceleración. Algunos de los regímenes más usados en la literatura son *free-flow*, *car-following*, *approaching*, y *emergency*, aunque algunos autores definen nuevos regímenes, cada uno con sus límites de aplicación. 90

39. Los cambios de carril se clasifican como aquellos necesarios para continuar con la conducción (obligatorios) y aquellos útiles para mejorar la situación de conducción (discrecionales). 92
40. En el modelo de Gipps, la distancia al punto determina el grado de obligatoriedad del cambio. 93
41. Estructura del modelo de comportamiento de los vehículos propuesto por [Toledo et al., 2007]. Este modelo se basa en el concepto de “objetivo a corto plazo” para elaborar un “plan a corto plazo” apoyándose, para ello, en un árbol de decisión. Aunque mantiene la clasificación, es probabilístico y existe opción de realizar un Discretionary Lane Change (DLC) en lugar de un Mandatory Lane Change (MLC) aún en situaciones donde acciones de ambas clases se activen. Para ello implementa agentes basados en utilidad donde ésta se calcula teniendo en cuenta cada uno de los nodos en un árbol de decisión. Fuente: [Toledo et al., 2007]. 94
42. Las principales áreas de aplicación de la Computational Intelligence en los Intelligent Transport System son el reconocimiento de patrones, la caracterización de conductores y la modelización de los mismos. Aunque son áreas de aplicación distintas, los estudios en general tienden a solaparse. Por ejemplo, las técnicas de reconocimiento de patrones pueden usarse como forma de extracción de características para una caracterización de conductores y a su vez esta caracterización puede usarse como base para su modelado. 96
43. Al trabajar con métodos como las Redes Neuronales Artificiales o la Logica Difusa, la inexactitud y la incertidumbre son ciudadanos de primera clase y forman parte de los modelos solución. 97

Índice de cuadros

1. Tabla comparativa donde se contrastan las características de los simuladores seleccionados. El simulador SUMO es el que más características cumple de las originalmente planteadas. 80


Introducción

Es un hecho que la **Inteligencia Artificial (AI, Artificial Intelligence)** como área de conocimiento ha experimentado un creciente interés en los últimos años. Esto no siempre ha sido así, ya que tras un nacimiento muy esperanzador, con mucho optimismo, le siguieron unas épocas de apenas avance. Sin embargo, en la actualidad es muy difícil encontrar un campo que no se beneficie directamente de sus técnicas.


Una de sus razones es su carácter multidisciplinar ya que, aunque pertenece al campo de la informática, es transversal a muchos otros de naturaleza en principio muy diferente, como pueden ser por ejemplo la biología, neurología o la psicología.

Dentro del área de la **AI** es común diferenciar dos tipos de aproximaciones a la hora de representar el conocimiento: el enfoque **clásico**, que postula que el conocimiento como tal se puede reducir a un conjunto de símbolos con operadores para su manipulación, y el enfoque de la **Inteligencia Computacional (CI, Computational Intelligence)**, que defiende que el conocimiento se alcanza a través del aprendizaje, y que basa sus esfuerzos en la simulación de elementos de bajo nivel esperando que el conocimiento “emerja” de la interacción de éstos.

El límite entre ambos conjuntos no está perfectamente definido, más aún si tenemos en cuenta las diferentes terminologías existentes, las sinergias entre distintas técnicas dentro del área y los diferentes puntos de vista sobre éstas por parte de los autores. Sin embargo, una de las principales diferencias de ambos paradig-



Una aproximación *top-down* a los problemas funciona definiendo primero el algoritmos que resuelve el problema para posteriormente ejecutarlo y llegar así a la solución exacta.



Por otro lado, una aproximación *bottom-up* el algoritmo de resolución no se programa, sino que se aprende, llegando él sólo a soluciones no necesariamente exactas pero sí lo suficientemente buenas para ser aceptadas.

mas es el punto de vista a la hora de solucionar problemas, siendo la aproximación **top-down** la usada en problemas de **AI** clásica y la **bottom-up** la típica usada en la **CI**. Revisaremos las diferencias entre conceptos de diferentes autores en el capítulo **Inteligencia Computacional**.

Uno de los campos de aplicación es el de los **Sistemas Inteligentes de Transporte (ITSs, Intelligent Transport Systems)**. Éstos se definen como un conjunto de aplicaciones orientadas a gestionar el transporte en todos sus aspectos y granularidades (e.g. conducción eficiente, diseño de automóviles, gestión del tráfico o señalización en redes de carreteras) para hacerlos más eficientes y seguros. El interés es tal que en el año 2010 se publicó la directiva 2010/40/UE (ver [par, 2010]). En ella, los **ITSs** se definieron como *aplicaciones avanzadas que, sin incluir la inteligencia como tal, proporcionan servicios innovadores en relación con los diferentes modos de transporte y la gestión del tráfico y permiten a los distintos usuarios estar mejor informados y hacer un uso más seguro, más coordinado y «más inteligente» de las redes de transporte*, y se estableció el marco de implantación de los éstos en la Unión Europea.

En el caso concreto del comportamiento al volante, es interesante la evaluación de los conductores para conocer su manera de actuar en determinados escenarios, y poder extraer información de éstos que nos permitan, por ejemplo, detectar qué factores pueden afectar más o menos sobre determinados indicadores (e.g. el consumo estimado para una ruta en concreto). Sin embargo, la evaluación en algunos casos puede no ser posible debido a limitaciones como, por ejemplo, el tiempo, el dinero o la peligrosidad del escenario.

Los simuladores de tráfico son una solución para muchas de estas limitaciones, pero suelen basar su funcionamiento en conductores y vehículos (normalmente concebidos como una única entidad) basándose en modelos de conductor que responden a funciones más o menos complejas, además con pocas o ningunas opciones de personalización. Esto provoca que dichos modelos se adapten poco al modelo de un conductor en concreto.

Esta tesis pretende explotar la generación de modelos de con-

ductor para simuladores que respondan al comportamiento de conductores reales usando, para ello, técnicas pertenecientes al campo de la [CI](#).

Concretamente pretende desarrollar un método para el análisis de la eficiencia de los conductores realizando, para ello, un modelo del perfil de conducción a partir de técnicas de la [CI](#) y aplicándolo a un entorno de simulación basado en [Sistemas Multiagente \(MASs, Multi-Agent Systems\)](#). Así, una vez configurado el entorno, se podrán estudiar aspectos generales como la evolución del tráfico con determinados perfiles o particulares como el estilo de conducción o el impacto de los sistemas de asistencia.

Motivación

Los conceptos introducidos al comienzo del capítulo obedecen a una *necesidad* de la sociedad en la que vivimos, y que afecta tanto a nuestra generación como a las venideras: la eficiencia en el transporte. Dado que es imprescindible saber que existe un problema para arreglarlo, nada mejor que puntualizar algunos hechos de sobra conocidos:

- En el año 2014, el número de vehículos a nivel mundial superó los 1,200 millones, con una tendencia creciente [[OICA, 2015](#)]. Reducir en un pequeño porcentaje el consumo evita la emisión de toneladas de gases considerados nocivos para el medio ambiente y el ser humano¹.
- Aunque existen diferentes puntos de vista acerca de cuándo se agotarán las reservas de petróleo, los combustibles fósiles son recursos **finitos**. Lo más probable es que no se llegue a agotar debido a la ley de la oferta y la demanda, pero hay que recordar que el petróleo se usa como base para la producción de otros muchos tipos de productos, como por ejemplo la vaselina, el asfalto o los plásticos.
- La emisión de gases está correlacionada con el aumento de la temperatura del planeta, hecho que se ilustra en la [figura 1](#).

¹ Uno puede argumentar que el parque automovilístico se recicla con nuevos vehículos eléctricos categorizados “de consumo o”. La triste realidad es que estos vehículos consumen la electricidad generada actualmente de una mayoría de centrales de combustibles fósiles y nucleares. Además, mientras que en países desarrollados el crecimiento ha sido en torno al 4-7 %, en países subdesarrollados, donde no existe aun infraestructura para la recarga de vehículos eléctricos, dicho crecimiento ha superado el 120 %.




Figura 1: Desde el comienzo de la revolución industrial, el uso masivo de combustibles fósiles y el crecimiento de la población propició un aumento desproporcionado de CO_2 a la atmósfera, tendencia que sigue en aumento aún con la (lenta) adopción del vehículo eléctrico. La gráfica muestra cómo ambos valores parecen estar correlacionados. Fuente: Environmental Defense Fund (edf.org).

De seguir con el ritmo de consumo actual, se teme llegar a un punto de no retorno con consecuencias catastróficas para la vida en el planeta.

- La conducción eficiente afecta directamente a factores correlacionados con el número de accidentes de tráfico. Un factor de sobra conocido es el de la velocidad, factor relacionado no sólo con el número sino con la gravedad de los accidentes ([Imprialou et al., 2016]). Otros indicadores son las aceleraciones, deceleraciones y maniobras de cambio de dirección, cuyas frecuencias son directamente proporcionales a la agresividad, falta de seguridad y accidentes e inversamente proporcionales a la eficiencia ([Dingus et al., 2006, Lerner et al., 2010]).

Estos son sólo algunos hechos que ponen de manifiesto la necesidad de centrarse en el problema de cómo hacer de la conducción una actividad más eficiente y segura. Por ello, la **conducción eficiente** o *eco-driving* se define como la aplicación de una serie de reglas de conducción con el objetivo de reducir el consumo de combustible, independientemente del tipo (e.g. electricidad, gasolina, ...).

Si es posible discriminar entre conductores eficientes y no eficientes se pueden identificar los hábitos recurrentes en estos últimos y adecuar la formación para eliminar dichos hábitos. Más aún teniendo en cuenta la relación existente entre la peligrosidad y algunas conductas agresivas. Un ejemplo donde la identificación de perfiles no eficientes pueden tener impacto claro económico y social es el de las empresas cuya actividad se basa en el transporte de mercancías o de personas.

Sin embargo, identificar la conducta de un conductor no es fácil, dado que su comportamiento se ve condicionado por numerosos factores como el estado de la ruta, el del tráfico o el estado físico o anímico. Además, la ambigüedad de las situaciones dificulta todavía más la identificación. Por ejemplo, un conductor puede ser clasificado en un momento como agresivo o no eficiente en una situación, únicamente porque su comportamiento ha sido condicionado por las malas reacciones de otros conductores conductores.

El análisis de todos los posibles casos es una tarea prácticamente imposible. Por ello, las simulaciones pueden dar una estimación de los posibles resultados de un estudio en el mundo real. Las simulaciones con **MASs** representan a los conductores como agentes independientes, permitiendo la evaluación del comportamiento tanto individual como general del sistema en base a sus individuos a través de iteraciones discretas de tiempo.

Si el comportamiento de dichos agentes es extraído a partir de los datos reales de conductores, su comportamiento dentro de la simulación podría ser considerado como fuente de datos para condiciones de tráfico y/o rutas no contempladas en el mundo real. De esta forma, se dispondría de un marco de trabajo para la comparación de diferentes conductores sin necesidad de exponerlos a todos y cada uno de los posibles eventos posibles. También sería factible evaluar sistemas de asistencia evitando los problemas de no comparabilidad de condiciones del entorno entre pruebas.

Demostrar que la evaluación de un modelo del conductor en entornos simulados es equivalente a la evaluación de conductores en entornos reales implica que se pueden comparar dos conductores usando un criterio objetivo, es decir, sin depender del estado del resto de factores a la hora de realizar la prueba de campo. Dicho de otro modo, implicaría que es posible comparar la eficiencia de dos conductores independientemente del estado del tráfico e, incluso, sobre rutas diferentes.

Objetivos

El objetivo de esta tesis doctoral es la de demostrar la hipótesis **1**, quedando dicha demostración dentro de los límites impuestos por los supuestos y restricciones indicados más adelante.

Hipótesis 1 (H1): *La aplicación de técnicas pertenecientes al campo de la **CI** con datos extraídos de un entorno de microsimulación de espacio continuo y tiempo discreto basado en sistemas multiagentes permitirá modelar, de manera fiel a la realidad, el comportamiento de conductores reales.*

Los Estudio Naturalista de Conducción (NDS, *Naturalistic Driving Study*) basan su funcionamiento en la captura masiva de datos de conducción, normalmente involucrando una gran cantidad de sensores, para analizar el comportamiento del conductor, las características del vehículo, la vía, etcétera. La cantidad de sensores y la velocidad de captura hacen que la tarea de analizar y extraer conclusiones sea una tarea prácticamente imposible para un humano, por lo que es necesario el uso de técnicas de análisis de datos que suelen recaer en los campos de la estadística y del aprendizaje automático.

Por tanto, el objetivo de la tesis es el de simular el comportamiento de conductores en entornos de micro-simulación a partir de su comportamiento en entornos reales usando técnicas de CI. Para ello se consideran los siguientes objetivos específicos:

- Estudiar y aplicar técnicas de la CI sobre el área de la conducción.
- Realizar un Estudio Naturalista de Conducción sobre conductores reales para:
 1. Generar modelos personalizados de conductor a partir de los datos de conducción obtenidos.
 2. Aplicar modelos de conductores a entornos de simulación multiagente.
 3. Validar los modelos de conductor contra conductores reales.
- Estudiar la efectividad de sistemas de asistencia encaminados a mejorar la eficiencia y analizar el comportamiento de conductor.

Supuestos

- La circulación se supone por la derecha de la vía en el sentido de la circulación, siendo los carriles de lento a rápido de derecha a izquierda respectivamente.
- Los datos de los que extraer el comportamiento se corresponderán con lecturas realizadas durante el día, con buena visibilidad y sin lluvia.
- El tipo de vehículo sobre el que modelar el comportamiento será el *utilitario*.
- El conductor a modelar pertenecerá al grupo más representativo de conductores. Esto se corresponde con varón de 35 a 39 años (ver figura 2).




Figura 2: Último censo de conductores según género segmentado por edades. Fuente: Dirección General de Tráfico (dgt.es).

Restricciones

- Reduciremos el comportamiento del conductor a los de circulación en línea y en cambio de carril².
- El Sistema Multiagente hará uso de [Driver-Vehicle Units \(DVUs\)](#) como agentes, es decir, usando la tupla (conductor, vehículo) como un todo.
- La resolución máxima del modelo creado será de 1 Hz.
- En el caso de los modelos que hacen uso de Red Neuronal Artificial, no se pueden explicar las razones del comportamiento inferido.

² Son conocidos en la literatura como **models de aceleración** y **modelos de cambio de carril**. Entraremos en detalle sobre ambos conceptos en el capítulo [Modelos de comportamiento](#)

Estructura de la tesis

La tesis está estructurada de la siguiente manera:

En los capítulos [Inteligencia Computacional](#), [Simulación de tráfico](#) y [Modelos de comportamiento](#) se expone la revisión realizada del estado de la cuestión donde se explica en qué punto se encuentra la literatura de los temas en los que se apoya la presente tesis.

En el capítulo XXX se explica el método seguido para la confirmación de la hipótesis describiendo además las instrumentaciones, los conjuntos de datos obtenidos, las técnicas utilizadas y las aplicaciones desarrolladas.

Por último en los capítulos [Resultados](#) y [Conclusiones](#) se exponen los resultados y las conclusiones respectivamente extraídos de la tesis. Además, tras las conclusiones se indican una serie de posibles líneas futuras de trabajo consideradas interesantes tras la realización de la tesis.

Inteligencia Computacional

El comportamiento de un individuo en un entorno se ve influenciado por una infinidad de variables. Identificar las relaciones entre éstas es en la mayoría de las ocasiones una tarea que va de lo muy difícil a lo imposible, más aún si añadimos que éstas son muy numerosas y pueden llegar a ser imposibles de cuantificar o incluso de detectar.

La CI engloba un conjunto de técnicas que facilitan enormemente estas tareas. En este capítulo se ofrece una perspectiva de la literatura actual sobre las técnicas de la CI que son de interés para esta tesis. Introduciremos el concepto y las nociones de “agente” y de “aprendizaje” para posteriormente introducir algunas de las técnicas utilizadas dentro del área. Por último, desarrollaremos las tres técnicas principales sobre las que reposa el trabajo teórico de esta tesis: Redes Neuronales Artificiales, Logica Difusa y Computación Evolutiva.

Inteligencia Artificial vs. Inteligencia Computacional

¿Qué es la CI? Para entender el significado de éste término tenemos que entender cómo ha evolucionado el término AI a lo largo de los años.

El primer concepto a introducir es el de “conexionismo”. Se puede considerar a Santiago Ramón y Cajal como principal precursor de esta idea por sus trabajos acerca de la estructura de las neuronas y sus conexiones (e.g. [y Cajal, 1888] y [Ramón and Cajal, 1904]).




Figura 3: Ilustración del Test de Turing. Modelo propuesto para probar si una máquina es capaz de exhibir comportamiento inteligente similar al del ser humano. Hay tres participantes, dos humanos (A y C) y una máquina (B), separados entre sí pero pudiendo intercambiarse mensajes de texto. C envía preguntas a A y B sin saber quién es humano y quién es máquina y éstos le responden. Si C no es capaz de identificar qué participante es la máquina, se puede concluir que la máquina es inteligente. Fuente: Hugo Féréé, via Wikimedia Commons.




Figura 4: “La habitación china” es un experimento mental propuesto por John Searle que parte de un Test de Turing donde la máquina ha aprendido a hablar chino. Ésta es reemplazada por una persona que no sabe nada del idioma pero que va equipada con manual de correspondencias (ideograma de entrada → ideograma de salida). Cuando una persona le manda mensajes en chino, esta otra responde. ¿Podemos decir que dicha persona sabe chino? Evidentemente no. Pero entonces, ¿cómo podemos asegurar que la máquina reemplazada ha “aprendido” chino?. Autor: Jolyon Troscianko (<http://www.jolyon.co.uk/>)

Otros prefieren citar el trabajo “*A logical calculus of the ideas immanent in nervous activity*” ([McCulloch and Pitts, 1943]) sobre Redes Neuronales Artificiales (ANNs, Artificial Neural Networks) o “*The organization of behavior*” ([Hebb, 1968]) acerca de la teoría del aprendizaje como primeros trabajos en este tema. Independientemente de su origen, el conexionismo postula que la mente y el conocimiento surgen de redes formadas por unidades sencillas interconectadas (i.e. neuronas).

Por otro lado, en 1950, Alan Turing publicó un artículo que comenzaba con la frase “*Can machines think?*” [Turing, 1950], introduciendo el famoso Test de Turing para determinar si una máquina es o no inteligente (figura 3). Se puede considerar este momento como el punto donde se estableció el objetivo a largo plazo del campo de la AI, ya que en el artículo Turing propuso un método para determinar si una máquina era capaz de exhibir comportamiento inteligente. Sin embargo, no fue hasta 1956 en la Conferencia de Dartmouth [McCarthy et al., 1956] donde John McCarthy acuñó el término AI a la vez que presentó el tema de la conferencia como la pregunta realizada por Turing en dicho artículo.

A partir de este punto la investigación en AI recibió muchísima atención por parte de investigadores y gobiernos, lo que se tradujo en financiación. Los estudios estaban dominados por aquellos relacionados con las ideas del conexionismo hasta que en 1969, se publicó el libro *Perceptrons* [Minsky and Papert, 1969] de Marvin Minsky y Seymour Papert, donde se expusieron las limitaciones de los modelos de ANNs desarrollados hasta la fecha. El impacto fue tal que la investigación en AI se abandonó casi por completo. Concretamente el conexionismo dejó de estar presente en la literatura científica durante dos décadas. Es lo que se conoce como *AI Winter*⁴.

El interés por el campo volvió de nuevo a principios de 1980 con la aparición en escena de los primeros Sistemas Expertos, los cuales se consideran como el primer caso de éxito en la AI ([Russell et al., 2003]). A finales de la década, sin embargo, empezaron a resurgir los enfoques conexionistas, en gran parte por la aparición de nuevas técnicas de entrenamiento en perceptrones

multicapa o por conceptos como activación no lineal en neuronas (e.g. [Rumelhart et al., 1985] o [Cybenko, 1989]). En este momento los sistemas expertos empezaron a perder interés frente al nuevo avance del conexionismo⁵.

Mientras que el enfoque clásico de la AI postulaba que la mente operaba de la misma manera que una máquina de Turing, es decir, mediante operaciones sobre un lenguaje de símbolos, el enfoque del conexionismo postulaba que la mente, el comportamiento inteligente, emergía de modelos a más bajo nivel. Esto provocó que algunas voces se alzaran contra lo que se consideraba el “enfoque incorrecto” de la AI. Sin embargo, otras técnicas alineadas con el conexionismo (debido a su enfoque de comportamiento emergente y aproximación como lo son la *Logica Difusa* (FL, *Fuzzy Logic*) o los *Algoritmos Genéticos* (GAs, *Genetic Algorithms*)) ganaban popularidad y alimentaban el éxito cosechado por este “enfoque incorrecto”⁶.

Esto provocó una explosión de terminologías para diferenciar las investigaciones de la propia AI clásica. Por un lado se evitaba el conflicto, nombrando las áreas de trabajo con un término más acorde con el comportamiento o técnica utilizada. Por otro, se separaba de las connotaciones negativas que fue cosechando la AI con el paso de los años, “promesas, pero no resultados”).

Lo verdaderamente interesante es ver la evolución de la literatura, y por tanto de los objetivos de la AI durante estos años. En el nacimiento del campo, se buscan literalmente máquinas que piensen como humanos, o al menos seres racionales, con mente. Con el paso de los años (y los continuos choques contra la realidad), la literatura va tendiendo hacia la búsqueda de conductas y comportamientos inteligentes cada vez más específicos. Este hecho se hace más patente en este momento, donde cada investigación se nombra de cualquier forma menos con el término AI (e.g. *Aprendizaje Automático* (ML, *Machine Learning*), *Sistemas de Recomendación* (RSs, *Recommender Systems*), o *Procesamiento de Lenguaje Natural* (NLP, *Natural Language Processing*)). Es evidente que la AI se puede observar desde diferentes puntos de vista, todos perfectamente válidos. En [Russell et al., 2003], tras

³ El propio concepto de “pensar” es en sí un tema controvertido en el propio ser humano: ¿pensar es algo inherentemente biológico? ¿surge de la mente? Tanto si sí como si no, ¿de qué forma lo hace? Por ello existen detractores de la validez del Test de Turing. Por ejemplo, el experimento de la habitación china (figura 4) nace precisamente como refutación de dicho test, aunque puede llevar a cuestiones quizá más intrigantes. Por ejemplo, si la máquina es capaz de realizar una acción sin entender lo que hace y por qué lo hace, ¿qué garantías tenemos de que el humano sí es capaz? Si los ordenadores operan sobre símbolos sin comprender el verdadero contenido de éstos, ¿hasta qué punto los humanos lo hacen de forma diferente?.

⁴ Es injusto achacar el *AI Winter* sólo al libro *Perceptrons*. El “efecto gurú” del libro fue sólo la gota que colmó el vaso. A la emoción inicial por los avances le siguieron muchos años de promesas incumplidas, investigación sin resultados significativos, limitaciones de hardware, aumento de la complejidad del software (los comienzos de la crisis del software. Ver [Dijkstra, 1972]). Todo ello provocó un desinterés y una disminución de la financiación que se retroalimentaron la una a la otra.

⁵ A esta década se la conoce como segundo *AI Winter* dado que la investigación sobre Sistemas Expertos disminuye. Sin embargo no fue un abandono tan acusado como el del primer *AI Winter*.

⁶Es comprensible ya que el método clásico produce modelos fáciles de interpretar mientras que el enfoque conexionista produce modelos cuyo funcionamiento en general no es del todo deducible. Sin embargo, existen problemas con alto grado de generalización y, a la vez, muy difíciles de modelar. Más aún, cuando éstos se refieren al comportamiento humano, la naturaleza estática de la inteligencia humana o el ideal de la inteligencia (racionalidad). Fuente: *Artificial Intelligence: A Modern Approach* (3rd Ed.), [Russell et al., 2003].

un análisis de las definiciones existentes en la literatura por parte de diferentes autores, se hace énfasis en este hecho mostrando los diferentes puntos de vista a la hora de hablar de lo que es la **AI**. El resumen se puede observar en la figura 5.

Thinking Humanly "The exciting new effort to make computers think ... <i>machines with minds</i> , in the full and literal sense." (Haugeland, 1985) "[The automation of] activities that we associate with human thinking, activities such as decision-making, problem solving, learning .. ." (Hellman, 1978)	Thinking Rationally "The study of mental faculties through the use of computational models." (Charniak and McDermott, 1985) "The study of the computations that make it possible to perceive, reason, and act." (Winston, 1992)
Acting Humanly "The art of creating machines that perform functions that require intelligence when performed by people." (Kurzweil, 1990) "The study of how to make computers do things at which, at the moment, people are better." (Rich and Knight, 1991)	Acting Rationally "Computational Intelligence is the study of the design of intelligent agents." (Poole et al, 1998) "AI ... is concerned with intelligent behavior in artifacts." (Nilsson, 1998)

Volviendo al tema de la terminología, muchas de las diferentes técnicas se fueron agrupando dentro de diferentes áreas. Una de ellas es la conocida como Computational Intelligence. Dado que persigue el mismo objetivo a largo plazo y que surge de la propia **AI** parece lógico mantenerla como un subconjunto y no como un nuevo campo del conocimiento humano. Sin embargo, algunos autores abogan por que la **CI** es un campo diferenciado de la **AI**.

Podemos definir la **CI** como la "*rama de la **AI** que aporta soluciones a tareas específicas de forma **inteligente** a partir del aprendizaje mediante el uso de **datos experimentales***". A diferencia de la aproximación clásica de la **AI**, se buscan aproximaciones a las soluciones y no las soluciones exactas. Esto es debido a que muchos problemas son de naturaleza compleja, ya sea por la erlación entre sus multiplas variables, a la falta de información o a la imposibilidad de traducirlos a lenguaje binario.

Se puede fijar el año 1994 como el que el término **CI** nace como área, coincidiendo con el cambio de nombre del *IEEE Neural*

Networks Council a IEEE Computational Intelligence Society (<http://cis.ieee.org/>). Poco antes, en 1993, Bob Marks en su trabajo [Bezdek, 1993] presentó las que él consideraba diferencias fundamentales entre la AI y la CI resumiéndolas en la siguiente frase.

“Neural networks, genetic algorithms, fuzzy systems, evolutionary programming, and artificial life are the building blocks of CI.”

Durante estos años ganaba popularidad también el concepto del Soft Computing (SC). Éste engloba las técnicas que buscan resolver problemas con información incompleta o con ruido. Debido a que el conjunto de técnicas definidas como consituyentes del SC son las mismas que las de la CI algunos autores consideran ambos términos equivalentes. Nosotros consideramos que el SC es un punto de vista de la computación más que de la AI en contraposición con el Hard Computing (HC), y que la CI hace uso de métodos del SC⁷.

Aprendizaje

La resolución clásica a un problema suele ser la aplicación de una secuencia de instrucciones basadas en un conjunto de símbolos (e.g. una función escrita en el lenguaje de programación C). Esta forma de solucionar un problema no *aprende* a solucionarlo. Se puede interpretar como que la solución está grabada en su memoria.

En la aproximación de la CI, existen modelos y existen técnicas para hacer aprender esos modelos. La aplicación de dichas técnicas es lo que se conoce como **aprendizaje**. Las técnicas de aprendizaje en CI se suelen clasificar en 2 paradigmas:

- **Supervisado.** El entorno presentado al modelo consiste en un conjunto de la forma $D = (I_i, O_i) | \forall i \in \mathbb{N}$, donde cada O_i es la salida esperada del modelo a la entrada I_i . Los algoritmos tratarán de ajustar el modelo todo lo posible para que las salidas obtenidas sean lo más parecidas a las salidas originales.

⁷ El HC es como se define la computación convencional frente al SC. El HC basa sus técnicas en aquellas basadas en modelos analíticos definidos de forma precisa y que en ocasiones requieren mucho tiempo de cómputo. Están basados en lógica binaria, análisis numérico, algoritmos y respuestas exactas. El SC por otro lado es tolerante a la imprecisión y al ruido y tiende a llegar a soluciones aproximadas de manera más rápida. Se basa en modelos aproximados, emergencia de algoritmos y modelos estocásticos.

Este paradigma de entrenamiento suele estar relacionado con problemas de *regresión*.

- **No supervisado.** Al modelo se le ofrece un conjunto de la forma $D = I_i | \forall i \in \mathbb{N}$, donde cada I_i es una entrada al problema, pero del que no conocemos la salida. Los algoritmos dentro de esta categoría harán uso de estos datos para ir reajustando el modelo tratando de encontrar las estructuras ocultas entre dichos datos (e.g. patrones, correlaciones o clases). Es un paradigma de entrenamiento íntimamente relacionado con problemas de *clasificación*.

Algunos autores hacen uso de técnicas pertenecientes a ambos paradigmas en forma de aproximación híbrida para suplir deficiencias u optimizar/acelerar el aprendizaje. Un claro ejemplo lo podemos ver en [Hinton, 2006], donde los autores hacen uso de *autoencoders* como técnica no supervisada para la inicialización de los pesos de una red neuronal y posteriormente realizan un entrenamiento supervisado para la optimización es éstos.

Otros, añaden un paradigma más a estos dos existentes, el denominado aprendizaje **por refuerzo**. Sin embargo, nosotros preferimos considerarlo como un tipo de aprendizaje supervisado, ya que la única característica que lo diferencia es que es un tipo de aprendizaje que se usa en entornos de aprendizaje *on line* ajustando el modelo en función de los estímulos percibidos del entorno por sus acciones sobre el mismo, y no en un entorno aislado previo de entrenamiento (*off line*), como la práctica totalidad de técnicas supervisadas y no supervisadas.

Técnicas en la Inteligencia Computacional

Bajo el paraguas de la CI se incluyen muchas técnicas diferentes, entre las cuales están las usadas en esta tesis. El resto de la sección describe el funcionamiento de cada una de estas técnicas.

Redes Neuronales Artificiales

Una **Red Neuronal Artificial** puede considerarse como una herramienta que trata de replicar las funciones cerebrales de un ser vivo de una manera muy fundamental (esto es, desde sus componentes más básicos, las neuronas) basándose para ello en estudios de neurobiología y de ciencia cognitiva moderna del cerebro humano⁸.



Una **ANN** es independiente del modelo del problema a solucionar. Se la puede considerar como una caja negra que aprende las relaciones que subyacen en los datos del problema para abstraer el modelo a partir de éstas. Estas características de aprendizaje y abstracción son los factores determinantes por los que son usadas en prácticamente todas las áreas de la ciencia y de la ingeniería ([Du and Swamy, 2006]).

EL MODELO DE NEURONA ARTIFICIAL de McCulloch-Pitts introducido en el trabajo "A logical calculus of the ideas immanent in nervous activity" ([McCulloch and Pitts, 1943], ilustración en la figura 7) es el considerado primer trabajo en la disciplina de las **ANNs**, y aunque existen muchas y muy diferentes tipologías y formas de operar con redes, todas funcionan de la misma manera: unidades (i.e. neuronas) interconectados mediante enlaces por los que fluye la información de manera unidireccional, donde algunas de dichas unidades sirven de entrada al sistema (i.e. entradas o sensores), otras sirven de salida del sistema (i.e. salidas y actuadores) y otras como elementos internos (i.e. ocultas), y donde las

⁸ Aún apoyándose en la topología y funcionamiento del cerebro humano para realizar el simul, lo asociado a las capacidades cognitivas y que supone alrededor de un 76% del volumen total del cerebro humano. Está distribuido en 6 capas y miles de columnas que las atraviesan, con alrededor de 160,000 parámetros a ser ajustados (podemos abstraernos y pensar en ellos como conexiones entre neuronas). Como dato anecdótico, se estima que sólo en el neocórtex (ver figura 6) del ser humano existen alrededor de 20,000 millones de neuronas, cada una de las cuales conectada a entre 100 y 100,000 neuronas vecinas ([Pakkenberg and Gundersen, 1997]). Esto supone entre $2 \cdot 10^{12}$ y $2 \cdot 10^{15}$ conexiones. Tecnológicamente hablando, la sensación es que estamos aún a años luz de aproximarnos siquiera a la complejidad de un cerebro humano.

conexiones se ajustan mediante un proceso denominado *entrenamiento*.

Figura 7: Variación de la representación del modelo de neurona artificial propuesto por McCullochs y Pitts. En éste, cada una de las entradas x_i es incrementada o inhibida aplicando el producto con su peso asociado w_i . La activación vendrá determinada por la aplicación de una función (denominada “de activación”) a la suma de los valores. Esta variación en concreto incluye una entrada x_0 y un peso w_0 como bias de la neurona para la variación dinámica del umbral de activación.

⁹ Concretamente la función logística de pendiente 1 definida como:

$$\frac{1}{1 + e^{-x}} \quad (1)$$



Figura del modelo artificial de McCullochs-Pitts

Este primer modelo de neurona proponía una función escalón para determinar si la neurona se activaba o no (analogía al funcionamiento de la neurona artificial). Posteriormente aparecieron nuevos modelos de neuronas diferentes funciones de activación. De éstas, las más comunes son las de tipo sigmoide⁹.

TODO!Parrafito sobre la limitación de la neurona singular para dar hilo a las topologías

EXISTEN DIFERENTES TOPOLOGÍAS DE REDES NEURONALES O arquitecturas dependiendo de qué forma toma el grafo que modela las neuronas y sus conexiones. En este caso, las redes neuronales pueden ser de dos tipos:

- **Feed-Forward.** Sus grafos no contienen ningún ciclo (figura XXX). Es la topología más usada en aplicaciones prácticas debido a su sencillez y su efectividad. En ellas el flujo de información sigue un camino desde las entradas hasta las salidas, sin ninguna retroalimentación. No es requisito que las neuronas se agrupen en capas, aunque suele ser la estructura común. A las redes de más de dos capas ocultas (i.e. las capas que se encuentran entre la capa de neuronas de entrada y la capa de neuronas de salida) se las denomina “profundas” o *deep*. Algunos tipos pertenecientes a esta categoría pueden ser el Perceptrón [Rosembat, 1957], el Perceptrón multicapa [Rumelhart

et al., 1986], el algoritmo LVQ y su sucesor los Mapas Auto-Organizados [Kohonen, 1998].

- **Recurrentes.** Sus grafos contienen uno o más ciclos, de tal manera que el flujo de información de salida de una neurona puede llegar a afectar a su propio estado. Estas topologías representan de una forma más fiel las bases biológicas de las ANN, pero son más complejas a la hora de operar y entrenar. Algunos casos particulares de este tipo de arquitectura son las Redes de Hopfield [Hopfield, 1982] o las memorias LSTM (del inglés Long-Short Term Memory) [Hochreiter & Schmidhuber, 1997].

Aprendizaje en Redes Neuronales Artificiales

Logica Difusa

La lógica matemática (y por extensión la teoría de conjuntos)¹⁰ tiene como misión servir de fundamento del razonamiento matemático. Se basa en la definición precisa y con rigor de un razonamiento evitando cualquier tipo de ambigüedad y de contradicción. Es por ello que la lógica tradicional no suele servir como fundamento de razonamientos del mundo real.

Los conceptos que se manejan en el mundo real suelen ser vagos, llenos de imprecisiones. Además tienden a ser nombrados cualitativamente, no cuantitativamente, y cuando existe una correspondencia, ésta suele estar marcada por la subjetividad de los términos.

Explicar lógica difusa y control difuso. Indicar los controladores difusos de segundo, tercer y sucesivos niveles.

Teoría de conjuntos difusos

A diferencia de los conjuntos tradicionales, los conjuntos difusos expresan el grado de pertenencia de un elemento a la categoría representada por el conjunto. La definición podría escribirse de la siguiente manera:

¹⁰ Se puede establecer el siglo IV a.C. como el momento del nacimiento de la lógica dentro de la física Aristotélica, que permaneció inalterada hasta los trabajos de Galileo (cita?) y Newton (cita, seguramente el Principia Mathematica) en el siglo XVI. d.C., momento en que se separó y permaneció como disciplina paralela perteneciente más al campo de la filosofía que de la física y la matemática. Empezó a relacionarse de nuevo con la matemática a principios del siglo XIX y a principios del siglo XX la lógica y la teoría de conjuntos pasaron a convertirse en partes indispensables la una de la otra. Por ello suelen ir de la mano cada vez que se habla de la una y de la otra. La evolución de la teoría de conjuntos (Cantor, finales del siglo XIX, buscar referencia) y su unión con la lógica es una época bastante convulsa dentro de la historia de la matemática pero esta tesis no es lugar para su desarrollo. Por ello se ofrece la referencia al libro *La historia de la matemática* de Miguel de Guzmán (referencia. Poner la página. Lo mismo no es de aquí y es del libro de "Los lógicos", pero estoy casi seguro de que es aquí.) en caso de que el lector tenga interés en el tema.

TODO!Creo que habría que definir antes qué es un dominio

Definición 1: Sea X una colección de elementos. Se define al **conjunto difuso** F como un conjunto ordenado de pares de la forma $F = (x, \mu_F(x)) | x \in X$, siendo $\mu_F(x) \in [0, 1] \forall x \in X$.

La función de la definición 1 se denomina **función de pertenencia**, y caracteriza unívocamente a un conjunto difuso del dominio de X .

TODO!Quizá aquí habría que decir qué es una partición de un dominio

Operaciones entre conjuntos

¹¹ Las implicaciones se representan como $A \rightarrow B$, donde A es cualquier operación de premisas y B la conclusión que arrojan.

En lógica tradicional, el valor de verdad de una implicación es equivalente al de la expresión $\neg A \vee B$. Sin embargo, en lógicas multivaluadas (y por tanto en lógica difusa) esta equivalencia da lugar a razonamientos que se pueden considerar contraintuitivos.

En el caso concreto de la lógica difusa se han propuesto gran cantidad de equivalencias. Sólo en los trabajos [Kiszka et al., 1985] se analizan 72 alternativas al operador $\neg A \vee B$.

El operador más usado no obstante es el definido como $A \wedge B$ debido a su rendimiento (en la implicación de Mamdani la T -norma se implementa como el operador mínimo).

¹² En realidad se llaman *modus ponendo ponens* ("la forma que al afirmar, afirma") y *modus tollendo tollens* ("la forma que al negar, niega").

La unión, intersección y el complemento son operaciones básicas en la teoría de conjuntos. **TODO!** hablar aquí de t norm, t co-norm y complemento, pero someramente. No hay que enrollarse demasiado.

Razonamiento

Al igual que en la lógica tradicional, en la **FL** el razonamiento o inferencia es la manera de extraer conclusiones a partir de premisas en función de un conjunto de reglas.

Estas reglas se expresan como implicaciones, definidas típicamente en lógica difusa como $A \rightarrow B \equiv A \wedge B^{11}$.

Las dos formas de extraer conclusiones a partir de premisas en **FL** son el *modus ponens* generalizado (del que hablaremos) y el *modus tollens* generalizado, modificaciones sobre los procesos de inferencia *modus ponens* y *modus tollens*¹², dos formas similares de razonamiento (figura 8). Nosotros centraremos nuestro discurso en la primera.

EL MODUS PONENS GENERALIZADO ES UNA GENERALIZACIÓN DEL MODUS PONENS DE LA LÓGICA TRADICIONAL donde, en lugar de expresar las reglas de forma absoluta, se expresan de forma

Figura 8: Formas de razonamiento en lógica tradicional: *modus ponendo ponens* y *modus tollendo tollens*.



aproximada. En la figura 9 se ilustra las diferencias fundamentales entre ambos modos.




Figura 9: Proceso de razonamiento según el *modus ponens* tradicional frente al *modus ponens* generalizado. En el primero, si la premisa A es cierta, entonces la conclusión B será cierta. En el segundo, dado que la premisa A no es del todo cierta (es A'), entonces la conclusión B será cierta sólo en parte (B').

Para determinar qué grado le asignamos a un consecuente a partir de las premisas parciales y las reglas que dirigen el razonamiento se utiliza un método denominado **regla composicional de inferencia**.

Una regla $A' \rightarrow B'$ se puede representar como una implicación caracterizada por una función $I(\mu_A(x), \mu_B(y))$ ([Ful,]).

TODO!Explicar mejor porque es terrorífico.

...

En [Ma, 2004] hay un capítulo de razonamiento que parece que está guay. Revisarlo un poco a fondo a ver si merece la pena tirar or ahí.

Fuzzy Inference System

Los Sistema de Inferencia Difusa (FIS, Fuzzy Inference System) (o Sistema de Control Difuso difusa (FCS, Fuzzy Control System)) son el caso de éxito de la lógica difusa que más resultados ha cosechado tanto a nivel académico como a nivel industrial. Se trata sistemas que utilizan el razonamiento difuso para inferir una respuesta a partir de un conjunto de entradas.

Figura 10: Diagrama del esquema general de un Fuzzy Inference System.



Habitualmente son descritos como un componente dividido en tres bloques conceptuales:

- **Fuzzificación.** Traducir los valores de entrada en crudo del dominio sobre el que está definida cada variable lingüística a sus respectivos grados de pertenencia a conjuntos difusos a través de sus funciones de pertenencia. **TODO!** Ojo, algunos controladores toman como valores de entrada conjuntos difusos según [Ma, 2004]. Habrá que buscar sobre ello.
- **Inferencia.** Realiza todo el proceso de razonamiento difuso a partir del conjunto de reglas que dan significado a este controlador difuso.
- **Defuzzificación.** Traduce el conjunto difuso resultado del proceso de inferencia a valores de los dominios sobre los que están definidos dichos conjuntos difusos. **TODO!** En un sugeno, la salida es una función directamente así que se podría especificar que en un tipo Sugeno, se puede ver como que la salida son

sólo singletones, manteniendo la generalización del proceso de funcionamiento de un FIS.

Esta división se ilustra en la figura 10.

HAY VARIOS TIPOS DIFERENTES DE FIS, aunque tienden a seguir el esquema básico de un controlador difuso típico (figura 10).

Sistemas de tipo Mandamni Son la primera aproximación de FIS propuestos

Sistemas de tipo Takagi-Sugeno ...

Hablar someramente de los tres tipos clásicos que se usan, e indicar que al final los más usados son el Mandamni y el Sugeno. Añadir también quizá una tabla comparativa entre los tres o al menos entre los dos principales:

El consecuente de un FIS de tipo Mandamni siempre es un conjunto difuso. Por tanto, el proceso de sacar un valor crisp es costoso. Lo bueno, se mantiene significado semántico de las salidas. El consecuente en un Sugeno es un valor, y se puede decir que no necesita proceso de defuzzificación. Si embargo, la respuesta pierde significado semántico si la suma de la fuerza de salida no es 1 (no entiendo qué quiero decir con esto).

Computación Evolutiva

Otra de las técnicas inspiradas en principios biológicos es la de la Computación Evolutiva (EC, *Evolutionary Computation*). Esta área de la CI trabaja sobre algoritmos iterativos inspirados en la síntesis evolutiva moderna o *neodarwinismo*.

Existe un conjunto de algoritmos denominados *Inteligencia de enjambre* (SI, *Swarm Intelligence*) que también son algoritmos iterativos estocásticos inspirados en cómo se comportan sistemas colectivos donde el conocimiento emerge de la interacción de indivi-

duos, ya se trate de sistemas naturales como por ejemplo el de las bandadas de murciélagos ([Yang, 2010]) o de sistemas artificiales como sistemas de partículas abstractas ([Artyukhin and Avery, 2014]). Algunos autores consideran este conjunto de algoritmos como pertenecientes al subcampo de la EC, pero nosotros consideramos a la SI como un subcampo independiente dado que el adjetivo *evolutivo* no es característico de este tipo de algoritmos¹³.

¹³ El punto de vista de los autores que lo incluyen es que la evolución no sólo ha sido la razón de la adaptación de los individuos, sino que también es la causante de comportamientos inteligentes grupales. Y, aunque es una apreciación cierta, el adjetivo *evolutivo* se refiere a cómo trabajan los algoritmos, no a lo que ha propiciado la evolución en la naturaleza.

Algoritmos Genéticos: bases y funcionamiento

Un GA es un algoritmo iterativo estocástico donde se aplica una serie de pasos inspirados en la síntesis evolutiva moderna para la resolución de un problema. Éstos fueron introducidos por John Henry Holland en su libro “*Adaptation in Natural and Artificial Systems*” ([Holland, 1975]) y constituyen una familia de soluciones con mucho éxito en problemas de aprendizaje, búsqueda y optimización. Desde nuestro punto de vista, podemos decir que la EC es el área que trabaja con GA.

TODO!Esto lo he extraído de una marginnote que no iba bien. Hay que reformular o recolocar Dentro de la EC existen familias de algoritmos consideradas por muchos autores como entidades diferentes a los GAs:

- **Estrategias Evolutivas (ESs, Evolution Strategies).** Surgen casi a la par con los GA por parte de Ingo Rechenberg ([Rechenberg, 1973]). Se caracterizan principalmente por ser algoritmos iterativos inspirados en la evolución pero que basan su funcionamiento en los pasos de selección y mutación y donde el reemplazo es total.
- **Programación Genética (GP, Genetic Programming).** Sus comienzos se pueden trazar hasta Koza 13, donde el autor hace uso de algoritmos genético para la generación de programas. La idea de esta aproximación es la de representar los genotipos de los individuos no como cadenas de símbolos (la representación clásica de genotipos) sino como árboles sintácticos.

Quizá en el momento de su nacimiento pudieran estar más diferenciadas, pero en la actualidad se puede pensar en ellas como diferentes especializaciones de un GA genérico. En el caso de las ESs, es evidente que se pueden considerar como una especialización de algoritmo genético donde la recombinación y el reemplazo parcial pasan a un segundo plano, y en el caso de la GP, son un GA una estructura de datos diferentes para el genotipo (la cual conlleva una serie de modificaciones a los algoritmos de recombinación y mutación, así como una serie de desventajas inherentes a su representación). **TODO!**Hasta aquí

La síntesis evolutiva moderna o neodarwinismo es una integración de teorías que complementan la teoría de la evolución propuesta por Charles Darwin. En el momento de enunciar la teoría, no se conocía de qué manera los organismos vivos transmitían sus rasgos característicos a su progenie. Las características en las que se inspiran los GAs de la síntesis evolutiva moderna incluyen, entre otras:

- El principio de selección natural. Introducido en la teoría de la evolución, el principio de selección natural indica que las características de un individuo en un entorno son las que facilitan (o dificultan) sus posibilidades de reproducción, y por tanto de posibilidad de transmisión de dichas características.
- La teoría genética, por Gregor Mendel. Concretamente los conceptos de gen (unidad de información genética que tiene posición y valor dentro de un genotipo), alelo (variación de valor de un gen que da lugar a variaciones en el individuo, como por ejemplo color de ojos), genotipo (conjunto de genes que caracterizan a un individuo de una especie), fenotipo (las características físicas del individuo, determinadas por el genotipo y el entorno) y la herencia genética.
- La mutación como fuente de variación dentro de una población.
- El principio de diversidad alélica de la genética de poblaciones.

Basándose en estos conceptos, la estructura de un GA se asemeja al proceso de evolución de poblaciones finitas de individuos.




Figura 11: Esquema general del funcionamiento de un Genetic Algorithm. Se parte de una población de individuos y en iteraciones de selección-recombinación-mutación-reemplazo se va mejorando la población hasta llegar a una solución que, si bien no tiene por qué ser necesariamente la mejor, es lo suficientemente buena como para ser válida.

Un ejemplo de esta estructura lo podemos ver en la figura 11 Los principales pasos dentro del algoritmo son los siguientes:

- **Inicialización.** El algoritmo crea una *población* de individuos donde cada uno representa una posible aproximación a la solución del problema a resolver.
- **Selección.** Al igual que en la naturaleza, donde el individuo más apto tiene la mayor probabilidad de sobrevivir y tener descendencia con sus características diferenciadoras, en un GA el individuo más apto (que represente una solución más cercana a la buscada) es el que más probabilidades tiene de ser seleccionado para transmitir sus características a las sucesivas poblaciones.
- **Recombinación.** Tras seleccionar a uno o más individuos, existe una probabilidad (generalmente alta) de que éstos generen uno o más individuos con una composición genética resultado de la combinación de éstos. El algoritmo general habla de selección de 2 individuos y del operador “cruce”, pero es posible generalizarlo para que el cruce vaya de 1 individuo (i.e. no hay cruce, es traspaso de una versión de los genes) a n (i.e. todos los individuos tienen probabilidad de transmitir su genotipo, ya sea directamente o aplicando una función a combinaciones de éstos). La recombinación consigue que la composición genética de los individuos (que probablemente sea buena porque han sido seleccionados frente al resto de individuos) se perpetúe en sucesivas poblaciones.

- **Mutación.** Una vez generada una descendencia en la recombinación (o no, pueden ser los individuos originales), los individuos tienen cierta probabilidad (por lo general baja) de que su genotipo sea modificado aleatoriamente. Esto puede hacer del individuo resultante una mala solución, pero también puede hacer que la solución sea nueva o si no, al menos ofrecer más variedad genética a la población.
- **Reemplazo.** Tras uno o más pasos de selección, recombinación y mutación, los nuevos individuos generados reemplazarán a individuos de la población inicial. En general la población en un **GA** contiene el mismo número de individuos según pasen las generaciones, pero no es un requisito fundamental.

El balance de la biodiversidad: presión selectiva y convergencia

Las características de todo individuo vienen determinadas por su genotipo. Éste contiene conjuntos de uno o más genes que se manifiestan en el fenotipo como rasgos característicos del individuo. Algunos rasgos son más favorables que otros¹⁴ y hacen que el individuo tenga más probabilidad de sobrevivir y, por tanto, de recombinarse y transmitir sus genes.

LA PRESIÓN SELECTIVA es el mecanismo por el cual se favorece o penaliza la biodiversidad. Cuando es fácil sobrevivir en un entorno, todas las variaciones de una especie son capaces de recombinarse, tener descendencia y seguir perpetuando rasgos característicos. Cuando es difícil, sólo los más aptos son los que sobreviven y por lo tanto los que se reproducen.

LA BIODIVERSIDAD se refiere a la riqueza genética que existe entre los individuos de la población. Si la biodiversidad es alta, tenemos más posibilidades de combinaciones de genes. Visto de otro modo, cuando tenemos más variedad de genes en la población, la cantidad de posibles soluciones a explorar es mayor.

Mantener una biodiversidad justa en un **GA** es esencial. Cuan-

¹⁴ Lo bueno o malo que es un individuo viene determinado también por el entorno y no sólo por el individuo. Un ejemplo claro es el de la mariposa del abedul. A principios del siglo XIX, en Inglaterra, la mariposa se confundía con los líquenes de la corteza del abedul debido a que tenían colores y patrones similares (ambas eran blancas). Sin embargo, un cambio en un único gen las convertía en negras, y por tanto muy apetecibles para los depredadores, por lo que se puede concluir que las mejores eran las de color blanco. Sin embargo, para mediados de siglo, el hollín del humo del carbón de las fábricas había teñido de negro la práctica totalidad de los líquenes convirtiendo la ventaja de la mariposa blanca en una total desventaja. Por tanto, los rasgos son favorables dependiendo del entorno.




Figura 12: No sé cómo explicarlo. uando esté más despierto mejor.

¹⁵ En realidad sí es posible, con la mutación, pero generalmente es un operador que entra en juego con probabilidad muy baja y por tanto no se puede depender únicamente en él para mantener la biodiversidad.

do la variedad genética es demasiado baja, los individuos tienden a ser muy parecidos y se hace imposible que aparezcan rasgos genéticos nuevos¹⁵, haciendo que el algoritmo se estanque. Por otro lado, cuando la variedad genética es muy alta quiere decir que hay muchos individuos todos con características muy distintas. Esto provoca tal cantidad de posibles variaciones que el algoritmo acaba avanzando muy lentamente hacia la solución. Una ilustración de este concepto se puede ver en la figura 12.

SEGÚN EL ALGORITMO CONVERGE, LA BIODIVERSIDAD DISMINUYE. Esto es debido a que cuando según vamos acercando nuestra población a una región del espacio, todos los valores que se toman tienden a ser cercanos a esta posición. Esta característica se denomina *explotación*, y es el caso contrario a la *exploración*, es decir, cuando los individuos están distribuidos por todo el espacio de búsqueda buscando posibles soluciones.

Es importante que nuestro algoritmo tienda a explorar en los estadios iniciales de su funcionamiento, y que tienda a explotar cuando se encuentre en momentos cercanos a la localización de una solución. Ésto se puede lograr mediante un buen ajuste de la presión selectiva, aunque el operador de recombinación es el más indicado para gestionar este equilibrio exploración/explotación.


Aptitud y selección de individuos

Cuando hablamos del individuo “más apto”, nos referimos a la mejor solución encontrada hasta el momento. Para ello, la manera de decidir cuándo una solución es mejor que otra es la aptitud o *fitness* de una solución.

EL FITNESS de una solución es una función que nos da una idea de la calidad de ésta como número real¹⁶ en su entorno.

El rango del fitness depende de la representación de las soluciones y del problema en sí. Una forma muy útil que mantiene la relación de orden y permite su fácil representación gráfica es la mostrada en la ecuación 2 (ver figura 13). No obstante esta representación es válida únicamente cuando es posible conocer el error de una determinada solución. Otros casos requerirán de funciones alternativas de fitness.

$$\frac{1}{1 - \text{error}} \quad (2)$$



¹⁶ En realidad, para la mayoría de los algoritmos de los diferentes pasos de un GA basta con que la función de fitness defina una función de orden entre soluciones (de la forma “la solución S_1 es mejor que la solución S_2 ”). Sin embargo, asociar un valor real a cada una de las soluciones nos da esta relación de orden además de otras ventajas, como por ejemplo un valor del que podemos observar la evolución a lo largo de los pasos y otros algoritmos como la selección proporcional al fitness.


Figura 13: Representación del fitness como función inversamente proporcional al error de una solución. Esta forma mantiene el fitness siempre en el intervalo $(0, 1]$. Cuanto menor es el error, esto es, cuanto más tiende a 0, más se acerca el fitness a 1.

TODO! No sé si se podría hablar del gaussian kernel aquí como medida del error. De hecho no sé si se usa en algún lado, pero yo creo que sería válido y que da representaciones más fieles en una gráfica.

LA SELECCIÓN se apoya en el fitness para aumentar o disminuir

la probabilidad de un individuo para ser seleccionado. Este operador es uno de los más influyentes en un GA para mantener el nivel de presión selectiva.

Figura 14: Tres ilustraciones de las técnicas de selección más comunes en Genetic Algorithm. De izquierda a derecha (a) selección proporcional al fitness, (b) selección proporcional a la posición y (c) selección por torneo.



El operador de selección se ejecuta cada vez que se quiere seleccionar un individuo para la recombinación por lo que, si la recombinación requiere de dos individuos, el operador de selección será llamado dos veces. Las técnicas más comunes, ilustradas en la figura 14 son las siguientes:

- **Selección proporcional** al fitness (también conocido como **selección por torneo**). En esta selección a los individuos se ordenan por fitness y se les asigna una probabilidad proporcional a su fitness. Una vez hecho esto, se genera un valor aleatorio y se comprueba qué individuo ha sido seleccionado. Este operador tiene la desventaja de que, si en un momento unos pocos individuos consiguen un fitness muy alto respecto al resto, acapararán la práctica totalidad del rango de probabilidades, haciendo que disminuya drásticamente la variedad genética.
- **Selección proporcional a la posición**. Varía con el anterior en que la probabilidad asociada a cada individuo es proporcional a la posición y no al fitness. Aunque supone una ventaja respecto al anterior en materia de mantener la biodiversidad, si el tamaño de la población es medio o grande, la probabilidad queda muy repartida, eliminando casi por completo la presión selectiva sobre la población.
- **Selección por torneo**. Esta selección se apoya en dos pasos. En

el primero, se extraen aleatoriamente un número n de individuos, independientemente de su *fitness*. Una vez extraídos, se seleccionará aquel que tenga el *fitness* mayor. Este operador es rápido, dado que no es necesario calcular el *fitness* de todos los individuos, sino de sólo los seleccionados y, con el parámetro n correctamente seleccionado, mantiene la presión selectiva.

Representación de individuos

Un individuo es una solución a nuestro problema. Sin embargo, no existe una única representación para un problema y elegir la mejor representación posible es crucial para un buen desempeño del algoritmo. Para comprender la importancia de una correcta codificación, vamos a formalizar un poco el concepto del problema.




Figura 15: Situaciones posibles cuando la cardinalidad del conjunto de las codificaciones de nuestro problema es (a) mayor, (b) menor o (c) igual que la cardinalidad del conjunto del espacio de soluciones posibles.

Supongamos que tenemos $P = p_1, \dots, p_n$ el dominio del problema (determinado por la codificación del problema, es decir, todos los posibles genotipos), $I = i_1, \dots, i_m$ con $m > n$ el dominio de los posibles individuos, $I_v = i_1, \dots, i_j \subset I$ con $m > j$ el subconjunto de I con todos los individuos que son solución y $f : P \rightarrow I$ una aplicación inyectiva (para simplificar nuestra formalización). Dependiendo de la cardinalidad de los conjuntos se nos pueden dar tres casos (figura 15):

1. $n > j$. Cuando la codificación de nuestro problema genera individuos fuera del conjunto de soluciones, quiere decir que

habrá codificaciones que nos generen individuos no válidos. Nuestro algoritmo tendrá que tener mecanismos para que estos individuos no sean seleccionados (e.g. asignando un *fitness* de 0) con la consiguiente penalización en tiempo.

2. $n < j$. En este caso, todas las codificaciones de nuestras soluciones tendrán una correspondencia con un individuo válido. Sin embargo, existirán individuos válidos que no serán alcanzados nunca por nuestras codificaciones, y por tanto habrá soluciones no exploradas.
3. $n = j$. Este caso es el óptimo. Al aplicar f a cualquier codificación de solución para nuestro problema, alcanzaremos un individuo válido. Por tanto no tendremos ningún problema de individuos inválidos ni de soluciones fuera de nuestro alcance.

Por ello es importante dedicar especial atención a la codificación de los genotipos de nuestro individuo. Y aunque la codificación es dependiente del problema, existen codificaciones estándar que se usan en la mayoría de los problemas.

LA CODIFICACIÓN **en lista** es quizá la más usada en algoritmos genéticos. En ésta, el genotipo de un individuo se representa como una lista de longitud fija de valores, todos ellos pertenecientes al mismo alfabeto.


Existen dos representantes típicas de esta codificación, dependiendo de si el alfabeto es finito o infinito¹⁷: La representación binaria, donde los posibles valores que puede tomar cada gen del genotipo es 0 o 1 y la representación real, donde los valores pueden tomar cualquier valor $x \in [0, 1] \subset \mathbb{R}$ (figura 16).

No existe una codificación superior a otra, todo depende del problema. El sentido común suele dictar que cuando el dominio del problema es continuo (e.g. aproximación de funciones continuas), se debe usar una codificación infinita mientras que cuando es discreto (e.g. búsqueda de ruta óptima en un grafo), una finita.

LA CODIFICACIÓN EN ÁRBOL es otra representación clásica en

¹⁷ Esto no quiere decir que sean las únicas, sino que son casi equivalentes. Si, por ejemplo, nuestro problema necesita una codificación donde el alfabeto necesita 16 caracteres, es más eficiente trabajar con un alfabeto hexadecimal. Los alfabetos finitos además tienen una desventaja en función de la cardinalidad del alfabeto: si la cardinalidad es c y la longitud del genotipo es l , pueden representar hasta c^l puntos en el espacio por lo que si nuestro problema no requiere de tantos puntos estaremos generando individuos no válidos, con los problemas que ello conlleva (ver [Figurafig:why-we-need-a-correct-codification](#))

Figura 16: Diferencias entre una representación binaria y una representación real de un problema.



algoritmos genéticos usada, principalmente, para programación genética. En ella, cada uno de los individuos representa un posible programa. Las ventajas de esta representación son claras: facilidad de definir un problema y longitud variable de genotipos.

Sin embargo, posee dos desventajas principales: la primera es relativa a la operación de recombinación. Debido a que los genes del genotipo son de tipos diferentes (i.e. unos representan a variables, otros representan a constantes, otros a funciones unarias, otros a binarias, ...), es necesario implementar controles para garantizar que un individuo (a) recién creado, (b) resultado de una recombinación o (c) mutado sea válido. La segunda está relacionada con la ventaja de la longitud. Los individuos a lo largo del tiempo en esta representación tienden a crecer (después de todo, el espacio de exploración en un árbol de longitud variable es infinito) por lo que es necesario instalar mecanismos para evitar este comportamiento.

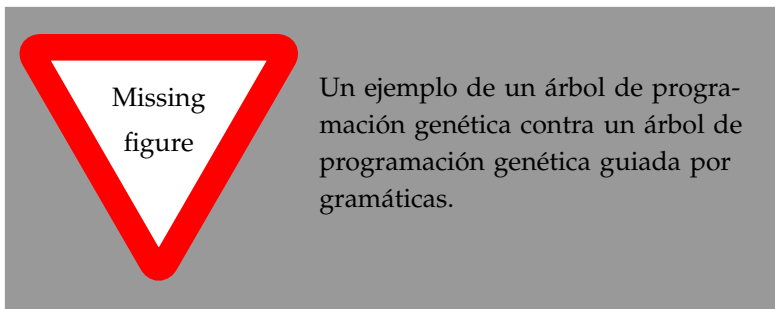


Figura 17: Diferencias entre un árbol que codifica un programa en GP y uno que codifica una palabra de una gramática libre de contexto en Grammar Guide Genetic Programming.

Una línea muy prometedora con codificaciones en árbol es la de la [Programación Genética Guiada por Gramáticas \(GGGP, Grammar Guide Genetic Programming\)](#). En ésta los árboles de los individuos no representan programas en sí, sino una palabra perteneciente a una gramática libre de contexto (figura 17). De esta manera, se garantiza que la generación de individuos es válida (se generan a partir de unas reglas de producción) y la recombinación y mutación son más sencillas de implementar.

Manipulación de individuos: recombinación y mutación

La población debe evolucionar para llegar a una solución. El principal paso en la evolución de una población en un [GA](#) es el de la recombinación, y aunque la mutación nos da probabilidad de saltar a regiones del espacio de búsqueda no exploradas con anterioridad, la recombinación guía todo el proceso de búsqueda hacia la solución.

Ambos operadores dependen más de la representación del problema que del problema en sí. Por ello existen operadores genéricos para codificaciones en lista de alfabeto finito o infinito así como para codificaciones de árboles de programa o gramaticales. Esto no quiere decir que estos operadores no se puedan personalizar, sino que son formas de operar con ventajas y desventajas ya conocidas. Por tanto, si es posible codificar un problema de una forma clásica, no es necesario reimplementar los operadores de recombinación y mutación.

LA RECOMBINACIÓN es la principal responsable de la búsqueda dirigida en el espacio de estados, es decir, de explorar el espacio y explotar las potenciales soluciones. y esta toma dos formas: exploración y explotación. en el espacio guía al algoritmo hacia mejores soluciones

Recombinaciones clásicas para los individuos de antes. Matizar que la recombinación puede depender mucho del problema.

Recombinaciones con árboles y sus problemas principales.

Reemplazo de individuos

Tasa generacional, diferencia entre generacional vs. steady-state y variación de elitismo es en realidad una tasa generacional donde deja un individuo.

Algoritmos de reemplazo clásicos.

Variaciones y operadores adicionales

Hablar de los catastróficos y los que me falten. Hay que encontrar más, porque me parece ridículo un apartado para sólo uno.

Genetic Algorithms distribuidos

Optimización de Fuzzy Inference systems mediante Genetic Algorithms

Agentes inteligentes

Si echamos un poco la vista atrás, en la figura 5 se mostraban los cuatro objetivos perseguidos por la AI. En uno de ellos en particular se la entiende como el estudio del conseguir que las entidades (e.g. sistemas, software, ...) actúen de la manera más inteligente posible. A dichas entidades se las conoce como *agentes*, concretamente en este contexto como *agentes inteligentes*¹⁸. Sin embargo, si es difícil encontrar un consenso en la definición de agente más lo es a la hora de definir cuándo la conducta de éstos es inteligente.

Lo que sí existe es una serie de características comunes que se repiten a lo largo de la literatura (figura 18):


- Operan siempre en un **entorno**, ya sea éste físico (e.g. una red de carreteras para un vehículo autónomo) o virtual (e.g. un cliente de correo electrónico para un clasificador de spam).

¹⁸ En realidad los autores prefieren denominarlo *agente racional*, dado que captura la esencia de lo que es un comportamiento inteligente. Sin embargo, según esta definición, hasta un elemento tan rudimentario como un termostato puede ser considerado como elemento inteligente, ya que realiza siempre la mejor acción para cumplir sus objetivos, por simples que puedan parecer. Dónde está el límite entre qué es y que no es un agente inteligente cae dentro de los dominios de la filosofía.

- Tienen la capacidad de **percibir** el entorno por medio de *sensores* y de **actuar** sobre él por medio de *actuadores*.
- Son **autónomos** en el sentido de que pueden actuar sin intervención externa (e.g. humana u otros agentes) teniendo control sobre su estado interno y su comportamiento. Algunos autores les presuponen una autonomía absoluta mientras que otros hablan de que sólo es necesaria cierta autonomía parcial.
- Tienen **objetivos** a cumplir, actuando para ello sobre el entorno de la manera que les indique su comportamiento.
- Pueden ser **sociales**, es decir, tienen la capacidad de comunicarse con otras entidades (e.g. otros agentes) para llevar a cabo sus objetivos.

¹⁹ En [Russell et al., 2003] se define como “...just something that acts” alegando que la palabra *agent* proviene del latín *agere*. Para clarificar esto, *agere* es la forma verbal para *hacer*, pero imprime el significado de mover a un agente/actividad diferente que no tiene que ver con la definición conforme al *paper* de *agentes* para que existe una serie de propiedades que los que los caracterizan. Es una revisión que opera en la categoría de un agente dependiendo de las percepciones que le llegan de éste y tiene la capacidad de comunicarse con el resto de elementos, incluidos otros agentes.

Por tanto nosotros usaremos la siguiente definición: Un agente es una entidad física o virtual que realiza una acción¹⁹ de manera total o parcialmente autónoma dada una secuencia de percepciones del entorno en el que se ubica.



Pero, ¿qué hace a un agente inteligente? Según algunos autores, el hecho de que posea unos objetivos y autonomía suficiente para cumplirlos ya denota inteligencia (**TODO!** encontrar el trabajo y citar). Según otros, es necesario que el comportamiento sea flexible, esto es, que sea reactivo (reacciona ante el entorno que percibe), proactivo (iniciativa para tratar de cumplir sus objetivos) y social (capaz de interactuar con otros agentes para cumplir sus objetivos) [Wooldridge et al., 1995]. Y otros directamente exigen,

además, un comportamiento racional a la hora de cumplir los objetivos para calificarlo de inteligente (**TODO!** encontrar el trabajo y citar).

Por tanto, asumiremos la definición ofrecida por [Russell et al., 2003] donde, se indica que un agente es considerado **agente inteligente** cuando éste realiza la mejor acción posible (según un criterio de medida). En este contexto, “la mejor acción posible” se refiere en términos de objetivos y comprensión del entorno, que puede ser o no correcta²⁰.

Las nociones de agentes inteligentes y la de **CI** van de la mano. Esto es debido a que su definición funciona a la perfección para las técnicas de la **CI**, esto es, agentes autónomos que perciben el entorno (problema) y actúan de la mejor manera posible sobre él (resuelven) de acuerdo a su conocimiento del medio y su estado interno (en base a algoritmos como **ANN**, **FL**, ...). Por ello desde mediados de los años 1990 el concepto de agente inteligente ha ganado tanta popularidad²¹.

Tipos de entorno

La tupla (*entorno, agente*) es esencialmente una metáfora para referirse a la tupla (*problema, solución*) por lo que existen casi tantos entornos diferentes como problemas.

Afortunadamente es posible caracterizar los entornos de acuerdo a un conjunto de propiedades o dimensiones. Este conjunto es usado por la totalidad de la literatura a la hora de caracterizar entornos:

- **Observable.** Un entorno es **totalmente observable** cuando el agente es capaz de captar toda la información relevante para la toma de una decisión y no necesita mantener ningún modelo interno del entorno, **parcialmente observable** cuando la información obtenida es incompleta o tiene ruido y **no observable** cuando el agente no posee sensores.
- **Multiagente o. monoagente.** Un entorno es **multiagente** cuan-

²⁰ Que la comprensión del entorno no sea total es un factor clave que diferencia la racionalidad de la omnisciencia. La omnisciencia significa conocer el resultado de toda acción antes de realizarla y por tanto implica el conocimiento de absolutamente todos los detalles del entorno. La racionalidad existe dentro de un contexto de conocimiento limitado.

²¹ Tanto es así que en algunos trabajos se define el objetivo de la **AI** como la implementación de la función agente, esto es, la función que realiza la correspondencia de una percepción a una acción, para un problema dado.

do requiere de múltiples agentes interactuando para llegar a una solución mientras que es **monoagente** cuando sólo requiere de uno para ello.

²² En general, los entornos del mundo real tienden a ser tan complejos que es imposible para un agente abarcar todos los aspectos medibles de éste. Por lo tanto, sea o no la naturaleza del entorno determinista, en general se suele suponer éste como no determinista.

- **Determinista o. no determinista.** Si el estado del entorno actual depende totalmente del estado anterior, se dice que el entorno es **determinista**. Si no es así, se considera **no determinista** o **estocástico**²².
- **Episódico o. secuencial.** Un entorno en el que las acciones se dividen atómicamente donde cada una de ellas conlleva un ciclo de (percepción, decisión, acción) y sin relación una con otra se denomina episódico. Si en lugar de ello la acción del agente puede afectar a las decisiones futuras se dice que el entorno es **no episódico** o **secuencial**.
- **Estático o. dinámico.** Si durante la toma de decisión en entorno no cambia, se dice que el entorno es **estático**. En caso contrario, se dice que es **dinámico**.
- **Discreto o. continuo.** Esta dimensión en realidad se divide en cuatro, estado del entorno, tiempo en el entorno, percepciones y acciones. La dimensión es **discreta** cuando ésta se divide en una partición discretizada, y **continua** cuando no. Por ejemplo, en el Juego de la Vida de Conway, si se modela en un sistema multiagente, tanto el estado (i.e. tablero) como el tiempo (i.e. turnos) como las percepciones y acciones están discretizadas. Sin embargo, en un entorno de conducción automática se puede determinar que las cuatro dimensiones son continuas.
- **Conocido o. desconocido.** Un entorno es **conocido** cuando es posible determinar cuál va a ser el resultado de una acción. Si por el contrario no es posible, entonces se dice que es **desconocido**.

Arquitecturas

Existe una serie de arquitecturas básicas o tipos de agentes que dependen principalmente de cómo perciben el entorno y de qué

forma se comportan aunque, dependiendo de los autores, las nomenclaturas, tipologías y esquemas pueden variar. Por ello, hemos decidido ofrecer una abstracción donde poner de manifiesto las partes comunes y no comunes entre arquitecturas.



Figura 19: Arquitectura básica de un agente. Aunque existen múltiples arquitecturas diferentes, todas se basan en la misma estructura. El agente percibe el entorno, lo interpreta y toma la decisión de cómo actuar sobre él.


La figura 19 muestra el esquema de las partes principales de un agente. En general, toda arquitectura de agente inteligente está cortada por el mismo patrón y obedece al siguiente funcionamiento:

1. El agente, a través de sus **sensores**, percibe el entorno en el que éste se mueve.
2. De acuerdo a cómo recordamos el entorno (llamémoslo **modelo del entorno**), el agente genera una **interpretación del entorno** tal y como supone el agente que es. Esto es, percibe el entorno y, de acuerdo a sus sensaciones, lo entiende de una determinada forma.
3. Esta interpretación del entorno es pasada a un proceso de **inferencia** el cual, en función de la implementación para la consecución de sus objetivos, generará una serie de acciones a realizar sobre el entorno.
4. Estas acciones serán ejecutadas sobre el entorno a través de una serie de **actuadores**, provocando probablemente una modificación en éste que será percibida de nuevo en momentos sucesivos.

La primera diferencia clave surge en la manera que se ofrece

al bloque de inferencia la interpretación del entorno y genera la primera clasificación (figura 20):

Figura 20: Ilustración de la diferencia entre un agente sin modelo de entorno y uno con modelo de entorno. Cada acción realizada por el agente con modelo de entorno tiene en cuenta el estado del entorno en momentos pasados. El agente sin modelo de entorno actúa tal y como interpreta el entorno en cada momento, como si sufriese de amnesia.




- **Sin modelo de entorno.** Si el agente ofrece su interpretación del entorno directamente, sin hacer uso de información histórica sobre el entorno que se ha movido. Otras formas de denominar a estos agentes es como *agentes reactivos* o *simple-reflex agents* ([Russell et al., 2003]). Sin embargo, los términos *reactivo* o *reflex* para algunos autores se refieren a la forma de inducción de acciones a partir de percepciones, y por ello preferimos la denominación *sin modelo de entorno*.
- **Con modelo de entorno.** El agente genera su interpretación más detallada del entorno a partir de las percepciones que llegan desde los sensores y de el histórico del entorno que mantiene. Otras formas de llamarlo es *agentes con estado* o *Model-based*, pero lo hemos denominado de esta manera para diferenciar que el modelo que se mantiene en este punto pertenece únicamente al entorno.

La siguiente clasificación viene motivada por la forma de deducir el conjunto de acciones a ser aplicadas por parte de los sensores. En este sentido podemos identificar tres tipos distintos de agentes (figura 21):

- **Reactivos.** Son aquellos donde el uso de un proceso de razonamiento explícito es demasiado costoso para producir una conducta en un tiempo aceptable. Se suelen implementar como co-

Figura 21: Distintas arquitecturas de agentes en función del comportamiento. Dependiendo de las acciones a realizar, se identifican tres tipos, los reactivos que aplican una acción sin proceso deductivo y los basados en modelo y utilidad (en algunos contextos denominados deliberativos) que basan su comportamiento en alguna forma de deducción.



responsabilidades (percepción \rightarrow acción) sin ningún razonamiento adicional.

- **Basados en objetivos.** Plantean una deducción de forma que determinan cuál sería el estado del entorno tras aplicar varias o todas las acciones que puede realizar. En base a los resultados, selecciona la acción que se corresponde con sus propios objetivos.
- **Basados en utilidad.** Éstos plantean una deducción similar a los basados en objetivos con la diferencia de que, mientras los primeros sólo diferencian entre entorno objetivo o no objetivo, éstos asignan un valor (i.e. *utilidad*) a cada uno de los escenarios de entorno posibles para seleccionar el mejor (e.g. el que mayor utilidad tiene).

En la literatura se describen muchos tipos de agente, como por ejemplo los agentes BDI (Believe-Desire-Intention) o los agentes lógicos (i.e. el entorno se representa con reglas lógicas y se infiere mediante métodos como por ejemplo deducción lógica o prueba de teoremas). Sin embargo, éstos pueden definirse en los términos aquí expuestos (figuras 19, 20 y 21).

Sistema Multiagente

Son aquellos sistemas compuestos de dos o más agentes que interactúan de alguna manera para llegar a una solución.

Cuando los agentes son inteligentes y el problema cae dentro del dominio de la **AI**, el ámbito de estudio es el de la **Inteligencia Artificial Distribuida (DAI, Distributed Artificial Intelligence)**, la rama dedicada a la resolución de problemas mediante procesamiento descentralizado.


Desde el punto de vista de la ingeniería de sistemas, y a pesar del aumento de complejidad, los **MAS**, al ser sistemas inherentemente descentralizados, ofrecen múltiples ventajas frente a los sistemas centralizados tradicionales:

- Los sistemas son más robustos y fiables frente a fallos, ya que los agentes son autónomos e independientes del resto.
- La modificación del sistema se puede realizar sobre la marcha, agente a agente sin necesidad de parar el sistema al completo.
- Su diseño fuerza a desacoplar las dependencias entre agentes.
- Son inherentemente paralelizables y por tanto pueden llegar a ser más eficientes que sus homólogos centralizados. Este punto es quizá el más controvertido, ya que esta ganancia en eficiencia se puede perder rápidamente en función de la cantidad de comunicación existente entre agentes.
- Debido al nivel de complejidad alcanzado en los sistemas existentes en la actualidad, la computación se distribuye a través de múltiples sistemas, normalmente heterogéneos. La tendencia además es a la alza. La definición de los **MAS** hace natural su implementación en este tipo de arquitecturas.

Desde el punto de vista de la **AI** podemos añadirles la ventaja de que permiten el estudio de conductas complejas de poblaciones a partir del comportamiento de sus elementos básicos, facilitando el estudio de modelos y de teorías sobre éstos.

LA COMUNICACIÓN ENTRE AGENTES, se trata de una característica clave en un MAS, ya que para denominarse de esta manera dos o más agentes deben interactuar (i.e. comunicarse) entre si. Esta interacción puede implementarse de diversas maneras²³ y siempre toman una o las dos formas siguientes (figura 22):

- **Cooperación.** Los agentes intercambian información entre sí para llegar a una solución. Esta solución puede ser fragmentada (i.e. cada agente posee parte de la solución y se comunican para ir avanzando de forma común hacia la solución global) o poseerla uno o varios agentes que hacen uso de más agentes para ir avanzando la solución.
- **Competición.** Los agentes compiten dentro de un entorno, generalmente mediante la adquisición de recursos limitados. Un ejemplo de este tipo de sistemas multiagente puede ser aquellos sistemas de vida artificial.



TODO! Aquí una figura de un entorno de vida artificial y un entorno multiagente donde cooperen

²³ Las formas clásicas de comunicación son el de paso de mensajes, los sistemas de pizarra y la estigmergia. Para los dos primeros existen dos propuestas para estándar de lenguaje de comunicación, [Knowledge Query and Manipulation Language \(KQML\)](#) ([Finin et al., 1994]) y [Agent Communications Language \(ACL\)](#) ([Poslad, 2007]). La tercera forma de comunicación suele ser muy dependiente del problema y no se apoya en lenguajes estándares. Se trata de una forma de comunicación basada en la modificación del entorno, como la efectuada por las hormigas en la búsqueda de alimento, donde éstas dejan rastro de feromona. La diferencia entre un agente sin modelo de entorno y el agente con modelo de entorno es que el agente con modelo de entorno tiene en cuenta el estado del entorno en momentos pasados. El agente sin modelo de entorno actúa tal y como interpreta el entorno en cada momento, como si sufriese de amnesia.

Simulación de tráfico

En un sistema de comportamiento tan caótico como lo es el del tráfico, obtener modelos de su funcionamiento es una tarea prácticamente imposible. Por un lado, el numero de variables existentes es innumerable y en muchos casos con relaciones no detectables a primera vista. Por otro, es un sistema que funciona en el mundo real, es decir, donde las mediciones en muchos caso afectan a los resultados y donde muchas mediciones no se pueden realizar, ya sea por regulaciones vigentes o por imposibilidad física.

Los simuladores de tráfico son herramientas de software que, usando diferentes modelos para representar sus componentes, describen el tráfico como sistema, permitiendo, entre otros:

- Extracción de resultados y conclusiones en escenarios de tráfico determinados.
- Implementación de técnicas determinadas en tráfico simulado para su evaluación sin necesidad de alterar el tráfico real.
- Introducción de modificaciones en puntos determinados (e.g. espaciales o temporales) de un escenario conocido para estudiar la divergencia en la evolución del tráfico.

El objetivo principal de un simulador de tráfico es el de hacer que sus modelos se parezcan lo máximo posible a la realidad. En este capítulo vamos a ver cuál es la realidad actual de este tipo de simuladores, cuáles son sus diferentes tipologías y formas de modelar los diferentes aspectos del tráfico y, posteriormente,



ok

Figura 23: A lo largo del capítulo, se utilizarán indistintamente los términos DVU, conductor y vehículo para referirse al mismo concepto. En caso de no ser así, se indicará de manera explícita.

qué simulador de los disponibles en el mercado es el idóneo para nuestro trabajo.

Limitaremos nuestro estudio a los simuladores de DVUs, obviando otros tipos de simulación de tráfico que nada tienen que ver con esta temática, como por ejemplo los orientados a la evaluación de sistemas de señalización inteligentes (e.g. [Jin et al., 2016]), a la estimación de emisiones (e.g. [Quaassdorff et al., 2016]) o los de carreras (e.g. [Wymann et al., 2013]²⁴).

²⁴ Aunque TORCS es usado como entorno de simulación en diversos concursos e investigaciones, se trata de un juego, y es que los juegos son un sandbox perfecto como entorno de simulación, ya que presentan una abstracción del dominio sobre el que trabajar. Algunos trabajos interesantes que usan como base TORCS son [Muñoz et al., 2010] y [Van Hoorn et al., 2009], donde en ambos se hace uso de conjuntos de datos de conductores reales (en el simulador) para emular su comportamiento mediante redes neuronales (el primero usando un enfoque clásico de entrenamiento mediante *back propagation* y el segundo usando algoritmos genéticos multiobjetivo). Sin embargo, este tipo de modelos se encuentran más cercanos al nivel de control que al nivel de maniobra descritos en la figura 34.

Clasificación de simuladores de tráfico

Los aspectos simulables y medibles del problema del tráfico son muy diversos, dependiendo sobre todo:

- Del nivel de **complejidad** del tráfico (e.g. modelar una vía por la que circula un centenar de coches no es lo mismo que modelar una ciudad por la que circulan millones).
- De **qué** queremos medir (e.g. evaluar a un conductor en una situación determinada o evaluar la evolución del flujo de tráfico en un cuello de botella causado por un accidente).
- De **cómo** (e.g. un **Autómata Celular (CA, Cellular Automaton)** se modela de forma diferente a un modelo lineal de vías o carriles).

El resto de la sección ofrece una visión de las principales categorías existentes para clasificar a los simuladores de tráfico.

Tipos de simulador en función de la complejidad

La complejidad en una simulación se refiere al nivel de detalle que queremos alcanzar durante la ejecución de la misma y/o en sus resultados. Es evidente que según aumentamos el detalle en la simulación aumenta la cantidad de cálculo. Por ejemplo, si queremos modelar el comportamiento de 10 billones de canicas cayendo

por un tubo es considerablemente más eficiente modelarlas como un fluido con una serie de parámetros que como una colección de elementos individuales, cada uno con sus propiedades (e.g. masa, aceleración, ...) e interaccionando entre sí.

El caso de los simuladores de tráfico es similar. En éstos existe un amplio intervalo de granularidades, desde por ejemplo el flujo de entrada en una autopista hasta el consumo de carburante de un vehículo en ciudad. Lo más común es clasificar los simuladores dentro de dos grandes grupos, los cuales se ilustran en la figura 24:

- **Microsimulación** o simulación de tipo **micro**. Su objetivo es estudiar, desde un punto de vista de granularidad fina (e.g. vehículos o peatones), las micropropiedades del flujo de tráfico como, por ejemplo, los cambios de carril, las aproximaciones a vehículos delanteros o los adelantamientos, para evaluar su comportamiento. Tiene dos principales ventajas, la posibilidad de estudiar el tráfico como un todo a partir de sus elementos más simples (ofreciendo una representación más fiel de éste) y la posibilidad de estudiar cada elemento por separado. Sin embargo, la principal desventaja de este tipo de modelos es que cada elemento de la simulación requiere de cómputo independiente y por tanto simulaciones con alto contenido de elementos pueden llegar a ser inviables²⁵.
- **Macrosimulación** o simulación de tipo **macro**. Este tipo de modelos centran su esfuerzo en estudiar el flujo de tráfico como un todo (generalmente como fluido), explorando sus macropropiedades (e.g. evolución del tráfico, efectos onda, velocidad media o flujo en vías). Su ventaja principal es que a nivel macroscópico permiten estudiar propiedades que a nivel microscópico requeriría una cantidad ingente de recursos. Sin embargo, con este modelo es imposible obtener información precisa de un elemento en particular del tráfico.

Aunque ésta es la categorización típica de modelos, en la literatura aparecen otros tipos de modelo con granularidades que pueden considerarse no pertenecientes a ninguno de estos dos

²⁵ Existen técnicas de computación distribuida que superan ampliamente los límites impuestos por la computación en un único nodo. Un ejemplo relativamente reciente es el simulador de IBM *Megaffic*. Éste implementa un modelo de granularidad micro donde cada elemento es un agente independiente (i.e. sistema multiagente) usando para ello entornos con cientos de núcleos de proceso que proveen de capacidad suficiente para modelar ciudades enteras como Tokio (ver [Osogami et al., 2012] y [Suzumura and Kanezashi, 2012]).




Figura 24: Taxonomía clásica de simuladores en función de la granularidad (complejidad) de la simulación. En la imagen de la izquierda se muestra un ejemplo clásico de macrosimulador donde el tráfico se modela como un flujo a través de las vías. En la de la derecha, se ilustra un modelo clásico de microsimulación donde cada elemento (en este caso vehículos) circula por un carril de la vía.

conjuntos. Éste es el caso de los simuladores de tipo **sub-micro** y de tipo **meso**, de los cuales se muestra un ejemplo en la figura 25.

Los **sub-micromodelos** especifican granularidades por debajo del nivel de “vehículo” o “peatón”. Por ejemplo, en ([Minderhoud, 1999]) trabaja a nivel de funcionamiento del control de cruce inteligente de un vehículo en función del entorno del vehículo.

Figura 25: Otras aproximaciones alternativas de modelos en función de la complejidad. Ejemplo de mesosimulación como ventana de microsimulación dentro de un macrosimulador (e.g. [Munoz et al., 2001]) y ejemplo de submicrosimulación donde se modelan componentes internos de un vehículo.



Por otro lado los **mesosimuladores** (e.g. [Munoz et al., 2001] o [Casas et al., 2011]) nacen para amortiguar los problemas inherentes a la complejidad en los micromodelos y a la falta de resolución en los macromodelos.

Dado que el objetivo de la tesis la evaluación de modelos de comportamiento de conductores concretos, nos ceñiremos al uso de simuladores que modelen un nivel de granularidad **micro**.

Tipos de simulador en función del espacio y el tiempo

Existen otras dos formas de clasificar los simuladores en función de cómo evolucionan en la simulación las dimensiones **es-**

pacio y tiempo. Sin embargo, aunque *complejidad, espacio y tiempo* son dimensiones diferentes a la hora de clasificar simuladores, el tipo de simulador según una de ellas tiende a determinar en gran medida los tipos en las demás.

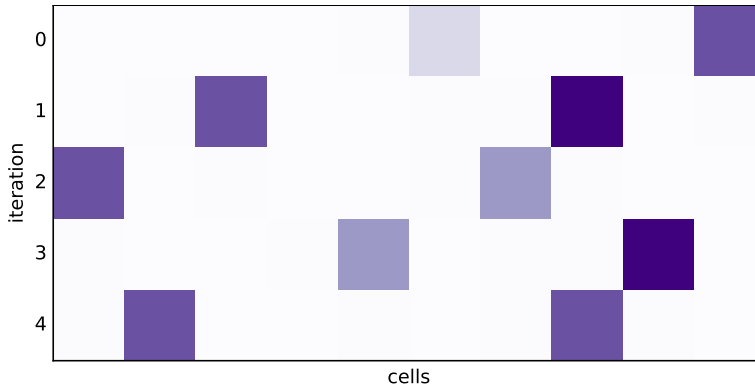


Figura 26: Simulador de tráfico basado en CAs. En éste, el espacio se divide en celdas que pueden, o bien estar vacías, o bien ocupadas por un vehículo a una velocidad (más oscuro implica más lento). Concretamente muestra la evolución a lo largo del tiempo del movimiento de un modelo de *car-following* de 5 vehículos donde en eje x representa la posición en la vía y el eje y el momento temporal (iteración) de la vía. Ilustración generada con el simulador *nagel-scherckenberg-demo* desarrollado en esta tesis.

En el caso de la dimensión **espacio**, la clasificación diferencia las simulaciones que se mueven por un espacio discreto o por uno continuo:

- **Espacio discreto.** Simulación donde el espacio está dividido en celdas que normalmente sólo pueden estar ocupadas por un elemento en un momento determinado. Este es el caso, por ejemplo, de los simuladores basados en CAs. La figura 26 ilustra el comportamiento de uno de estos tipos de simulador.
- **Espacio continuo.** Simulación que transcurre en una secuencia infinita de puntos en el espacio. Es el caso por ejemplo de los simuladores basados en modelos lineales, como podemos ver en la figura 27.

En el caso de la dimensión **tiempo**, la división se realiza en los mismos términos que en los del espacio:


- **Tiempo discreto.** También denominada *simulación de eventos discretos*, divide el tiempo en intervalos discretos, generalmente (aunque existen excepciones) de longitud fija durante toda la

simulación. Los simuladores basados en CAs son también simuladores típicos discretos, ya que cada posición en el espacio se va calculando para cada intervalo discreto de tiempo (ver figuras 26 y 28).

- Tiempo **continuo**. En estos simuladores el tiempo es un factor más para un modelo de ecuaciones diferenciales. La figura 27 ilustra un modelo de **car-following** que puede implementarse en una simulación de tiempo continuo si la aceleración viene determinada por un modelo que entre otros factores incluye el tiempo.

Dado que en nuestro caso queremos conocer la situación exacta del vehículo y no una situación aproximada en una separación discreta del espacio. Esto nos dirige hacia simuladores de espacio continuo. Por otro lado, realizamos la recolección de datos en intervalos cuantificables de tiempo, los cuales serán usados para modelar los comportamientos de los conductores y para contrastar los resultados; por tanto, la elección en la dimensión tiempo ha de ser de eventos discretos.

Figura 27: Ejemplo de un modelo lineal en un espacio continuo. La posición del vehículo es un valor $x \in \mathbb{R}$. Este ejemplo muestra un modelo de **car-following** donde el comportamiento de la aceleración del vehículo es determinado por la distancia al coche siguiente. **TODO!** Si hago yo la ilustración, me quito de esta cita y de este dibujo tan feo. Fuente: [Tordeux et al., 2011].



Modelos de microsimulación

Los simuladores que se basan en un modelo de granularidad micro están en su mayoría implementados en dos tipos de paradigma: **Autómatas Celulares** y **Sistemas Multiagente**.

Existe un tercer punto de vista a la hora de implementar este tipo de modelos, que es el de los sistemas de partículas. Sin embargo, su ámbito de aplicación es el mismo que el del punto de vista macroscópico, esto es, usar sistemas de partículas para

el análisis del tráfico como fluido. Por tanto, el resto de la sección describirá los dos tipos principales sin tener en cuenta éste último.

Microsimulación basada en Autómatas Celulares

Un CA es una colección ordenada de celdas o *células* ordenadas en un espacio n -dimensional que parcelan el universo en estudio. Cada una de ellas se encuentra en un estado (e.g. contiene un valor numérico), y el estado de toda la malla se actualiza de manera síncrona (esto es, todas a la vez) en intervalos regulares de tiempo denominados *ciclos*. El cambio de estado de cada célula depende de los valores de las células vecinas y del mismo algoritmo de modificación al que responden todas y cada una de las células.²⁶

Estos modelos de microsimulación, debido a la propia naturaleza de los CAs, se encuentran clasificados como simuladores de tiempo y espacio discreto, y se usa debido a su facilidad de implementación y a su eficiencia, ya que es fácilmente paralelizable.

El modelo clásico de esta aproximación es el propuesto por Nagel-Scherckenberg en su artículo *A cellular automaton model for freeway traffic* [Nagel and Schreckenberg, 1992], un modelo teórico creado para la simulación de tráfico en autopistas. La figura 28 muestra la evolución del tráfico en una autopista a lo largo del tiempo en una implementación basada en este paradigma. El resumen de su funcionamiento es el siguiente:

²⁶ Existen arquitecturas diseñadas para operar de esta manera, esto es, arquitecturas basadas en CAs (e.g. [Margolus, 1993]). En ellas, cada ciclo de reloj actualiza todas las celdas de memoria del autómata. Estas arquitecturas se suelen usar para la implementación de modelos físicos superando en varios órdenes de magnitud la capacidad computacional de las arquitecturas tradicionales.




Figura 28: Aparición de retenciones en una autopista de 250 celdas de usando el modelo Nagel-Scherckenberg. La densidad de ocupación es de 50 coches en la vía, la velocidad máxima es de $5c/\Delta t$ y la probabilidad de frenada es de $p = 0,5$. Se puede observar en la figura cómo se desplazan las olas del atasco a lo largo de las 100 iteraciones. Ilustración generada con el simulador *nagel-scherckenberg-demo* desarrollado para esta tesis.

- La vía está dividida en celdas de longitud $7,5m$. La razón de este valor es debida a que esta es la distancia media entre los parachoques traseros de dos coches consecutivos en un atasco.
- La celda puede tener dos estados, vacía o con un vehículo a velocidad $v = \{0, \dots, v_{max}\} \in \mathbb{N}$, esto es, discreta. La unidad de medida es $c/\Delta t$ siendo c un número de celdas.
- Δt queda establecido en $1s$, considerado el tiempo medio de reacción de un conductor ante una eventualidad. Esto hace, por ejemplo, que una velocidad de $6c/\Delta t$ sea $45m/s$ ($162km/h$).
- En cada ciclo, se realizan cuatro acciones de manera simultánea: acelerar (una unidad si no están a la máxima velocidad), frenar (si se ven obligados en función de la velocidad y la distancia del siguiente vehículo), freno aleatorio (la velocidad se reduce en una unidad hasta un mínimo de $v = 1c/\Delta t$ con una probabilidad de $p = 0,5$) y reposicionamiento (se avanzan tantas celdas como indica la velocidad.)


En general los modelos de la literatura suelen ser una variación de éste con ligeras modificaciones para estudiar aspectos concretos de modelos de tráfico, como la modificación del paso de *aleatorización* (e.g. [Barlovic et al., 1998]) o celdas más pequeñas (e.g. [Krauss et al., 1997]) para comprobar la metaestabilidad del flujo de tráfico, o modelos y reglas para vías de dos carriles como modelos para cambio de carril (e.g. [Brilon and Wu, 1999] y [Nagel et al., 1998]). Concretamente, en [Wagner et al., 1997] los autores centran su esfuerzo en la definición de una jerarquía de muchas reglas individuales (e.g. reglas para describir cuándo cambiar de carril, reglas para determinar los niveles de molestia a los coches del carril destino, etcétera) para dotar de la mayor cantidad de realismo posible al modelo.

Microsimulación basada en sistemas multiagentes

Los modelos basados en CA, aunque interesantes, no son suficientemente realistas desde un punto de vista microscópico. Por

poner un ejemplo, en una situación típica de un modelo Nagel-Scherckenberg, las posiciones de los vehículos se dan en múltiplos de 7,5 metros. Además, un vehículo realiza aleatoriamente aceleraciones y deceleraciones de 27km/h . Incluso en una situación favorable, cualquier vehículo puede realizar una aceleración de 0 a 162km/h en sólo 6 segundos. Por tanto, no ofrecen una visión demasiado realista ni fiable en caso de querer realizar estudios muy detallados de tráfico a nivel micro.

Por otro lado, en un MAS cada uno de los individuos o “agentes” tiene su propia entidad dentro del sistema. Esto es, perciben tanto el entorno como al resto de agentes y actúan de acuerdo a lo percibido y a su comportamiento preestablecido. Basarse no sólo en las magnitudes físicas del resto de vehículos (e.g. distancia, aceleración, ...) sino también en un comportamiento de conducción ofrece un interesante campo de estudio a nivel cognitivo. El paradigma de los sistemas multiagentes se desarrolla en detalle en el capítulo ?? y los comportamientos concretos de los agentes de interés para esta tesis en el capítulo . Por ello, este apartado únicamente hará una pequeña introducción a estudios existentes y aplicaciones de simuladores basados en este modelo.



A diferencia de los CAs, los MASs pueden emplazarse en un entorno virtual que represente un espacio continuo y no discreto. Esto permite modelar con mayor fidelidad magnitudes físicas asociadas a cada agente (e.g. posición y velocidades actuales, dimensiones del vehículo, masa, velocidad máxima permitida, ...). Sin embargo, aun así no es una propiedad inherente de éstos. No

Figura 29: Simulación de comportamiento en intersección basada en un MAS. En ésta, cada uno de los vehículos representa a un vehículo real que posee un controlador para hacerlo autónomo. Modelar este caso de estudio con una arquitectura basada en MASs permite centrarse en el diseño del agente en concreto (i.e. el controlador de conducción del vehículo) y estudiar el comportamiento emergente surgido de la interacción de todos los agentes. Fuente: Proyecto AIM (<http://www.cs.utexas.edu/~aim/>).


existe ninguna limitación en cuanto a la representación del espacio y es perfectamente posible representar un modelo basado en un CA usando para ello un MAS.

Cada uno de los agentes es independiente del resto, y una consecuencia directa es que el comportamiento de cada individuo permite evaluar comportamientos grupales complejos, como el descrito en la figura 29²⁷. Esta independencia da la posibilidad de tener todos los agentes diferentes entre sí y, por tanto, ofrece la ventaja de permitir experimentar con diferentes perfiles de conducción (e.g. un perfil agresivo en un flujo de tráfico dominado por conductores tranquilos). Esto es debido a que en un MAS cada agente es una parte del sistema y las decisiones de cómo se ha de comportar las toma él mismo. Desde el punto de vista de un CA, el comportamiento existe en cada celda, sin dar control al contenido o estado de cada celda.

En general los estudios basados en este modelo suelen seguir el patrón 1 DVU, 1 agente, dando así una enorme cantidad de posibilidades a experimentar. Por ejemplo en [Das et al., 1999] se hace uso de sistemas difusos para decidir cómo comportarse en la vía mientras que en [Ehlert and Rothkrantz, 2001] se hace uso de un patrón reactivo. Otros, como [Dia, 2002] o [Balmer et al., 2004] hacen uso de encuestas o censos para establecer las propiedades y calibrar los parámetros de diferentes tipos de agentes.

²⁷ Existe también una aproximación de modelar agentes como zonas de la vía y donde los vehículos, aunque poseen comportamiento, lo reciben del agente que les guía de acuerdo a la zona en la que se encuentran. Esto tiene la ventaja de que el paso de información a vehículos dentro de la misma zona se realiza mucho más rápido en un entorno distribuido. Para más información, en [Galis and Rao, 2000] se implementa un simulador siguiendo este concepto.

Figura 30: Captura de pantalla del simulador MovSim. Este simulador implementa un modelo multiagente donde los vehículos incorporan sistemas de comunicación vehicular. El estudio se centra en el uso de la comunicación entre vehículos para el acoplamiento dinámico de vehículos en sus respectivos carriles. Fuente: [Gu et al., 2015].



Los estudios en materia de simuladores de tráfico con MAS no se limitan a vehículos, sino que se usan también en otras áreas como el control de luces de tráfico o agentes para peatones entre

otros. Un ejemplo es el estudio presentado en [Clymer, 2002] donde los agentes del sistema son las señales de tráfico luminosas y no los vehículos, y donde el objetivo es adaptar la señalización en una red de carreteras para minimizar al máximo el tiempo de espera por parte de los vehículos en las intersecciones gestionadas por las señales.

En los últimos años, otro concepto que está en auge es el de las llamadas redes o comunicaciones intervehiculares, o **Vehicle-to-Vehicle (V2V)** y extravehiculares, o **Vehicle-to-Infraestructura (V2I)**. El modelo de **MAS** permite la implementación rápida de diferentes políticas y protocolos de comunicación via sensores y actuadores para estudiar estos tipos de redes de comunicación (ver figura 30). Estudios como por ejemplo [Shiose et al., 2001] o [Galis and Rao, 2000] hacen uso de un **MAS** para implementar diferentes formas de **V2V** con el objetivo de aliviar congestiones de tráfico (en el primer caso) y por el propio estudio de las comunicaciones en si (en el segundo caso). En el caso de redes **V2I**, un buen ejemplo es [Dresner and Stone, 2004], donde se representan como agentes tanto los vehículos como las intersecciones de la vía. Éstas gestionan un sistema de reservas de tokens que los vehículos solicitan cuando van a entrar en la intersección y devuelven cuando salen, gestionando comunicando en todo momento mediante eventos los cambios en dicho sistema. El estudio concluye que una comunicación de este tipo es más eficiente que una intersección clásica basada en señales de tráfico luminosas.

Software de simulación

Para la realización de esta tesis es necesario contar con un paquete de simulación que permita modelar un **MAS** en el que poder ejecutar los modelos de comportamiento desarrollados.

Aunque en un principio se ha valorado el desarrollo de una solución propia, la oferta de simuladores en el mercado es muy amplia, cada uno de ellos implementando uno o varios modelos diferentes y bajo muy distintas licencias. Por ello se ha optado por la elección de un paquete de simulación ya desarrollado.

Para elegir el mejor simulador que se adapte a nuestras necesidades se ha realizado un listado de características obligatorias y, de este modo, realizar una primera criba eliminando simuladores no aptos:

1. **Tipo de simulador.** Para nuestras necesidades es necesario un simulador que implemente **microsimulación**, ya que es el único tipo de granularidad que permite evaluar el comportamiento de un conductor independientemente del resto de la simulación. Además, debido a la forma en la que se recolectan los datos, es necesario que represente un **espacio continuo** y una dimensión de **tiempo discreto** con una resolución de al menos 1 segundo.
2. **Modelo de simulación.** Debe ofrecer un entorno basado en un **MAS** donde cada **DVU** se comporte como agente individual.
3. **Entorno de simulación.** Debe ofrecer un entorno de **simulación de tráfico general**, permitiendo la creación de escenarios. Quedan excluidos los simuladores de propósito específico o de casos particulares como simuladores de autopistas, congestiones o colisiones.
4. **Extensibilidad.** El simulador debe permitir extender de alguna la ejecución de los modelos desarrollados en los agentes (**DVUs**). Aunque se puede considerar que si es simulador **Software Abierto (OSS, Open Source Software)**, es posible modificar su comportamiento para adecuarlo a los modelos desarrollados, es mejor que el propio software ofrezca los mecanismos necesarios para la integración sin necesidad de tocar los fuentes del sistema.
5. **Sistema operativo.** Es imprescindible que el software se ejecute sobre sistemas operativos GNU/Linux por la configuración de los sistemas sobre los que se trabaja.

Posteriormente se ha desarrollado un listado de características deseables. No son determinantes para descartar simuladores pero sí favorecen la elección de unos sobre otros.

1. **Activo.** Es preferible que el sistema esté activamente desarrollado porque eso favorece la aparición de parches y mejoras sobre el software. En caso contrario, se trata de un proyecto con poca actividad por parte de sus autores.
2. **Lenguaje de programación.** Es favorable la implementación de los modelos en código Python.
3. **Licencia.** Es preferible una licencia de tipo [OSS](#) ya que, en caso de error o falta de funcionalidad, es posible acceder a los fuentes para modificarlos.
4. **Sistema operativo.** Es favorable que el sistema se ejecute en entornos tipo OS-X.

Entornos de simulación a estudiar

El primer listado de características deja atrás la mayoría de simuladores (una gran cantidad de ellos son o bien de propósito específico, están desarrollados para sistemas operativos Windows o no permiten extender su modelo). Tras la selección, nos quedamos con tres simuladores: [AORTA](#), [MatSIM](#) y [SUMO](#).

TODO! Hay que evaluar [MovSim](#), porque tiene la licencia MIT y hay algunos modelos que lo usan

Dichos entornos están prácticamente igualados en las características presentadas, tal y como se puede observar en el cuadro 1. in embargo, en materia de extensibilidad, [SUMO](#) es el único que permite el desarrollo de [DVUs](#) de manera externa. Tanto [AORTA](#) como [MatSIM](#) requieren la modificación del código fuente del simulador para varias los comportamientos de los conductores. [AORTA](#) además no es un proyecto que se mantenga activo en la actualidad (las últimas modificaciones del repositorio datan de principios del año 2014).

No obstante se ha tratado de modificar los comportamientos de los conductores en los tres simuladores para validar este hecho y ha quedado patente que para nuestro cometido es mucho más eficaz usar [SUMO](#) como simulador para nuestro estudio.

	AORTA	MatSIM	SUMO
Activo	✗	✓	✓
Lenguaje de programación	Scala	Java	C++/Python
Licencia			
Propietaria	✗	✗	✗
Open Software	✓	✓	✓
Compatible GPL	✓	✓	✓
Extensibilidad DVUs			
Código fuente	✓	✓	✓
API	✗	✗	✓
Sistema operativo			
GNU/Linux	✓	✓	✓
OS X	✓	✓	✓
Windows	✓	✓	✓

Cuadro 1: Tabla comparativa donde se contrastan las características de los simuladores seleccionados. El simulador SUMO es el que más características cumple de las originalmente planteadas.

Entorno seleccionado: SUMO

En definitiva, el simulador que más se adapta a nuestras necesidades y el que se usará como simulador base en el desarrollo de esta tesis será SUMO. Existen muchas publicaciones acerca de aspectos de este simulador, pero las principales son [Krajzewicz et al., 2002], [Behrisch et al., 2011] y [Krajzewicz et al., 2012].


²⁸ Licenciado bajo la GPL, concretamente la versión 3.0.

SUMO es un entorno de microsimulación de código abierto²⁸ desarrollado por el instituto de sistemas de transporte del Centro Aeroespacial Alemán. Implementa un modelo discreto en el tiempo y continuo en el espacio.

Además de simulación clásica, incorpora de una interfaz gráfica (se puede ver una captura de la vista gráfica en la figura 31) donde se puede ver el comportamiento de cada vehículo durante la simulación. Es interesante para obtener de un vistazo información acerca del funcionamiento del modelo en concreto a controlar. Otras de las características que el simulador ofrece son las siguientes:

- Granularidad micro y meso.

Figura 31: Captura de pantalla del simulador SUMO. Además de software de simulación propiamente dicho, SUMO provee de una interfaz gráfica que permite una visualización general, de zonas y de elementos en concreto a la vez que permite la variación de configuración de la simulación durante el desarrollo de la misma. **TODO!** Meter una imagen de nuestras simulaciones cuando estén, a poder ser sin color. Hacer el alto más pequeño



- Multimodalidad permitiendo modelar no sólo tráfico de vehículos sino de peatones, bicicletas, trenes e incluso de barcos.
- Simulación con y sin colisiones de vehículos.
- Diferentes tipos de vehículos y de carreteras, cada una con diferentes carriles y éstas con diferentes subdivisiones de subcarriles (diseño conceptual para permitir modelar comportamientos en vehículos como motocicletas y similares).

Al estar licenciado bajo la licencia [GPL](#), su distribución implica a su vez la distribución de su código fuente. Esto permite la modificación de su comportamiento y el desarrollo de nuevos modelos integrados dentro del simulador. Sin embargo nosotros no haremos uso de esta característica, sino que usaremos SUMO como aplicación servidor y el módulo [TraCI](#) como aplicación cliente desde donde gestionar todos los aspectos de la simulación.

...

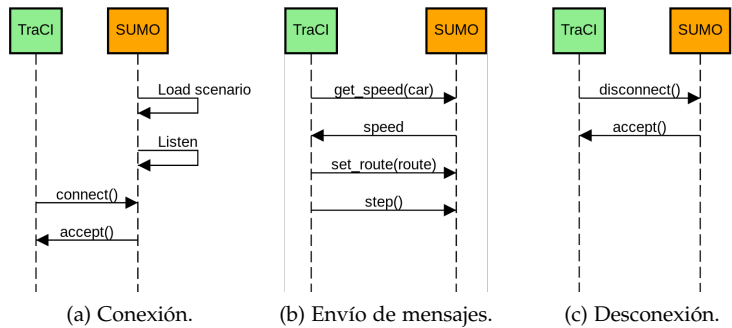
SUMO usa (al menos así lo indican en el paper del 2002) el modelo Gipps [[Krajzewicz et al., 2002](#)]. No sé si ellos han hecho una extensión del modelo o están referenciando la extensión y

ellos sólo la implementan. En el paper del 2012 citan que el modelo car-following que usan por defecto es el desarrollado por Stefan Krauß[Jin et al., 2016], debido a su simplicidad y su velocidad de ejecución. El modelo ha probado ser válido, pero tiene algunos defectos, por lo que existe un API para implementar otros modelos. En la actualidad están incluidos en el sistema los modelos IDM[Treiber et al., 2000] (*Intelligent Driver Model*), el modelo de tres fases de Kerner[Kerner et al., 2008] y el modelo de Wiedemann[Wiedemann, 1974].

La interfaz TraCI

TraCI ([Wegener et al., 2008]) es tanto el nombre del protocolo de comunicación expuesto por SUMO en su versión servidor como el nombre de la librería escrita en Python para interactuar con el mismo.

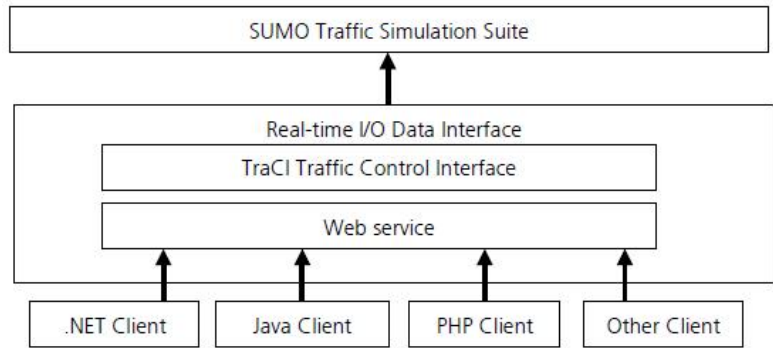
Figura 32: SUMO ofrece la posibilidad de interactuar con la simulación desde cualquier aplicación a través del uso del protocolo TraCI. En la figura podemos ver, de izquierda a derecha, ejemplos de comunicación a través de la interfaz como el *handshake* o inicialización, mensajes de obtención de información y modificación de la misma más una solicitud de avance de paso en la simulación y una señal de finalización de simulación y desconexión.



Como protocolo, la interacción a través de cliente/servidor comienza especificando a SUMO que se desea trabajar de este modo. En ese momento, SUMO se inicializa en modo servidor dejando abierto un puerto TCP para la conexión del cliente (figura 32 (a)).

Una vez el servidor se encuentra en ese estado, el cliente se conecta enviando una señal de conexión indicando que él se encargará de controlar la simulación. Desde ese momento y hasta que el cliente no envíe una señal de desconexión (figura 32 (c)), el cliente podrá enviar y recibir todos los mensajes que desee para capturar información y modificar los detalles de la simulación,

Figura 33: Concepto arquitectural de la plataforma TraaS. La plataforma se conecta como cliente a SUMO y ofrece un API basado en SOAP de mensajes que traduce en mensajes del protocolo TraCI, lo que independiza completamente la elección de lenguaje de programación a la vez que abstrae los detalles del protocolo de comunicación.



incluido el mensaje *step*, que es el encargado de avanzar un paso en la simulación (figura 32 (b)).

Como librería, TraCI es un módulo desarrollado en Python 2.7. Si bien es cierto que es posible trabajar directamente con el protocolo de comunicación a través de sockets, una librería abstrae todos los detalles dando una interfaz de trabajo más clara y sencilla. Por ello, aunque no se usarán en la tesis, existen otras dos implementaciones que merece la pena mencionar:

- **TraCI4J**²⁹. El homólogo de la librería de abstracción de Python pero para el lenguaje Java. Está desarrollada por un tercero.
- **TrasS**³⁰. Una plataforma ofrecida como SaaS que proporciona una interfaz de servicios web bajo protocolo SOAP para abstraer el protocolo en mensajes HTTP (figura 33).

²⁹ <https://github.com/egueli/TraCI4J>.

³⁰ <http://traas.sourceforge.net/cms/>.

Modelos de comportamiento

El objetivo que persigue la simulación de tráfico es hacer cada vez más realistas los modelos generados. Cuando el simulador está basado en Sistemas Multiagente, el realismo aumenta cuanto más se parece el comportamiento de los agentes al de los conductores reales.

Conducir implica la ejecución de múltiples tareas en paralelo, cada una de ellas pertenecientes a un nivel cognitivo. Además, las acciones no están limitadas a la interacción con el vehículo; el conductor ha de tener en cuenta otros factores como, por ejemplo las señales, los peatones o los [Sistemas Avanzados de ayuda a la Conducción \(ADASs, Advanced Driver Assistance Systems\)](#).




Figura 34: Los tres niveles jerárquicos que describen la tarea de conducción según [Michon, 1985]: *estrategia* (i.e. las decisiones generales), la *maniobra* (i.e. decisiones durante la conducción de más corto plazo) y *control* (i.e. automatismos).

[Michon, 1985] divide en tres los niveles de abstracción de las tareas: el nivel de **control**, que se ocupa de las tareas de más bajo nivel como son el mantenimiento de la velocidad o los cambios de marcha, el de **maniobra** o táctico, donde sus tareas son las encargadas de mantener la interacción con el entorno como los cambios de carril o el control de las señales y demás estímulos ex-

ternos, y el **estratégico**, que engloba las tareas de más alto nivel como el razonamiento y la planificación de rutas (ver figura 34). A pesar de que se trata de una clasificación subjetiva, algunos estudios llegan incluso a definir intervalos temporales de tiempo de razonamiento para las tareas de cada nivel. Por ejemplo, en [Alexiadis et al., 2004] se establecen los siguientes tiempos: alrededor de 30 s para las tareas del nivel de planificación, entre 5 s a 30 s para las tareas de nivel táctico y por debajo de los 5 s para las tareas de control.

Otro modelo jerárquico de tres niveles muy referenciado en la literatura es el *skill-rule-knowledge* de [Rasmussen, 1986], una generalización del modelo propuesto por [Michon, 1985] al comportamiento y razonamiento humano. Postula que éste se puede basar en **habilidades** (actividades completamente automatizadas de la forma *percepción* → *ejecución*), en **reglas** (situaciones familiares o estereotipadas de la forma *percepción* → *reconocimiento de la situación* → *planificación* → *ejecución*) y en **conocimiento** (actividades conscientes que implican resolución de problemas y toma de decisiones de la forma *percepción* → *reconocimiento de la situación* → *toma de decisión* → *planificación de la ejecución*) que suelen ser necesarias en situaciones poco familiares)³¹.

³¹ El trabajo presentado en [Chaib-draa and Levesque, 1994] se basa en esta jerarquización del razonamiento humano y abarca los 3 niveles de abstracción representando en un escenario urbano tres tipos diferentes de situaciones: rutinaria, familiar y no familiar.

El comportamiento de un conductor al volante tiene una relación directa con el nivel de abstracción táctico. Se puede entender como el nivel encargado de planificar acciones a corto plazo para conseguir objetivos a corto plazo. Las tareas de control son automáticas e influyen poco o nada en la toma de decisiones de tareas como *cuánto acelerar en esta situación* o *cuándo cambiar de carril*. Las tareas estratégicas están a un nivel más alto de abstracción (e.g. la ruta a seguir hasta mi destino) y tampoco afectan demasiado al comportamiento en situaciones concretas³².

³² No obstante algunos trabajos han demostrado que en ocasiones la planificación de la ruta sí afecta a decisiones normalmente asociadas al nivel táctico como por ejemplo la preferencia de un conductor por uno u otro carril de la vía [Wei et al., 2000, Toledo et al., 2003].

NUESTRO INTERÉS ES EL USO DE AGENTES como unidades en simulación. Después de todo trabajamos con Sistemas Multiagente. Sin embargo, y aunque en los trabajos más modernos exista una cierta predisposición hacia este paradigma, no todos los trabajos se basan en él. El auge de su uso coincide con el renacimiento de la

Inteligencia Artificial, alrededor de los años 90, y los modelos que se describen en este apartado, sobre todo posteriores a esta fecha, se basan en este tipo de sistemas.

Las tipologías de agentes utilizadas es de todo tipo. Existen desde trabajos que explotan las características de los agentes reactivos (e.g. agentes que continuamente van realizando decisiones de control para mantenerse en la vía y llegar a su destino [Ehlert and Rothkrantz, 2001]) hasta aquellos que proponen frameworks nuevos para definir comportamientos³³.

La información que manejan estos agentes dentro de los simuladores suele limitarse a tipologías de vehículo (e.g. utilitarios o vehículos de grandes dimensiones) y magnitudes físicas (tamaño, velocidad máxima). Dependiendo del trabajo, algunos autores añaden más conocimiento a los agentes; por ejemplo, en [Hidas, 2002], el autor incluye en los agentes, denominados *Driver-Vehicle Objects (DVOs)* (otra denominación del concepto de *DVU*), información adicional sobre el tipo de conductor y el nivel de conocimiento de la red de carreteras.

El resto del capítulo introducirá los modelos de comportamiento más conocidos y hará especial hincapié en el estado más reciente de modelos basados en técnicas de la Computational Intelligence.

Comportamientos modelados

Las tareas que se realizan en el nivel táctico del comportamiento son aquellas orientadas a circular dentro del flujo de tráfico interactuando con éste. En la literatura, estas tareas se centran en dos clases generales de problema diferentes (figuras 35 y 38): el de la **aceleración** y el del **cambio de carril**.


Los modelos de **aceleración** se ocupan de gestionar las alteraciones de la tasa de aceleración (positiva o negativa) en un entorno lineal como lo es un carril de tráfico.

El tráfico real, sin embargo, no está compuesto por un sólo ca-

³³ El *framework* propuesto por [Al-Shihabi and Mourant, 2001] es muy interesante por cómo modela los agentes del sistema. Se basan en cuatro unidades de funcionamiento interconectadas: (i) **percepción**, que percibe el entorno en términos locales y globales, (ii) **emoción**, que identifica cómo responde emocionalmente al entorno, (iii) **toma de decisiones**, que investiga posibles acciones para satisfacer al módulo emocional y (iv) **ejecución**, que intenta implementar las decisiones cuando surgen condiciones lo suficientemente seguras para llevarlas a cabo.

rril, sino por varios. Los modelos de **cambio de carril** (figure ??) tienen como objetivo identificar cuándo el conductor desea cambiar de carril y realizar dicho cambio, ya sea porque quiere mejorar su circulación (e.g. quiere realizar un adelantamiento) o porque su ruta lo requiere (e.g. está próxima la rampa de salida que quiere tomar en una autopista).

Figura 35: El cambio de carril se divide tradicionalmente en una operación que involucra dos pasos. La selección de carril (*lane-selection*) al que cambiarse y la ejecución del cambio (*merging*). En la operación de merging se suele involucrar otra operación denominada *gap-acceptance*, aunque algunos autores la tratan como operación independiente. Otros autores pueden llegar a añadir operaciones más especializadas.



En la literatura los modelos de aceleración han sido mucho más estudiados que los de cambio de carril, entre otras cosas por la dificultad en la captura de los datos y, por tanto, por su escasez.

El estudio del comportamiento en los cambios de carril es muy interesante debido a que tiene efectos opuestos según la carga de tráfico de la vía en la que se ejecutan. Por un lado, si la carga de tráfico es de ligera, mejora la velocidad media del flujo de la vía. Sin embargo, según aumenta la carga de tráfico, los cambios de carril comienzan a afectar a éste en formas de ondas de choque ([Sasoh and Ohara, 2002, Jin, 2006]) e interferir incluso más que los modelos de *car-following* ([Laval and Daganzo, 2006]).

Nomenclatura

Para no llevar a equívocos, en la figura 36 se ilustran los actores típicos en una situación de tráfico junto con los nombres y su rol. A continuación los explicamos:



- Lag car.
- Lead car.

Modelado de conductores clásico

Los primeros trabajos sobre modelos de conducción datan de comienzo de los años 50 con estudios sobre el concepto denominado **car-following**, acuñado por [Reuschel, 1950]. Un vehículo está en una situación car-following cuando su velocidad está condicionada por el vehículo que se encuentra frente a él. En el primer modelo concreto ([Pipes, 1953]), el comportamiento responde a tratar de mantener un espacio variable en función de la velocidad.

Este modelo se puede considerar de una clase que denominaremos **mantenimiento de medida** dado que su objetivo es mantener constantemente una distancia segura, determinada a partir de la ecuación de la velocidad cuando el tiempo no baja de 1,02 segundos. Otros trabajos trabajan con el mantenimiento de otras medidas como distancia relativa al parachoque delantero o trasero.

Figura 36: Representación de los vehículos en una vía junto con la nomenclatura a usar durante el resto de la tesis.

Modelo GHR


Presentado en [Chandler et al., 1958] es el modelo más conocido antes de la introducción del modelo de Gipps. Desarrollado a finales de los años 50 dentro de la *General Motors* (por ello también se le conoce como modelo *Generalized Model (GM)*), se caracteriza por el uso del concepto *estímulo* \rightarrow *respuesta*, donde la respuesta del vehículo (el cambio en la tasa de aceleración) es debida a la activación de un estímulo (la variación en la distancia con el vehículo delantero) tras pasar un tiempo de retardo τ . Concretamente calcula el valor de la aceleración a en un instante t como:

$$a(t) = cv^m(t) \frac{\Delta v(t - \tau)}{\Delta x^l(t - \tau)} \quad (3)$$

Siendo t es el instante actual, $a(t)$ la aceleración del vehículo, $\delta v(t)$ y $\delta x(t)$ son la velocidad y distancia relativas al siguiente coche respectivamente, v la velocidad del vehículo y c , m , l y τ constantes, siendo ésta última el tiempo de reacción del conductor.


Más adelante, a finales de la década se presentó el modelo [Gazis-Herman-Rothery \(GHR\)](#) (ver ecuación 3), el cual sirvió como base para el desarrollo de muchos modelos posteriores. Ese modelo dio origen a una nueva clase de modelos de conducción, los de tipo **estímulo → respuesta**.

Figura 37: Evolución de los tres tipos generales de modelo de *car-following*: mantenimiento de medidas, estímulo→respuesta y psico-físicos. Con la llegada de los psico-físicos se vio que *car-following* no era más que uno de tantos regímenes distintos dentro de los modelos de aceleración.



En realidad los modelos estímulo → respuesta son la evolución lógica de los modelos anteriores, donde se pasa de un cálculo de velocidad en función de la distancia (u otra medida) a un sistema de control donde la variable a controlar es la aceleración en función de uno o varios estímulos de entrada, además con un retardo simulando el tiempo de reacción. Algunas modificaciones sobre el algoritmo original son, entre otras, la asimetría en la tasa de cambio de aceleración y deceleración ([[Gazis et al., 1959](#)]) o la inclusión de segundos coches delanteros ([[Bexelius, 1968](#)]).

Figura 38: Tras la aparición de los modelos psico-físicos se comprobó que los umbrales en las percepciones y por tanto el comportamiento podía variar dependiendo de las situaciones. Por ello, el *car-following* no era más que una entre diferentes clases o regímenes de aceleración. Algunos de los regímenes más usados en la literatura son *free-flow*, *car-following*, *approaching*, y *emergency*, aunque algunos autores definen nuevos regímenes, cada uno con sus límites de aplicación.



Los métodos de estas dos clases tienen un problema principal:

suponen que el conductor es capaz de percibir incluso el más ínfimo cambio en las variables observadas cuando la realidad no es así. Por ello, a mediados de los años 70 apareció una nueva clase de modelos de *car-following*, denominados posteriormente como **psicofísicos** ([Wiedemann, 1974], donde se introduce el concepto de *umbral perceptual* como solución a dicha limitación. El *umbral perceptual* de una medida es el límite a partir del cual se percibe un cambio en dicha medida. Mediante el uso de umbrales perceptuales, se limitan las acciones de los coches a cambios perceptibles en los coches delanteros. A finales de la década, en 1978, se cumplió otro hito en el desarrollo de modelos de conducción. Sparmann en [Sparmann, 1978] define el primer modelo de cambio de carril, inspirándose en las clases de modelo psicofísico. El verdadero interés de este modelo es que sentó las bases de dos conceptos que perduran hoy en día. El primero, la diferenciación entre cambio a carriles rápidos y lentos³⁴. El segundo, la diferenciación entre la selección de carril o *lane-selection* y la ejecución del cambio o *merging*.

LA VIABILIDAD EN UN CAMBIO DE CARRIL se determina haciendo uso de modelos denominados *gap acceptance*, donde los vehículos calculan si caben o no en un determinado hueco y actúan en consecuencia.

En su origen los modelos de *gap acceptance* se desarrollaron para resolver situaciones en intersecciones e incorporaciones. En la actualidad son los modelos que se usan en el momento de después de seleccionar el cambio de carril y antes de ejecutar físicamente el cambio, y dependiendo del autor del modelo, lo incluye dentro de la operación *lane-selection* y la ejecución del cambio o **merging**.

En general se basan en una fórmula que determina si, en función de una serie de parámetros entre los que se incluye el hueco del carril destino, el cambio es viable, en cuyo caso el cambio se ejecuta. En la ecuación 4 se describe el modelo típico de un modelo de *gap acceptance*.

LLEGADOS A ESTE PUNTO, con los modelos psicofísicos se llegó a

³⁴ En [Sparmann, 1978] el autor entiende la derecha como el carril lento y la izquierda como el carril rápido, y es como se entiende dentro del contexto de esta tesis. Sin embargo en otros países esta correspondencia es al revés.

gap acceptance El modelo típico de *gap acceptance* responde a la ecuación 4, donde en un momento t , el cambio a un carril l es viable ($f_{g_l}(t) = 1$) o no ($f_{g_l}(t) = 0$) dependiendo de si el espacio en el carril destino $g_l(t)$ es mayor o menor que un “hueco crítico” (en inglés critical gap) $g_l^{crit}(t)$.

$$f_{g_l}(t) = \begin{cases} 0 & \text{si } g_l(t) < g_l^{crit}(t) \\ 1 & \text{si } g_l(t) \geq g_l^{crit}(t) \end{cases} \quad (4)$$

Por otro lado, existen autores que definen factores de influencia que modifican el modelo típico. Algunos ejemplos de factores pueden ser la velocidad absoluta del vehículo ([Gipps, 1986, K. et al., 1996]), el tipo de cambio (MLC o DLC, usado en [Ahmed, 1999, Toledo et al., 2007]), la relativa con los vehículos delantero y trasero del carril destino ([Ahmed, 1999]) o incluso el peso de encontrarse o no en una situación de cooperación ([Ahmed, 1999, ?]).

En el trabajo de [Weidemann and Reiter, 1992] se proponen hasta cuatro clases diferentes de modelos de aceleración en función de las posiciones y velocidades relativas entre el vehículo sujeto y el siguiente: (i) **free-flow**, donde el comportamiento no se ve afectado por el del vehículo delantero), (ii) **car-following**, donde el comportamiento sí se ve influenciado por el vehículo delantero, obligando a disminuir la velocidad deseada en el conductor en cuestión, (iii) **approaching**, situación intermedia entre las dos anteriores y (iv) **emergency**, donde la situación es crítica (e.g. colisión inminente) obligando, normalmente, a respuestas extremas.

Más adelante diferentes autores identifican otros regímenes que pueden considerarse en algunos casos como situaciones independientes (e.g. *close-following* o *stop-and-go* [Toledo et al., 2003, Liu and Li, 2013]).


Figura 39: Los cambios de carril se clasifican como aquellos necesarios para continuar con la conducción (obligatorios) y aquellos útiles para mejorar la situación de conducción (discrecionales).

la conclusión que no todas las situaciones eran iguales, sino que en función del entorno y el momento los umbrales podían variar, y que el *car-following* no era sino un subtipo más de una clase más amplia que se definió como *modelos de aceleración* (figura 38).

Debido a eso y a la irrupción de los modelos de cambio de carril, los posteriores modelos y *frameworks* desarrollados se componen de dos o más submodelos que responden a diferentes umbrales. Sin embargo, esto provoca que los modelos desarrollados sean más complejos ya que, cuantos más regímenes se tratan de agrupar en un mismo modelo, más aumenta el número de factores a generalizar y ajustar.

EL TRABAJO DE GIPPS en [Gipps, 1981] es uno de los primeros modelos que agrupa varios regímenes distintos (concretamente *car-following* y *free-flow*). Sin embargo consideramos más interesante su posterior trabajo, [Gipps, 1986] ya que puede considerarse como la primera solución para el cambio de carril.

Introduce el concepto de que los cambios de carril obedecen a diferentes motivaciones. Por un lado, los cambios pueden ser **obligatorios** (denominado en la literatura como **MLC**) cuando los vehículos se ven obligados a abandonar el carril que ocupan. Por otro lado, pueden ser **discrecionales** cuando el cambio obedece a motivaciones más relacionadas con la mejora del confort o de la situación actual de conducción (ver figura 39).



En su modelo Gipps propone un modelo para el cambio de ca-

rril al aproximarse a un cambio de dirección. Dicho modelo identifica tres distancias que caracterizan el comportamiento del conductor en función de cómo de lejos está dicho punto: (i) *lejos*, en el que no existe condicionamiento en la decisión de cambio de carril, (ii) *medio*, donde el conductor empieza a ignorar los cambios que dan ventaja de velocidad si no hacia carriles distanciados del de salida y (iii) **cerca** donde los vehículos deben estar en el carril de cambio de salida.

Otro concepto que incluye el modelo de Gipps y que exporta a modelos posteriores de cambio de carril es el de ampliar el *critical gap* a más de un hueco: las distancias hasta el vehículo delantero y hasta el vehículo trasero, forzando a que durante el proceso de gap acceptance las condiciones de ambos huecos tengan que ser aceptables.




Figura 40: En el modelo de Gipps, la distancia al punto determina el grado de obligatoriedad del cambio.

Posteriormente, en [Weidemann and Reiter, 1992] se desarrolla un framework similar pero teniendo en cuenta los cambios a carriles lentos (para representar, por ejemplo, obstrucciones como accidentes o un vehículo lento) y a carriles rápidos (para situaciones como condiciones de la ruta). Además el autor incluye un modelo para influir en su desempeño en función del entorno actual (las características de los vehículos de alrededor) y el entorno potencial (la estimación de las características del entorno en momentos posteriores).

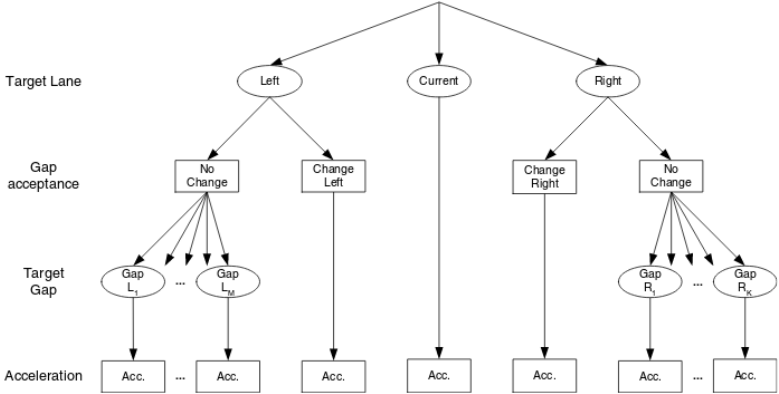
El modelo de Gipps sin embargo adolecía de dos problemas clave. Muchos de estos problemas fueron heredados por multitud de trabajos posteriores que basaban su funcionamiento o su

concepto en éste.

UN CAMBIO DE CARRIL NO SÓLO INVOLUCRA al conductor que lo ejecuta. En [?], el autor resalta el problema de que, en situaciones de congestión, el cambio ha de ser o bien forzado o bien a través de colaboración; en caso contrario, los vehículos no abandonarán el carril congestionado.

Uno de los primeros trabajos en abordar el comportamiento colaborativo es el de [Fritzsche and Ag, 1994]. En éste, se describe un modelo de microsimulación para analizar cuellos de botella (e.g. un accidente donde se bloquea uno de los carriles). Los autores describen el problema pero no consideran la modificación de los modelos en cambio de carril. [Yang and Koutsopoulos, 1996] sin embargo presenta un entorno de simulación (MovSim) que introduce, entre otros, un modelo de cambio de carril en el que se habla específicamente de comportamiento colaborativo. Introducen el concepto de función de cortesía (*courtesy yielding function*) la cuál afecta al modelo de *car-following* de un vehículo cuando otro intenta incorporarse al carril. Sin embargo, los detalles de dicho proceso no están especificados en el artículo.

Figura 41: Estructura del modelo de comportamiento de los vehículos propuesto por [Toledo et al., 2007]. Este modelo se basa en el concepto de “objetivo a corto plazo” para elaborar un “plan a corto plazo” apoyándose, para ello, en un árbol de decisión. Aunque mantiene la clasificación, es probabilístico y existe opción de realizar un **DLC** en lugar de un **MLC** aún en situaciones donde acciones de ambas clases se activen. Para ello implementa agentes basados en utilidad donde ésta se calcula teniendo en cuenta cada uno de los nodos en un árbol de decisión. Fuente: [Toledo et al., 2007].



ADEMÁS, AL USAR ÁRBOLES SECUENCIALES, los factores son evaluados uno detrás de otro hasta encontrar una situación favorable,

en cuyo caso el resto de factores no son evaluados. Por ejemplo, tal y como está formado el modelo de [?], un **MLC** inhibe cualquier posibilidad de realizar un **DLC** independientemente de la utilidad de ambos. Para evitar esta limitación, algunos autores hacen uso de técnicas como modelos probabilísticos. Ejemplos de avances en esta línea de trabajo pueden ser [Toledo et al., 2003, Toledo et al., 2007, Wei et al., 2000] (figura 41).

Modelado de conductores basado en Computational Intelligence

Desde mediados de los años 90 empezó a crecer el interés por aplicar técnicas de Inteligencia Artificial a los **ITS**. Hay dos razones por las que esto es así: la primera, en los éxitos cosechados por la rama de la **CI**, los cuales atrayeron a investigadores de multitud de áreas incluida esta. La segunda, por el rápido desarrollo de la tecnología³⁵, que ha posibilitado la existencia de conjuntos de datos masivos con la capacidad de explotarlos y aprender de ellos.

Algunos autores ([Zhang et al., 2011]) se atreven a afirmar incluso que el futuro de las **ITS** son las técnicas de la **CI**, y que los resultados que se puedan cosechar de técnicas basadas en el desarrollo convencional de sistemas es marginal comparado con las que se obtendrán con el nuevo enfoque.

Dentro de las **ITS**, las áreas de aplicación de la **CI** se centran en los siguientes conceptos: reconocimiento de patrones, caracterización de conductores y modelado de conductores. Es necesario mencionar que aunque se trate de áreas distintas, éstas suelen retroalimentarse, y es difícil encontrar estudios que se centren en una única área sin tocar el resto (figura 42). Por ello, aunque nuestro interés pueda centrarse en el modelado de conductores, es necesario conocer el estado de las demás áreas.


- En el **reconocimiento de patrones** las técnicas suelen trabajar en los temas de extracción de características y de predicción de comportamientos. La cantidad de datos que se pueden generar

³⁵ Cada vez es más barata, más precisa y con más funcionalidades. En la última década hemos vivido una explosión de dispositivos de todo tipo: teléfonos y relojes con GPS, acelerómetros y giroscopio, ordenadores completamente funcionales del tamaño de una moneda, sensores RADAR y LIDAR para uso amateur además de profesional y así un largo etcétera.

en un coche es tal que el trabajo a través de información en curdo es inviable (no digamos ya cuando los datos son extraídos de una flota de vehículos).

- La **caracterización de conductores** es interesante debido a que permite la identificación de perfiles de conducción y su clasificación de acuerdo a indicadores extraídos de su manera de conducir.
- El **modelado de conductores** nos permite la reproducción de cómporamientos en simulación.

Figura 42: Las principales áreas de aplicación de la Computational Intelligence en los Intelligent Transport System son el reconocimiento de patrones, la caracterización de conductores y la modelización de los mismos. Aunque son áreas de aplicación distintas, los estudios en general tienden a solaparse. Por ejemplo, las técnicas de reconocimiento de patrones pueden usarse como forma de extracción de características para una caracterización de conductores y a su vez esta caracterización puede usarse como base para su modelado.



Las principales técnicas de **CI** utilizadas en el modelado de conductores son las **ANN** y la **FLs**. Es comprensible ya que, las primeras son una de las técnicas principales en la rama del **ML**, y la segunda por ser una manera sencilla y cercana a la manera de razonar del ser humano.

En general, aun sólo por la propia naturaleza de las técnicas, los modelos incluyen siempre más de un único comportamiento: al ser entrenados con datos de conductores reales y manejar la información con incertidumbre, aprendieron a comportarse en diferentes regímenes (e.g. *free-flow*).

LAS REDES NEURONALES ARTIFICIALES fueron el punto de entrada de la CI en la modelización de conductores. Los perceptrones multicapa y sus nuevas técnicas de entrenamiento se habían convertido en la nueva solución universal para todo aquel problema del que se disponiesen datos.




Figura 43: Al trabajar con métodos como las Redes Neuronales Artificiales o la Lógica Difusa, la inexactitud y la incertidumbre son ciudadanos de primera clase y forman parte de los modelos solución.

Las ANN se han aplicado mucho sobre el campo de las ITSs en general, no sólo en modelado de conductores sino en prácticamente todos los aspectos como la clasificación de conductores [Díaz Álvarez et al., 2014], la conducción autónoma [Huval et al., 2015] o la predicción ([Dougherty et al., 1993, Chan et al., 2012] entre muchos otros.

El primer trabajo de la literatura sobre la aplicación de ANNs al modelado de conductores es [Fix and Armstrong, 1990], donde los autores desarrollan un controlador para imitar el comportamiento de un conductor.

En la misma década, en [Hunt and Lyons, 1994] se desarrolló uso de ANN aplicadas al entorno del vehículo para identificar el entorno y determinar cuándo y cómo realiza el conductor un cambio de carril.

Los modelos hasta el momento hacen uso de datos extraídos de conductores reales pero desde entorno de simulación. El primer trabajo en usar datos reales de vehículos instrumentados para este cometido es [Jia et al., 2003]. A partir de las entradas correspondientes a velocidad relativa, espacio relativo, velocidad y velocidad deseada (para ello, clasifican al conductor de agresivo,

normal, conservador) determinan la aceleración/deceleración del vehículo. No lo aplican a ningún simulador, sólo que los valores se ajustan. Otros trabajos similares son [Panwai and Dia, 2007, Khodayari et al., 2012].

El trabajo de [Simonelli et al., 2009] también se apoya en datos extraídos de entornos reales. El interés de este estudio radica en que es el primero en realizar una comparativa entre el desempeño de una arquitectura *fast-forward* (e.g. perceptrón multicapa) frente a una recurrente (e.g. red de Elman). El por qué del uso de redes recurrentes es porque las redes recurrentes son capaces de reconocer patrones dinámicos, los cuales son de esperar en este tipo de comportamientos.

EL PRIMER USO DE LA LOGICA DIFUSA fue contemporáneo al de las ANN, y también aplicada a un modelo de *car-following*. Después de todo los modelos psicofísicos aparecieron debido a que la percepción del conductor no es absoluta, sino imprecisa.

Estos modelos parten de la hipótesis de que la información que maneja el conductor a la hora de tomar decisiones proviene de un análisis no demasiado detallado de la situación que le rodea; es decir, la percepción y el comportamiento humanos son estímulos percibidos de manera aproximada. Por tanto, el resultado debe ser fruto de un proceso de razonamiento que tenga en cuenta esa imprecisión en los estímulos, y la lógica difusa es ideal para modelar la incertidumbre del mundo real y por tanto de las percepciones de los conductores.

[Kikuchi and Chakroborty, 1992] es el primer trabajo documentado sobre el tema. En él, los autores aplicaron la lógica difusa sobre un modelo de aceleración de tipo *car-following*. Utilizaron el modelo GHR (Ecuación 3) como base y determinaron las entradas al modelo como valores de pertenencia a conjuntos difusos. Las entradas del modelo eran la distancia y velocidad relativa entre el vehículo modelado y el delantero y la variación en la aceleración del vehículo delantero. Como salida, el cambio en la tasa de aceleración sobre el vehículo modelado.

[McDonald et al., 1997, Wu et al., 2003] desarrollaron del modelo Fuzzy LOGic motorWay SIMulation (FLOWSIM) con similares características pero incluyendo el comportamiento de cambio de carril, además en dos categorías: al carril lento (principalmente para evitar incordiar a los vehículos que se aproximan por detrás a velocidades superiores, usan dos variables, presión del vehículo trasero y satisfacción en el gap del carril destino) y al rápido (para ganar velocidad, variables: velocidad ganada con el cambio y oportunidad, es decir, seguridad y confort con el cambio).

Los modelos hasta el momento se basaban en conjuntos difusos y reglas definidos *ad-hoc*. En [Chakroborty and Kikuchi, 2003] se introduce el concepto de personalización, ajustando los conjuntos difusos de las variables de entrada y salida a valores extraídos de conductores reales. Este ajuste se realiza mediante la representación del controlador difuso como red neuronal y posterior ajuste mediante entrenamiento de dicha red (back-propagation). A este trabajo le siguen muchas otras aproximaciones neuro-fuzzy como [Ma, 2004, Zheng and McDonald, 2005]

Más adelante, en [Das and Bowles, 1999], dentro de su simulador Autonomous Agent SIMulation Package (AASIM) añaden los conceptos de MLC y DLC a los comportamientos de cambios de carril. En MLC las reglas tienen en cuenta la distancia al siguiente punto característico (e.g. una salida) y el número de cambios de carril necesarios. En DLC deciden si cambiar o no basándose en el nivel de satisfacción del conductor y en el nivel de congestión en los carriles adyacentes³⁶.

LAS REDES NEURONALES ARTIFICIALES Y LA LOGICA DIFUSA NO SON las únicas técnicas usadas para determinar comportamientos en conductores.

Por ejemplo, en [Maye et al., 2011] se presenta un modelo no supervisado, online y basado en redes bayesianas donde se infiere el comportamiento del conductor haciendo uso de una Inertial Measurement Unit (IMU) y una cámara. De la IMU se extraen datos que se separan en fragmentos para luego relacionarlos con las imágenes obtenidas de la cámara. Otro trabajo similar pueden ser

³⁶ Este trabajo se apoya en trabajos anteriores que separan las jerarquías en situaciones de MLC y DLC como [Yang and Koutsopoulos, 1996, Halati et al., 1997, ?]. Estos trabajos, no obstante, no pertenecen al área de la CI.

[Van Ly et al., 2013] el cual se apoya también en la segmentación de los datos extraídos de una IMU pero con técnicas distintas (concretamente *clustering* basado en Support Vector Machine (SVM) y en *k*-medias) y sin cámara.

En [Bando et al., 2013] describen otro modelo no supervisado, éste offline, basado en un modelo bayesiano no paramétrico para la clusterización, combinándolo con un modelos supervisado (Latent Dirichlet Allocation (LDA)) para la clusterización a más alto nivel. El trabajo de [Bender et al., 2015] usa una aproximación similar pero sin la segunda clusterización.

Otra aproximación es el de los Modelos Ocultos de Markov (HMMs, Hidden Markov Models). Por ejemplo, los trabajos [Kuge et al., 2000, Sekizawa et al., 2007] aplican entrenamiento supervisado sobre estos modelos para reconocer los eventos que están provocando los conductores (concretamente cambiando de un carril a otro). En [Hou et al., 2011] van un paso más allá desarrollando un modelo capaz de estimar si el conductor va a realizar un cambio a la derecha o a la izquierda a partir del ángulo de giro del volante (con una precisión de 0,95 en una ventana temporal de 1,5 segundos y de 0,83 en una ventana de 5 segundos).

Por último, [Aghabayk et al., 2013] presenta un modelo basado en Local Linear Model Tree (LOLIMOT) que son similares a una aproximación *neuro-fuzzy* del comportamiento. Intenta incorporar imperfecciones perceptuales en un modelo de *car-following*.

ESTAS TÉCNICAS NO SÓLO SE USAN PARA modelar comportamientos complejos o modelos enteros. Algunos trabajos se ocupan de características o aspectos de un modelo concreto. Por ejemplo, los trabajos [Hatipkarasulu, 2003, Zheng et al., 2013] se ocupan exclusivamente del cálculo de tiempo de respuesta del conductor en modelos de *car-following*, el primero con controladores difusos y el segundo con ANNs.

Sistemas desarrollados

Este capítulo describe todos los sistemas y el software desarrollados e implementados para realizar la tesis. Éstos son tanto los encargados de la captura de datos de los conductores, los que trabajan directamente con el simulador para integrar los controladores generados y los desarrollos para la generación de Software.

ScanBUS

ScanBUS es un software para la identificación de paquetes enviados por dispositivos a través del Bus CAN del vehículo.

Sistema para la captura de datos multidispositivo

Para la obtención de los datos de conducción se ha desarrollado un sistema que permite la conexión a múltiples dispositivos desde diferentes interfaces. Las razones para su desarrollo son las siguientes

- Sincronización automática de datos de dispositivo en intervalos configurables de tiempo. El sistema permite la configuración de la frecuencia de captura sincronizando los datos recibidos a esa frecuencia.
- Diseño extensible a otros dispositivos. Es software está diseñado para facilitar en la medida de lo posible la introducción de

nuevos dispositivos usando, para ello, las interfaces apropiadas.

- Hardware compacto. El sistema está integrado en un ordenador de tipo Raspberry PI, aunque es factible su integración en otros sistemas siempre y cuando funcionen con un sistema GNU/Linux e incluyan el hardware necesario para las capturas.

Biblioteca para la incorporación de modelos de conductor personalizados en SUMO

Hace uso de [TraCI](#).

Modelos de comportamiento

Entrenamiento de controladores difusos mediante [EC](#)

Estudio de modelos de comportamiento

...

Creo que además de crear modelos adaptados al conductor de car following y de lane change, estaría bien adaptar los parámetros de los modelos existentes y comparar.

Cosas que se me ocurren. Habría que tener un módulo que se plantea qué acción tomar en función del entorno y qué acciones ocurren alrededor nuestro. Quiero cambiar de carril, está entrando un usuario al carril,

Lo mismo es una chorrada, pero en [Alexiadis et al., 2004] el autor se saca de la manga un intervalo temporal para diferenciar las tareas de niveles estratégico, táctico y de control. Estos intervalos podrían ser una variable lingüística y sus particiones variar en función del conductor.

En [Toledo et al., 2007] (o [Toledo, 2007]), plantea cosas a mejorar en el estado de la cuestión: (i) más regímenes de conducción y mejor determinación de sus límites y sus transiciones, tanto en modelos de aceleración como en modelos de cambio de carril, mejorando así el realismo de la simulación, (ii) posicionamiento estratégico, es decir, incorporar el path planning y cosas por el estilo del comportamiento de planificación al táctico preposicionando el coche en los carriles más convenientes, (iii) más campo de visión, no sólo los delanteros y traseros del carril actual y carril destino, (iv) interdependencia entre modelos y regímenes de modelos, (v)

planificación y anticipación, sobre todo esto último en el tema de qué van a hacer los vehículos de alrededor. Si tiramos de algo de aquí, vendría bien mirar el paper porque da referencias a trabajos en estas direcciones.

El vehículo como agente inteligente

En nuestra tesis el trabajo se basa en la representación del comportamiento de un conductor. Para simplificar el problema asumiremos que los términos “conductor” y “vehículo” son equivalentes y que se refieren a la tupla “(vehículo, conductor)” (Hay un paper que lo denomina DVU como driver-vehicle-unit [Dia, 2002])

No sé cómo ponerlo, pero esta información puede ser útil aquí. A lo mejor hay que separarlo, no sé. Yo lo pongo aquí porque me ha venido ahora.

- **Percepción.** Característica intrínseca a todo ser vivo para la obtención de información del entorno. Pues para los agentes inteligentes, lo mismo. Puede ser en forma de sensores (e.g. sensor de velocidad, acelerómetro, sensor de distancia, lidar, cámaras, termómetros, gps, ...), conocimiento (e.g. controlador difuso, sistema experto, red neuronal, es decir, información procesada que ad valor añadido), datos GIS, comunicación con otros vehículos (e.g. V2V, V2E, ...). Un simulador nos ofrece estos sensores casi gratis, pero nuestro problema es que para la generación de modelos necesitamos previamente haber capturado información con dichos sensores y en físico ya es otra cosa.
- **Toma de decisiones.** Un agente racional en un sistema multiagente ha de ser capaz de razonar acerca del mundo, de su propio estado y del estado del resto de agentes.
- **Actuación.** La actuación es la consecuencia natural de las anteriores características. Dado un estado del mundo y un proceso cognitivo surgen acciones a realizar, tras las cuales se llega a un nuevo estado del entorno que provee de información actualizada para seguir actuando.

Resultados

Factores a mirar del tráfico. En un paper ponen esto: the simulation results indicate that the proposed model is explainable, and it can represent equilibrium and disequilibrium states of microscopic and macroscopic traffic, such as: stable traffic, unstable traffic, equilibrium speed-flow relationship, closing-in, shying-away, capacity drop, and traffic hysteresis.

Realizar comparativa de modelos existentes contra modelos de parámetros ajustados contra modelos creados.

Resultados

Mínimo de resultados, los datasets, porque además en materia de cambio de carril hay poco.

Conclusiones

¿Pierde rendimiento el sistema cuando se aplican los modelos a escenarios significativamente diferentes de los escenarios de test? Si sí, un trabajo futuro y algo para escribir en conclusiones sería hablar de este defecto y de cómo subsanarlo.

Aportaciones

Futuras líneas de investigación

¿A lo mejor se podría tirar por el campo de las V2X desde esta tesis?

¿Entrar en el tema de la mesosimulación?

Intersection model (lo he visto nombrar por primera vez en http://elib.dlr.de/89233/1/SUMO_Lane_change_model_Template_SUMO2014.pdf. Habrán creado también un concepto así rotondas?

No sé, pero me parece lógico tratar de realizar una disociación entre vehículo y conductor en lugar de contemplar el binomio vehículo/conductor como uno sólo. Es más, creo que resultaría interesante evaluar comportamientos de conductores sobre diferentes tipologías de vehículos. La librería de todas formas debería soportar esta disociación (y se debería indicar).

Hemos dejado fuera comportamientos interesantes de estudiar: cruces, rotondas (Driving behavior at a roundabout: A hierarchical Bayesian regression analysis), ...

Parece que se presta poca atención sobre el tema de vehículos pesados (creo que he encontrado en total un par de referencias), y su forma de funcionar es diferente. Puede ser interesante de cara a perfeccionar los simuladores con esta tipología de vehículos y de cara a ser de utilidad a empresas de transporte.

Los cambios de carril no son inmediatos, toman en torno a los 3 segundos, y no he visto que se tenga en cuenta. Todo se centra en la decisión del cambio de carril, pero a la hora de ejecutar van a saco. Quizá habría que prestarle un poco más de atención a este comportamiento.

Para evaluar la efectividad de determinadas técnicas se mira el comportamiento en nivel macro tanto del modelo real como del modelo simulado. De hecho es lo que haré en esta tesis. Sin embargo, no parece que sea el modo más correcto de evaluar la precisión de los modelos. Quizá habría que buscar más por este lado para ver cómo se comportan en nivel micro modelos reales y modelos simulados.

Glosario

AORTA (Approximately Orchestrated Routing and Transportation Analyzer). Entorno de microsimulación multiagente de tráfico desarrollado en el departamento de Ciencias de la Computación de la Universidad de Austin (Texas). Url: <http://www.aorta-traffic.org/>.. 64, 65

car-following Modelo de control de conductor que basa su comportamiento en el vehículo del mismo carril que le precede.. 16, 58, 59

GPL (General Public License). Licencia de software que garantiza las libertades del software. Asegura que cualquier versión, extensión o software derivado de éste permanecerá siendo software libre. Su última versión es la 3.0. Url: <https://www.gnu.org/licenses/gpl-3.0.html>.. 65, 66

MatSIM (Multi-Agent Transport Simulation). Software de microsimulación multiagente desarrollado en la ETH Zürich. Url: <http://matsim.org>.. 64, 65

MovSim (Microscopic Traffic SIMulator). Software de microsimulación desarrollado por el laboratorio de sistemas inteligentes de transporte del MIT. Url: <https://its.mit.edu/software/mitsimlab>.. 64, 73, 76

MovSim (Multi-model Open-source Vehicular-traffic Simulator). Software de microsimulación que implementa tanto modelo multi-

agente y como modelo basado en CAs. Url: <http://www.movsim.org/>.. 16, 62

Python Lenguaje de programación OSS. Url: <https://www.python.org/>.. 10

SUMO (Simulation of Urban MObility). Entorno de micro y mesosimulación multiagente desarrollado por el instituto de sistemas de transporte del DLR (Centro Aeroespacial Alemán). Url: <http://www.dlr.de>.. 10, 17, 19, 64–67

TORCS (The Open Racing Car Simulator). Software de simulación creado en un principio como videojuego de carreras y que ha evolucionado hacia plataforma de simulación de técnicas de Inteligencia Artificial aplicadas a la conducción. Url: <http://torcs.sourceforge.net/>.. 55

TraaS (TraCI as a Service). APIs basado en SOAPS para interactuar con el simulador **SUMO** cuando está funcionando en modo servidor. Url: <http://traas.sourceforge.net/cms/>.. 17, 67

TraCI (Traffic Control Interface). Término que sirve tanto para denominar al protocolo de comunicación ofrecido por **SUMO** en modo servidor para la interacción remota con la simulación como para denominar a la librería desarrollada para abstraer dicho protocolo cuando se trabaja desde **Python**. Url: <http://www.sumo.dlr.de/wiki/TraCI>.. 17, 66, 67, 89

Siglas

ACL Agent Communications Language. [54](#)

ADAS Advanced Driver Assistance System. [69](#), [79](#)

AI Artificial Intelligence. [23](#), [31–34](#), [48](#), [50](#), [53](#), [54](#), [77](#)

ANN Artificial Neural Network. [31](#), [32](#), [35–37](#), [50](#)

CA Cellular Automaton. [56](#), [58](#), [59](#), [61](#), [62](#)

CEP Complex Event Processing. [78](#)

CI Computational Intelligence. [23](#), [24](#), [26](#), [31](#), [33–35](#), [40](#), [50](#), [70](#), [73](#),
[77](#), [78](#), [80](#)

DAI Distributed Artificial Intelligence. [53](#)

DLC Discretionary Lane Change. [74](#), [75](#)

DVU Driver-Vehicle Unit. [27](#), [55](#), [62–64](#), [80](#)

EC Evolutionary Computation. [40](#), [90](#)

ES Evolution Strategy. [40](#)

FCS Fuzzy Control System. [39](#)

FIS Fuzzy Inference System. [39](#), [40](#)

FL Fuzzy Logic. [32](#), [38](#), [50](#), [78](#), [82](#)

GA Genetic Algorithm. [32](#), [40–44](#), [47](#)

GGGP Grammar Guide Genetic Programming. [47](#)

GHR Gazis-Herman-Rothery. [82](#)

GP Genetic Programming. [40](#)

HC Hard Computing. [34](#)

ITS Intelligent Transport System. [23](#), [78](#)

KQML Knowledge Query and Manipulation Language. [54](#)

MAS Multi-Agent System. [24](#), [26](#), [53](#), [54](#), [59](#), [61–63](#)

ML Machine Learning. [33](#), [78](#), [79](#)

MLC Mandatory Lane Change. [74](#), [75](#)

NDS Naturalistic Driving Study. [26](#)

NLP Natural Language Processing. [33](#)

OSS Open Source Software. [63](#), [64](#)

RS Recommender System. [33](#)

SC Soft Computing. [34](#)

SI Swarm Intelligence. [40](#)

V2I Vehicle-to-Infraestructure. [62](#)

V2V Vehicle-to-Vehicle. [62](#)

Bibliografía

[Ful,]

[par, 2010] (2010). Directive 2010/40/eu of the european parliament and of the council of 7 july 2010 on the framework for the deployment of intelligent transport systems in the field of road transport and for interfaces with other modes of transport text with eea relevance. *Official Journal of the European Union*, 50:207.

[Aghabayk et al., 2013] Aghabayk, K., Forouzideh, N., and Young, W. (2013). Exploring a local linear model tree approach to car-following. *Computer-Aided Civil and Infrastructure Engineering*, 28(8):581–593.

[Ahmed, 1999] Ahmed, K. I. (1999). Modeling Drivers ' Acceleration and Lane Changing Behavior. *Transportation*, Ph.D:189.

[Al-Shihabi and Mourant, 2001] Al-Shihabi, T. and Mourant, R. R. (2001). A framework for modeling human-like driving behaviors for autonomous vehicles in driving simulators. *The 5th International Conference on Autonomous Agents.*, (June):286–291.

[Alexiadis et al., 2004] Alexiadis, V., Colyar, J., Halkias, J., Hranac, R., and McHale, G. (2004). The next generation simulation program. *ITE Journal (Institute of Transportation Engineers)*, 74(8):22–26.

[Artyukhin and Avery, 2014] Artyukhin, A. and Avery, L. (2014). Collective behavior of *C.elegans* and *C.briggsae* starved L1 larvae. *The Worm Breeder's Gazette*, 20(1):19–20.

- [Balmer et al., 2004] Balmer, M., Cetin, N., Nagel, K., and Raney, B. (2004). Towards truly agent-based traffic and mobility simulations. *Proceedings of the Third International Joint Conference on Autonomous Agents and Multiagent Systems*, 1:60–67.
- [Bando et al., 2013] Bando, T., Takenaka, K., Nagasaka, S., and Taniguchi, T. (2013). Unsupervised drive topic finding from driving behavioral data. In *Intelligent Vehicles Symposium (IV), 2013 IEEE*, pages 177–182. IEEE.
- [Barlovic et al., 1998] Barlovic, R., Santen, L., Schadschneider, A., and Schreckenberg, M. (1998). Metastable states in cellular automata for traffic flow. *Eur. Phys. J. B*, 5:793–800.
- [Behrisch et al., 2011] Behrisch, M., Bieker, L., Erdmann, J., and Krajzewicz, D. (2011). Sumo—simulation of urban mobility: an overview. In *Proceedings of SIMUL 2011, The Third International Conference on Advances in System Simulation*. ThinkMind.
- [Bender et al., 2015] Bender, A., Agamennoni, G., Ward, J. R., Worrall, S., and Nebot, E. M. (2015). An unsupervised approach for inferring driver behavior from naturalistic driving data. *IEEE Transactions on Intelligent Transportation Systems*, 16(6):3325–3336.
- [Bexelius, 1968] Bexelius, S. (1968). An extended model for car-following.
- [Bezdek, 1993] Bezdek, J. C. (1993). Intelligence: Computational versus artificial. *IEEE Transactions on Neural Networks*, 4(5):737.
- [Brilon and Wu, 1999] Brilon, W. and Wu, N. (1999). Evaluation of cellular automata for traffic flow simulation on freeway and urban streets. *Traffic and Mobility*.
- [Casas et al., 2011] Casas, J., Perarnau, J., and Torday, A. (2011). The need to combine different traffic modelling levels for effectively tackling large-scale projects adding a hybrid meso/micro approach. *Procedia-Social and Behavioral Sciences*, 20:251–262.
- [Chaib-draa and Levesque, 1994] Chaib-draa, B. and Levesque, P. (1994). Hierarchical model and communication by signs, sig-

nals, and symbols in multi-agent environments. *on Modelling Autonomous Agents in a Multi- . . .*

- [Chakroborty and Kikuchi, 2003] Chakroborty, P. and Kikuchi, S. (2003). Calibrating the membership functions of the fuzzy inference system: Instantiated by car-following data. *Transportation Research Part C: Emerging Technologies*, 11(2):91–119.
- [Chan et al., 2012] Chan, K. Y., Dillon, T. S., Singh, J., and Chang, E. (2012). Neural-Network-Based Models for Short-Term Traffic Flow Forecasting Using a Hybrid Exponential Smoothing and Levenberg-Marquardt Algorithm. *IEEE Transactions on Intelligent Transportation Systems*, 13(2):644–654.
- [Chandler et al., 1958] Chandler, R. E., Herman, R., and Montroll, E. W. (1958). Traffic Dynamics: Studies in Car Following. *Operations Research*, 6(2):165–184.
- [Clymer, 2002] Clymer, J. (2002). Simulation of a vehicle traffic control network using a fuzzy classifier system. In *Proceedings 35th Annual Simulation Symposium. SS 2002*, pages 285–291. IEEE Comput. Soc.
- [Cybenko, 1989] Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of control, signals and systems*, 2(4):303–314.
- [Das and Bowles, 1999] Das, S. and Bowles, B. (1999). Simulations of highway chaos using fuzzy logic. *18th International Conference of the North American Fuzzy Information Processing Society - NAFIPS (Cat. No.99TH8397)*, pages 130–133.
- [Das et al., 1999] Das, S., Bowles, B. A., Houghland, C. R., Hunn, S. J., and Zhang, Y. (1999). Microscopic simulations of freeway traffic flow. In *Proceedings of the Thirty-Second Annual Simulation Symposium IEEE Computer Society*, pages 79–84. IEEE Comput. Soc.
- [Dia, 2002] Dia, H. (2002). An agent-based approach to modelling driver route choice behaviour under the influence of real-time information. *Transportation Research Part C: Emerging Technologies*, 10(5):331–349.

- [Díaz Álvarez et al., 2014] Díaz Álvarez, A., Serradilla García, F., Naranjo, J. E., Anaya, J. J., and Jiménez, F. (2014). Modeling the driving behavior of electric vehicles using smartphones and neural networks. *IEEE Intelligent Transportation Systems Magazine*, 6(3):44–53.
- [Dijkstra, 1972] Dijkstra, E. W. (1972). The humble programmer. *Communications of the ACM*, 15(10):859–866.
- [Dingus et al., 2006] Dingus, T. A., Klauer, S. G., Neale, V. L., Petersen, A., Lee, S., Sudweeks, J., Perez, M., Hankey, J., Ramsey, D., Gupta, S., et al. (2006). The 100-car naturalistic driving study, phase ii-results of the 100-car field experiment. Technical report.
- [Dougherty et al., 1993] Dougherty, M. S., Kirby, H. R., and Boyle, R. D. (1993). The use of neural networks to recognise and predict traffic congestion. *Traffic engineering & control*, 34(6):311–4.
- [Dresner and Stone, 2004] Dresner, K. and Stone, P. (2004). *Proceedings of the Third International Joint Conference on Autonomous Agents and Multiagent Systems : AAMAS 2004 : New York City, New York, USA : July 19-23, 2004*. IEEE Computer Society.
- [Du and Swamy, 2006] Du, K. and Swamy, M. (2006). Neural networks in a softcomputing framework.
- [Ehlert and Rothkrantz, 2001] Ehlert, P. a. M. and Rothkrantz, L. J. M. (2001). A reactive driving agent for microscopic traffic simulation. *Modelling and Simulation 2001*, pages 943–949.
- [Finin et al., 1994] Finin, T., Fritzson, R., McKay, D., and McEntire, R. (1994). KQML as an agent communication language. *Proceedings of the third international conference on Information and knowledge management - CIKM '94*, pages 456–463.
- [Fix and Armstrong, 1990] Fix, E. and Armstrong, H. (1990). Modeling human performance with neural networks. *1990 IJCNN International Joint Conference on Neural Networks*, pages 247–252 vol.1.

- [Fritzsche and Ag, 1994] Fritzsche, H.-t. and Ag, D.-b. (1994). A model for traffic simulation. *Traffic Engineering & Control*, 35(5):317–321.
- [Galis and Rao, 2000] Galis, a. and Rao, S. (2000). -"Application of Agent Technology to Telecommunication Management Services".
- [Gazis et al., 1959] Gazis, D. C., Herman, R., and Potts, R. B. (1959). Car-Following Theory of Steady-State Traffic Flow. *Operations Research*, 7(4):499–505.
- [Gipps, 1981] Gipps, P. G. (1981). A behavioural car-following model for computer simulation.
- [Gipps, 1986] Gipps, P. G. (1986). A model for the structure of lane-changing decisions. *Transportation Research Part B*, 20(5):403–414.
- [Gu et al., 2015] Gu, M., Billot, R., Faouzi, N.-e. E., Lyon, D., and Hassas, S. (2015). Multi-Agent Dynamic Coupling for Cooperative Vehicles Modeling. pages 4276–4277.
- [Halati et al., 1997] Halati, A., Lieu, H., and Walker, S. (1997). CORSIM-corridor traffic simulation model. *Traffic Congestion and Traffic Safety in the*.
- [Hatipkarasulu, 2003] Hatipkarasulu, Y. (2003). A Variable Response Time Lag Module for Car Following Models Using Fuzzy Set Theory. (225).
- [Hebb, 1968] Hebb, D. (1968). The organization of behavior.
- [Hidas, 2002] Hidas, P. (2002). Modelling lane changing and merging in microscopic traffic simulation. *Transportation Research Part C: Emerging Technologies*, 10(5-6):351–371.
- [Hinton, 2006] Hinton, G. E. (2006). Reducing the Dimensionality of Data with Neural Networks. *Science*, 313(5786):504–507.
- [Holland, 1975] Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems: An introductory analysis with applications to biology, control, and artificial intelligence.*, volume Ann Arbor. U Michigan Press.

- [Hou et al., 2011] Hou, H., Jin, L., Niu, Q., Sun, Y., and Lu, M. (2011). Driver Intention Recognition Method Using Continuous Hidden Markov Model. *International Journal of Computational Intelligence Systems*, 4(3):386–393.
- [Hunt and Lyons, 1994] Hunt, J. G. and Lyons, G. D. (1994). Modelling dual carriageway lane changing using neural networks. *Transportation Research Part C*, 2(4):231–245.
- [Huval et al., 2015] Huval, B., Wang, T., Tandon, S., Kiske, J., Song, W., Pazhayampallil, J., Andriluka, M., Rajpurkar, P., Migimatsu, T., Cheng-Yue, R., Mujica, F., Coates, A., and Ng, A. Y. (2015). An Empirical Evaluation of Deep Learning on Highway Driving. *arXiv*, pages 1–7.
- [Imprialou et al., 2016] Imprialou, M.-I. M., Quddus, M., Pitfield, D. E., and Lord, D. (2016). Re-visiting crash–speed relationships: A new perspective in crash modelling. *Accident Analysis & Prevention*, 86:173–185.
- [Jia et al., 2003] Jia, H., Juan, Z., and Ni, A. (2003). Develop a car-following model using data collected by ‘five-wheel system’. *IEEE Conference on Intelligent Transportation Systems, Proceedings, ITSC*, 1:346–351.
- [Jin et al., 2016] Jin, J., Ma, X., Koskinen, K., Rychlik, M., and Kosonen, I. (2016). Evaluation of fuzzy intelligent traffic signal control (fits) system using traffic simulation. In *Transportation Research Board 95th Annual Meeting*, number 16-4359.
- [Jin, 2006] Jin, W.-L. (2006). A kinematic wave theory of lane-changing vehicular traffic.
- [K. et al., 1996] K., A., M., B.-A., H., K., and R., M. (1996). Models of freeway lane changing and gap acceptance behavior. *Transportation and traffic theory*, 13:501–515.
- [Kerner et al., 2008] Kerner, B., Klenov, S., and Brakemeier, A. (2008). Testbed for wireless vehicle communication: A simulation approach based on three-phase traffic theory. In *Intelligent Vehicles Symposium, 2008 IEEE*, pages 180–185. IEEE.

- [Khodayari et al., 2012] Khodayari, A., Ghaffari, A., Kazemi, R., and Brauning, R. (2012). A Modified Car-Following Model Based on a Neural Network Model of the Human Driver Effects. In *IEEE on Systems, Man, and Cybernetics*, volume 42, pages 1440–1449.
- [Kikuchi and Chakroborty, 1992] Kikuchi, S. and Chakroborty, P. (1992). Car-following model based on fuzzy inference system. 1(1365).
- [Kiszka et al., 1985] Kiszka, J. B., Kochańska, M. E., and Sliwińska, D. S. (1985). The Influence of Some Parameters on the Accuracy of a Fuzzy Model. *Industrial Applications of Fuzzy Control*, pages 187–230.
- [Krajzewicz et al., 2012] Krajzewicz, D., Erdmann, J., Behrisch, M., and Bieker, L. (2012). Recent development and applications of SUMO - Simulation of Urban MObility. *International Journal On Advances in Systems and Measurements*, 5(3&4):128–138.
- [Krajzewicz et al., 2002] Krajzewicz, D., Hertkorn, G., Rössel, C., and Wagner, P. (2002). Sumo (simulation of urban mobility) – an open-source traffic simulation. In *Proceedings of the 4th Middle East Symposium on Simulation and Modelling (MESM20002)*, pages 183–187.
- [Krauss et al., 1997] Krauss, S., Wagner, P., and Gawron, C. (1997). Metastable states in a microscopic model of traffic flow. *Physical Review E*, 55(5):5597–5602.
- [Kuge et al., 2000] Kuge, N., Yamamura, T., Shimoyama, O., and Liu, A. (2000). A Driver Behavior Recognition Method Based on a Driver Model Framework. *Structure*, 109(1dm):469–476.
- [Laval and Daganzo, 2006] Laval, J. A. and Daganzo, C. F. (2006). Lane-changing in traffic streams. *Transportation Research Part B: Methodological*, 40(3):251–264.
- [Lerner et al., 2010] Lerner, N., Jenness, J., Singer, J., Klauer, S., Lee, S., Donath, M., Manser, M., and Ward, N. (2010). An exploration of vehicle-based monitoring of novice teen drivers. *Final Report. NHTSA, Report No. DOT HS, 811:333*.

- [Liu and Li, 2013] Liu, R. and Li, X. (2013). Stability analysis of a multi-phase car-following model. *Physica A: Statistical Mechanics and its Applications*, 392(11):2660–2671.
- [Ma, 2004] Ma, X. (2004). Toward An Integrated Car-following and Lane- changing Model by A Neural Fuzzy Approach. pages 1–15.
- [Margolus, 1993] Margolus, N. (1993). CAM-8: a computer architecture based on cellular automata *.
- [Maye et al., 2011] Maye, J., Triebel, R., Spinello, L., and Siegwart, R. (2011). Bayesian on-line learning of driving behaviors. In *Robotics and Automation (ICRA), 2011 IEEE International Conference on*, pages 4341–4346. IEEE.
- [McCarthy et al., 1956] McCarthy, J., Minsky, M., Rochester, N., and Shannon, C. (1956). Dartmouth conference. In *Dartmouth Summer Research Conference on Artificial Intelligence*.
- [McCulloch and Pitts, 1943] McCulloch, W. S. and Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, 5(4):115–133.
- [McDonald et al., 1997] McDonald, M., Wu, J., and Brackstone, M. (1997). Development of a fuzzy logic based microscopic motorway simulation model. *IEEE Conference on*.
- [Michon, 1985] Michon, J. A. (1985). A critical view of driver behavior models: what do we know, what should we do? In *Human behavior and traffic safety*, pages 485–524. Springer.
- [Minderhoud, 1999] Minderhoud, M. (1999). *Supported Driving: Impacts on Motorway Traffic Flow*. PhD thesis.
- [Minsky and Papert, 1969] Minsky, M. and Papert, S. (1969). Perceptrons.
- [Muñoz et al., 2010] Muñoz, J., Gutierrez, G., and Sanchis, A. (2010). A human-like torcs controller for the simulated car racing championship. In *Proceedings of the 2010 IEEE Conference on Computational Intelligence and Games*, pages 473–480. IEEE.

- [Munoz et al., 2001] Munoz, L., Gomes, G., Yi, J., Toy, C., Horowitz, R., and Alvarez, L. (2001). Integrated meso-microscale traffic simulation of hierarchical ahs control architectures. In *Intelligent Transportation Systems, 2001. Proceedings. 2001 IEEE*, pages 82–87. IEEE.
- [Nagel and Schreckenberg, 1992] Nagel, K. and Schreckenberg, M. (1992). A cellular automaton model for freeway traffic.
- [Nagel et al., 1998] Nagel, K., Wolf, D. E., Wagner, P., and Simon, P. (1998). Two-lane traffic rules for cellular automata: A systematic approach. *Physical Review E*, 58(2):1425–1437.
- [OICA, 2015] OICA (2015). Motorization rate 2014 – worldwide.
- [Osogami et al., 2012] Osogami, T., Imamichi, T., Mizuta, H., Morimura, T., Raymond, R., Suzumura, T., Takahashi, R., and Idé, T. (2012). IBM Mega Traffic Simulator.
- [Pakkenberg and Gundersen, 1997] Pakkenberg, B. and Gundersen, H. J. (1997). Neocortical neuron number in humans: effect of sex and age. *The Journal of comparative neurology*, 384(2):312–20.
- [Panwai and Dia, 2007] Panwai, S. and Dia, H. (2007). Neural agent car-following models. *IEEE Transactions on Intelligent Transportation Systems*, 8(1):60–70.
- [Pipes, 1953] Pipes, L. (1953). An operational analysis of traffic dynamics. *Journal of applied physics*.
- [Poslad, 2007] Poslad, S. (2007). Specifying Protocols for Multi-Agent Systems Interaction. *ACM Transactions on Autonomous and Adaptive Systems*, 2(4, Article 15):25.
- [Quaassdorff et al., 2016] Quaassdorff, C., Borge, R., Pérez, J., Lumbreras, J., de la Paz, D., and de Andrés, J. M. (2016). Microscale traffic simulation and emission estimation in a heavily trafficked roundabout in madrid (spain). *Science of The Total Environment*, 566:416–427.

- [Ramón and Cajal, 1904] Ramón, S. and Cajal, S. (1904). *Textura del Sistema Nervioso del Hombre y de los Vertebrados*, volume 2. Madrid Nicolas Moya.
- [Rasmussen, 1986] Rasmussen, J. (1986). *Information Processing and Human-Machine Interaction: An Approach to Cognitive Engineering*. North-Holland.
- [Rechenberg, 1973] Rechenberg, I. (1973). *Evolutionsstrategie Optimierung technischer Systeme nach Prinzipien der biologischen Evolution*.
- [Reuschel, 1950] Reuschel, A. (1950). Fahrzeugbewegungen in der Kolonne. *Osterr. Ing. Archiv.*, 4(1):193–215.
- [Rumelhart et al., 1985] Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1985). Learning internal representations by error propagation. Technical report, DTIC Document.
- [Russell et al., 2003] Russell, S. J., Norvig, P., Canny, J. F., and Malik, Jitendra M, E. D. D. (2003). *Artificial intelligence: a modern approach*, volume 2. Prentice hall Upper Saddle River.
- [Sasoh and Ohara, 2002] Sasoh, A. and Ohara, T. (2002). Shock Wave Relation Containing Lane Change Source Term for Two-Lane Traffic Flow. *Journal of the Physical Society of Japan*, 71(9):2339–2347.
- [Sekizawa et al., 2007] Sekizawa, S., Inagaki, S., Suzuki, T., Hayakawa, S., Tsuchida, N., Tsuda, T., and Fujinami, H. (2007). Modeling and recognition of driving behavior based on stochastic switched ARX model. *IEEE Transactions on Intelligent Transportation Systems*, 8(4):593–606.
- [Shiose et al., 2001] Shiose, T., Onitsuka, T., and Taura, T. (2001). Effective information provision for relieving traffic congestion. In *Proceedings Fourth International Conference on Computational Intelligence and Multimedia Applications. ICCIMA 2001*, pages 138–142. IEEE.
- [Siddique and Adeli, 2013] Siddique, N. and Adeli, H. (2013). *Computational intelligence: synergies of fuzzy logic, neural networks y evolutionary computing*. John Wiley & Sons.

- [Simonelli et al., 2009] Simonelli, F., Bifulco, G. N., and Martinis, V. D. (2009). Human-Like Adaptive Cruise Control Systems through a Learning Machine Approach. *Applications of Soft Computing*, pages 240–249.
- [Sparmann, 1978] Sparmann, U. (1978). *Spurwechselvorgänge auf zweispurigen BAB-Richtungsfahrbahnen*.
- [Suzumura and Kanezashi, 2012] Suzumura, T. and Kanezashi, H. (2012). Highly scalable x10-based agent simulation platform and its application to large-scale traffic simulation. *Proceedings of the 2012 IEEE/ACM 16th*.
- [Toledo, 2007] Toledo, T. (2007). Driving Behaviour: Models and Challenges. *Transport Reviews*, 27(1):65–84.
- [Toledo et al., 2003] Toledo, T., Koutsopoulos, H. N., and Ben-Akiva, M. (2003). Modeling Integrated Lane-Changing Behavior. *Transportation Research Record*, 1857(1):30–38.
- [Toledo et al., 2007] Toledo, T., Koutsopoulos, H. N., and Ben-Akiva, M. (2007). Integrated driving behavior modeling. *Transportation Research Part C: Emerging Technologies*, 15(2):96–112.
- [Tordeux et al., 2011] Tordeux, A., Lassarre, S., and Roussignol, M. (2011). A study of the emergence of kinematic waves in targeted state car-following models of traffic. <http://cybergeogeo.revues.org>.
- [Trask ANDREWTRASK et al.,] Trask ANDREWTRASK, A., Gilmore DAVIDGILMORE, D., and Russell MATTHEWRUSSELL, M. Modeling Order in Neural Word Embeddings at Scale.
- [Treiber et al., 2000] Treiber, M., Hennecke, A., and Helbing, D. (2000). Congested traffic states in empirical observations and microscopic simulations. *Physical review E*, 62(2):1805.
- [Turing, 1950] Turing, A. M. (1950). Computing machinery and intelligence. *Mind*, 59(236):433–460.
- [Van Hoorn et al., 2009] Van Hoorn, N., Togelius, J., Wierstra, D., and Schmidhuber, J. (2009). Robust player imitation using multiobjective evolution. In *2009 IEEE Congress on Evolutionary Computation*, pages 652–659. IEEE.

- [Van Ly et al., 2013] Van Ly, M., Martin, S., and Trivedi, M. M. (2013). Driver classification and driving style recognition using inertial sensors. In *Intelligent Vehicles Symposium (IV), 2013 IEEE*, pages 1040–1045. IEEE.
- [Wagner et al., 1997] Wagner, P., Nagel, K., and Wolf, D. E. (1997). Realistic multi-lane traffic rules for cellular automata. *Physica A: Statistical Mechanics and its Applications*, 234(3–4):687–698.
- [Wegener et al., 2008] Wegener, A., Piórkowski, M., Raya, M., Hellbrück, H., Fischer, S., and Hubaux, J.-P. (2008). TraCI. *Proceedings of the 11th communications and networking simulation symposium on - CNS '08*, (August 2016):155.
- [Wei et al., 2000] Wei, H., Lee, J., Li, Q., and Li, C. (2000). Observation-Based Lane-Vehicle Assignment Hierarchy: Microscopic Simulation on Urban Street Network. *Transportation Research Record*, 1710(1):96–103.
- [Weidemann and Reiter, 1992] Weidemann, R. and Reiter, U. (1992). Microscopic Traffic Simulation, The Simulation System-Mission. *University Karlsruhe, Germany*, 2:54.
- [Wiedemann, 1974] Wiedemann, R. (1974). Simulation des Straßenverkehrsflusses. Technical report.
- [Wooldridge et al., 1995] Wooldridge, M., Jennings, N. R., Adorni, G., Poggi, A., Allen, J. F., Bates, J., Bell, J., BELNAP, N., PERLOFF, M., Bratman, M. E., Israel, D. J., Pollack, M. E., Brooks, R., Brooks, R. A., Bussmann, S., Demazeau, Y., Castelfranchi, C., Chaib-Draa, B., Moulin, B., Mandiau, R., Millot, P., Chang, E., Chapman, D., Chellas, B. F., Cohen, P. R., Levesque, H. J., Cohen, P. R., Perrault, C. R., Cutkosky, M., Engelmores, R., Fikes, R., Genesereth, M., Gruber, T., Mark, W., Tenenbaum, J., Weber, J., Downs, J., Reichgelt, H., Emerson, E. A., Halpern, J. Y., Fagin, R., Halpern, J. Y., Vardi, M. Y., Fisher, M., Gasser, L., Gasser, L., Braganza, C., Herman, N., Genesereth, M. R., Ketchpel, S. P., Georgeff, M. P., Greif, I., Guha, R. V., Lenat, D. B., Haas, A. R., Halpern, J. Y., Halpern, J. Y., Moses, Y., Halpern, J. Y., Vardi, M. Y., Hayes-Roth, B., Hewitt, C., Huang, J., Jennings, N. R., Fox, J., Jennings, N. R., JENNINGS, N. R., Jennings, N., Varga,

- L., Aarnts, R., Fuchs, J., Skarek, P., Kaelbling, L. P., Kraus, S., Lehmann, D., Kripke, S. A., Maes, P., Maes, P., McCabe, F. G., Clark, K. L., Mukhopadhyay, U., Stephens, L. M., Huhns, M. N., Bonnell, R. D., Müller, J. P., Pischel, M., Thiel, M., Newell, A., Simon, H. A., Norman, T. J., Long, D., PAPAZOGLU, M. P., LAUFMANN, S. C., SELLIS, T. K., Perlis, D., Perlis, D., Perloff, M., Poggi, A., Reichgelt, H., Sacerdoti, E. D., Searle, J. R., Shoham, Y., Thomas, B., Shoham, Y., Schwartz, A., Kraus, S., Thomason, R. H., Varga, L., Jennings, N. R., Cockburn, D., Vere, S., Bickmore, T., Wavish, P., Graham, M., Weerasooriya, D., Rao, A., Ramamohanarao, K., and Wooldridge, M. (1995). Intelligent agents: theory and practice. *The Knowledge Engineering Review*, 10(02):115.
- [Wu et al., 2003] Wu, J., Brackstone, M., and McDonald, M. (2003). The validation of a microscopic simulation model: A methodological case study. *Transportation Research Part C: Emerging Technologies*, 11(6):463–479.
- [Wymann et al., 2013] Wymann, B., Espi, E., Guionneau, C., Dimitrakakis, C., and Sumner, A. (2013). TORCS : The open racing car simulator e. at <http://torcs...>, pages 1–4.
- [y Cajal, 1888] y Cajal, S. R. (1888). *Estructura de los centros nerviosos de las aves*.
- [Yang and Koutsopoulos, 1996] Yang, Q. and Koutsopoulos, H. N. (1996). A microscopic traffic simulator for evaluation of dynamic traffic management systems. *Transportation Research Part C: Emerging Technologies*, 4(3 PART C):113–129.
- [Yang, 2010] Yang, X. S. (2010). A new metaheuristic Bat-inspired Algorithm. In *Studies in Computational Intelligence*, volume 284, pages 65–74. Springer Berlin Heidelberg.
- [Zhang et al., 2011] Zhang, J., Wang, F.-Y., Wang, K., Lin, W.-H., Xu, X., and Chen, C. (2011). Data-Driven Intelligent Transportation Systems: A Survey. *IEEE Transactions on Intelligent Transportation Systems*, 12(4):1624–1639.

- [Zheng et al., 2013] Zheng, J., Suzuki, K., and Fujita, M. (2013). Car-following behavior with instantaneous driver-vehicle reaction delay: A neural-network-based methodology. *Transportation Research Part C: Emerging Technologies*, 36:339–351.
- [Zheng and McDonald, 2005] Zheng, P. and McDonald, M. (2005). Application of Fuzzy Systems in the Car-Following Behaviour Analysis. pages 782–791. Springer Berlin Heidelberg.

Índice alfabético

- neodarwinismo*, 45
- back propagation, 68
- car-following, 88, 89, 91, 92, 94, 98, 100
- courtesy yielding function, 94
- critical gap, 91, 93
- fast-forward, 98
- fitness, 51, 53, 54
- free-flow, 92, 96
- gap acceptance, 91
- gap acceptance, 91, 93
- lane-changing, 93
- lane-selection, 91
- merging, 91
- neodarwinismo*, 47
- neuro-fuzzy, 99, 100
- recurrente, 98
- síntesis evolutiva moderna, 45-47
- selección por torneo, 52

Cómo citar esta tesis

Si deseas citar esta tesis, lo primero gracias. Me alegro de que te sirva para tu investigación. Si lo deseas, incluye el siguiente código en bibtex:

```
@phdthesis{blazaid20167,  
  author = {Alberto Díaz Álvarez},  
  abstract = {XXX},  
  pages = {XXX},  
  title = {Modelado de comportamiento de conductores con técnicas de Inteligencia Computacional},  
  url = {XXX},  
  year = {26 de octubre de 2016}  
}
```

Acerca del código fuente

La presente tesis lleva consigo numerosas horas de programación y, por tanto, muchísimas líneas de código. Éste se encuentra en formato electrónico como datos adjuntos a la memoria y no como capítulo o anexo a ésta, una forma más manejable para su consulta y a la vez respetuosa con el medio ambiente. No obstante sí es posible que existan pequeños fragmentos de código para apoyar explicaciones. En caso de necesitar los fuentes y no estar disponibles los datos anexos a la memoria, puedes contactar directamente conmigo en alberto.diaz@upm.es.